

机器人 One-Shot 技能习得 调研全文报告

HOST (arXiv 2607.20033) × GEN-1.5 × S1 及同期 15 项工作的深度解读与趋势洞察

从「训练问题」到「提示问题」的范式拐点，以及「涌现 vs 机制」之争

调研日期：2026-08-31 (增补 S1 与四篇 EICL 论文后修订)

论文范围：HOST · GEN-0/1/1.5 · S1 · Instant Policy · ICRT · RoboTTT · WAM-TTT · StellaVLA · Zero-WAM · BPP · RICL · Vid2Robot · ViVLA · π 0.5 · Wall-OSS · EgoScale · EgoWAM · WALL-WM · Fast-WAM (LLM 背景：GPT-3 / Emergent Abilities / Mirage)

配套材料：17 篇论文中英对照 PDF · 22 页汇总 PPT (survey_slides.html / .pdf)

目录

1. HOST 深度解读：机器人从一段人类视频里秒级习得操作技能
2. GEN 系列深度解读：Generalist AI 的具身基础模型三部曲
3. Instant Policy 深度解读：把 in-context 模仿学习变成图扩散，用仿真伪演示喂出即时策略
4. ICRT 深度解读：next-token prediction 原教旨主义的机器人 in-context learning 配方
5. RoboTTT 深度解读：把 Test-Time Training 装进机器人策略，上下文扩到 8K 步
6. BPP 深度解读：一条演示当 prompt，任务多样性是 in-context 操作的第一驱动力
7. RICL 深度解读：给预训练 VLA 事后注入 in-context 学习能力
8. Vid2Robot 深度解读：端到端视频条件策略的 Google 规模实践
9. 外围论文速览：one-shot 技能习得调研的五个坐标
10. EgoWAM 深度解读：换掉世界预测目标，人类数据才不「漏毒」进动作头
11. Zero-WAM 深度解读：把人类视频「造」出来当任务规格，再用 IFP 逼模型真的去看
12. WALL-WM 深度解读：把世界-动作建模「循事件关节」下刀
13. WAM-TTT 深度解读：把人类演示写进快权重记忆，且只许写在感知侧
14. StellaVLA 深度解读：把演示翻译成「为什么」，四篇里唯一真零梯度
15. S1 与「涌现之争」：2026 年 8 月具身 ICL 三连发的完整拼图
16. 趋势与洞察：机器人 One-Shot 技能习得的 2026 拐点

HOST 深度解读：机器人从一段人类视频里秒级习得操作技能

HOST: Robots Acquire Manipulation Skills in Seconds from a Single Human Video arXiv 2607.20033v4

(2026-08-20 更新) · 北京理工大学 + X SQUARE ROBOT (自变量机器人) + 清华大学 作者: Guangyan Chen 等; 项目负责: Xiaofan Li; 通讯: Hao Wang、Mengyin Fu、Yi Yang、Yufeng Yue 2026-08-03 起论文、代码、模型权重全部开源 (GitHub / HuggingFace)

1. 一句话定位

HOST 把「教机器人一个新技能」从训练环节挪到了推理环节：给一段人类演示视频（不需要遥操作、不需要微调、不更新任何参数），机器人平均 29 秒后就能执行这个新任务，50 个未见任务平均成功率 62%，同时已掌握的旧技能一点不丢。

对照今天的主流做法——每个新任务先遥操作采集几十条演示、再离线微调几小时、还会把旧技能冲掉——HOST 相当于把「学费」从 4.0–4.9 小时/任务压到 29 秒/任务（507 倍加速），把数据需求从 50 条机器人演示压到 1 段人类视频（50 倍缩减），成功率还反超微调基线 6 个百分点（62% vs Wall-OSS+SFT 的 56%）。

2. 要解决的问题：训练环节循环的三重代价

当前教机器人新技能的标准流程是一个「训练环节循环」(training-time loop)：

- 贵**：熟练操作员遥操作实体机器人采集专用演示，消耗专家人力和稀缺的机器人时间；
- 慢**：离线微调把演示灌进策略要几个小时，新技能才可用；
- 自毁**：微调覆写跨技能共享的参数，每学一个新技能都会侵蚀旧技能（灾难性遗忘）。论文实测： $\pi 0.5$ +SFT 微调后旧任务只保留 20% 原性能，HOST-base+SFT 保留 22%，最好的 Wall-OSS+SFT 也只保留 43%。

强化学习路线更不可行：任务特定奖励在实体机器人上难设计、交互慢、样本效率低，而且同样会退化旧技能。

人类的对照组是显性的：看别人做一遍，把观察到的动作适配到自己身体上，不需要反复物理排练。这个设定在学术上叫 one-shot visual imitation (OSVI)，可以追溯到 Kuniyoshi 1994 年的「learning by watching」愿景，但三十年来一直没做通——此前最强 OSVI 方法在 HOST 的评测里只有 19% 成功率（HOST 62%，+43%）。

3. 为什么 OSVI 一直做不通：视频与执行的结构性错配

论文对失败根源的分析是全文最有洞察力的部分。以往方法把演示视频当条件输入直接回归动作，预测目标锚定在执行轨迹的固定时间偏移上。这有三个结构性问题：

(1) **时间错位把视频降格为被动上下文。** 视频演示和机器人执行是两个独立进程，速度天然不同步。把预测目标绑定在机器人轨迹的固定时间偏移上，等于让目标和视频内容解耦——模型学到的是「忽略视频照常预测」，推理时自然无法从新视频里学到新技能。

(2) **状态差异阻碍行为到动作的转译。** 整段视频一次性喂给模型，充斥着与当前阶段无关的状态；即使在对应片段上，人类视频和机器人轨迹在具身、视角、外观上差异巨大。从高维视频直接回归低维动作，模型要一步跨过所有这些鸿沟。

(3) **成对监督稀缺。** 人类视频很多、机器人轨迹也很多，但「同一行为的人类-机器人配对数据」极少，可靠的跨具身技能学得学不出来。

4. HOST 的两大机制

4.1 机制一：把预测目标耦合到演示上 (Target Coupling)

核心思想：预测目标不再是「执行轨迹上固定时间偏移处的片段」，而是「与视频未来进展逐步对应的机器人轨迹动态片段」——视频从被动条件变成预测的主动驱动者。

实现靠一个自监督对齐模块，把视频演示和机器人轨迹映射到**共享任务进度流形**上：

- 帧嵌入模型基于 Qwen3-VL-Embedding-8B，端到端训练，多视角观测拼成图像序列，取 [EOS] 位置隐状态经线性投影 + L2 归一化得到帧嵌入；
- 用负平方 L2 距离建相似度矩阵，列向 log-softmax 归一化成代价矩阵；
- **Smooth DTW**（可微分动态时间规整）前向-后向动态规划恢复单调软匹配概率，配合**时间循环一致性损失 (TCC)**（每帧经软最近邻循环回自身，惩罚偏差）和 DTW 全局对齐损失，完全不需要帧级标注；
- 得到双向帧对应后，对机器人时刻 t ：先映射到视频对应帧，取视频后续 H 帧，再映射回机器人轨迹，得到的 H 个机器人时刻片段就是预测目标。

对齐质量的硬数字：按时钟时间匹配的进度误差为 0.079 ± 0.062 ，进度流形对齐为 0.006 ± 0.008 ，一个数量级的改善（以人工标注事件为参照）。

消融链条证明每个成分都必要（50 个新任务平均成功率）：

- 整段视频直接条件化：0.21
- 按时间戳选窗口：0.29
- 按任务进度选窗口：0.45
- 目标耦合到视频未来进展（完整机制）：**0.62**

4.2 机制二：自接地预测级联 (Self-Grounded Prediction)

模仿人类观察学习的认知级联（检索任务相关片段→内部模拟动作→转译为执行），HOST 把执行拆成单一自回归扩散模型内的三级因果级联：

1. **定位**：机器人当前处在演示流程的哪个阶段（输出标量进度 p ）；

2. **未来观测预测**：把视频即将发生的进展转译成**机器人自己视角、自己具身**的未来观测（这一步完成跨域翻译）；
3. **动作生成**：从预测的未来观测导出动作。

关键架构细节：

- 所有视觉元素（视频窗口、近期机器人观测、目标未来观测）用 **Wan VAE** 编码到共享隐空间；
- 主干是**双专家 Mixture-of-Transformers**：视频专家从 Wan2.2 视频扩散模型初始化（负责定位+未来观测预测），动作专家同深度但更窄（动作分布复杂度低）；两专家在每层拼接 QKV 共享自注意力，FFN 各自独立；
- 语言指令经 UMT5-XXL 编码 + 本体状态投影，作为每层 cross-attention 条件；
- **自回归 flow matching**：每个生成目标表示为（噪声 token，干净 token）对，因果注意力掩码强制 $p \rightarrow o \rightarrow a$ 顺序，训练时干净 token 用真值（detach 梯度）+ 小幅高斯噪声弥合训练-推理差距，三个目标在单次前向里联合优化；
- 推理时视频窗口按预测进度自主推进（ $w_{t+1} = \text{定位帧} - L/2$ ），执行 H 步动作块后进入下一轮。

消融链条（同样 50 任务）：

- 视频直接映射动作（保留目标耦合）：0.34
 - 定位级：0.43
 - 视觉预测级（与动作并行）：0.55
 - 因果级联（动作从预测观测导出）：**0.62**

两条消融融合起来读：**目标耦合贡献 0.21→0.62 里的大头，级联在耦合基础上再贡献 0.34→0.62**。定位精度 MAE 0.013（归一化进度），预测的未来观测能跨物体外观和初始配置变化保持准确。

4.3 两阶段训练：绕开成对数据稀缺

- **Stage 1（同具身预训练）**：193,462 条机器人轨迹、229 个任务。同任务的不同 episode 天然构成「演示-执行」对（一条当视频，另一条提供目标观测和动作），教会模型「跟随演示流程」的能力，完全不涉及跨具身。
- **Stage 2（跨具身适配）**：5,847 条自采人类视频，与同任务机器人轨迹配对。目标仍来自机器人轨迹，只是条件视频换成人类视频。

数据配比是 33:1——同具身数据便宜管够，人类-机器人配对只要一小撮。消融证明 Stage 1 数据量单调提升最终性能，0% Stage 1（只用 Stage 2 数据）性能很差。**这个两阶段设计是 HOST 能落地的工程关键**：它把「跨具身技能习得」这个难题分解成「跟随演示」（数据充裕）+「跨域适配」（数据稀缺但需求量少）。

4.4 技能持久化：视频即技能库

习得的技能以视频形式存在外部记忆里（不写进权重）：每段视频连同指令文本嵌入和初始场景嵌入（均由 Qwen3-VL-Embedding-8B 编码）入库；新任务来了按「指令相似度 ω + 场景相似度 $(1-\omega)$ 」加权检索，超过阈值 δ 就复用库存视频，否则请求新演示。实测：召回旧任务和识别新任务在很宽的阈值带内同时保持高位；用检索视频执行 $\approx$ 用新录视频执行。

这个设计把「持续学习」的灾难性遗忘问题直接架空了——技能在上下文里而不在参数里，自然谈不上遗忘。

5. 实验结果全景

平台：双臂 ARX R5（各 6 轴 + 平行夹爪），3 个 RGB 相机（双腕装 + 一个第三人称固定位），20 维双臂动作空间。每任务 20 次试验，随机初始物体位姿，人工判定成功。任务集覆盖放水果、堆碗、擦盘子、插笔等 50 项训练阶段未见的桌面操作。

对比对象	条件	成功率	HOST 优势
HOST	1 段人类视频，零参数更新	62%	—
Vid2Robot / AWDA (OSVI)	同样 1 段人类视频	$\leq 19\%$	+43%
$\pi 0.5$ / Wall-OSS (零样本 IL)	语言指令	$\leq 17\%$	+45%
Wall-OSS+SFT (最强微调基线)	50 条遥操作演示 + LoRA 微调	56%	+6%，数据 1/50，速度 507 倍

细节值得注意：OSVI 基线的条件机制被移植到 HOST 同款主干上评测（排除主干差异）， $\pi 0.5$ 和 Wall-OSS 则从各自大规模预训练权重继续在同一批 193k 轨迹上训练——对比是公平口径。

鲁棒性（四种部署扰动下保留大部分性能）：光照/颜色偏移 -1%、未见物体替换 -4%、场景替换 -6%、执行中人为移动物体 -9%。最后一项最有说服力：人在机器人执行中途移动物体，模型的定位级会感知进度倒退，重新对齐视频对应阶段并纠正执行——这是级联结构的直接红利。

6. 局限（作者自认 + 延伸批判）

作者列了三条：单一双臂平台未验证跨机器人形态迁移；视频不携带接触力信息，精细操作受限（提出可穿戴触觉手套方向）；技能库检索在指令/场景细微差异时可能混淆。

延伸几条论文没明说的：

- 62% 离部署仍远。**20 次试验的成功判定是人工的，任务多为桌面短程操作；与 GEN-1 后训练后的 99% 相比，one-shot 范式给出的是「快速可用的初始能力」，不是「精通」。二者互补：HOST 类方法快速冷启动，再用 GEN-1 类后训练冲精通。
- 29 秒的口径**是「录制视频 + 推理准备」的均值，不含用户走到机器人面前摆放场景的时间；但即便宽松计算，与 4 小时的差距仍是数量级的。
- 对齐模块依赖任务进度单调性假设。**SDTW 的单调路径约束意味着演示里若有来回往复、可选分支、失败重试，进度流形可能失效——这类非单调任务是天然边界。

4. **Stage 2 的 5,847 条人类视频仍是自采的。**虽然比遥操作便宜得多，但说「彻底摆脱数据采集」还早；真正的下一步是像 Vid2Robot 那样直接吃野生 YouTube 视频。

7. 意义与位置

HOST 出现在一个有趣的时间点：同月（2026-08）Generalist AI 发布 GEN-1.5，宣布 one-shot 物理技能学习作为**涌现能力**出现在 50 万小时数据预训练的大模型里。HOST 则证明**不需要那个数据量级**——用聪明的归纳偏置（进度流形对齐 + 自接地级联），193k 机器人轨迹 + 6k 人类视频就能把 one-shot 做到 62%，还比 GEN-1.5 的 59%（10 任务）在更大任务集（50 任务）上略高。

两条路线构成上下界：GEN 系证明数据够大能力自己长出来，HOST 证明数据不够可以靠结构设计补。对绝大多数没有 50 万小时私有数据的团队，HOST 给出的配方是可复制的：先在自己的机器人数据上做同具身「跟随」预训练，再用少量跨域配对适配——这个模式不限于人类视频，理论上可以推广到任何演示模态（仿真轨迹、其他机器人、甚至动画）。

而且这个配方是真开源：2026-08-03 起论文、代码和模型权重全部上线 GitHub（X-Square-Robot 组织）与 HuggingFace。发布方自变量机器人（X SQUARE ROBOT，C 轮）把 HOST 定位为其「推理时技能获取」战略的公开落子——该公司同时维护 WALL-A（百亿级 VLA+世界模型旗舰）、Wall-OSS（开源 VLA，即 HOST 论文里最强微调基线）和 X-Tokenizer（SRQ 动作分词器，2.4M 轨迹预训练）等产品线。学术界拿到的不只是一篇论文，而是一套可以直接跑的推理时技能习得栈。

方法论上最值得借鉴的两点：**把「对齐」从隐式期望变成显式模块**（用 SDTW+TCC 学进度流形，而不是指望 transformer 自己领悟时间对应），以及**把跨域翻译从动作空间挪到观测空间**（先预测「我自己做这件事会看到什么」，再从观测导出动作——比直接回归动作多了一个自我参照的中间表征）。

GEN 系列深度解读：Generalist AI 的具身基础模型三部曲

GEN-0 (2025-11) · GEN-1 (2026-04) · GEN-1.5 (2026-08) Generalist AI (官方博客发布, 非 arXiv 论文) 原文: generalistai.com/blog/gen-0 · [/gen-1](https://generalistai.com/blog/gen-1) · [/gen-1.5](https://generalistai.com/blog/gen-1.5)

1. 一句话定位

GEN 系列用九个月时间把机器人学习从「验证 scaling law 存在」(GEN-0) 推到「简单任务 99% 精通」(GEN-1), 再推到「one-shot 上下文学习涌现」(GEN-1.5) ——最后这一步意味着: 给模型看 3-12 秒的一段演示, 不做任何梯度更新, 机器人几秒钟后就开始执行新任务, 10 个任务平均成功率 59%。

这是目前唯一一条公开验证了「物理交互数据规模化预训练 → 类 GPT-3 涌现能力」完整路径的工作线。GPT-3 当年靠 few-shot prompting 宣告语言模型进入基础模型时代; GEN-1.5 试图为机器人复刻同一时刻——他们自己称之为 "physical prompting" (物理提示)。

2. 三部曲时间线：每一代解决一个问题

代际	发布	数据规模	核心命题	关键数字
GEN-0	2025-11	27 万小时真实操作数据	机器人存在 scaling law 吗? ——存在	7B 参数出现「智能相变」; 每周新增 1 万小时数据
GEN-1	2026-04	50 万+ 小时	规模化能到商用精度吗? ——能	6 任务平均 99% 成功率 (GEN-0 基线 64%); 速度 3 倍于 SOTA; 每任务只需约 1 小时机器人数据
GEN-1.5	2026-08	持续预训练 8 个月	适应成本能压到零吗? ——接近零	one-shot in-context 59%; 10 梯度步 + 5 分钟数据 83%; 权重变化 <0.15%

三代模型背后是同一台「数据引擎」: 不用遥操作、不用仿真, 而是给人类戴上低成本手持夹具设备, 在上千个家庭、仓库、工厂里采集日常操作活动。GEN-0 时是 27 万小时, GEN-1 时超 50 万小时, 采集速度每周 1 万小时且在加速。预训练数据里**没有一条机器人数据**——机器人执行是靠人类数据预训练 + 少量后训练迁移出来的。

3. GEN-0：机器人版 scaling law 与「智能相变」

3.1 主张

GEN-0 是直接在高保真物理交互数据上做多模态训练的具身基础模型, 架构原生面向「人类级反射与物理常识」设计。核心机制叫 **Harmonic Reasoning (谐波推理)**: 感知 token 流和动作 token 流异步、连续时间地交织训练——物理世界不会暂停等你思考, 所以模型必须边想边动。这让它不依赖 System1/System2 双系统架构就能扩展到大参数量。

3.2 最重要的发现：7B 相变 (ossification)

- **1B 模型**：预训练中出现「骨化」（ossification）——权重逐渐丧失吸收新信息的能力，数据越喂越多，模型反而卡死。
- **6B 模型**：开始受益于预训练，多任务能力显现。
- **7B+ 模型**：能内化大规模机器人预训练数据，下游任务只需几千步后训练。

这是机器人领域首次观察到 ossification。LLM 文献里这个现象出现在 $O(10M)$ 参数量级，机器人却要 $O(1B)$ 才跨过门槛——作者用 Moravec 悖论解释：人类觉得毫不费力的感知与灵巧操作，计算复杂度远高于抽象推理。**物理智能的「激活阈值」比语言智能高一个数量级以上**。这个观察对整个行业有定价意义：低于 7B 的端侧小模型路线在高数据机制下可能存在天花板。

3.3 可预测的 scaling law

固定下游任务和微调预算，验证误差随预训练数据量 D 呈幂律： $L(D) = (D_c/D)^\alpha$ 。这让「还要采多少数据才能到目标性能」变成可计算问题——例如服装整理任务，给定 10 亿条动作轨迹就能预测模型表现。16 个任务集（乐高搭建、快餐打包、“anything”类泛化任务）全部单调受益于更多预训练。

真机 A/B 盲测确认趋势外推到实体：仅用 5.6 小时任务数据后训练，预训练越多成功率越高；预训练 + 550 小时任务数据时部分任务峰值达 99%。

3.4 数据科学细节

大规模消融的结论是**质量和多样性比体量重要**。他们把数据按采集模式分类（Class 1 特定任务 / Class 3 自由活动 / Class 2 介于两者），跨数据供应商 A/B 测试，用两个指标筛数据：验证 MSE（低→适合 SFT）和 reverse KL（低→分布多峰、适合 RL 后训练）。数据引擎每天能吸收 6.85 年的真实世界操作经验。

4. GEN-1：把「精通」定义成可测量的三件事

4.1 Mastery = 可靠性 × 速度 × 即兴智能

GEN-1 的贡献不在架构（仍是 GEN-0 基础的继续 scaling + 算法改进），而在证明了规模化路线能跨过**商用门槛**，并把「精通」操作化为三个可测维度：

可靠性：6 个任务平均 99% 成功率。对照：GEN-0 微调 64%，从头训练 19%。实测视频包括连续 1 小时汽车零件配套、连续折 86 件 T 恤、连续 200+ 次维护扫地机器人、连续 1800 次装箱、连续 200 次折纸箱、连续 100 次装手机——全程无人工干预。

速度：折纸箱 12.1 秒，此前 SOTA（GEN-0 和 $\pi 0$ 在相同纸箱上）约 34 秒，快 2.8 倍。关键是模型能**超过演示速度**执行——速度提升来自经验学习（RL）+ Harmonic Reasoning 推理演进 + 数据引擎天然包含高速人类操作（遥操作数据因延迟和缺乏力反馈天然偏慢，人类穿戴设备数据没有这个问题）。

即兴智能：垫圈被碰离抓取位置时，模型会放回重抓、或部分插入槽位借助外部灵巧性（extrinsic dexterity）调整、或换另一只手双手协同重抓——这些行为都在训练分布之外。

4.2 值得注意的工程事实

- 每个 99% 任务只用了约 1 小时机器人数据。预训练零机器人数据，所以后训练是同时在适应「这个任务」和「这台机器人」。
- GEN-1 是「系统」而非单纯权重：推理基础设施（自研 paged attention 变体支撑实时推理）、后训练技术（RL + 多模态人类引导）、模型 harness 共同贡献性能。
- 数据效率：某些测试中 GEN-1 用 1/10 的任务数据和微调步数达到 GEN-0 同等性能。

4.3 GEN-1 提出的新问题：具身对齐

涌现即兴是双刃剑：模型会自发「抖动袋子让物体归位」「重新整理放错物品」——但物理动作有真实后果，机器人的「成功」定义是任务、工作流、用户三层特定的。**不该做什么和该做什么同样重要**。这段讨论预示了具身模型的对齐研究会成为独立方向。

5. GEN-1.5: one-shot 学习涌现——机器人的 GPT-3 时刻

5.1 能力清单

GEN-1.5 是一个处理视频输入（30 秒记忆窗口 + 传感器 + 语言 + 本体感知）、输出 100Hz 动作轨迹的大型多模态模型。它展示的能力：

1. **One-shot 上下文学习**：3-12 秒单段演示插入上下文窗口，无训练，几秒后开始执行。10 个任务（拉链、开罐、从钱包取钱等）平均成功率 59% ($\pm 10\%$)。
2. **组合泛化**：两个独立录制的物理提示放进上下文，模型自动串成连续长程行为，中间的重定位、换抓、纠错动作**两段演示里都没有**。
3. **零样本 sim-to-real**：预训练完全没有仿真数据，但仿真里录的演示（脚本策略 / RL agent / 仿真遥操作）可以直接提示真机执行，且泛化到不同手、新物体位置与尺寸。
4. **人类到机器人 ICL**：某些情况下人直接用自己的手在机器人相机前演示，机器人立刻复现——跨具身差距的上下文迁移。
5. **极少梯度步适应**：1-10 步梯度下降 + 1-5 分钟数据（约 10-50 条演示）即可微调新任务。10 步 + 5 分钟数据达 83% ($\pm 9\%$)；极限 1 步 + 1 分钟数据达 66.5%。
6. **工具即兴**：微调「用刷子扫积木进碗」后，给香蕉会拿香蕉当刷子；给簸箕会改变策略——用簸箕铲起积木倒进碗里。这个接触序列在微调数据和预训练数据里都不存在（他们用语言最近邻搜索在 189 万个场景里核对过）。

5.2 最关键的科学事实：这些能力是涌现的，不是设计的

原文的表述值得逐字记录："We did not explicitly train GEN-1.5 for in-context learning"——没有为 ICL 做架构修改、没有 meta-learning 内外环、没有鼓励即兴的辅助目标、测试任务没有事先工程进预训练数据。物理提示在时间上是不连续的拼接（模型在训练中从未见过这种跳变），但模型能理解并执行。

为什么涌现？博客给了两个假说（均类比语言模型 ICL 文献）：

- 物理观测与动作的分布可能具有 **burstiness 和 Zipfian 结构**（Chan et al. 2022 证明这类数据分布特性驱动 transformer 的 ICL 涌现）；

- 物理劳动包含**自然重复循环**，模型学会了检测并延续模式（类比 Mirchandani et al. 2023 "LLM as general pattern machines"）。

5.3 few-step adaptation 的深层含义

10 个梯度步只改变权重不到 0.15%——作者的解读是：**微调不是在建立新表征，而是在轻微重新配置已有知识**。「更像是提醒模型它几乎已经知道的事，而不是传统意义上的任务训练。」

一个反直觉发现：即兴能力随微调步数减少而**增强**——轻度适应的模型更贴近预训练先验，遇到偏离演示的情形时能调用更广的行为库。这和 LLM 领域「过度微调损伤通用能力」的经验完全同构。

5.4 physical prompt engineering：新的交互范式

拖放界面选择演示片段插入上下文窗口，现场录像展示了背靠背教两个任务（拉开笔袋拉链→取出钱）。组合提示意味着：**长程任务可以从短小可复用的物理提示库里组装**，而不必采集完整复合任务的演示——这是语言 prompt chaining 的物理类比。

6. 批判性评估

这是博客不是论文。没有 peer review，没有完整方法细节（模型参数量、上下文编码方式、动作头设计全部未公开），数字无法独立复现。GEN-0 声称的 scaling law 图表没有给出原始数据，GEN-1.5 的 10 任务评测协议（每任务试验次数、初始条件随机化程度）未披露。对照 HOST 论文 50 任务 × 13 基线的公开评测，GEN 系列的证据强度低一档——但其数据规模（50 万小时）和涌现现象的定性展示（视频）又是学术界拿不出来的。

任务是「简单短视界」的，作者自己承认。59% 的 one-shot 成功率意味着五分之二的失败率，离部署很远。ICL 学到的技能「比微调模型更脆」。

私有数据引擎是核心壁垒也是核心不可验证点。27→50 万小时人类穿戴设备数据，成本量级估计在数千万美元。学术界无法复现这条路线，只能走 HOST 式的「聪明架构弥补数据稀缺」路线——这构成了本调研最重要的产业-学术分野（见 insight 报告）。

「预训练零机器人数据」的说法要小心读。预训练全是人类手持夹爪数据，但后训练/微调仍需机器人数据（每任务约 1 小时）。GEN-1.5 的 one-shot 物理提示可以是人类数据，但效果最稳的仍是机器人自身 rollout。

7. 与 HOST 的正面对照

维度	GEN-1.5	HOST
路线	大数据涌现（50 万小时私有数据）	架构设计（共享任务进度流形 + 自接地预测级联）
ICL 机制	隐式，从预训练涌现	显式，SDTW 对齐 + 目标耦合设计进架构
演示形式	人类手持夹爪 / 机器人 rollout / 仿真	纯人类视频（第三人称 RGB）
适应耗时	秒级（in-context）或 1-10 梯度步	平均 29 秒（无梯度更新）

维度	GEN-1.5	HOST
成功率	59% (10 任务, one-shot)	62% (50 任务, one-shot)
旧技能保持	未量化报告	显式验证不遗忘
可复现性	不可 (私有数据+闭源)	完全开源 (2026-08-03 起代码+权重上线 GitHub/HuggingFace)
证据形式	博客 + 视频	arXiv 论文 + 13 基线对比

两者在 2026 年 8 月同月发布，从两条完全不同的路线逼近同一个目标——「看一次就会」。GEN 证明数据规模足够时该能力自己长出来；HOST 证明数据不够时可以用归纳偏置把它设计出来。这不是竞争关系，是上下界关系：HOST 类方法给出了小数据机制的性能下界，GEN 类方法给出了大数据机制的涌现上界。

8. 给从业者的判断

1. **scaling law 在机器人领域成立已是多方验证的事实**（GEN-0、 π 系列、字节 GR 系列都有印证），争论已转移到「数据从哪来」：人类穿戴设备（Generalist）、遥操作（多数公司）、人类视频（HOST/Vid2Robot 学术线）、仿真（NVIDIA 线）四条数据路线的成本-质量权衡是当前最重要的开放问题。
2. **7B 相变**如果被独立复现，对端侧部署路线是坏消息，对云端推理/蒸馏路线是好消息。
3. **ICL 涌现把「任务适应」从训练问题变成提示工程问题**——physical prompt engineering 可能催生类似 LLM prompt 工程师的新工种，以及「物理提示库」这种新资产形态。
4. GEN-1 强调的**速度维度**（3x SOTA）长期被学术评测忽视——成功率之外，任务完成时间会成为下一个军备竞赛指标。

Instant Policy 深度解读：把 in-context 模仿学习变成图扩散，用仿真伪演示喂出即时策略

Instant Policy: In-Context Imitation Learning via Graph Diffusion arXiv 2411.12633v2 (2025-04-25 更新) · ICLR 2025 · Imperial College London, The Robot Learning Lab 作者: Vitalis Vosylius, Edward Johns

1. 一句话定位

Instant Policy 把「给 1-2 条演示就立即会做新任务」拆成两个可解的子问题：用异构图 + 扩散过程给 In-Context Imitation Learning (ICIL) 注入空间结构归纳偏置，用程序化生成的仿真「伪演示」(pseudo-demonstrations) 提供近乎无限的训练数据。结果是一个基础版完全不碰真实数据的模型，真机 16 个日常任务平均成功率 88.75%，比同数据训练的 BC-Z/Vid2Robot/GPT2 式基线 (34.4%-40.6%) 高一倍以上；每个新任务只需现场动觉示教 1-2 条，零训练、零微调。

2. 要解决的问题

ICL 在 NLP/视觉里是海量数据喂出来的涌现能力，机器人没有这个数据条件。要在机器人上做 ICIL，卡在两点：

- 数据效率**：以往 ICIL 方法 (BC-Z 的隐嵌入条件化、Vid2Robot 的 Perceiver + cross-attention、GPT2 式因果序列建模) 把演示当扁平向量或 token 序列处理，3D 空间结构全靠网络自己领悟，数据不够就悟不出来——在本文的 RL Bench 评测里这三类方法平均只有 0.34-0.38；
- 数据来源**：人工采集机器人演示贵且慢，靠真实数据堆不出 ICIL 需要的任务多样性。

作者的关键观察是概念性的：BC 的权重编码「特定任务的策略」，而 ICIL 的权重编码的是「解读上下文并照做」这个任务无关的元能力。所以训练数据不必是真实任务，只需要「语义一致的轨迹集合」——这直接解锁了第二个卡点。

3. 方法

3.1 表征：三层异构图

局部图 G_l ：分割点云（降采样到 2048 点、变换到末端执行器坐标系）经最远点采样 + PointNet++ Set Abstraction 编码成 $M=16$ 个节点，特征来自一个在 ShapeNet 上预训练、训练策略时冻结的占据网络 (occupancy network) 编码器，保证特征描述局部几何（端到端训练或微调它反而显著变差）。夹爪表示为 6 个刚性变换的关键点节点，特征编码节点身份 + 开合状态。场景节点与夹爪节点连边，边属性用 NeRF 式 $\sin/\cos$ 高频位置嵌入表示相对位置。

上下文图 G_c ：演示轨迹是局部图序列（每条演示降采样到 $L=10$ 个 waypoint，保留起止点、夹爪开合切换点和减速点），跨时刻夹爪节点连「相对运动」边，所有演示夹爪节点连到当前观测的夹爪节点。边数随演示条数 N 和长度 L 线性增长，任意 N 、 L 都能处理。

动作图 Gla: 未来 $T=8$ 步动作 (SE(3) 位移 + 夹爪开合) 表示成「假装执行后」的局部图——把动作的空间后果直接画进图里, 而不是当抽象向量回归。当前与未来夹爪节点之间的边编码相对运动。

3.2 学习: 图上的扩散

把 ICIL 建模为图生成: 前向过程在动作上加噪 (SE(3) 经 Logmap 投影到切空间加高斯噪声再 Expmap 回来), 反向过程由异构图 transformer 预测每个夹爪节点的去噪方向 $\varepsilon \in \mathbb{R}^7$ 。三个关键设计:

- **平移/旋转解耦的流 (flow) 表示:** 去噪方向拆成质心平移 + 绕质心旋转两个分量, 避免大平移淹没小旋转。消融: 不解耦 -15%, 换四元数表示 -37%, 换轴角 -21%;
- **SVD 恢复 SE(3):** DDIM 更新节点位置后, 利用已知点对应用 SVD 求出对齐变换作为该步动作更新——动作始终以点集形式存在于图空间, 与观测同构;
- **三级子网络级联 $\sigma \rightarrow \phi \rightarrow \psi$** (各 2 层、隐维 1024、16 头), 分别负责局部几何传播、上下文汇聚、动作节点更新。换成单个大网络或全连接图 (等价于稠密自注意力 transformer) 都显著变差——结构化信息流是必需品, 不是锦上添花。 ϕ 的输出在当前观测的夹爪节点上形成信息瓶颈, 后面的下游应用靠它。

扩散本身也不可省: 去掉扩散直接回归动作 -29%。预测时域 $T=1$ 时 -52%, $T=8$ 为基准。

3.3 数据: 伪演示引擎

生成流程: ShapeNet 随机放 2 个物体 $\rightarrow$ 在物体上/附近采样 2-6 个 waypoint 构成「伪任务」 $\rightarrow$ 虚拟移动 Robotiq 夹爪网格依次到达、开合时刚性吸附/释放最近物体 $\rightarrow$ PyRender 三个仿真深度相机录制点云。同一伪任务换物体位姿、换起始位姿重复生成, 就得到语义一致的演示集合。轨迹不需要动力学甚至运动学可行——动力学和可行抓取由推理时的真实演示 (上下文) 定义。

细节决定成败: 一半样本偏向常见技能 (抓取、抓放、开合) 采样, 一半全随机; 30% 轨迹注入局部扰动 + 回归参考轨迹的修正动作 (催生恢复行为); 10% 样本翻转当前夹爪状态输入——不加这条, 策略永远学不会松手后重抓。动作归一化到每步 $\leq 1\text{cm}/3^\circ$ 。

训练 2.5M 步 (约等价 700K 条独立轨迹, 边生成边训练、样本不重复), AdamW lr $1e-5$ 、float16, 单张 RTX 3080-ti 约 5 天。这个成本在同类工作里低得反常。

4. 实验结果

仿真 (RLBench, 24 任务 $\times$ 100 rollout, Franka Panda): 纯伪演示训练平均 0.71, 基线 0.34-0.38。追加 12 个任务各 20 条真演示微调 (PD++) 后, 见过的 12 任务 0.97, 未见的 12 任务 0.82 (基线 0.31-0.43)。注意力可视化显示模型确实在追踪任务阶段并选择性聚合上下文对应片段。

真机 (Sawyer + Robotiq 2F-85, 2 个 RealSense D415, SAM + XMem++ 分割, 动觉示教): 16 个日常任务 $\times$ 10 rollout, 平均 88.75% (16 项中 7 项 10/10), 对 BC-Z* 34.38%、Vid2Robot* 40.63%、GPT2* 36.88%。基线全部移植到同一点云编码器、同参数量、去掉语言辅助损失, 口径公平。部署前用 5 个评测外任务的演示混合伪演示 co-finetune 了 100K 步以适应真实噪声。

新几何泛化（涌现能力）：上下文里放不同几何物体的演示、测试完全没见过的同类物体，成功率随演示数单调上涨：N=1 时 40%，N=2 时 52.5%，N=3 时 85%，N=4 时 90%。训练时从未构造过跨几何上下文——这是图表征 + 结构化注意力的涌现红利。

Scaling：69M→117M 参数，平台期成功率显著上升；117M→178M 只有边际改善，瓶颈转移到数据多样性。验证损失随训练算力和容量持续下降。

推理参数：扩散步数从 4 砍到 2 只掉 2%；演示长度 L=1（只给最终目标）暴跌 71%，L=5 仍掉 26%——上下文必须够稠密，因为任务信息不在权重里；演示数 N=2 够用（N=1 掉 12%，N=3 仅 +2%）。

下游应用：人手演示跨具身迁移（MediaPipe 关键点手工映射到夹爪位姿，简单抓放可用）；利用 ϕ 输出的信息瓶颈 + Sentence-BERT + 对比学习，小规模语言标注数据即可零样本执行语言指令任务。

5. 局限

作者自认六条：依赖分割点云；点云无颜色和语义；短视野 Markov 假设；对演示质量和降采样敏感；无碰撞规避、不控制完整构型空间；精度不足以做低容差和富接触任务。

延伸批判：

1. **分割是真机最大单点故障。**SAM + XMem++ 遮挡即崩，分割混入桌面或机器人点会直接污染图节点。方法主体的鲁棒性建立在一个比它脆弱的感知前置上；
2. **88.75% 不是纯仿真训练的数字。**真机评测用的是 co-finetune 后的模型，纯伪演示模型的真机成绩未单独报告，「零真实数据」的宣称要打个折扣；
3. **伪演示的先验圈定了任务空间：**刚性吸附抓取、2–6 个 waypoint、每步 1cm/3°，实际把能力限制在准静态位移操作。铰接体开合能做（微波炉 0.23/0.56 已是全表最低分之一），柔性物、动态操作、力控任务出圈；
4. **失败模式印证了 Markov 假设的代价：**演示信息冲突或状态歧义时策略停滞或振荡，作者也承认要把历史观测加进图里。

6. 与 HOST / GEN-1.5 的关系

Instant Policy 和 HOST 同属「结构派」：都赌 one-shot 能力可以靠归纳偏置在小数据下做出来，不必等 50 万小时数据的涌现。差别在结构加在哪一维——Instant Policy 加在**空间**（图表征 + 3D 点云 + SE(3) 扩散），HOST 加在**时间**（进度流形对齐 + 自接地级联）。两者对基线的诊断也互相印证：Vid2Robot 式扁平 cross-attention 条件化在 HOST 评测里 $\leq 19\%$ （对 HOST 62%），在这里真机 40.63%（对 88.75%）——「演示被当成被动上下文」是两篇论文共同指认的病灶，只是开的药方不同。

按调研坐标系逐条摆放：

- **演示模态线：**Instant Policy 原生要机器人自己的演示（动觉/遥操作），人手演示只是靠 MediaPipe 手工映射的附加实验，精细任务映射即失效。HOST 用 Stage 2 学习的跨具身适配原生消化人类视频，这条线上 Instant Policy 被明确超越；

- **数字口径**：88.75%（16 任务，演示与测试同物体）vs HOST 62%（50 任务，人类视频跨具身）vs GEN-1.5 59%（10 任务）不可直接比大小——三者的泛化难度不在同一层级，Instant Policy 的设置最宽松；
- **对 GEN-1.5**：本文的 scaling 实验是 GEN 路线的小尺度预演——性能随仿真数据和容量增长、178M 后卡在数据多样性上。「需要更多样、更接近真实任务的数据」这个结论，GEN-1.5 用 50 万小时真实数据给出了暴力解，Instant Policy 给出的是程序化生成解；
- **独特剩余价值**：一是伪演示引擎——证明 ICIL 元能力可以与任务语义完全解耦、用零真实成本的仿真数据训练，这个思想至今没有被 HOST/GEN 任何一方吸收（HOST 的 Stage 1 仍烧 193k 条真实轨迹，二者能否用伪演示替代是开放问题）；二是图注意力提供了 ICIL 内部机理最干净的可解释窗口（模型在哪个演示片段上聚合，直接可视化）；三是 $N=1 \rightarrow 40\%$ 、 $N=4 \rightarrow 90\%$ 的跨几何插值曲线，是「上下文内泛化」能力最干净的行为学证据。

ICRT 深度解读：next-token prediction 原教旨主义的机器人 in-context learning 配方

In-Context Imitation Learning via Next-Token Prediction arXiv 2408.15980v2 (2024-09-27 更新) · ICRA 2025 · UC Berkeley AUTOLAB/BAIR + Autodesk Research 作者: Letian (Max) Fu*, Huang Huang*, Gaurav Datta*, Lawrence Yunliang Chen, Will Panitch, Fangchen Liu, Hui Li, Ken Goldberg

1. 一句话定位

ICRT 用最朴素的配方验证机器人 ICL 成立：一个随机初始化的 Llama2 架构因果 transformer (12 层、768 维)，对原始感知运动轨迹（图像、本体状态、动作）做 next-token prediction，测试时把新任务的遥操作演示轨迹直接当 prompt 喂进去，权重不动即可执行——12 个未见任务平均 79.2%，同期最强的微调后 Octo 9.2%、OpenVLA 7.5%、goal-conditioned 基线 20.0%。核心发现不在架构而在数据：让 ICL 出现的是「同一初始观测下存在多个可能任务」的数据结构（自采 ICRT-MT 仅 1098 条轨迹），不是数据量——只用 DROID 子集训练的对照组成功率为 0%。

2. 要解决的问题

多任务机器人基础模型预训练完仍教不会新任务：新任务要再采遥操作数据、再微调一轮，流程复杂到难以落地。LLM/LVM 已经示范了另一条路——in-context learning，prompt 里给例子、权重不动就适配新任务。本文问的是：ICL 是语言/视觉独有的，还是 next-token prediction 框架的普适性质，能否直接搬到真机连续控制上。

已有 few-shot IL 方法各有拖累：对比学习式上下文编码器与 NTP 框架难以整合；DOME 需要额外的物体分割模型；KAT 要把轨迹转成 3D 关键点 token 借用 LLM 的少样本能力；Vid2Robot 靠一堆辅助损失；One-Shot Imitation Learning (Duan et al. 2017) 和 Prompting Decision Transformer 只在仿真 + 全状态 + 已知奖励下成立。ICRT 的立场是做减法：无关键点、无分割、无辅助损失、无奖励建模，原始轨迹进、动作出，单一 L1 损失。

3. 方法

3.1 数据构造（真正的贡献所在）

- **DROID 预训练子集**：76k 条真实演示，过滤（保留 30–450 步）后采样 10k 条，按语言指令的 CLIP 文本嵌入余弦相似度 ≥ 0.9 分组、每组至少 4 条轨迹（保证能互为 prompt），最终约 2k 条可用；
- **ICRT-MT 自采数据集**：1098 条轨迹、29 个任务、6 个动作原语（抓取、抓放、堆叠、推、戳、开关抽屉），采集协议的核心约束是**每个场景至少存在 2 个可行任务**。单任务场景（DROID 大量如此）会让模型学捷径——只看当前观测就能唯一确定动作，prompt 沦为摆设；多任务同场景把「读 prompt」从可选变成必需。这一条解释了 DROID-only 训练全零的结果。

序列构造：同任务轨迹随机洗牌拼接，截取 $L=512$ 个 (state, action) 步的子序列（约容纳 5 条轨迹），随机取前 k 条标为 prompt（至少含一条完整轨迹）。传统 BC 用短序列建模轨迹内部行为，ICRT 用长序列建模**轨迹之间**的模式。

3.2 架构

- **视觉编码器**：ViT-Base，用 CrossMAE 在 ImageNet + Open X-Embodiment 各半的混合上预训练（专门缩小与含机器人/夹爪图像的域差），训练 ICRT 时冻结；
- **模态投影**：每个相机的全部视觉 token 与本体嵌入（MLP）做 attention pooling，多相机结果拼接成单个 state token；动作经 MLP 成 action token。每个时间步只占 2 个 token，这是 512 步长上下文能塞下 5 条轨迹的前提；
- **主干**：Llama2 架构随机初始化，12 层、768 维；输入 state/action 交替序列，在 state 位置解码未来 $h=16$ 步动作（L1 损失），执行时时间集成 + 后退视野控制取 10 步；
- **参数化**：本体 = 绝对末端位姿（xyz + 旋转矩阵前两行展平的 6D 旋转 + 连续夹爪），动作 = 相对当前位姿的增量位姿 + 绝对夹爪，各 10 维。

3.3 两个反直觉的训练决策

1. **prompt 部分不算损失**（借鉴 Vicuna 等多轮对话模型只对 response 算损失）：对 prompt 也算损失的对照组从 79.2% 崩到 22.5%。机制：prompt 位置没有上下文可依赖，强迫模型在此做无条件生成，等于训练它「不看 prompt 也要输出」，这个习惯会泄漏到 prompt 之后；
2. **两阶段而非混合训练**：DROID 预训练（4 epoch，56 分钟）→ ICRT-MT 微调（125 epoch，18 小时）， $4\times A100$ 。单阶段混训只有 6.7%——DROID 约 200 任务对 MT 29 任务的失衡淹没了 MT 的结构信号。

3.4 推理

KV cache 流式推理，每步只算新 token，复杂度从二次降到线性，实测 39.6 Hz（3090Ti），支持真机实时闭环。演示以「与训练数据完全同格式」的传感运动轨迹给入，无任何转换环节。

4. 实验结果

平台：Franka Emika，固定侧视 + 腕装相机。评测协议设计得很尖锐：2 个原语（抓放、戳）× 各 6 个未见任务（3 个训练见过的物体 + 3 个全新物体）× 5 个难度层（0–3 个干扰物、干扰放置位），每层 1 次尝试共 60 试验；prompt 场景与测试场景不同摆放，防止照抄动作；抓放计分「抓对 0.5 / 放对 1.0」，25 秒内可重试。

主结果（平均成功率 ± 标准误）：goal-conditioned 20.0% (±4.3)，Octo 微调后 9.2% (±3.5)，OpenVLA 微调 + 16 步 chunk 后 7.5% (±2.9)，ICRT 79.2% (±4.6)，其中抓放 65.0%、戳 93.3%。戳任务是照妖镜：目标图像与初始状态几乎无差别，goal-conditioned 直接失明（6.7%）；OpenVLA 常把戳做成抓（3.3%）——只有轨迹 prompt 能无歧义地传达「用什么运动模式」。

消融（Table II）：

- **ICRT-Llama2-7B** (LoRA $r=32$ 微调): 58.3%，比从头训练的 Base 低 21 个点。训练损失更低但推理只有 10.7 Hz (对 39.6 Hz)，实时性拖垮闭环表现；语言预训练先验在感知运动序列上没有兑现；
- **ICRT (DROID only)**: 0.0%——数据结构不对，多少数据都白搭；
- **ICRT (MT only)**: 73.3%，只比完整版低 6 个点。大规模预训练有正贡献（尤其戳原语 70% 对 93.3%）但远非决定性；
- **prompt 类型鲁棒**：换不同类型 prompt（无/有干扰物、干扰放置位）或 1–3 条 prompt，成功率稳定在 60–80%；
- **重复性**：两个任务各 25 次试验，标准差 0.5% 和 3.2%；
- **近似新原语**：grasp-and-drop (40–80%)、放到某物右侧 (80%) 可以泛化；与训练原语无相似性的动作不行。

5. 局限

作者自认：无法泛化到完全未见的动作原语，只能在 6 个训练原语的邻域内换物体、换布局；假设固定形态 + 固定阻抗控制器，跨形态迁移未涉及；ICRT-Llama2 推理太慢。

延伸批判：

1. **评测统计功效弱**：60 次总试验、每个难度层只测 1 次，与 HOST 的 50 任务 $\times$ 20 试验相比薄得多；重复性实验只覆盖 2 个任务，无法完全打消方差疑虑；
2. **「未见任务」定义宽松**：新物体 + 旧原语 + 新摆放。原语级技能空间在训练时就封闭了 (6 个)，这与 HOST 意义上 50 个未见任务的任务级泛化不是一个难度层级；
3. **同具身假设是隐性成本**：prompt 必须是本机器人的遥操作轨迹，每个新任务仍要专家上手采 1–3 条——比人类视频 (HOST 的输入) 的采集门槛高一个量级，「免微调」不等于「免专家」；
4. **冻结视觉编码器的代价已现形**：同色异形干扰物会导致抓错，作者自己承认需要微调视觉编码器——细粒度视觉表征是明确短板。

6. 与 HOST / GEN-1.5 的关系

ICRT 是「规模派」的最小可行原型：与 GEN-1.5 共享同一信念——ICL 是 next-token prediction 的普适性质，不需要机器人特有的结构设计。GEN-1.5 用 50 万小时数据把这个配方推到涌现 (59%)，ICRT 用约 3k 条轨迹证明配方本身成立，并揭示了小数据下的苛刻前提：**数据结构必须强迫模型读 prompt** (多任务同场景 + prompt 免损失)，否则模型必然走捷径。

这个前提恰好是 HOST 论点的实证注脚。HOST 批判以往方法「时间错位把演示降格为被动上下文，模型学会忽略演示」；ICRT 的两个消融从数据侧复现了同一病灶——prompt 算损失就崩 (79.2% 到 22.5%)，单任务数据就归零。差别在药方：ICRT 用**数据工程**绕开 (精心构造逼模型读 prompt 的训练分布)，HOST 用**结构工程**正面解决 (目标耦合让演示主动驱动预测目标)。数据可控时前者便宜，数据来源不可控 (野生人类视频) 时只有后者可行。GEN-1.5 则暗示第三条路：数据量大到自然覆盖多任务歧义时，强迫函数可能自动出现——但这只是从其涌现结果反推的猜想，50 万小时对 1098 条，成本差五个数量级。

坐标定位：

- **演示模态线**：ICRT 只吃同具身遥操作轨迹，被原生消化人类视频的 HOST（62%/50 任务/29 秒习得）明确超越；
- **规模线**：被 GEN-1.5 沿完全相同的技术路线（自回归序列模型 + 轨迹 prompt）用三个数量级的数据碾过；
- **独特剩余价值**：一是 39.6 Hz KV-cache 流式闭环，是本调研涉及方法中唯一把「prompt 不重算、逐 token 增量推理」工程化并报告实时数字的；二是「数据结构大于数据量」的定量证据（1098 条精构轨迹从 0% 做到 73.3%，10k 条 DROID 是 0%），对任何 ICIL 数据预算分配是直接可操作的结论；三是 LLM 初始化的负结果（7B 反而低 21 个点）——「拿语言先验白嫖机器人控制」在这个数据尺度不成立，且失败原因（推理延迟拖垮闭环）提醒所有人：机器人 ICL 的模型选型受实时性硬约束，这条约束在语言域不存在。

RoboTTT 深度解读：把 Test-Time Training 装进机器人策略，上下文扩到 8K 步

RoboTTT: Context Scaling for Robot Policies arXiv 2607.15275v1 (2026-07-16) · NVIDIA GEAR + Stanford + UT Austin 作者: Yunfan Jiang 等; 共同指导: Li Fei-Fei、Yuke Zhu、Linxi "Jim" Fan

1. 一句话定位

RoboTTT 把 Test-Time Training (TTT) 层插进 VLA 模型 (GR00T N1.7)，用「推理时也做梯度下降的 fast weights」充当循环状态，把视觉运动上下文从单步扩到 8K 时间步 (30Hz 下约 5 分钟) ——比现有 SOTA 长三个数量级，推理延迟却不随上下文增长。这个长度解锁四种能力：从一段 in-context 人类视频 one-shot 模仿新装配配置 (6/10 成功，基线全灭)；DAgger Distillation 带来的在线自我改进 (+36%)；外部扰动恢复 (83% vs 最强短上下文基线 53%)；长程任务总分比单步基线高 87%，且是唯一完成 5 分钟 10 阶段 Gear Bot 装配的方法。更大的发现是：预训练上下文从 128 扩到 8K，闭环性能单调上升无饱和 (8K 比 1K 高 63%) ——上下文长度是机器人基础模型的一条新 scaling 轴。

2. 要解决的问题

主流机器人基础模型 (π_0 、OpenVLA、GR00T、RDT 等) 只吃单步或 2-8 帧短历史，而 LLM 那边上下文长度早已是核心 scaling 轴。长视觉运动上下文对三类能力不可绕过：one-shot in-context 模仿、从自身部署历史在线改进、多阶段长程任务的闭环执行 (视觉相似的阶段造成状态混叠，短上下文策略会跳步或重复做)。

做长上下文有三个结构性障碍。一是容量：RNN 的向量状态压不住几千步的稠密观测流。二是利用：朴素拼接历史帧会引入虚假相关 (causal confusion)，论文实测 GR00T N1.7 加一帧历史后在 Pup Go Car 上从 57% 掉到 39.5%——历史不但没帮忙反而有毒。三是成本：Transformer 即便有 KV cache，解码延迟仍随上下文线性涨，5 分钟 @30Hz 的近万步历史在真机上不可行。

3. 方法

3.1 TTT 层：用梯度下降当记忆写入

fast weights W 参数化一个小网络 f_W (两层 MLP)。每个时间步先「update」：对当前键值对做一步梯度下降，最小化 $\|f_W(K_t) - V_t\|^2$ (学习率可学习)，把上下文写进参数空间；再「apply」： $O_t = f_W(Q_t)$ 读出。训练与推理都执行这套 update-then-apply。QKV 投影矩阵与初始权重 W_0 由外层任务损失端到端学习， W_0 走 MAML 式二阶梯度元学习——更新规则本身是学出来的，这是它与 Gated DeltaNet 等线性递归记忆的本质区别。

3.2 与 VLA 的融合

主干是 GR00T N1.7 (VLM + 16 层 DiT flow-matching 动作头)。每层 DiT 的自/交叉注意力后插一个 TTT 层：注意力只处理单步内 token ($N=16$ 个可学 register token、本体 token、噪声动作 token，

cross-attend 该步的视觉语言 token)，TTT 层沿时间维跨步整合。视觉语言 token 不直接过 TTT（省算力），靠 register token 携带其信息跨时间。 $\tanh$ 门控 $O = \tanh(a) * O_TTT + O_attn$ ， a 初始化 0.001，让 TTT 贡献从近零起步、不冲垮预训练能力。

3.3 训练配方：两个使长上下文可训的技巧

Sequence action forcing：序列内每个动作块独立采样 flow-matching 噪声水平， $t = s(1-u)$ ， $u \sim \text{Beta}(1.5, 1)$ ， $s=0.999$ 。共享一个噪声水平会让整条序列同等难/易，训练不稳定（呼应 Diffusion Forcing 的发现）；消融显示去掉它闭环性能崩塌。

TBPTT（截断式沿时间反传）：序列切段，梯度只在段内流动，fast weights 跨段传递但 detach 梯度。显存由段长而非总长决定，训练上下文可任意加长； W_0 仍从首段获得梯度。

预训练：桌面双臂机器人数据 + 第一视角人类数据混合，上下文逐步升到 8K，30K 步 x 16 张 GB200。每个下游任务再以 1K 上下文 post-train 20K 步。

3.4 两种上下文玩法

把 flow-matching 损失在选定时间步 mask 掉，这些步就成了纯上下文（只更新 fast weights、不当模仿目标）。由此派生两个能力：

one-shot 视频模仿：训练时把同配置的（人类演示视频，机器人轨迹）拼成一条序列，视频段 mask 损失。所有配置共用同一句指令「assemble circuit」，目标配置只能从视频认出。测试时喂一段未见配置的人类视频即可复现装配。

Dagger Distillation：Dagger 轨迹里机器人错误动作和人类纠正交错。标准 Dagger 只在纠正上微调、丢掉错误动作；RoboTTT 让完整历史（含错误动作）更新 fast weights，损失只算人类纠正段——失败当上下文、纠正当目标，把「失败到纠正」的映射蒸馏进 fast weights，是 Algorithm Distillation 在机器人上的实例化。测试时模型自己犯错自己纠，无需人在环。

4. 实验结果

平台：YAM 双臂 + 4 RGB 相机（顶、底、双腕）。三个装配任务：Pup Go Car（平均 2 分钟，8 小时数据）、Circuit（1 分钟，80 个配置训 20 测 60，6 小时）、Gear Bot（5 分钟 10 阶段，5 小时）。

主结果：平均任务完成分 RoboTTT 79%，GR00T N1.7 42%（相对 +87%），GDN（把 TTT 换成 Gated DeltaNet 线性递归记忆的对照）56%（+41%）。三任务全成功数 9/20、13/20、2/10；Gear Bot 上 RoboTTT 是唯一有全成功的方法，所有基线 0/10。

上下文 scaling：预训练上下文 128 到 8K，RoboTTT 闭环分数单调升到 71.5%，比 1K 版（43.9%）高 63%、比最强短上下文基线（45.6%）高 57%，无饱和迹象；GDN 完全没有此趋势。作者归因：梯度下降更新加元学习的 W_0 与更新动力学能被更长的训练序列塑形，线性关联状态没有这个元学习空间。1K 以下 RoboTTT 变弱的原因也给了：rollout 时长超过训练窗口，fast weights 被推到训练没见过的更新步数、位置编码外推。

one-shot 模仿：Circuit 未见配置 6/10 成功（完成分 65%），GDN 0/10（33%）——GDN 拿错部件或装错顺序，说明递归记忆「能编码但不会用」上下文；RoboTTT 靠测试时梯度更新的 fast model 按需检

索演示配置。

扰动恢复：执行中人为拆掉已装好的顶棚/轮胎，RoboTTT 恢复 15/20 和 18/20，GDN 13/20 和 18/20，短上下文基线最高 10/20（含 30 分钟扰动数据共训）。

Dagger Distillation：100 条 DAgger 轨迹（RoboTTT 与 GR00T 各采 50 条）训练所有方法。标准 DAgger 平均提升 9%；蒸馏版平均 +33%（RoboTTT +36%、GDN +29%）。关键对照：把含错误动作的完整轨迹直接微调 GR00T，结果与只用纠正段完全相同（都 57%）——错误动作作为模仿目标零价值，作为上下文才值钱。定性看增益主要来自「做错后重试」：钻头没对准螺丝，抬臂、重新对准、再钻，最多重试两轮后成功。

消融（Pup Go Car）：linear fast model 比 MLP 差 27%（非线性容量是关键）；TTT 只吃 state token 起步，加 action token 相对 +23%（感知自身过去动作有助建模环境动力学），再加 register token 又 +18%；同样的 register token 加给 GR00T N1.7 无任何提升——它只在配合 TTT 时序建模时才有用。

5. 局限

作者自认三条：训练成本随上下文长度上涨（可引入 TNT 等更省的 TTT 训练法）；TTT 层沿用通用键值重建目标、未做机器人特化；不能覆盖全部失败模式，接 RL 直接优化任务成功率是下一步。

延伸批判：

1. **one-shot 的口径远窄于字面**。评测只在 Circuit 单一任务族的未见配置上进行，且训练用了该任务族的成对数据（每配置 5–20 段人类视频）。这是「配置级」泛化——同一装配任务换目标布局——不是跨任务的技能级 one-shot。
2. **每个下游任务仍要 20K 步 post-training**。新任务族的部署门槛没有消除，one-shot 只发生在 post-train 覆盖的分布内。
3. **人类视频与机器人执行同场景同相机**（机器人 idle、人上手装配），跨具身鸿沟被采集设定大幅压缩；换成第三人称视角或野生视频能否成立未验证。
4. 「延迟不随上下文增长」是相对声明，正文未报告 TTT 每步梯度更新的绝对推理开销，常数项多大不明。

6. 与 HOST / GEN-1.5 的关系

三条 one-shot 路线在此完整成形：HOST 靠**显式结构**（进度流形对齐 + 自接地级联，零参数更新，50 任务 62%）；GEN-1.5 靠**数据规模涌现**（50 万小时预训练，ICL 59%，1–10 梯度步适应 83%）；RoboTTT 给出第三条——**架构机制**：让模型在推理时继续做元学习过的梯度下降，但只在 fast weights 上。它恰好落在 HOST（零更新）与 GEN-1.5 适应模式（全模型梯度步）之间：参数确实在测试时变，但变的只是被设计成「记忆」的那一小块，且更新规则是预训练里学好的。

按 one-shot 广度比，RoboTTT 被 HOST 明确压制：6/10（60%）只覆盖单任务族的配置变化，HOST 62% 覆盖 50 个不同任务且跨具身（第三人称人类视频、不同场景）。但 RoboTTT 有三块 HOST 与 GEN-1.5 都没有的独特价值：一是**长程**，5 分钟 10 阶段任务的闭环执行与状态消歧，HOST 任务多为桌面短程；二是 **Dagger Distillation**，「失败当上下文、纠正当目标」的在线自我改进机制——HOST 的定位级

只能感知进度倒退后重对齐，没有学习过的纠错行为分布；三是**上下文长度 scaling 律的首次实证**，这条轴与 GEN-1.5 的数据小时数轴正交，两轴原则上可叠加。

对本调研的定位：RoboTTT 提供的是**基础设施层**答案（长上下文怎么做、值不值得做），HOST 提供的是**跨具身翻译层**答案（人类视频怎么变机器人动作）。两者不互斥——把 HOST 式进度对齐与预测级联装在 RoboTTT 式 TTT 主干上，是一条明显的合流方向。

BPP 深度解读：一条演示当 prompt，任务多样性是 in-context 操作的第一驱动力

Behavior Prompting Policy: Demonstrations as Prompts for Manipulation arXiv 2606.30457v1 (2026-06-29) · Stanford (Shuran Song REAL Lab) + UC Berkeley 作者: Austin Patel、Ben Pekarek、Joel Enrique Castro Hernandez、Shuran Song

1. 一句话定位

BPP 把一条与机器人同传感运动空间的演示（观测 + 本体 + 动作序列，称 behavior prompt）直接喂给策略，推理时零参数更新执行新任务；配套交付三件东西：受控数据研究（固定预算下任务多样性远比每任务演示数重要，2000 任务 x 5 demos 是配方）、采集硬件 iPhUMI（UMI 夹爪的 GoPro 换成 iPhone，ARKit 免建图 + 无线传 prompt）、两个新基准（DrawAnything、LIBERO-Gen）。未见画作重建误差比 goal-image 条件低 80.7%、比 ICRT 低 33.3%；LIBERO-Gen 上无任何基础预训练即追平 LoRA 微调 10 万步的 $\pi 0.5$ 。

2. 要解决的问题

教机器人新技能要重训或微调；语言与 goal image 作为任务描述天生残缺——语言说得清「做什么」说不清「怎么做」（低层轨迹、抓取策略、空间细节），goal image 只有终态没有过程，「画一幅任意图」这类任务两者都原理性失灵。VLA 的零样本泛化集中在新环境、新物体，对新低层行为基本无效。

演示条件化的 in-context 路线早已存在（Duan 2017 的 one-shot IL、Vid2Robot、ICRT），但最相关的 ICRT 只在 29 任务、1098 条轨迹、6 种运动原语的规模上验证过。留下的开放问题：prompting 能力如何随任务多样性 scale、又能解锁什么测试时能力？现有基准撑不起这个问题——要么任务多样性不足，要么只测语义/视觉适应而不测动作适应。

3. 方法

3.1 behavior prompt 与架构

prompt 是一条完整演示（环境配置与执行时不同），同时提供 what 与 how。BPP = prompt encoder + action decoder：

- **分块编码**：观测/本体降采样到 1Hz，动作不降采样以保留完整行为序列；每块 {o, q, a} 经 attention pooling 合成单个 chunk embedding，一举完成同时刻模态关联与序列长度压缩；
- **prompt encoder**：transformer decoder，当前观测 token 对 prompt chunk 序列做 cross-attention，按当前所处阶段抽取相关 prompt 信息；学习式位置编码，LIBERO-Gen 版本另加 attention sink token；
- **action decoder**：Diffusion Policy 的 CNN + FiLM 架构，条件是当前观测、抽取的 prompt 信息与扩散步 k，迭代去噪出动作块。

推理效率设计：chunk embedding 每回合只算一次并缓存；prompt 信息抽取每控制步一次，与 K 步去噪解耦——去噪循环不必反复扫整条 prompt。

3.2 训练：不要任何对应标注

每个训练步采一条演示当 prompt，再从**同任务的其它演示**采 receding-horizon 观测与未来动作块当监督目标。两条演示环境配置不同，模型必须端到端学会 prompt 与当前观测之间的时间对应与空间差异——不需要任何显式时空对齐标注。这意味着 BPP 可直接吃现成多任务模仿学习数据集，零额外采集。任务分组粒度决定 prompt 能控制什么：想让 prompt 指定抓取策略，就得把不同抓法分成不同任务组。

3.3 iPhUMI 与基准

iPhUMI 保留 UMI 手持夹爪设计，把 GoPro 换成 iPhone 15 Pro：ARKit 实时 SLAM 免掉建图步骤，App 无线把演示传给工作站即刻条件化策略——同一设备既采训练数据、又在部署时出 prompt。

四个基准：DrawAnything-Sim（2000 个程序生成画图任务 x 5 demos，测 50 条人手采集的未见画作，rollout 时画板朝向与 prompt 不同，逼策略做空间换算）；DrawAnything-Real（ARX 臂 + iPhone 腕相机 + 马克笔，1000 任务 = 200 人采 + 800 脚本生成，6DoF 动作）；LIBERO-Gen Combination（LIBERO Spatial 从 10 扩到 174 任务，两只同款碗与 9 个放置位，held-out 10 个「拆开都见过、合起来没见过」的取放组合）；LIBERO-Gen Chain（LIBERO Goal 从 10 扩到 321 任务，两步链式任务含开抽屉/推盘子/开灶台，held-out 10 个未见链）。

4. 实验结果

画图：未见画作上 BPP 比 Goal-Image 降 80.7% Chamfer 误差、比 ICRT 降 33.3%。Goal-Image 在训练画作上尚可、在未见画作上退化不成形的笔画（真机上其 Chamfer 误差看似中等，实为无意义涂抹恰好盖住目标区域）；ICRT 把整条 rollout 历史留在模型上下文里，被虚假相关拖出分布。真机上 BPP 能从一条 iPhUMI 演示重建未见画作。

LIBERO-Gen：BPP 全面超过 Goal-Image 与 Language 基线，且无预训练即追平微调后的 $\pi 0.5$ 。Chain 上去掉「第二步单独任务」的消融（策略从未见过抽屉已开时怎么放酒瓶这类接续状态）让 BPP 对 Language 的优势从 +10.7% 扩大到 +20.8%——越是训练分布覆盖不到的状态接续，prompt 的逐步引导越值钱。总结律：任务的时序复杂度越高（单步取放 → 两步链式 → 连续画图），更富时序信息的任务描述符（goal image → 语言 → behavior prompt）收益越大。

机制可视化：prompt encoder 注意力在画图任务里连续追踪与当前观测最接近的 prompt 段，在 LIBERO-Gen 里离散跳向下一个「里程碑」（下一个交互物体、放置点、任务切换）。结论：BPP 的适应机制是把 prompt 当**密集子目标序列**用——比从单张终态图反推全过程容易得多。

表征消融（DrawAnything-Sim）：观测必需（锚定检索）；动作有用（填补 1Hz 降采样间隙的时序过渡）；本体无用（光标已在图像中可见）；观测降采样低于 1Hz 显著劣化；attention pooling 优于每模态独立 token。

数据消融（全文核心科学结论）：固定演示预算下，多任务 x 少演示显著优于少任务 x 多演示；训练任务数单调提升未见任务性能，每任务 5 条演示就够；只训 1-3 部件的简单画作适应不了复杂未见画，只训 4-6 部件复杂画效果最好（代价是演示数据量大涨）。

诚实负结果（叠衣案例）：3 个双臂叠衣任务、每任务约 150 条演示加共约 1000 条纠错演示的低多样性设定下，语言条件 96–100% 成功，BPP 分别 76%、100%、60%（fold bottom up 常做成别的任务，右臂抓对了底边、左臂却去叠袖子）。低任务多样性时 prompt 的时长与空间变化不再携带区分信息、反而是噪声，作者怀疑模型过拟合了背景等虚假任务线索。原版 LIBERO 上 BPP 97.48% 与 Language DP 96.23%、 $\pi 0.5$ 97.15% 打平——旧基准已饱和，测不出范式差异，这也是要造 LIBERO-Gen 的原因。

5. 局限

作者自认：很多任务语言或 goal image 就够用且更便宜（愿景是多描述符灵活切换）；需要可观的训练任务多样性；**桌面操作上没有证据能适应全新动作原语**；低多样性 regime 任务条件化弱于语言；实验里 prompt 与执行同环境，跨环境 prompt 未测。

延伸批判：

1. **「新任务」的实质是组合泛化。**LIBERO-Gen 的未见任务是已见原语的新组合/新排序，DrawAnything 的未见画是已见笔画部件（线、圆、Bezier）的新拼接。技能级 one-shot（全新原语）明确不在能力范围内。
2. **实验主体在仿真。**真机只有画图（10 个评测任务）和叠衣（3 任务且以负结果为主），真机操作类任务的 prompt 适应未验证。
3. **prompt 不是自由人类视频。**iPhUMI 演示在 UMI 传感运动空间里，跨具身问题被硬件在采集端消解——免学跨域翻译是优点，但出 prompt 必须手持专用夹爪，普适性低于「拍段视频就行」。
4. $\pi 0.5$ 对照单 seed、100K LoRA 步；DrawAnything 上的消融结论作者自己声明不保证迁移到其它域。

6. 与 HOST / GEN-1.5 的关系

放进调研坐标系，三者代表三种杠杆：HOST 是**结构派**（进度流形对齐 + 自接地级联，50 真机任务 62%，29 秒习得，跨具身人类视频）；GEN-1.5 是**规模派**（50 万小时预训练涌现 ICL 59%，1–10 梯度步适应 83%）；BPP 是**数据配方派**——架构全是标准件（cross-attention prompt encoder 加 Diffusion Policy decoder），真正的贡献是那条受控结论：**驱动 in-context 能力的是任务多样性，不是数据总量。**这条结论 HOST（229 任务 19.3 万条轨迹）和 GEN-1.5（50 万小时）都隐含依赖但都没有单独验证，BPP 用 2000 任务 x 5 demos 的受控设定把它钉死了。

prompt 模态光谱上三者各占一格：HOST 吃第三人称人类视频（跨具身鸿沟最大，靠观测空间预测级联跨越）；BPP 吃 UMI 空间传感运动演示（硬件消解跨具身，换来信息最全的 prompt——自带动作真值）；GEN-1.5 吃机器人自身经验上下文。演示获取成本 BPP 居中：比遥操作便宜，比拍人类视频贵。

被谁超越：真机任务级 one-shot 的广度与难度上被 HOST 全面压制（50 个真机任务、跨具身 62%，对比 BPP 真机只有画图与叠衣负例）；能力上限被 GEN-1.5 的涌现路线展示（BPP 结语自己也展望 foundation-level pretraining 与 behavior prompting 的结合）。

剩余独特价值有四：任务多样性配方直接指导任何 one-shot 系统的采集预算分配，对 HOST 的 Stage 1 同样适用；DrawAnything 是「语言与 goal image 原理性失灵、prompt 不可替代」的最干净论证——

HOST 的 50 任务里没有这类连续指令跟随任务；LIBERO-Gen 把 in-context 操作研究变成可复现、免工业级数据的科学问题；叠衣负结果划出了适用边界——低任务多样性时 prompt 反而不如语言，这对 HOST 类方法是同样成立却未被 HOST 测试过的预警。

RICL 深度解读：给预训练 VLA 事后注入 in-context 学习能力

RICL: Adding In-Context Adaptability to Pre-Trained Vision-Language-Action Models arXiv

2508.02062 · CoRL 2025 (首尔) · 宾夕法尼亚大学 + 不列颠哥伦比亚大学 作者: Kaustubh Sridhar、

Souradeep Dutta、Dinesh Jayaraman、Insup Lee · 代码与权重开源 (ricl-vla.github.io)

1. 一句话定位

RICL (读作 rickle) 用 400 条演示做一次「检索增强式后训练」, 给本不具备 in-context learning (ICL) 能力的 π_0 -FAST-DROID 事后装上这个能力: 此后每个新任务只需采 10-20 条演示放进检索库, 零参数更新, 完整任务成功率从基线的 2.5% 升到 31.25%, 追平「基线+微调」的 31.67%; 若再在这 20 条演示上做检索增强微调, 达到 61.67%, 几乎是普通微调的两倍。这是第一个开源 (代码+权重齐全) 的通用操作 ICL 接口。

2. 要解决的问题

LLM 好用的一半原因是 ICL+RAG: 例子放进上下文, 不动参数就学会新任务。VLA 没有这个接口——模仿学习目标 + 相对窄的演示分布, 训不出 ICL 涌现。于是今天改进预训练 VLA 的唯一路径是收数据再微调参数, 终端用户玩不转。

已有的机器人 ICL 尝试两边都有硬伤:

- 用现成 LLM/VLM 做 ICL (keypoint 表征、代码策略、in-context value function): 被迫开环或近开环执行, 纯语言通道还丢视觉细节, 闭环适应能力差;
- 从零训练自带 ICL 的 agent (MTT、ICRT、REGENT): 都不建立在通用机器人 VLA 之上, 覆盖面限于游戏、仿真或单一平台设定。

RICL 的定位是拼接两边优点: 拿一个已能真机部署的 SOTA VLA (π_0 -FAST-DROID = SigLIP 视觉编码器 + Gemma 3B + FAST 动作 tokenizer, 经 DROID 数据集微调), 事后教会它使用上下文。

3. 方法

3.1 上下文组织与检索

查询 = 当前时刻三视角图像 (top/side/wrist) + 语言指令 + 本体状态 (7 关节角 + 夹爪位置)。上下文 = 检索到的 4 组近邻, 每组含三视角图像、状态和动作块, 按相似度从近到远排在查询左侧。检索键刻意做到极简: 只取 top 相机图像的 DINOv2 嵌入, ℓ_2 距离 + FAISS 索引, 单次检索低于 1 毫秒。

3.2 动作插值层: 检索先验的硬编码

最终动作不是 LLM 输出直接用, 而是与最近邻动作 a' 做距离加权插值 (对 FAST tokenizer 的每个动作 token 独立进行): 输出 = $e^{(-\lambda d)} \cdot \text{one-hot}(a') + (1 - e^{(-\lambda d)}) \cdot \text{softmax}(\text{LLM 输出})$, $\lambda=10$, d 为查询与

最近邻 top 图像的 DINO 嵌入距离。d 趋近 0 时输出坍塌为复制最近邻（1-NN 行为），d 大时交还 LLM 自主预测。该层继承自同组前作 REGENT（ICLR 2025），是「查询与演示够像就直接抄」的显式归纳偏置。

3.3 Priming 训练配方

- 数据：Franka DROID 平台自采 20 个 pick-place 任务 × 每任务 20 条 = 400 条演示，15 Hz 采集；
- 序列构造：每条演示的每个状态当查询，从同任务其余 19 条里检索 4 组近邻拼训练序列——训练形态与部署形态完全一致；
- 只全量微调 Gemma LLM，冻结 SigLIP 图像编码器；损失只对查询的动作块算 cross-entropy（REGENT 连检索到的动作一起算，RICL 砍掉）；
- 超参：3 epochs，峰值学习率 $2.5e-5$ 余弦衰减，batch 16，2 张 A100；动作块 15 步（实测优于 10 步），执行时先取前 3 步、检测到夹爪动作后改取 8 步。

3.4 两档用法

档位一（纯 ICL）：新任务采 20 条演示进检索库，不做任何训练。档位二（RICL-finetuned）：在同 20 条上按 RICL 同款检索增强目标再微调 1000 步——finetune like you pretrain。推理开销：token 数变 4 倍，实际 rollout 时长仅为 $\pi 0$ -FAST 的约 1.33 倍。

4. 实验结果

评测设定：8 个任务（pokeball、idliplate、squeegee、sink-idliplate、sink-squeegee、toaster、door、bagel），覆盖全新物体、全新动作、新场景（厨房水槽区，相机重摆无标定）与训练分布长尾；物体/动作已核查不在 DROID 和 priming 数据中；每任务 10 次 rollout，初始位姿全桌面随机。

方法	目标任务参数更新	完整成功率	检查点完成率
$\pi 0$ -FAST-DROID	无	2.5%	至多 21.25%
RICL- $\pi 0$ -FAST-DROID	无	31.25%	至多 83.75%
$\pi 0$ -FAST-DROID + 微调	有	31.67%	—
RICL + 检索增强微调	有	61.67%	—

四个可以单独记住的结论：

1. 纯 ICL（31.25%）追平基线微调（31.67%）：零梯度更新打平了动参数的对手。Retrieve-and-play（1-NN）与从零训练的 Diffusion Policy 在最简单的三个任务上就已明显落后，被提前淘汰出后续对比。
2. 检索增强微调几乎两倍于普通微调（61.67% vs 31.67%）。作者的解释：RAG 化的模型不必用容量背数据，专注学「在检索到的状态-动作间插值」，与 RAG LLM 的参数效率结论一致。

3. 演示数量消融 (idlplate): 5 条时 RICL 退化成基线行为 (同样去抓干扰物苹果), 10 条起效, 随演示数增加逼近微调版; RICL-finetuned 在每个演示数量档位都显著高于普通微调。
4. 能力无损: 把检索库换成随机 priming 演示, 在 3 个基线本来会做的任务上 RICL 版本 80% 成功率与原版持平——注入 ICL 没有毁掉零样本能力。

另有一个计划外现象: idlplate 的 20 条演示全是「夹爪伸进盘子凹槽拖动」, RICL 却自己走到盘子左侧、闭合夹爪把盘子推过去 (toaster 任务同样观察到)。作者称之为 elicited latent actions: 上下文触发了基座潜藏的操作知识, 而非复制演示。

5. 局限

作者自认四条: (1) 教不会离基座能力太远的任务, 评测因此局限在 pick-place 变体, 网球正手这类大幅新动作失败; (2) 每个新任务仍要 10-20 条遥操作演示, 跨场景不可扩展, 作者点名人类视频 (R+X 路线) 是出路; (3) 相机视角/场景大变时检索失效 (priming 阶段未见过此类扰动); (4) 性能仍有空间, 寄望于扩大 priming 任务数与参数量。

延伸批判:

1. 评测样本量小: 8 任务 $\times$ 10 rollouts, 无置信区间, 31.25% 与 31.67% 的「追平」在这个样本量下统计上很脆。
2. 检索键太弱: 只用单视角单帧的 DINO 嵌入, 语言指令不参与检索, 场景相似但任务不同时必然串台——这是最容易被打穿的工程点。
3. priming 分布只有 20 个 pick-place 任务, 注入的与其说是通用 ICL, 不如说是「pick-place 域内的插值能力」, 与 LLM 跨域 ICL 有本质距离; 作者用网球例子自己承认了这一点。
4. 每任务 20 条遥操作的成本没有消失, 只是从「微调机时」换成「采数据人时」; 对比 HOST 的 1 段人类视频, 数据接口贵 20 倍且必须占用真机。

6. 与 HOST/GEN-1.5 的关系

三条路线获得 ICL 的方式不同: GEN-1.5 用 50 万小时数据把 ICL 「养」出来 (涌现, one-shot 59%); HOST 用结构归纳偏置把 ICL 「设计」出来 (进度流形对齐 + 自接地级联, 1 段人类视频、29 秒、50 任务 62%); RICL 用后训练把 ICL 「注入」现成 VLA (400 条 priming 演示, 每任务 10-20 条, ICL-only 31.25%)。

RICL 与 HOST 最本质的差别在演示接口: RICL 的上下文吃同具身遥操作演示 (自带动作标签), 检索-插值机制依赖「上下文里有可直接参照的动作」; HOST 吃跨具身人类视频 (无动作标签), 靠观测预测级联完成跨域翻译。RICL 绕开了跨具身鸿沟, 代价是数据贵; HOST 直面它, 代价是需要专门的对齐机制。RICL 未被 HOST 评测 (平台、任务、演示模态都不同), 二者不构成直接胜负; 但按「降低新技能习得成本」这条主轴, HOST 的接口成本 (1 段视频、29 秒、零遥操作) 明显低于 RICL (20 条遥操作演示)。

RICL 保留的独特价值有三点: (1) 生态位——唯一开源、可直接架在 $\pi 0$ 系 VLA 上的 ICL 接口, 工程复用性最强; (2) 「检索增强微调约 2 倍于普通微调」的发现独立于 ICL 本身, 对所有做少样本 VLA 适配的团队都可用; (3) 能力保持性验证 (随机上下文不掉点) 为「后训练注入 ICL 不伤基座」给出第一份证据。

elicited latent actions 现象与 HOST 的「先预测自己视角的未来观测」殊途同归：有效的 ICL 不是复制上下文，而是用上下文激活模型内部已有的知识。两条线显然的合流点是把 RICL 的检索式后训练配方接上人类视频演示接口——作者在 limitations 里自己指了这个方向。

Vid2Robot 深度解读：端到端视频条件策略的 Google 规模实践

Vid2Robot: End-to-end Video-conditioned Policy Learning with Cross-Attention Transformers arXiv 2403.12943 · RSS 2024 · Google DeepMind Robotics + CMU + 多伦多大学 作者: Vidhi Jain (Google 实习成果)、Maria Attarian 等; 末位作者 Debidatta Dwibedi 是 TCC 损失的原作者 · vid2robot.github.io

1. 一句话定位

Vid2Robot 是 2024 年初 Google DeepMind 交出的端到端视频条件策略：看一段人类演示视频（语言不输入策略），直接在真机上输出动作复现同一任务。9 个任务上人类视频提示成功率 52.8%，比 BC-Z 基线（30.6%）高 22 个点；并首次系统展示「跨物体动作迁移」这一涌现能力——提示视频里的动作可以施加到场景中完全不同的物体上（34.2% vs BC-Z 的 17.5%）。

2. 要解决的问题

语言条件策略（RT-1/RT-2/RT-X）的任务接口有两个结构缺陷：一是多义性，open drawer / open jar / open cabinet 共享动词但运动控制完全不同，语言嵌入分不清「何时该泛化、何时不该」；二是「怎么做」缺失，目标图像条件下 hold the flag 与 wave the flag 的终态图一样。视频同时携带 what 和 how，是更稠密的任务规范。

但 2024 年初的视频条件策略要么假设演示与执行在同一工作区、变化有限，要么性能明显落后语言条件策略（BC-Z 口径）。作者归纳三大障碍：视频维度高（算力/显存压力）、人-机配对数据稀缺、人类演示在速度和风格上差异大。

3. 方法

3.1 三层配对数据：90% 是免费的

训练需要「提示视频-机器人轨迹」对。Vid2Robot 按成本递增拼三种来源，共约 38 万对：

- Robot-Robot（占混合比 90%）：把已有 RT-1/RT-2 机器人数据按语言指令配对——同指令、不同场景的两条轨迹互为提示。12 万条轨迹 × 每条采 3 个提示 = 36 万对，零新增采集成本；
- Hindsight Human-Robot（5%）：按机器人数据集的既有指令，让 1-5 名人类在机器人视角相机前演示，5 千条人类视频得 1.5 万对，不需要新遥操作；
- Co-located Human-Robot（5%）：人和机器人在同一工作区（客厅、会议室、厨房、工具台等）各演示一遍，金标准但最费人力，仅 5 千对。

语言指令只用于配对和辅助损失，不进策略输入——这是它与语言条件策略的分界线。

3.2 架构：四模块全 cross-attention

策略 $\pi(a_t | S_t, V)$ 由四个模块组成：

- 1. 提示视频编码器：逐帧 ViT-B/16 + Perceiver Resampler (2 层、64 个 latent token)；
- 2. 机器人状态编码器：共享同一个 ViT + 独立 Resampler，输入当前帧加近 7 帧 (k=8)；
- 3. 状态-提示编码器：4 层 cross-attention，状态 token 当 query、提示 token 当 key/value，输出 prompt-aware state tokens——按视频内容决定关注状态里的哪个物体；
- 4. 动作解码器：4 层 cross-attention，可学习的动作位置嵌入当 query (ACT 式一次前向，不做 RT 系的自回归多次前向)，输出 11 维动作 (模式 + 夹爪位姿与开合 + 底盘) × 每维 256 bins，argmax 执行，预测视野 4 步。

Cross-attention 是显存上的胜负手：16 帧提示 + 8 帧状态在 ViT-B/16 下共 4704 个 token，全自注意力矩阵约 2200 万项；两个 64-latent Resampler 把它压到约 30 万项，缩减 70 倍，配对视频训练才跑得动。

3.3 一主三辅四损失

总损失是四项等权平均：

- 1. 动作 cross-entropy (主损失，端到端行为克隆)；
- 2. TCC 时间循环一致性：对提示/机器人视频的逐帧嵌入 (经 2 层 MLP alignment pooling) 做软最近邻 cycle-back，强制两段视频的帧级进度互相对应，逼图像编码器对具身、光照、背景、视角保持不变、只编码任务进度；
- 3. 视频-视频对比 (VVCL)：attention pooling 得到整段视频嵌入，SigLIP 损失拉近同任务的提示-机器人视频对、推远批内其他对；
- 4. 视频-文本对比 (VTCL)：与冻结文本编码器的指令嵌入做 SigLIP，即 BC-Z 式语言辅助监督。

实现：Jax，20 万步，batch 2048，AdamW 峰值 8e-5 余弦衰减至 1e-6。平台：Google Robot 移动机械臂 (7 自由度、双指软夹爪、自我中心相机)，客户端-服务器部署，推理 5-7 Hz。

4. 实验结果

评测协议先记住：人工评估员按 reach→grasp→release→terminate 四个检查点判定，全过程正确才算成功——规则式终态判定会把「抓取失败但瓶子恰好倒成目标姿态」误判为成功。主表 288 次真机 rollout (9 任务 × 8 次 × 4 行)。

提示来源	BC-Z	Vid2Robot
机器人视频	52.6%	54.9%
人类视频	30.6%	52.8%

- 关键读法：机器人提示下两者打平 (训练对 90% 是机器人-机器人，都吃饱了)；换成人类提示后 BC-Z 掉 22 个点、Vid2Robot 只掉 2 个点——TCC 加对比损失学出的具身不变表征在这里兑现。
- 扩大样本的统计版 (限 2 个任务、共 314 次 rollout)：Vid2Robot 43.4±7.2% vs BC-Z 30.2±7.1%，13 个点的差距在更大样本下保持。

- 分阶段成功率：够到正确物体 78%（高出基线 8 个点）；抓取 65% vs 45%——差距最大的环节，也是整个 rollout 成败的关键；正确释放与自主终止约 57%（BC-Z 没有终止动作，只能跑满固定步数）。
- 跨物体动作迁移（240 次 rollout）：用「把可乐罐立起来」等 5 个提示对绿罐、薯片袋、订书机、毛绒玩具等 6 种无关物体执行同一动作，总体 34.2% vs 17.5%；place-into 类 54.2% vs 29.2%，knock-over 29.2% vs 0%，从抽屉取放到台面 25% vs 0%。训练配对里从未出现「提示物体 ≠ 场景物体」的样本，纯属涌现；模型还表现出隐式语用推理——场景里有绿罐时优先选最接近可乐罐的它下手。
- 无提示消融（120 次 rollout）：空白视频提示下 Vid2Robot 23%、BC-Z 5%，远低于有提示的约 55%/52.6%——策略确实在读视频，不是拿场景先验猜任务。
- 辅助损失消融（162 次 rollout）：全损失约 61%，只留动作损失约 45%；单去掉视频-文本对比仅降 1-2 个点。涨点主要来自 TCC 对齐与视频-视频对比；BC-Z 引以为核心的语言辅助监督几乎不贡献。
- 免费的长程能力：串接多段提示视频（开抽屉→放入物体→关抽屉），terminate 信号触发切换下一段，不需要任何长程训练数据。

5. 局限

作者自认三类：自遮挡（IK 解可能把机械臂横在相机前）、抓取失败（透明/可变形物体、抽屉把手等易碰撞区域）、干扰物误识别；单目 RGB 隐式学深度，遮挡时失效，需要多模态传感融合；训练视频全部是精心采集的 5-20 秒短指令视频，长程演示与真正 in-the-wild 网络视频需要新的配对策略。

延伸批判：

1. 评测任务全部来自训练指令集（视频未见、任务本身见过），真正 unseen task 的能力没有测——与 HOST/RICL 测全新物体+全新动作的口径不可比；跨物体迁移的 34.2% 才是它最接近 unseen 设定的数字。
2. 绝对天花板低：最好设定 54.9%，跨物体 34.2%，离可部署有代差。
3. 配对完全依赖语言标注，可扩展性受限于「带指令标签的机器人数据」，与它自己批评语言接口的立场构成微妙张力（XSkill 等免配对路线针对的正是这点）。
4. 视频是被动条件：16 帧均匀采样一次性喂进 Resampler，推理时没有执行进度与视频进度的显式对齐，TCC 只做训练期正则——这是后来被 HOST 点名的结构性死穴。

6. 与 HOST/GEN-1.5 的关系

Vid2Robot 在本调研坐标系里是「被超越的直接前辈」：HOST 论文把它当 OSVI 基线复现（条件机制移植到 HOST 同款主干上以排除主干差异），在 50 个未见任务上只有约 19%，被 HOST 的 62% 拉开 43 个点。

失败根源可以用它自己的设计解释：整段视频压成 64 个 token 当被动上下文，动作监督锚定在机器人轨迹的固定时间步——HOST 诊断的「时间错位让模型学会忽略视频」三宗罪，在 Vid2Robot 架构上全部成

立。修复路径有清晰的师承：Vid2Robot 的末位作者 Dwibedi 正是 TCC 原作者，Vid2Robot 把 TCC 用作辅助正则（只塑造表征）；HOST 把同一个 TCC 加上 Smooth DTW 升级成显式进度流形，推理时用它主动选择预测目标。同一个工具从「训练期损失」变成「推理期机制」，one-shot 成功率从 19% 走到 62%——这是本调研里最干净的一组对照。

对 GEN-1.5 路线，Vid2Robot 是数据曲线上的早期点位：约 10 万条机器人轨迹 + 约 1 万条人类视频，用显式配对监督练出视频跟随能力；GEN-1.5 用 50 万小时数据把同类能力做成免显式配对的涌现 ICL（59%）。Vid2Robot 留下两笔至今独特的资产：三层配对数据构造法（90% 免费的 Robot-Robot 配对 + 少量 hindsight 人类演示）是跨具身训练的省钱配方原型——HOST 的两阶段训练（193k 同具身轨迹 + 5.8k 人类视频配对）本质上是同一思想的放大版；提示视频串接做长程任务的组合技，至今仍是视频条件策略的零成本红利。跨物体动作迁移（动词与宾语解耦）则预演了 HOST 鲁棒性实验中「未见物体替换只掉 4 个点」的能力来源。

外围论文速览：one-shot 技能习得调研的五个坐标

配合 01_HOST_zh.md (HOST, arXiv 2607.20033) 与 02_GEN_series_zh.md (GEN-0/1/1.5) 阅读。

本合集的五篇论文各占调研版图的一个坐标。ViVLA 是 HOST 一作团队 (Guangyan Chen / Yufeng Yue) 的直系前作，代表「隐动作端到端」的 one-shot 视频模仿路线，与 HOST 的「显式对齐 + 级联」构成方法演化链。 $\pi 0.5$ 与 Wall-OSS 是 HOST 评测的两类基线：前者是语言条件零样本 IL 的上限 ($\leq 17\%$)，后者是最强 SFT 微调基线 (56%)，且与 HOST 同属 X SQUARE ROBOT。EgoScale 代表与 HOST 结构路线对照的「人类数据规模化」路线，用 2 万小时第一人称数据给出 scaling law 与 one-shot 适配能力，呼应 GEN-1.5 的涌现叙事。Fast-WAM 是 HOST-base 引用的世界动作模型架构来源，其「视频建模的收益在训练时而非测试时」的受控结论，是 HOST 主干选型 (双专家 MoT + Wan2.2 + flow matching) 的实证支撑。

1. ViVLA (See Once, Then Act: Vision–Language–Action Model with Task Learning from One–Shot Video Demonstrations)

arXiv 2512.07582 · 北京理工大学 + LimX Dynamics · arXiv preprint (2025–12)

一句话定位：测试时给一段专家示范视频 (含人类视频)、零参数更新学会新操作任务的 VLA；一作 Guangyan Chen 与通讯 Yufeng Yue 即 HOST 团队，可视为 HOST 的直系前作。

核心方法：基于 Qwen2.5–VL 联合处理示范视频与机器人观测，同时预测示范中的动作序列和机器人后续动作。跨具身动作空间靠 latent action tokenizer 统一：仅从视觉学隐动作，专家视频与机器人轨迹联合训练，加 action-centric cycle consistency 正则与局部–全局判别器防止解码器把隐动作信息泄漏回编码器。动作生成用并行解码替代自回归 (START token 指定并行数量，单次前向出全部动作 token)，避免 shortcut learning 并压低推理延迟；temporal–spatial masking 削减视频 token 冗余。数据侧自建 expert–agent 配对管线：7,421 条人类视频 (100+ 任务) 经 3D Gaussian Splatting 渲染成机器人执行同任务的 4D 场景，得到 Human2Robot 数据集 89,736 对，训练总量 892,911 对样本。

关键结果：unseen LIBERO 任务成功率较基线提升超 30%，跨具身示范视频条件下保持 35% 以上增益，真机上从人类视频学 unseen 任务提升超 38%。

在本调研中的角色：HOST 的方法学前身。ViVLA 把跨具身翻译埋在隐动作空间、把视频–执行时间对应交给 transformer 隐式学习；HOST 恰好把这两处换成显式模块 (SDTW+TCC 进度流形对齐、定位–未来观测–动作级联)。对照读能看清 HOST 每个设计选择的动机来源。

2. $\pi 0.5$ ($\pi 0.5$: a Vision–Language–Action Model with Open–World Generalization)

arXiv 2504.16054 · Physical Intelligence · arXiv preprint (2025–04)

一句话定位：用异构数据 co-training 做开放世界泛化的旗舰 VLA，首个在完全未见过的真实家庭里完成 10–15 分钟长程操作（清洁厨房/卧室）的端到端系统。

核心方法：同一模型分层推理——先以文本预测语义子任务（如「拿起砧板」），再条件于子任务输出低层动作块。预训练混合移动机器人真实家庭数据（约 400 小时）、非移动机器人多环境数据、实验室跨具身数据（含 OXE）、高层子任务标注与网页多模态数据，首阶段 97.6% 的样本不来自移动操作本体；离散 token 预训练 280k 步后，后训练 80k 步加入 flow matching action expert，并用「语言遥操作」采集的口头指令示范训练高层子任务选择。控制侧 50 Hz 输出 18–19 维动作（双 6-DoF 臂 + 夹爪 + 全向底盘 + 躯干升降）。

关键结果：在三个训练集外真实家庭的厨房/卧室清洁任务上一致成功，mock 环境评测与真实家庭表现吻合；泛化能力随训练环境数量持续 scaling。

在本调研中的角色：HOST 评测的零样本 IL 基线。在与 HOST 相同的 193k 轨迹上继续训练后， $\pi 0.5$ 面对 50 个新任务仅 $\leq 17\%$ 成功率（HOST 62%）——语言指令给得出任务语义，给不出新技能的运动细节，这 45 个百分点的差距是「视频演示携带执行信息」价值的直接量化。它同时也是 Fast-WAM 的主要参照（RoboTwin 79.8% vs Fast-WAM 91.8%），在本调研中是贯穿多篇论文的公共基线。

3. Wall-OSS (WALL-OSS: Igniting VLMs toward the Embodied Space)

arXiv 2509.11766 · X SQUARE ROBOT（自变量机器人）· arXiv preprint（2025-09），代码开源（wall-x）

一句话定位：X SQUARE ROBOT 的开源具身基础模型，针对 VLM 到 VLA 的三重 gap 给出紧耦合 MoE + 统一跨层级 CoT 的配方；在 HOST 评测中既是零样本基线也是最强微调基线，与 HOST 同公司。

核心方法：先诊断 VLM 迁移到动作空间的三个 gap——模态与数据规模（动作缺大规模对齐语料）、预训练分布（第一人称/鱼眼/自遮挡视角 vs 网络图像）、训练目标（离散 next-token vs 连续高频轨迹）。对应解法：紧耦合 MoE 在不同训练阶段激活不同专家，Inspiration 阶段以 FAST 离散 token 向 VLM 输出空间注入粗动作先验并补具身 VQA，Integration 阶段用 flow matching 训高频连续控制再联合优化；Uni-CoT 把指令推理、子目标分解、细粒度动作合成放进单一可微框架，推理时可自适应决定是否展开 CoT、可边推理边执行。数据超 10,000 小时：自采多平台真机数据 + 24 个开源动作数据集（AgiBot World、DROID、BC-Z 等）+ 通用/具身 VQA。基座 Qwen2.5-VL-3B。

关键结果：具身 VQA（场景描述/目标定位/动作规划）显著超原基座；六个操作任务（其中 set-table、tidy-bedroom、place-by-color 三个 unseen）超 $\pi 0$ 等基线，长程任务与指令跟随增益最大。

在本调研中的角色：HOST 的双重对照。零样本口径 $\leq 17\%$ ；加 50 条遥操作演示 + LoRA 微调后 56%，是 HOST 论文全部微调基线中最强的，但仍低于 HOST 用 1 段人类视频、零参数更新的 62%，且 SFT 后旧技能仅保留 43%。同公司出品让这个对照排除了「挑弱基线」的质疑——HOST 打赢的是自家最强 SFT 配方。

4. EgoScale (EgoScale: Scaling Dexterous Manipulation with Diverse Egocentric Human Data)

一句话定位：用 20,854 小时动作标注的第一人称人类视频（较此前工作大 20 倍以上）预训练灵巧手 VLA，给出人类数据的 log-linear scaling law，one-shot 任务适配作为副产品出现。

核心方法：把人类视频转成显式动作监督——相对腕部 SE(3) 运动（消除相机全局运动依赖）+ retarget 到高自由度手关节，而非学任务无关的视觉特征。三阶段流程：2 万小时人类数据预训练 flow-based VLA；50 小时人类 + 4 小时机器人的对齐 play 数据 mid-training（匹配桌面场景与视角，把表征接地到机器人传感与控制）；下游任务 post-training。

关键结果：验证损失随数据量呈 log-linear: $L = 0.024 - 0.003 \cdot \ln(D)$ ，拟合 $R^2 = 0.9983$ ，且直接预测真机表现——1k 到 20k 小时，五任务平均完成度从 0.30 升到 0.71，无饱和迹象。22-DoF 灵巧手五个任务（衬衫卷叠/卡片分拣/夹钳取物/拧瓶盖/注射器移液）上比无预训练基线平均成功率提升 54%；单条机器人示范适配 unseen 衬衫折叠任务达 88% 平均成功；迁移到 Unitree G1 三指手仍有 30% 以上绝对提升。

在本调研中的角色：与 HOST 构成「数据 vs 结构」的路线对照。EgoScale 与 GEN-1.5 同属规模化路线——GEN-1.5 用 50 万小时遥操作数据让 one-shot 涌现，EgoScale 用 2 万小时人类视频给出可外推的定量 scaling law；HOST 则证明 193k 轨迹 + 6k 人类视频靠归纳偏置也能做到 62%。另需辨析：EgoScale 的 one-shot 是「单示范 post-train」（更新参数），HOST 是「in-context 零更新」，两种 one-shot 语义不同，这是本调研需要区分的核心概念。

5. Fast-WAM (Fast-WAM: Do World Action Models Need Test-time Future Imagination?)

一句话定位：用受控消融回答世界动作模型 (WAM) 的根本问题——收益来自训练时的视频建模目标，还是测试时的未来想象？答案是前者：保留视频协同训练、砍掉测试时未来生成，性能基本不掉、延迟降 4 倍。

核心方法：Mixture-of-Transformers 架构——Wan2.2-5B 视频 DiT + 1B action expert (hidden 1024) 共享注意力，总参数 6B，双分支同用 flow matching (10 步去噪)。训练时联合优化视频预测与动作目标；推理时视频 DiT 仅对观测上下文做单次前向、充当 world encoder，只去噪动作分支。构造三个对照变体隔离变量：Fast-WAM-Joint（未来视频与动作联合去噪）、Fast-WAM-IDM（先生成未来视频再条件出动作）、无视频协同训练版。

关键结果：RoboTwin 2.0 上 91.8%（不用具身预训练），超 $\pi 0.5$ (79.8%) 与带预训练的 Motus (87.8%)，持平带预训练的 LingBot-VA (92.2%)。变体对照：Joint 90.6%、IDM 91.3%、无视频协同训练 83.8%——测试时想象最多贡献 1.2 个点，视频协同训练贡献 8 个点。LIBERO 平均 97.6%（去掉协同训练跌至 93.5%）。真机延迟 190 ms，比 imagine-then-execute 类 WAM 快 4 倍以上。

在本调研中的角色：HOST 论文中 HOST-base 基线引用的架构来源；HOST 主干的双专家 MoT、视频专家从 Wan2.2 初始化、共享注意力、flow matching 设计与 Fast-WAM 同构。Fast-WAM 的结论也为 HOST 的选型提供实证：HOST 的「未来观测预测」级不做迭代视频去噪的完整想象，而是级联内单次自回归 flow matching 的中间表征——视频先验的承重在训练目标而非测试时生成，与 Fast-WAM 的发现互为印证。

EgoWAM 深度解读：换掉世界预测目标，人类数据才不「漏毒」进动作头

EgoWAM: World Action Models Beyond Pixels with In-the-Wild Egocentric Human Data arXiv

2607.08436 (2026-07) · Georgia Tech RL2 Lab (Danfei Xu 组) 作者: Baoyu Li*, Xinchun Yin*, Mengying Lin, Yixin Zhang, Danfei Xu

1. 一句话定位

EgoWAM 是一项受控对比研究：固定 HPT 主干（256 维/16 层）、flow-matching 动作头与数据配比，只换世界模型头的预测目标——Pixel VAE / DINO 特征 / 相机稳定化 3D motion flow——回答「WAM 人机共训中，什么世界表征最利于野生第一人称人类数据向机器人迁移」。在三个真实双臂任务、共 1800 次 rollout 上：自然人类数据经常把 BC 共训拖到 robot-only 之下，WAM 共训却稳定获益；像素目标迁移最弱，DINO 把 OOD 物体/场景泛化最高提到 4 倍，3D flow 把 in-domain 性能提高 20-30%，且对人类数据是否与机器人对齐完全免疫——cup-on-saucer 上无论演示者自然发挥还是刻意模仿机器人都恒 85%，而 Pixel/DINO 要靠人工对齐才能从 35%/50% 升到 65%/70%。结论浓缩成世界表征三准则：外观抽象（D1）、跨具身一致（D2）、自我运动分解（D3）。

2. 要解决的问题

行为克隆共训是吃人类数据的主流路线：把手演示重定向进机器人动作空间一起模仿。要害在于共享动作解码器是人类数据进入策略的唯一通道，可迁移内容（物体、场景、语义）与不可迁移执行（形态、头动、行为风格）被迫纠缠——论文称之为 action-level 共训的 bitter lesson。EgoScale 等已证明该范式可 scale，但前提是采集时就把视角、速度、风格对齐到机器人；一旦换自然数据，不可执行的类人动作（人横握杯、夹爪只能正面夹）漏进动作头造成负迁移——实验中三任务里只有 bag-grocery 的拾放动作天然对齐、BC 共训才有正收益。WAM 加一个预测未来场景的辅助头，开出第二条监督通道：动力学基于观测而非动作，对形态差异钝感。但「该预测什么」此前无人受控研究——多数 WAM 沿用视频 VAE 像素隐变量，光度重构把运动与外观纠缠，论文定位其为像素级 WAM 共训失效的主因。

3. 方法

先把动作通道做满，保证 BC 是强基线而非稻草人：人/机动作统一到 14 维末端空间（双臂 6-DoF SE(3)+夹爪）；人手位姿用头部位姿变换回瞬时设备系，扣掉头部自运动；速度错位用差异化窗口（人 1s、机 1.5s，均重采样 100 步）；分位数归一化抗跟踪外点。

WAM 第二通道：主干上 64 个动作 token 与 16 个未来 token 并行查询，联合损失 $L_{\text{action}} + \lambda \cdot L_{\text{world}}$ ($\lambda=1$)。三种可插拔目标：(a) Pixel——冻结 Wan VAE 隐变量 + DiT 头（从零 6 层 384 维；Pixel-PT 用预训练 VACE-1.3B），三准则全违背的重构基线；(b) DINO——DINOv2-B 补丁特征 + RAE 宽 DDT 头，满足 D1/D2，但特征锚定图像网格，D3 只部分缓解；(c) 3D flow——Track4World 稠密 3D

点跟踪 + Aria VIO 位姿把未来点变换回当前相机系，静止背景流场归零， $28 \times 40 = 1120$ 锚点回归 100 步位移场（机器人 2mm、人类 10mm 阈值去噪），构造性满足全部三准则。

推理只留动作头：沿用 Fast-WAM 的结论（WAM 收益来自训练时表征塑造而非测试时想象），部署时丢弃世界头，单张 4090 上 30Hz，四个变体部署开销一致，rollout 差异全部归因于训练期表征。

4. 实验结果

平台：双 ARX5 + 头戴 Aria + 双腕 D405。三任务各 300–360 条机器人演示（2.5–3h）；人类数据两档：in-domain 各 2h（1:1）、EgoVerse-A 野生 20.5h/21h/7h（标称约 10:1）。每方法 ID/OOD 各 20 rollout（OOD=10 未见物体+10 新场景），报告 finite-sample 95% 置信区间。

主结果（Fig 3）：WAM 全面压过 BC。Pixel 最弱——bag-grocery 上凭空抓取、fold-clothes 第三折做不完；DINO OOD 最强（最高 4 倍）；3D flow ID 最强（+20–30%，全工作台任意杯位精准放置）。

UMAP（Fig 4）显示 BC 下人/机嵌入割裂，WAM 下融为一体。

四组关键消融：

- **对齐消融（A.1, cup-on-saucer）**：演示者刻意模仿机器人后 BC 才升到 robot-only 之上；Pixel 35%→65%、DINO 50%→70%，量化了违背 D3 的代价；3D flow 两种采集方式下都是 85%——别人靠人工对齐挣回的分，它构造性免费拿到。
- **错位消融（Q3, bag-grocery）**：故意采夹爪无法复刻的怪异抓取，BC 崩到 robot-only 之下，3D flow 仍高于 robot-only。
- **模态消融（A.2, cup-on-saucer）**：人类批次只给世界监督（无动作标签）已胜过只给动作标签，OOD 场景 10% vs 0%；联合最优——动作标签反向充当上下文，把流场预测损失从人流 0.23/机流 0.20 降到 0.22/0.19（表 1）。
- **仿真复现（RoboTwin, 表 4）**：pick-diverse-bottles 上 DINO 单机 4%→跨机 28%、3D flow 0→16%、BC 2→6%，而同动作空间、无世界头的 ACT-EE/DP-EE 只有 2%/5%——增益归于世界头而非统一动作空间；stack-bowls-three 因资产材质漂移意外变成外观偏移测试，只有 DINO（8%）与 flow（16%）存活，BC/Pixel 归零；hanging-mug 毫米级插入全员 ≤1%。
- **Pixel-PT 失效（A.3）**：预训练视频先验幻想袋子已打开，策略直接跳过开袋；从零训练的 Pixel 画面糊但时序忠实，反而更可靠。

5. 局限

作者自认三条：增益停留在 context 级（换物体/场景），学不到新运动原语（T 恤模型折不了短裤）；每任务单独训一个策略，多任务未验证；最优世界表征仍是开放问题。

延伸批判：

1. **三准则只有两条被实验支撑。**D3 有 A.1 直接量化，D1 有 RoboTwin stack 外观漂移的意外验证，但 D2「跨具身一致」通篇只有构造性论证和 Fig 4 的定性 UMAP，没有任何把 D2 与 D1/D3 解耦的实验。理论框架的三分之一是信念而非证据。

2. **统计功效薄**。3 个任务、每格 20 rollout, OOD 再劈成 10+10;「最高 4 倍」这类比值口径落在 10 次试验的分母上 (10%→40% 不过是 1 次对 4 次成功), 区间极宽。且主实验只有柱状图没有数值表, 4 倍与 20–30% 都要读图。置信区间做得比同行认真, 但改不了样本量。
3. **「in-the-wild」实为「Aria 采的 wild」**。3D flow 依赖 Aria VIO 位姿做相机稳定化, 动作标签依赖 Aria MPS 手部姿态——表现最好的表征恰是对专用眼镜元数据依赖最重的。无 VIO 的 YouTube 级真野生视频能否支撑该管线未验证。
4. **scaling 声明超出证据**。「unlock human–data scale」只有 2h 与约 20h 两个数据点, 没有 EgoScale 式多点曲线; bag–grocery 的 EgoVerse 仅 7h (对 2.5h 机器人数据不足 3:1), 10:1 是标称而非逐任务事实。
5. **受控实验没控头容量**。Pixel–PT 头 1.3B/30 层, flow 头 4 层 256 维, 「只换表征」实际同时换了头架构与容量; 且 DINO/flow 的互补结论在仿真里翻转——stack (外观偏移) 上 flow 16% 反超 DINO 8%, 「OOD 用 DINO」并不稳定。

6. 与 HOST / GEN-1.5 / EgoScale / Fast–WAM 的关系

在本调研「人类数据怎么用」的问题谱上, EgoWAM 给出**表征层答案**, 与另两篇构成三角对照: EgoScale 走**数据轴**——用采集纪律把人类数据对齐到机器人, BC 共训跑出 2 万小时 log–linear scaling law; Fast–WAM 走**时机轴**——证明视频建模的收益在训练时而非测试时; EgoWAM 走**表征轴**——把 Fast–WAM 的结论当设计前提 (推理丢世界头), 把 EgoScale 的「对齐前提」变成待消解的问题。其引言直接点名 EgoScale ([71]) 为「只有对齐数据才能 scale」的例证, 而 A.1 是两条路线的显式对照实验: 手工对齐演示者 (EgoScale 式纪律) 能救 BC、给 Pixel/DINO 提 20–30 个点, 3D flow 却不需要这一切——对齐的收益被表征选择免费吸收。

与 HOST/GEN-1.5 是分工而非竞争: EgoWAM 不做 one–shot, 作者自认增益停在 context 级、学不到新技能, 这与 HOST (测试时从一段人类视频接出动作, 50 个未见任务 62%) 和 GEN-1.5 (50 万小时数据涌现 ICL, 59%) 处于不同层。EgoWAM 回答的是这些系统**预训练阶段**该拿什么目标吃人类数据: 若 GEN-1.5 式大规模预训练把世界目标从像素换成 DINO/3D flow, 按本文证据 OOD 泛化仍有放大空间; HOST 的测试时翻译层与 EgoWAM 的训练时表征层原则上可直接叠加。A.2 还额外给了一条合流证据: 动作标签与世界监督互为增益、联合最优——动作重定向 (EgoScale 路线) 与世界预测 (EgoWAM 路线) 不是二选一, 而是两条监督通道的并联。

Zero-WAM 深度解读：把人类视频「造」出来当任务规格，再用 IFP 逼模型真的去看

Zero-WAM: In-Context World-Action Modeling from Human Videos for Open-Ended Task

Generalization arXiv 2608.26103 (2026-08) · Robbyant + 香港科技大学 (广州) + 香港科技大学

1. 一句话定位

四篇具身 ICL 论文里唯一正面攻打「未见任务」的一篇：在 RoboTwin 2.0 做任务级切分（43 任务训练、7 任务完全留出），测试时不给未见任务任何机器人数据、不更新任何参数，只靠一段人类操作视频当上下文，7 个未见任务平均成功率 46.95%，比 LingBot-VA（17.45%）高 29.50 个百分点、七项全胜，评测规模也是四篇里最大的（3 种子 × 每任务 100 次闭环 rollout）。两块核心积木：HumanGen 数据流水线——方向反转，从有动作的机器人轨迹合成人类视频，74.2K 对 / 8.6K 任务 / 超 45 种本体；IFP 训练期反捷径目标——没有它，人类视频塞进上下文反而是净负收益。

2. 要解决的问题

论文把零样本跨任务泛化重述为任务规格问题：LLM 靠上下文指定新任务，机器人也应如此；而操作任务最自然的规格不是语言（难以刻画空间约束、中间状态与时序结构），而是人类视频——它直接展示场景应当如何演化。落地有两只拦路虎。一是数据：任务丰富的人-机配对数据稀缺，人工采集成本随任务数爆炸（RH20T 110K 样本仅 147 个任务）。二是捷径：teacher-forcing 训练下，下一段机器人视频往往靠外推机器人历史即可预测，模型不读人类视频也能降损失，到未见任务上便继续无视上下文——恰好在最需要它的时候。

3. 方法

3.1 HumanGen：方向反转的数据流水线

主流做法先采人类视频再想办法配机器人动作；Zero-WAM 反过来，从已有可执行动作的机器人轨迹出发：VLM（Gemini 3.1 Pro / Qwen3.6-Plus）做任务分析并产出图像编辑提示 → 图像编辑模型（Nano Banana 2 / Qwen-Image-2.0）把机器人首帧改写成人类操作场景 → 视频生成模型（Wan 2.7 / Kling AI 3.0）合成人类操作视频 → VLM 按语义保持与物理合理性打分质检。产出 74.2K 对人-机 ICL 配对、8.6K 任务、超 45 种本体，任务数约为 RH20T（147）的 60 倍。External 子集刻意加大视觉不对齐（强制改场景、背景、物体实例与摆放，混两种视角），逼模型学任务级对应而非外观复制；In-house 子集反向保持对齐。同一套任务级重采样还产出 Task-diverse VA：把五个公开数据集重切成 6,000 多个任务、每 epoch 均衡采样约 40 万条轨迹，防止预训练被少数任务的重复遥操淹没。

3.2 模型：人类视频只进视频分支

主干沿 LingBot-VA 框架把 Wan-2.2-Ti2V-5B 改造成因果视频-动作模型：MoT 双 Transformer 各持参数、共享注意力，先预测下一段机器人视频，动作分支作为逆动力学从预测视频解码动作。人类视频经同一

VAE 编码后拼作前缀记忆，仅供视频分支 attend；动作分支的条件完全不变——任务语义已被吸收进预测出的机器人视频。RoPE 高度轴偏移 $\Delta H=32$ 把人类视频 latent 挪出机器人视频坐标范围防混淆。ICL 推理时人类视频编码一次缓存复用，语言指令可整个关掉。

3.3 IFP：训练期反捷径目标

借鉴 Next Forcing 的多 chunk 预测：加 $K=4$ 个 IFP 模块（各一层 Transformer，从视频分支末层初始化），要求从当前机器人视频表示（多个中间层特征融合）预测跨步 $s=2$ 的多个未来 chunk，推理时整个移除。最关键的设计是 IFP 刻意不直接以人类视频为条件：若直接吃人类视频，辅助分支会自学出一个独立的视频条件预测器，主分支照旧偷懒，推理一剥离便一无所获；只有让未来损失去监督主分支表示，捷径才被堵死。这段论证对一切「训练挂辅助、推理剥离」的设计通用。预训练 15,360 GPU 小时，VA 与 HumanGen 数据按 1:5 采样，ICL 样本把语言 dropout 提到 0.4 以削弱文本依赖。

4. 实验结果

仿真主结果（3 种子 $\times$ 100 rollout）：Zero-WAM 46.95 ± 0.72 ，LingBot-VA 17.45 ± 1.40 ，WAN-Action 10.98 ± 1.07 ，七个未见任务全部领先；place empty cup 达 84.87%（是两基线的两倍以上），stack blocks three 上唯一非零（9.00%）。真机（双臂 Franka，每族 30 次）：物体入容器 53.3 vs 43.3，三物体顺序操作 33.3 vs 10.0，双桌腿插装 16.7 vs 0.0；注意接口不对称——Zero-WAM 只看人类视频，LingBot-VA 拿的是详细文字指令。

消融链条是全文信息量最大处。把两张消融图串起来：LingBot-VA 17.45 $\rightarrow$ （仅任务均衡采样的 text-only 变体）39.44 $\rightarrow$ （加人类视频、去 IFP）28.55 $\rightarrow$ （完整）46.95。三个读数：其一，头条 +29.50 中约 22 分来自任务级重采样这个数据工程决策，标题主张的人类视频机制连同 IFP 贡献约 7.5 分；其二，无 IFP 时加人类视频比不加低 10.89 分——朴素塞演示进上下文是净负收益，强力自证捷径论点，也说明「人类视频作为任务规格有效」远比摘要读起来脆弱；其三，IFP 把 stack blocks three 从 0.00 破到 9.00。另一组小规模消融（只用 43 个已见任务训练）显示 ICL 本身能把 10.98 提到 36.36，但长时程全灭，大规模任务多样的 ICL 预训练不可省。限定：39.44 与 28.55 出自不同消融面板，论文未声明两变体训练配置严格匹配，方向性结论成立、严格等价待作者确认。

5. 局限

作者自认（仅讨论一段）：实验限于静态桌面操作，移动操作、更长时程、动态非结构化环境留作未来；人-机在具身、观测、动作上的 gap 仍在，HumanGen 只是语义级桥接。

延伸批判：

1. **人类视频 100% 合成，合成到真实的 gap 零评估。** 仿真评测的测试视频原文明说由流水线生成；真机训练对用词是 collect（应为真拍），但测试视频来源未明示。落地第一堵墙没有测。
2. **质检零数字。** VLM 打语义分与物理分，但通过率、抽检一致性、错误类型分布一律未报——「零人工标注」的另一面是「零人工质量把关」。
3. **基线近亲。** 唯一外部基线 LingBot-VA 是同组前作，WAN-Action 为自建变体，没有与任何专为 ICL 设计的方法比过；stamp seal 与 move stapler to pad 的成功判据被修改过（对所有方法一

致、承诺开源)，而两者是其第四、第二高分任务。

4. **HumanGen 不新增任务知识**：人类视频从机器人轨迹渲染而来，规模化的是接口，不是知识。

5. **复现难**：流水线依赖 Gemini、Nano Banana、Kling 等闭源商业模型，外部重造 HumanGen 的路被堵住大半。

6. **「未见任务」只在仿真成立**：真机三族均为未见构型而非未见任务；未见环境从未测过；长时程仍是崩塌区。

6. 与 HOST / GEN-1.5 / S1 及四篇 EICL 论文的关系

四篇具身 ICL 各守一条泛化轴：WAM-TTT 未见场景、RoboTTT 未见构型、StellaVLA 未见扰动、Zero-WAM 未见任务——离「跨任务技能习得」的正题最近。它与 StellaVLA 同处纯上下文、零梯度一侧，且两篇撞出同一套路的两种变体：都用 VLM 把机器人轨迹重渲染成另一模态当上下文（结构化文本 vs 合成视频），互不引用；但 Zero-WAM 缺 StellaVLA 那种对/无/错演示三向干预，「上下文确实被用上」的证据只有 IFP 消融这一间接层。论文相关工作里明确与快权重派（WAM-TTT、RoboTTT 仍需测试时适应）划界，却同样零直接对比。

对产业叙事，它是最尖锐的学术反证。GEN-1.5 声称 ICL 从 50 万小时预训练自然涌现、无架构改动无辅助目标（一次性提示 59%），S1 称一条演示可抵约 380 条后训练示例（未见长时程 66%）；Zero-WAM 恰是学术侧最接近该路线的一篇——大规模预训练、纯上下文、零梯度——却用自己的核心消融证明：在 15,360 GPU 小时的规模上，没有 IFP 这个显式反捷径目标，人类视频是净负收益。公平限定：学术规模远小于产业主张，「更大规模能否免掉显式机制」仍未定论。

与 HOST 对照最意味：HOST 用真实人类视频加进度流形显式对齐（50 任务 62%，秒级习得），Zero-WAM 用合成人类视频加 IFP 反捷径——一个在推理期上结构、一个在训练期上目标，却确认了同一个病灶：演示默认会被模型忽略，必须显式逼它用。与 RoboTTT 则是互补拼图：Zero-WAM 打下未见任务但长时程崩（堆三积木 9.0%），RoboTTT 打下 5 分钟长时程但场景与任务全固定；一个占输入前缀、一个占递归状态，架构不冲突，合流是明摆着的下一步。

WALL-WM 深度解读：把世界-动作建模「循事件关节」下刀

WALL-WM: Carving World Action Modeling at the Event Joints arXiv 2606.01955 (2026-06) · X Square Robot Team (自变量机器人) 技术报告, 未经同行评审 作者 31 人, Shalfun Li 领衔 (核心贡献者+项目负责人), Hao Wang 通讯; 标题化用柏拉图《斐德罗篇》「循自然关节而解」

1. 一句话定位

WALL-WM 是自变量机器人 (Wall-OSS/wall-x 出品方) 的世界-动作模型 (WAM) 预训练报告: 把 VLA 学习的原子单元从「固定长度动作 chunk」换成「动作接地的语义事件」——起止由行为切换而非外部时钟决定的变长片段——并配齐事件级四层字幕数据生态、Wan 视频塔+动作 DiT 层耦合双塔、Muon 基建与蒸馏+FP8 的 10Hz 部署栈。真机四套评测 (自建双臂平台, Task Progress 0-100 口径) 事件模式全面领先: 多样操作 75.86 对 π 0.5 的 55.64; 关键消融显示事件条件执行+跨视角注意力把推理类任务从 32.6 拉到 71.6。

2. 要解决的问题

主流 VLA/WAM 以固定 chunk 为监督单元, 等于用外部时钟切割具身动力学。三模态粒度天然不同: 语言描述目标与事件, 视觉沿场景动力学连续演化, 动作在控制时间尺度上对接触与时序敏感。强行共享一个固定预测窗, 训练退化为短视相关拟合: chunk 会拦腰截断语义行为、或把多个行为并成一个目标, 还需额外历史帧才能确定自身语义; 这不仅浪费视频基础模型的视觉-语义先验, 还会用 chunk 特有的动作捷径覆写它, 伤及组合性与长程泛化。作者给对齐单元立三原则——保几何 (不把三模态压进单一嵌入空间)、保先验 (兼容 caption-to-video 结构)、可执行因果 (时间支撑清晰、时长跟任务走) ——固定 chunk 三条全违反, 「语义事件」三条全满足。

3. 方法

事件为原子的双塔去噪器。建模 $p(V_e, a_e | V_0, s, c_e)$: 给定当前多视角关键帧、本体状态与事件字幕, 联合去噪事件对齐的变长未来视频与末端轨迹。视频塔继承 Wan T2V DiT (视频评测版自 Wan2.2-5B 初始化), 三件加装完成多视角化: 零初始化投影的跨视角自注意力、Camera RoPE (每相机可学旋转身份, 运行时免标定)、训练期几何掩码对 (视锥相交掩码修剪注意力拓扑+管状 patch 掩码制造跨视角检索需求)。动作塔为同深度 DiT、随机初始化, 逐层单向读视频特征, 本体 token 走专属交叉注意力。

训练五段: 一、只训视频塔 (事件潜变量上 v-预测流匹配, 事件截 65 潜帧/129 原始帧; 字幕按事件长度以 0.1→0.9 概率丢弃, 逼模型学纯物理延拓)。二、冻结视频塔只训动作塔, 非对称 1-to- N_d 映射: 视频前向只跑到 50 步调度的中噪锚点 $s^*=45$, 动作全部 50 步都从这一次前向读特征 (每优化步复用 $K=6$ 个动作噪声抽样提吞吐)。三、Qwen3.5-9B 对齐 T5 特征空间成为可插拔条件器, 附带下一事件描述头与剩余时间回归头。四、Staircase 蒸馏: MoT 分支在中继深度分叉, 下层算一次共享表征、上层并行产出 K_c 个连续潜推理态, 由冻结 Qwen3.5-0.8B 的潜到文本重建损失监督, 绕开逐 token 自回归。五、可选 next-chunk 适配 (观测中心窗+历史帧)。推理两模式共用主干: 事件模式由 VLM/人给下一事件描述、执行变长段; 统一模式固定 chunk 滚动, 文本条件三源可中途热切换。

数据与基建。四象限数据地图：互联网视频（含 1.2M OpenVID 切片）、第一视角人类视频、XRZero-G0 免机器人穿戴采集（毫米级位姿、IK 重定向）、异构遥操+开源机器人数据，中心为失败-恢复数据；光流×动作差分校正视频-动作常量时偏（20FPS 下 2 帧约 100ms）；Task/Subtask/Action/Segment 四级字幕先按原子动作边界切分再命名；VL+动作双聚类均衡采样让长尾恢复行为成为显式采样单元；接触位形附近随机初始化主动制造恢复轨迹。基建：DMuon 分布式 Muon（原生实现优化器步近 2 倍前反向开销，DMuon 压成次要成本）、多事件序列打包、DMD 蒸馏（去掉动作锚损失则动作 MAE 恶化 53%）+FP8 分块量化+CUDA Graph，端到端 10Hz 闭环。

4. 实验结果

视频侧（WorldArena 协议，自建 200 域内+50 域外任务）：对 Wan2.1-1.3B/Wan2.2-5B，具身维度全面占优——交互质量 0.434 对 0.226/0.219 近乎翻倍，语义对齐 0.886，运动平滑 0.771；画质微降（0.503 对 0.577）。CO3Dv2 3D 探针（VidFM-3D 协议）：点误差 0.271、深度误差 0.132 皆最佳（胜 WAN2.1-14B 与 DINOv2/V-JEPA），AUC@30 0.727 略逊 WAN2.1-14B。

真机（自建桌面双臂，Task Progress 0-100 连续口径、全文无二值成功率；基线 $\pi 0.5$ /DreamZero/LingBot-VA，另设无事件预训练的从头对照 WALL-WM-U-Scratch；事件模式由微调 Qwen3.5-VL-9B 供事件描述）：

- 多样操作（7 任务）：75.86，对 U-Scratch 63.00、 $\pi 0.5$ 55.64、DreamZero 39.97、LingBot-VA 29.71；
- 推理操作（5 任务）：71.60 对 59.50/56.40/32.70/31.60；按序按按钮 64 对 U-Scratch 的 18；
- 灵巧操作（2 任务）：32.00 仅略高于 U-Scratch 的 31.25——瓶颈在低层位姿精度，事件分解帮不上，绝对分很低；
- 泛化套件（杂乱场景+指令随机切换，4 任务）：53.75 对 DreamZero 28.50、 $\pi 0.5$ 24.00，U-Scratch 崩至 18.50——预训练先验在指令切换下才真正兑现；
- 消融（有预训练、去跨视角注意力、固定长度解码，对事件模式）：推理套件 32.6→71.6、泛化 22.0→53.75，按序按按钮 0→64；作者自注这是两因素合并效应，无法归因单一组件。

5. 局限

作者自认：自建平台+平台对齐的预训练数据构成「共享任务定义也消不掉的评测环境优势」，与 LingBot-VA/DreamZero 的比较含不对等的调参投入；事件结构依赖大规模时间接地与细粒度字幕，自监督事件边界留作未来工作；成功率类指标粗糙；灵巧接触任务仍难。

延伸批判：

1. **「关节」是标注管线手工雕的。**事件边界来自字幕栈按原子动作切分，Human 质控层未报任何边界准确率——「按事件切分更优」的核心主张，其地基（切分质量）本身不可验证。
2. **口径自定且封闭。**Task Progress 评分表自定义、无二值成功率，无法与外部论文横比；「泛化」只测场景杂乱与指令切换，无跨具身、无新技能、无 one-shot/ICL 评测。

3. **事件模式命脉在 VLM 规划器**。下一事件描述若错，主干只会忠实执行错误事件；错误传播未量化，也没有 oracle 字幕对照。
4. **部署形态与世界模型话术有距离**。推理时视频只做一次到中噪锚点 $s^*=45$ 的前向，未来影像从不完整成像，再叠 DMD 蒸馏——实为「视频先验当特征库」，与 Fast-WAM「收益在训练时」在工程上殊途同归（论文也引用并认可其免想象路线）。
5. **规模信息不透明**。自采机器人数据小时数、真机所用具体模型规模（家族横跨 10B 以下至数百亿）均未披露，「更大更好」的 scaling 声明无法复核。

6. 与 HOST / GEN-1.5 及 WAM 系工作的关系

Wall-OSS 系谱（确认）：署名 X Square Robot Team 即自变量机器人——Wall-OSS (wall-x 开源) 出品方、HOST 论文（北理工+自变量+清华）合作机构；文中 QUANTA X2 轮式人形亦属其产品线。WALL 系两代同堂：Wall-OSS 是 chunk 式 SFT VLA (HOST 的最强 SFT 基线，50 任务 56%)，WALL-WM 则判 chunk 式训练「短视相关拟合」死刑、以事件单元重造底座。注意论文通篇未引用 Wall-OSS，系谱在公司层面而非引用层面。由此可见一条公司内演进线：自家 chunk 基线被自家参与的 HOST (62%，一段人类视频 29 秒零更新习得) 超越后，底座层也转向结构化单元。

时间接地三方案对照：HOST 用连续、自接地的进度流形（零语言标注）；WALL-WM 用离散、语言命名的事件加剩余时间回归头（重标注）；StellaVLA 的语义分段居间。WALL-WM 的剩余时间头本质是离散化的进度坐标——两条线在「模型须知自己处于任务何处」上收敛，分歧仅在该知识由标注供给还是由结构自举。

与 WAM 系：对 Fast-WAM（视频建模收益在训练时而非测试时）表面唱反调（保留完整视频塔）、实际同流（推理只取锚点特征、不做未来想象），贡献轴正交——Fast-WAM 问「要不要想象」，WALL-WM 问「监督单元切在哪」。Staircase 的 MoT 分支与 Fast-WAM 的 MoT 双专家（HOST 主干来源）同构不同用。

对本调研主线：WALL-WM 无任何 ICL/one-shot 能力，是 2026-08 具身 ICL 拐点的底座层候选而非拐点本身。其价值在为「单元假设」提供公司级证据：泛化套件 53.75 对从头训练的 18.50，说明预训练单元切对与否决定先验能否兑现。若 GEN-1.5 证明 ICL 可从 50 万小时涌现 (59%)，WALL-WM 的隐含反题是：单元切对，涌现所需规模或可大减——这正是 HOST（结构派）与 GEN-1.5（规模派）之争在预训练层的镜像。

WAM-TTT 深度解读：把人类演示写进快权重记忆，且只许写在感知侧

WAM-TTT: Steering World-Action Models by Watching Human Play at Test Time arXiv 2607.06988

(2026-07) · 北京大学 + 银河通用 Galbot + 中科院自动化所 + 清华

1. 一句话定位

WAM-TTT 把「用人类视频引导机器人」形式化为测试时训练问题：部署时只拿一小批无标注第一人称人类视频，对冻结世界-动作模型（WAM）视频专家上的 TTT 快权重做 $N=1$ 步 inner SGD——主干、慢投影、动作专家全冻结——再拿适应完的固定快权重去跑机器人。演示不是被模仿的轨迹，也不是拼进上下文的 token，而是被自监督视频预测「吸收」成的离线技能记忆。9 个真机任务的未见家庭场景（New 设定）平均 progress 46.2%，比把同批视频当上下文 token 喂的 WAM-ICL（7.1%）高 39.1 个点；而去掉人机配对 meta-training 后成绩几乎归零（100.0 掉到 9.0），这是四篇 EICL 论文里对「ICL 纯涌现」最直接的一条学术反证。

2. 要解决的问题

机器人基础模型的知识固化在预训练权重里，部署后行为由权重加狭窄条件接口（语言、目标图、短历史）决定；想引导它做新任务变体，要么补采机器人演示（贵），要么任务级微调（灾难性遗忘、丧失可复用性）。人类视频是最自然的引导接口，但现有用法各有死穴：co-training 或微调需要手部姿态、3D 运动、重定向轨迹等额外监督，噪声大成本高；直接把原始人类视频当上下文条件（如 MimicDroid）则要求预训练阶段就学会这种能力，且上下文长度随演示积累暴涨。WAM-TTT 的目标清单是：不重定向、不要机器人动作、不要人侧标注、不动预训练主干，还要可复用。

3. 方法

3.1 架构：TTT 残差只挂视频专家

主干是 LDA-1B（Qwen3-VL-4B VLM + DiT-L 双专家 MMDiT，16 块），块内视频专家与动作专家经联合注意力耦合。唯一改动是给视频专家加 TTT 残差支路：视频流输出加上 Δz_{TTT} ，动作流一行不改。TTT 层含慢投影 $\theta_K/\theta_V/\theta_Q/\theta_O$ 与快权重小 MLP f_W （head 维 48、隐宽 128），读出 $\Delta z_{TTT} = \theta_O \cdot f_W(\theta_Q(z))$ 。人类信息在架构上就进不了动作专家——这是它抗域漂移、抗遗忘的结构性原因。

3.2 人机 meta-training：预先学好记忆接口

对相位对齐的人机配对演示（机器人第 t 步取 $\phi=t/T_r$ 最近相位的人类帧），内层对快权重做 SGD，损失 = 人类视频预测 + $\lambda \cdot$ 逐层键值记忆重建（KVM）——衡量 f_W 能否从人类 Key 重建人类 Value。外层用标准 WAM 机器人多任务损失（视频+动作双 diffusion）反传穿过内层更新，训练 WAM、慢投影与快权重初始化 W_{init} ；样本用完快权重即丢弃重置。

全文最扎实的一步在附录 A：KVM 的线性特例有闭式解 $W^* = V_h^T \cdot K_h \cdot (K_h^T \cdot K_h)^{-1}$ ，各向同性假设下退化为 Hebbian 外积记忆，用机器人 Query 查询恰得 $\sum(k_i^T \cdot Q_r)v_i$ ——一个没有 softmax 的线性注意力读出。所以 KVM 不是随手加的正则项，而是「用快权重实现对人类 Key/Value 交叉注意力」的变分定义，概念上把「演示当上下文」与「演示当记忆」两种对立做法缝在了一起。

3.3 测试时：一步 SGD，然后冻结去跑

部署时输入只有目标场景无动作的人类 RGB 视频（GoPro 第一人称，无姿态、无接触、无 3D 线索）。以视频生成模式跑与 meta 期同款的组合目标（两项都只依赖人侧）做 $N=1$ 步 inner SGD（学习率 0.01，meta 期 0.1），适应完的快权重在整个 rollout 期间固定。所谓「零梯度」精确说法是零主干梯度。训练开销 8 张 H800、10 万步。

4. 实验结果

三种真机本体（Unitree G1 人形、Galbot gripper 双臂二指、Galbot sharpa 双臂灵巧手 58 维）、9 个任务、2,286 对配对人机 episode；指标是 progress（部分给分），每格 25 次试验，Orig.（标准隔间）与 New（光照/桌高/物体联合变化的未见家庭）双设定。

主结果（New）：WAM-TTT 46.2%，对 LDA 主干 32.5%（+13.7）、WAM-Cotrain 25.3%、EgoScale 15.0%、 $\pi 0.5$ 14.8%、WAM-ICL 7.1%（+39.1）。9 任务赢 7 个，Flip Steak 34.3 对 Cotrain 34.2 近乎打平（正文误写为 10.0，以 Table 1 为准），唯一输的是 Stamp Paper（8.3 对 LDA 33.3）。Orig. 到 New 的保持率最说明问题：WAM-TTT 0.76（61.1 到 46.2），WAM-ICL 仅 0.15（48.4 到 7.1）——同一批视频，当上下文 token 在真实漂移下是负资产，当快权重记忆则大部分收益存活。适应后再加扰动（Deliver Drink 换光照/空间位置），WAM-TTT 66.0/56.0 仍最高，说明快权重不是死记了那条演示。

消融（10 试验，Table Bussing / Swap Place）四条都硬：去 meta-training 100.0 掉到 9.0、88.9 掉到 0.0，几乎归零——「人到机器人」的记忆接口必须预先显式学；LoRA 替换 TTT 只有 30.0/0.0——起作用的是记忆结构而非「多了组可调参数」；去 KVM 掉到 66.7/72.0；完全去 TTT 为 40.0/74.1。

两个附录消融的信息量不亚于主表。数据配比：等预算 200 条 episode 下，（机器人100，人类100）=74.1 与（200，0）=73.7 统计上不可区分——配对人类数据可 1:1 替代机器人数据、遥操成本减半；但（10，190）只有 51.4，机器人 grounding 不可少。伪动作消融：给人类侧加 MANO 重定向伪动作与前向动力学损失，四任务均值 72.3 掉到 28.9（-43.4），三种末端全部受损——在当前单视角手部追踪成熟度下，保持人类视频「无动作」、只用抗噪的视频预测损失是对的。

5. 局限

作者自认三条：meta-training 的相位配对假设人机 episode 覆盖同一技能相位分布，错配会静默降级适应信号、损失不报警；适应能力受快权重表达力与冻结慢投影约束，部署任务离配对分布越远越弱，且边界未做实证刻画；接口只吃第一人称 RGB，不利用手姿、接触、3D 场景线索。

延伸批判：

1. **progress 指标显著抬高观感**。部分给分权重压在少数关键里程碑上（Pour Water 的「倒水成功」一项占 0.60，Stamp Paper 的「盖章成功」占 0.50），真实的二元完成率会显著低于 46.2%。

2. 「零梯度」实为零主干梯度，测试时仍对快权重做 SGD，与 StellaVLA、Zero-WAM 的完全零梯度不是一档。
3. WAM-ICL 这个靶子不对口：LDA 主干本就不是为长上下文 ICL 预训练的，7.1% 的崩塌有一部分要算在主干头上；「快权重优于上下文条件」未在专为 ICL 预训练的主干上验证过。
4. 无代码、无项目页、无数据集，2,286 对配对 episode 的采集协议外部无法复现，四篇里开源程度最差的一档。

6. 与 HOST / GEN-1.5 / S1 及其余三篇 EICL 论文的关系

在 2026-08 具身 ICL 拐点坐标系（HOST 显式结构、50 任务 62%；GEN-1.5 涌现叙事、ICL 59%；Skild S1 视频提示未见长时程 66%）里，WAM-TTT 占「演示改权重 × 适应发生在部署前一次」一格：快权重是离线装好的**技能包**，装完冻结去跑。它对「涌现」的反证在四篇里最直接——去掉 meta-training 归零，说明至少在学术界可负担的规模上，「演示能被用上」这件事必须显式教。

与其余三篇：和 RoboTTT（解读见 05）同名 TTT 却不是一回事——RoboTTT 快权重挂动作头、rollout 每步更新，是**流式工作记忆**；WAM-TTT 挂视频专家、执行期冻结。互补处几乎像刻意：RoboTTT 自述局限之一是「快权重目标仍是通用 MSE」，KVM 恰好是一个带线性注意力理论论证的机器人向替代品。和 StellaVLA、Zero-WAM 处在坐标对角：后两篇零梯度、演示留在输入里；WAM-TTT 用 WAM-ICL 的崩塌主张上下文条件不行，StellaVLA 却用结构化语言证明上下文可行——分歧其实在演示的表示（原始视频 token 对结构化文本），而四篇之间零直接对比，这是本方向最该补的实验。三条跨篇共同经验里它贡献两条实证：人类信息只许改写感知侧（残差只挂视频专家，动作流零扰动）；伪动作净负面（72.3 到 28.9）从反面确认不许碰动作侧。对本调研的定位：它是 human-robot gap「机制层跨越」的代表，代价是 2,286 对配对 episode 的采集；HOST 用进度流形对齐绕开配对、StellaVLA 用表示层消解，三种成本结构差着数量级，尚无人同台比过。

StellaVLA 深度解读：把演示翻译成「为什么」，四篇里唯一真零梯度

StellaVLA: In-Context Structured Demonstration for Generalizable Vision-Language-Action Models
arXiv 2608.11671 (2026-08) · StellarEdge AI (公司技术报告)

1. 一句话定位

StellaVLA 把 in-context 模仿学习 (ICIL) 的创新点从适应机制挪到演示的表示形式：一条全自动离线流水线用 Qwen3-VL 把每条专家轨迹拆成 K 个语义段，生成「语义理由 (子目标描述) + 运动学理由 (3D 位移与 2D 投影的文字化)」的结构化演示；测试时检索一条当前缀，主干全程冻结——无快权重、无 inner loop，是四篇 EICL 论文里唯一真正零梯度的。VLA-Arena 榜单 (2026-08-01) 总分 0.63 居首 ($\pi 0.5$ 为 0.44、LingBot-VLA 为 0.22)，LIBERO 98.8%、LIBERO-Plus 85.1%。方法论上最大的贡献是三向干预实验：同一 checkpoint 只换演示内容，对 98.8 / 无 62.4 / 错 44.9——「错比无差 17.5 个点」直接证明策略真在用上下文。这应当成为所有 ICL 论文的标配自检。

2. 要解决的问题

VLA 模型出分布即崩：场景、视角、物体一变，通常就得补数据再微调。ICIL 给出测试时零权重更新的出路——把检索到的专家轨迹拼进上下文当非参数记忆。但现有 ICIL 把演示当「原始观测 + 连续动作」直接塞，只传达专家做了什么、不传达为什么，鼓励表层模仿；策略常把演示当噪声无视、退回预训练先验 (论文称为行为惯性)。另一头，Embodied CoT 类方法让模型显式推理换泛化，但自回归文本生成的延迟撞碎实时控制预算 (本文实测解码 83 个 token 要 3177ms)。StellaVLA 想同时拿两头：推理带来的泛化，与无自回归解码的控制频率。

3. 方法

3.1 离线结构化上下文提取

原始轨迹可来自真机遥操、人手追踪或 XR 重定向。流水线分两层：Qwen3-VL 按视觉变化把长轨迹切成 K 个语义段、每段生成子目标描述 (如「伸向蓝色马克杯的手柄」)；确定性 verbaliser Φ 把段内动作跨度翻译成 3D 工作空间位移与投影到相机平面的 2D 轨迹文字。全程零人工标注。最精巧处是 Φ 的双尺度复用：整段尺度的输出进上下文，动作 chunk 尺度的输出做训练监督——「别人的演示」与「策略自己的预测」由此进入同一套词汇，天然可比，这是它敢做跨本体上下文的机制根基。

3.2 并行双专家训练

主干 Qwen3-VL-4B 全参微调，输入 = 结构化演示前缀 $\oplus$ 任务指令 $\oplus$ 当前观测。共享表示 h_t 并行喂两个专家：动作专家 (OpenVLA-OFT 式 MLP 头) 以 L1 回归动作 chunk；空间语言专家 (原生 LM 头) 以交叉熵预测当前子任务与同一 chunk 的 Φ 文字化。两专家严格并行，动作预测不因果依赖文本 token；

总损失 $L_{act} + \lambda \cdot L_{lang}$, $\lambda=0.3$ 。检索只用任务指令语言 embedding 的余弦相似度取 top-1, 训练时 leave-one-out。训练 3 万步、全局批 128。

3.3 非对称推理与前缀缓存

部署时空间语言专家整个拆掉, 单次前向 + MLP 头出动作; 演示前缀整个 episode 不变, KV cache 只算一次。实测: 无演示 64ms; 带演示无缓存 183ms、有缓存 91ms; 若保留语言解码则 3177ms (约 36 倍)。真机全管线约 205ms/chunk。「训练期挂辅助推理、推理期整个剥离」由此成立。

4. 实验结果

LIBERO (每 suite 500 rollout): 平均 98.8%, 超 matched control StarVLA-OFT (同主干同数据、无演示无语言监督) 的 96.6%, 增益集中在当前观测无法唯一确定意图的 Goal (+3.4) 与 Long (+3.0)。

VLA-Arena (训练只用 L0 数据, 测试时给一条目标任务演示、零参数更新): L0/L1/L2 均值 0.84/0.62/0.43 三级全部第一, 总分 0.63 对 $\pi 0.5$ 的 0.44。逐 suite 三条最有信息量: Unseen Objects 三级全 0.80 (换物体指代、程序可迁移); Task Workflows 从 L0 的 0.64 升到 L2 的 0.84——测试流程离训练越远, 上下文越有用; Long Horizon 则 L1 仅 0.02、L2 为 0.00, 所有方法归零——固定前缀能指定程序, 无法在执行漂移后重新规划。

LIBERO-Plus 零样本鲁棒性 85.1% 对 StarVLA-OFT 的 75.0, 增益分布本身就是机制证据: 相机视角 +23.5、传感器噪声 +19.7、机器人初始状态 +14.7、语言 +8.3——都是观测变了但任务程序不变的轴; 物体布局仅 +0.1, 演示里场景特定的空间关系失配时结构化上下文帮不上。

真机 (AgileX Piper 六自由度, 125 条遥操 71,702 帧, 检索池另入 26 条 XR 人手与 26 条重定向轨迹): 分内 85.0%; OOD-L1 配对退化仅 -5 点 (StarVLA-OFT 为 -25、 $\pi 0.5$ 为 -20); OOD-L2 未见抽屉任务无人完成, StellaVLA progress 1.9/4 领先 ($\pi 0.5$ 为 1.5、StarVLA-OFT 为 1.1)。跨源一致性: 固定观测只换演示来源, 动作分歧 $0.0014-0.0016\sigma$ (合 $0.02^\circ-0.03^\circ$ 关节角)——结构化表示确实抽掉了本体外观。

理解性实验三连是全文精华。三向干预: 对 98.8 / 无 62.4 / 错 44.9; Goal suite 从 99.6 掉到 24.8 再到 0.0 (演示在定义任务意图), Spatial 在无/错下几乎一样 (72.2/72.6, 观测自带交互位置线索)。模态消融: 评测时 Text-only 98.8/84.4 几乎等于完整 Image+Text 的 98.8/85.1, Image-only 塌到 92.9/75.7——可迁移信息几乎全在语言里; 训练时 Image-only 分内略好 (98.4 对 97.3) 但 LIBERO-Plus 差 6.3 点 (78.7 对 85.0)——视觉演示诱导「外观对应」捷径。 λ 消融: LIBERO-Plus 在 $\lambda=0$ 时最高 86.9、单调降到 $\lambda=1.0$ 的 81.9, 选用的 $\lambda=0.3$ 只有 85.1。子目标粒度: 3 帧 98.1 对 10 帧 98.8——起作用的是子目标分解而非稠密轨迹重放。

5. 局限

作者自认三条: 长时程组合性——前缀固定无法在执行漂移后重规划, VLA-Arena Long Horizon 对所有模型都近零; 依赖检索质量——错误演示比无演示更差, 域漂移下的鲁棒检索是下一步; 运动学文字化的量化误差可能限制精细操作精度。

延伸批判:

1. **λ 消融自拆招牌的一半**。论文两大贡献之一是「并行双训练把推理内化」，但 $\lambda=0$ （无语言监督）的 OOD 鲁棒性反而最高（86.9 对选用的 85.1）：语言监督换来饱和基准上 +1.2 的分内提升，代价是 -1.8 的 OOD。真正起作用的是上下文条件本身；论文诚实报了数字，摘要仍把双训练当卖点。若目标是泛化而非刷榜，应先试 $\lambda=0$ 。
2. **封闭指令集使检索退化为任务标签匹配**（附录 A 自认）。仿真里检索即精确任务匹配，98.8 对 62.4 的差距有相当部分在测「知不知道任务标签」，而非开放场景的检索能力。
3. **VLA-Arena 存在测试时信息不对称**：基线数字取自榜单未重跑，只有它测试时额外拿到一条目标任务演示，且该基准上没有 matched control。
4. **真机每格仅 10 次 rollout**，作者自述单格 10–15 点噪声；跨源一致性只验证了单步预测，不是闭环不变性。
5. **算力完全未披露**（四篇里唯一一篇）；标注 VLM 与主干同为 Qwen3-VL，标注噪声与模型归纳偏置同源，且无任何质检数字。

6. 与 HOST / GEN-1.5 / S1 及其余三篇 EICL 论文的关系

在 2026-08 具身 ICL 拐点坐标系（HOST 显式结构、50 任务 62%；GEN-1.5 涌现叙事、ICL 59%；Skilld S1 视频提示未见长时程 66%）里，StellaVLA 占「演示改输入 × 不做任何适应」一格，是四篇里最接近产业博客主张的路线：零梯度、纯上下文。但它恰恰构成对「纯涌现」的反证：要让上下文真被用上，需要一整条离线结构化流水线、训练期语言监督加检索机制——而且自家 λ 消融显示辅助监督还在伤 OOD。与 HOST 的分野在 gap 解法层：HOST 在机制层用进度流形对齐跨越人机差异，StellaVLA 在表示层直接消解——外观进不了结构化文本，跨本体自动成立，代价是依赖可靠的 VLM 与相机内外参。

与其余三篇：和 WAM-TTT 处在坐标对角——后者用 WAM-ICL 的崩塌（7.1%）主张上下文条件不行，StellaVLA 证明结构化表示下上下文可行，分歧在演示的表示而非机制本身，但双方零直接对比。和 RoboTTT（解读见 05）是互补失败：StellaVLA 的前缀是 episode 常量、无法重规划所以长时程归零；RoboTTT 的递归快权重恰好解决长时程却从未面对真正的分布漂移——常量前缀加递归状态在架构上不冲突，是明摆着的合流方向。和 Zero-WAM 是结构性巧合：两篇都用 VLM 把机器人轨迹重新渲染成另一种模态当上下文（结构化文本对合成人类视频），互不引用却发明了同一套路的两种变体。三条跨篇共同经验里它贡献两条实证：训练期挂辅助推理期剥离（3177ms 对 88ms）；上下文不是免费午餐（Image-only 训练的外观捷径）。它的三向干预实验则是四篇里唯一直接证伪「策略忽略上下文」的证据链——方法论价值大于榜单名次。

S1 与「涌现之争」：2026 年 8 月具身 ICL 三连发的完整拼图

Introducing S1: In-Context Learning for Robotics Skild AI 技术博客，2026-08-18 · 无论文、无开源权重、内部 benchmark 本篇同时覆盖：三家产业发布的时间线拼图，以及「ICL 是涌现还是造出来的」这场正在重演的辩论（Brown 2020 / Wei 2022 / Schaeffer 2023 → GEN-1.5/S1 vs 四篇 EICL 学术论文）

1. 一句话定位

Skild AI 的 S1 把具身 ICL 的主张推到三家产业发布里最远的位置：一条视频演示当 prompt，能执行**预训练从未见过、长达 10 分钟**的长时程任务（66% 累计逐步成功率，同规模语言提示只有 9%），单条上下文演示约等于 380 条后训练遥操作示范（那 380 条要花 50-100 小时采集）。与 HOST（8-03 开源）、GEN-1.5（8-19 博客）放在一起，2026 年 8 月「教机器人 = 给一段演示」在三家互不相识的机构同时成立——而同月的四篇学术论文用消融证据对「这能力是涌现出来的」这一叙事给出了一致的反证。

2. S1 的主张与数字

****核心能力声明。****任务由视频演示指定而非语言；演示可来自不同场景、视角、具身，策略必须隐式学出演示者意图、功能对应与任务进度。同一套权重覆盖博客全部展示，无微调无后训练。四个未见长时程任务（种植盆栽、煎饼、手冲咖啡、组件装配）最长 10 分钟、数十个操作步骤，由单条第一人称人类视频驱动。种植任务从「道具进门」到自主执行只用 33 分钟，其中演示到执行 11 分钟。

****ICL scaling 对照（博客最有科学价值的部分）。****在过滤后的预训练池上做受控研究：ICL 策略与语言条件 VLA 用完全相同的数据、架构（除 prompt 嵌入）、算力，从 1k 到 100k 小时。结果分两段读：

- **已见任务：**1k 小时时语言条件反超 ICL（53% vs 43%）——语言 token 压缩任务信息在小数据下更省，ICL 的高维条件反而易过拟合；scale 到 100k 小时后 ICL 达 96%，反超语言条件。归因：语言指令容许多种合法执行、存在歧义，演示无歧义。
- **未见任务：**语言提示随数据涨得极慢，100k 小时才 9%；ICL 同点 66%，且**差距随数据量指数级扩大**。归因：新原语（翻煎饼）语言无法接地到动作；新组合语言过粗、演示直接给出。

****扰动分级 L1-L5 定量。****两条轴分开测：部署场景偏离训练条件、部署场景偏离上下文演示。L5（物体摆位迫使一半动作换到另一只臂）下语言 VLA 退化幅度是 ICL 的 3 倍；ICL 对 L4（同可供性物体替换 + 15cm 垂直位移）以内的偏移稳健，只在演示隐含的执行计划整体失效（L5）时显著退化。

****单条演示的兑换率。****未见任务上后训练 VLA 需约 380 条遥操作示范才追平 ICL 单条演示的 66%；2000 条时后训练达 86% 反超。Skild 的表述值得注意：期望靠继续 scale ICL 预训练或 ICL 后训练缩小这个差距。

涌现性质（定性展示）。中途扰动（滑走物体、换物、改光照）不在 prompt 里仍完成；失败后自发重试（未见任务滑板轮装配也有）；常识替代（prompt 用烧水壶，现场只有杯子，S1 用杯子；杯子已近满就只加一点）；演示纠错——示范者失手掉鸡蛋弄脏台面，S1 同一步骤做得干净利落。博客的总结句子是全文最重要的机制线索：S1 把演示当目标规格而非要复现的轨迹。

****数据引擎。*披露有限但立场清晰：**遥操作（硬件贴近性高、扩展性最差）、UMI（全面中等）、第一人称视频（扩展性最好、域差最大）、仿真（多样性低）四类源没有全能者，全部自建并战略性混合；每 1 美元采集配 3 美元质检。时间线：LocoFormer（2025-09，运动控制 ICL）→ 2026-02 域内 ICL 首个信号 → 2026-05 第一张煎饼 → 2026-08 S1 发布。

3. 该打的折扣

- 1. **证据形式仍是博客：**无论文、无开源权重、无 API，benchmark 全部内部构建，数字不可复核。这一点与 GEN-1.5 完全相同；
- 2. **评分口径含人工干预：**长时程任务用「累计逐步成功率」，rollout 中靠人工干预从失败恢复以保证每步都被计分——博客自己说明这主要是为了 VLA 基线（否则语言基线一次都完成不了整个任务、得分为零）。这个口径下 66% vs 9% 的对比成立，但 66% 不能读成「无干预端到端完成率」；
- 3. **「未见任务」的边界模糊：**四个展示任务（煎饼、咖啡、盆栽、装配）声明不在预训练中，但预训练池的任务清单未公开，「未见」无法外部审计；
- 4. **380 条兑换率是插值估计：**博客自己注明 crossing 由测量点之间插值得出。

4. 三连发时间线：一个月内的七次发布

日期	工作	形式	主张强度
2026-07-08	WAM-TTT（北大+银河通用）	arXiv	快权重技能吸收，未见场景
2026-07-16	RoboTTT（NVIDIA GEAR）	arXiv	上下文 8K scaling 轴，配置级 one-shot
2026-08-03	HOST（北理工+自变量+清华）	arXiv+开源	50 未见任务 62%，跨具身人类视频
2026-08 中	StellaVLA（StellarEdge AI）	arXiv	结构化语言上下文，真零梯度
2026-08-18	S1（Skild AI）	博客	未见+10 分钟长时程 66%
2026-08-19	GEN-1.5（Generalist AI）	博客	50 万小时涌现 ICL 59%
2026-08 末	Zero-WAM（Robbyant+港科广）	arXiv	合成人类视频，任务级零样本 46.95%

三家产业机构互不相识、路线各异（HOST 结构设计 / GEN-1.5 数据涌现 / S1 数据+配方，且 S1 博客明确点名 GEN-1.5 和 RoboTTT「局限于短时程或分布内任务」），却在 16 天窗口内发布同一能力。学术侧四篇论文两个月内齐发且互相知晓却零对比。这个密度本身就是调研第 10 号报告「拐点」判断最硬的证据。

5. 涌现之争：LLM 的辩论在具身领域重演

LLM 前史三步曲。Brown et al. 2020（GPT-3）展示 few-shot ICL 随规模出现，确立「prompt 里给例子、权重不动」的范式；Wei et al. 2022 把这类「小模型没有、大模型突然有、无法从小模型外推」的能力命名为涌现能力（emergent abilities）；Schaeffer et al. 2023（NeurIPS 2023 杰出论文）泼冷水：所谓涌现可能是度量的海市蜃楼——非线性、不连续的度量（exact match、多选正确率）会把平滑的底层改

进渲染成突变，换成连续度量后大部分「涌现」曲线变得平滑可预测。涌现是研究者度量选择的产物，还是模型的真实相变，至今没有共识。

具身领域的重演，攻守双方都已就位。

产业侧的叙事是「涌现」：GEN-1.5 博客强调 ICL 能力从 8 个月连续预训练中出现，**无架构改动、无 meta-learning 循环、无辅助目标**——这是把自己对标 GPT-3 时刻的修辞。S1 的措辞更谨慎（「task diversity and scale drive the emergence」），并用 meta-learning 语言解释：预训练是外环、推理时演示驱动内环），但同样主张核心能力来自规模而非机制。

学术侧四篇论文的消融证据全部指向反面：

- WAM-TTT：去掉 meta-training 阶段，成绩从 100.0/88.9 掉到 9.0/0.0，几乎归零；
- RoboTTT：去掉 sequence action forcing 训练直接不稳定；register token 单独加给基线无效，只在配合 TTT 时 +18%；
- StellaVLA：需要一整条离线结构化流水线把演示翻译成「为什么」；
- Zero-WAM：**最致命的一条**——它是四篇里最接近产业路线的（大规模预训练+纯上下文+零梯度），但没有 IFP 反捷径目标时，往上下文里加人类视频是净负收益（28.55 vs 不加的 39.44）。捷径学习不会因为数据大就自动消失，至少在 15,360 GPU 小时的规模上不会。

****公平的限定。没有任何一篇学术论文达到过 GEN-1.5（50 万小时）或 S1（100k 小时对照研究）的预训练规模。四篇严格证明的是「在学术界能负担的规模上，ICL 需要显式机制」，不是「在任何规模上都需要」。裁决实验只有一个：在产业规模上做一次去机制消融。在那之前，两边都没资格宣布获胜。**

Schaeffer 式度量批判在具身领域同样适用，且几乎无人提及。机器人评测用的二元成功率和 rubric 完成分，恰好是 Schaeffer 指出的容易人为制造「突变」的不连续度量。GEN-1.5 的「智能相变」叙事建立在成功率曲线上；而 S1 自己公布的 scaling 曲线（1k→100k 小时，ICL 与语言的差距平滑地指数扩大）反而更接近「连续可预测改进」而非相变。如果换成逐步进度这类连续度量，「涌现」还剩多少？这是把 LLM 那场辩论的方法论武器搬进具身领域的第一个具体研究机会，目前没有人做。

6. 对调研主线的修订

1. **口径提醒升级**：S1 66%、HOST 62%、GEN-1.5 59% 落在同一区间纯属巧合——三者的「未见」定义、任务时长、判定口径、干预政策全部不同。真正可比的是证据形式：HOST 有论文+代码+权重+50 任务口径可复查，两家博客只有 demo 视频和内部曲线；
2. **S1 的独特坐标**：它是唯一同时主张「任务未见」与「10 分钟长时程」两轴的发布——恰好落在四篇学术论文的漂移轴地图上无人覆盖的右上角（长时程 × 分布外），这也解释了它为什么最不可复核；
3. **「演示当目标规格而非轨迹」**：S1 的演示纠错现象与 RICL 的 elicited latent actions、HOST 的观测空间预测殊途同归——三条独立证据指向同一结论：有效的 ICL 不是复制上下文，是用上下文激活模型内部已有的能力；
4. **涌现之争成为领域主矛盾**：本调研第 10 号报告「趋势四：涌现 vs 设计，两边都赢」需要修订为三方格局——涌现叙事（GEN-1.5/S1）、机制证据（四篇 EICL 论文）、度量质疑（Schaeffer 式批判

尚无人做)。12-24 个月内最有价值的单个实验就是产业规模的去机制消融。

趋势与洞察：机器人 One-Shot 技能习得的 2026 拐点

本报告基于对 HOST (arXiv 2607.20033)、GEN-0/1/1.5、Skild S1、Instant Policy、ICRT、RoboTTT、WAM-TTT、StellaVLA、Zero-WAM、BPP、RICL、Vid2Robot、EgoScale、EgoWAM、WALL-WM、 π 0.5、Wall-OSS、Fast-WAM 等工作的深度解读，以及 2026 年 8 月底的扩展检索 (ManiLong-Shot/RLBench-Oneshot、EgoSteer/EgoSmith、Ego2Robot 等)。写作时间：2026-08-31 (09-01 增补 S1 与四篇 EICL 论文后修订)

0. 一页结论

2026 年 8 月是机器人技能习得范式的分水岭：「教机器人」正在从训练问题变成提示问题。同月内，Generalist AI 宣布 one-shot 上下文学习作为涌现能力出现在 50 万小时数据预训练的 GEN-1.5 里 (59%，10 任务)，自变量机器人开源了用架构设计达成同等能力的 HOST (62%，50 任务，29 秒/技能)，Skild AI 发布了把主张推到最远的 S1 (未见且长达 10 分钟的任务 66%，同规模语言提示仅 9%)。三家互不相识的机构、三条不同的路线在 16 天窗口内汇合于同一个能力点——这不是巧合，是领域相变的信号。同月，四篇学术论文 (WAM-TTT、RoboTTT、StellaVLA、Zero-WAM) 把「演示怎么被用上」做成了可核对的实验，其消融证据一致指向：至少在学术可负担的规模上，具身 ICL 需要显式机制，不是免费涌现 (详见第 16 号报告)。

类比语言模型的历史坐标：这就是机器人的 GPT-3 时刻。GPT-3 (2020) 之后，NLP 的重心从「为每个任务微调」转向「为每个任务写 prompt」；机器人正在进入同一转折——physical prompting (物理提示) 取代 per-task fine-tuning。

1. 领域快照：通往 2026-08 的时间线

时间	事件	意义
1994	Kuniyoshi "learning by watching"	OSVI 愿景起点
2017-2018	MAML 系 one-shot 模仿 (Finn、Yu)	元学习路线，泛化受限
2024-03	Vid2Robot (DeepMind)	端到端视频条件策略，跨注意力+辅助对比损失
2024-08	ICRT (Berkeley)	机器人 ICL 用 next-token prediction 形式化
2024-11	Instant Policy (Imperial)	图扩散 ICL，伪演示无限生成
2025-04	π 0.5 (Physical Intelligence)	VLA 开放世界泛化的代表
2025-08	RICL	给预训练 VLA 后装 ICL 能力的通用配方
2025-09	Wall-OSS 开源 (自变量)	中国开源 VLA 基座
2025-11	GEN-0 (27 万小时)	机器人 scaling law + 7B 相变
2026-01	ManiLong-Shot / RLBench-Oneshot	OSIL 标准仿真基准出现

时间	事件	意义
2026-02	EgoScale (NVIDIA GEAR)	20,854 小时第一人称人类视频, log-linear scaling law
2026-04	GEN-1	6 任务 99% 精通 + 3x 速度
2026-06	BPP	行为提示策略
2026-06	WALL-WM (自变量系)	事件关节切分的世界动作建模
2026-07	EgoWAM (Georgia Tech)	WAM 世界表征对照: DINO/3D flow 远胜像素
2026-07-08	WAM-TTT (北大+银河通用)	快权重技能吸收: 人类视频写进感知侧记忆
2026-07-16	RoboTTT (NVIDIA GEAR + Stanford)	TTT 快权重把上下文扩到 8K timestep (3 个数量级)
2026-08-03	HOST 开源	架构派 one-shot: 62%, 29 秒, 零参数更新, 不遗忘
2026-08 中	StellaVLA (StellarEdge AI)	结构化语言上下文, 三向干预实验首创
2026-08-18	S1 (Skild AI)	未见+10 分钟长时程 66%, 单演示≈380 条后训练示范
2026-08-19	GEN-1.5	涌现派 one-shot: 59%, physical prompting 命名确立
2026-08 末	Zero-WAM (Robbyant+港科广)	合成人类视频 74.2K 对, 任务级零样本 46.95%

2. 六大趋势

趋势一：ICL 正在成为机器人学习的新范式轴，四条实现路线并行

「从演示上下文即时学习、不更新参数」这一目标，2026 年有四条技术路线同时逼近：

- 涌现派 (GEN-1.5)：**什么都不设计，靠 50 万小时数据预训练让 ICL 自己长出来。上限最高（还能组合泛化、sim2real 提示、跨具身提示），但不可复现、需要天价数据引擎。
- 架构派 (HOST、Instant Policy)：**把「对齐」「跨域翻译」显式设计进模型。HOST 用 SDTW+TCC 学共享任务进度流形 + 三级自接地级联；Instant Policy 用图扩散把 ICL 结构化。小数据可达（HOST 只用 193k 轨迹 + 5.8k 人类视频），完全开源。
- 上下文扩展派 (RoboTTT、ICRT)：**把 LLM 的长上下文/TTT 技术搬到机器人。RoboTTT 用 TTT 快权重（每个传感器读数触发内部小模型一次梯度步，把历史压缩进权重空间）把上下文从约 10 timestep 扩到 8,000（30Hz 下约 5 分钟），推理成本不变；8K 上下文预训练比 1K 好 62%，比单步基线好 87%，且 context scaling curve 无饱和迹象。
- VLA 加装派 (RICL、BPP)：**不动预训练 VLA 基座，通过 retraining recipe 后装 ICL 能力。工程上最务实——所有已部署的 π_0 /OpenVLA 类模型都可以走这条路升级。

判断：四条路线会合流。终局形态大概率是「大规模预训练基座（涌现派的数据）+ 显式对齐结构（架构派的归纳偏置）+ TTT 长上下文（扩展派的机制）」的混合体。RoboTTT 已经是雏形——它把 ICL 和梯度更新的界限直接消掉了：上下文处理本身就是梯度步。

2026 年 7-8 月的四篇 EICL 论文把实现空间切得更细（详见第 12/14/15 号报告与第 05 号 RoboTTT 报告）。两个维度：演示最终改变了什么（写进快权重 vs 停留在输入里）× 适应发生在何时（部署前一次 vs

每步 vs 不适应)。四篇各占一格零重叠：WAM-TTT（快权重·感知侧·部署前一次）、RoboTTT（快权重·动作侧·每步递归）、StellaVLA（纯上下文·结构化语言·真零梯度）、Zero-WAM（纯上下文·合成人类视频·零梯度）。GEN-1.5 与 S1 主张的路线落在「纯上下文·零梯度」一格，与 Zero-WAM 最近——而恰是 Zero-WAM 的消融证明了这一格需要反捷径机制才能成立。四篇互相知晓却零直接对比，「三种上下文接口同台对照」是当前边际信息量最高的空缺实验。

趋势二：上下文长度成为机器人 scaling 的新轴

GEN-0 证明了数据轴（27 万小时→幂律），GEN-1.5 的 30 秒记忆窗口装下一段演示，RoboTTT 则把「上下文长度」独立成第三条 scaling 轴：128→8K timestep 单调提升闭环性能、无饱和。Jim Fan 的表述值得记录："What LLM enjoys, robotics should too. Soon, even 1M context is not a fantasy."

上下文变长的直接后果：能装进上下文的东西从「一段演示」变成「多段演示 + 自己的执行历史 + 纠错记录」。RoboTTT 已展示 on-the-fly self-improvement——机器人中途失败后的自我修正会进入上下文、改进后续动作。上下文即记忆，记忆即学习。

趋势三：数据路线四分天下，人类数据 scaling law 已被量化

「数据从哪来」是当前最重要的产业分歧，四条路线的 2026 版图：

路线	代表	规模	优势	短板
穿戴设备/手持夹爪	Generalist (GEN 系)	50 万小时，每周 +1 万	高保真动作标签、天然高速	私有、成本数千美元级
第一人称人类视频	EgoScale、EgoSteer	EgoScale 20,854 小时；公开 ego 视频存量约 11.6 万小时	log-linear scaling law 已验证；embodiment-agnostic motor prior	需 4D 重建提取动作，误差累积
合成/重定向	Ego2Robot	18,561 小时、15 种机器人形态	一次采集多形态复用	渲染真实差距
人类视频直接条件化	HOST、Vid2Robot	HOST 仅 5.8k 段	零标注、用户可产生	无力信息、依赖对齐质量
合成人-机配对	Zero-WAM (HumanGen)	74.2K 对 / 8.6K 任务 / >45 本体	任务覆盖比 RH20T 高约 25 倍、零人工标注	全合成、真实性未评估、依赖闭源商业模式

EgoScale 的贡献是把第二条路线的收益变成可预测的：人类数据规模 vs 验证损失呈 log-linear，且验证损失强相关于真机性能——22-DoF 灵巧手 +54%（对比无预训练）。这意味着人类视频数据的采购决策可以像 GEN-0 的机器人数据一样精算了。

趋势四：涌现 vs 设计——LLM 的辩论在具身领域重演，现在是三方格局

Sutton 的 bitter lesson 预言通用方法+算力终将碾压手工设计。GEN-1.5 是教科书式的涌现叙事（强调无架构改动、无 meta-learning 循环、无辅助目标），S1 的措辞稍缓但同样把能力归因于任务多样性与规

模。但 HOST 用 1/100 量级的数据靠归纳偏置达到了同等成功率——在数据受限机制下，设计仍然是不可替代的杠杆。

2026 年 8 月之后，这个二元对立升级成了三方格局（完整论证见第 16 号报告）：

1. **涌现叙事（产业侧）**：GEN-1.5/S1，证据是 demo 视频与内部曲线，规模不可复现；
2. **机制证据（学术侧）**：四篇 EICL 论文的消融全部反对免费涌现——WAM-TTT 去 meta-training 从 100.0 掉到 9.0；RoboTTT 去 sequence action forcing 训不出来；StellaVLA 需要整条离线结构化流水线；Zero-WAM 最致命，它是路线上最接近产业博客的一篇（大规模预训练+纯上下文+零梯度），但没有 IFP 反捷径目标时往上下文加人类视频是净负收益（28.55 vs 39.44）。公平的限定：四篇的规模都远低于产业（最大 15,360 GPU 小时 vs 50 万小时数据），严格结论是「在学术可负担的规模上需要显式机制」；
3. **度量质疑（尚无人做）**：Schaeffer et al. 2023 证明 LLM 的「涌现」很大程度是不连续度量制造的海市蜃楼。机器人的二元成功率和 rubric 完成分恰是这类度量；S1 自己公布的 scaling 曲线（1k→100k 小时差距平滑指数扩大）反而更像连续改进而非相变。把度量批判搬进具身领域是当前空白。

原有的信息论判断仍然成立且被 S1 加强：HOST 62%、GEN-1.5 59%、S1 66% 落在同一区间（口径不可比，但量级一致），**one-shot 学习的瓶颈可能已经不在方法，而在信息论层面**——一段演示视频本身承载的任务信息有上限（初始条件覆盖、力信息缺失、意图歧义）。下一波提升更可能来自：(a) 多模态提示（视频+语言+力反馈）；(b) 交互式澄清（执行中请求补充演示）；(c) 提示组合（GEN-1.5 的 prompt chaining、S1 的长时程组合已是雏形）。

趋势五：评测严重滞后，「62%」和「59%」不可直接比

- GEN-1.5：10 个任务、试验次数未披露、任务自选、无第三方复核；
- S1：内部 benchmark、任务清单未公开；长时程「累计逐步成功率」允许人工干预恢复计分（博客自述主要为救语言基线，否则基线为零），66% 不能读成无干预端到端完成率；
- HOST：50 个任务、每任务 20 试验、13 个基线对照，但平台单一（ARX R5 双臂）、成功判定人工；
- 仿真侧 RL Bench-Oneshot (ManiLong-Shot, AAAI 2026) 刚出现：30 任务（10 短程 + 20 长程分三档）、25 试验 × 5 种子，是 OSIL 第一个像样的标准协议，但仿真结果与真机相关性未知。

真机 one-shot 评测没有共同基准，是当前论文数字通胀的根源。谁先建立被广泛采纳的真机 OSVI 评测协议（固定任务集 + 固定扰动协议 + 第三方复核），谁就拿到定义领域进展的话语权。

趋势六：开源在加速吃掉先发优势

2026 年的开源节奏：AgiBot World 数据集（智元）→ Wall-OSS/Wall-OSS-0.5（自变量）→ X-Tokenizer（自变量，SRQ 动作分词器）→ EgoSmith 数据流水线（开源，9 倍于 HaWoR 吞吐）→ HOST 全栈（论文+代码+权重）。闭源阵营只剩数据壁垒（Generalist 的 50 万小时、Physical Intelligence 的采集网络）。

自变量的策略清晰可读：用开源抢生态位。HOST 开源意味着任何拥有中等规模机器人数据（10 万条轨迹级）的团队都能复刻推理时技能获取——这直接把「one-shot 能力」从竞争壁垒降格为公共基础设施，逼迫闭源玩家在数据规模和工程系统上继续拉开差距。

3. 七条核心洞察

Insight 1: 技能的存储位置从参数空间迁移到上下文空间，技能因此变成资产。 HOST 的技能库=视频库（外部记忆，检索复用，永不遗忘）；GEN-1.5 的技能=物理提示片段（可拖放、可组合）。当技能不再固化在权重里，它就变成了可存储、可传播、可交易的数字资产。可预见的衍生形态：机器人技能商店（上传一段演示视频=发布一个技能）、技能版本管理、跨机器人技能市场。灾难性遗忘这个困扰持续学习二十年的问题，被「技能外置」直接架空而非解决。

Insight 2: physical prompt engineering 会成为真实工种。 GEN-1.5 已有拖放式提示界面；提示的选择（哪 3-12 秒）、组合（A+B 串联）、质量（视角/速度/清晰度）显著影响成功率。类比 2021-2023 年 LLM prompt 工程师的出现轨迹，12-24 个月内会出现：物理提示设计指南、提示库标准格式、提示质量自动评估工具。HOST 的检索阈值 δ 调优就是这个工种的雏形工作内容。

Insight 3: ICL 与梯度适应的边界正在消失。 GEN-1.5 的 1 梯度步（权重变化 $<0.15\%$ ）效果接近 ICL；RoboTTT 干脆把「处理上下文」实现为「对内部快权重做梯度步」。二者是同一枚硬币：都是把新信息以极低成本注入模型。理论含义：ICL 可能本来就是隐式的元优化（LLM 文献已有此论），机器人给了这个假说一个物理验证场。工程含义：未来的适应接口不会区分「提示」和「微调」，只有一个连续的「适应预算」旋钮（0 步=纯 ICL，1-10 步=轻适应，1000+ 步=后训练冲精通）。

Insight 4: one-shot 的下一个瓶颈是信息，不是算法。 59-62% 的汇合（趋势四）+ HOST 扰动实验（人为干扰只掉 9%）说明现有方法已经能高效榨取单段视频的信息。剩下 38% 失败里，相当比例来自视频根本没携带的信息：接触力大小、被遮挡的接触点、演示者的隐含意图（「轻放」还是「随便放」）。三个补救方向都已有先行者：触觉手套采集（HOST 作者自己提的方向）、多模态提示融合、执行中交互式请求补充演示。

Insight 5: 「跟随演示」与「跨具身翻译」的解耦是可推广的方法论。 HOST 两阶段训练（193k 同具身对预训练「跟随」+ 5.8k 跨域对适配「翻译」，配比 33:1）本质上发现了：模仿能力的大头可以从廉价数据学，昂贵的配对数据只需教「翻译」。EgoScale 独立验证了同构配方（human 预训练 + aligned mid-training）。这个模式适用于一切跨域模仿设定——仿真到真机、机器人到机器人、甚至动画到机器人。

Insight 6: 具身对齐将从脚注变成独立研究方向。 GEN-1 首次把它说透：涌现即兴是能力也是风险（机器人自发「整理」你故意摆的东西）。ICL 加剧了这个问题——技能来自用户随手拍的视频，模型对「不该做什么」的理解为零。物理世界没有 undo。预计 12 个月内出现第一批「physical prompt injection」攻击研究（恶意演示视频诱导危险行为）和对应的提示过滤/行为约束工作。

Insight 7: 中国团队第一次在范式定义层面与美国头部并跑。 此前中国具身智能的叙事是「跟随+工程化」（复现 $\pi 0$ 、复现 RT-2）。HOST 是范式级原创：问题定义（推理时技能获取 vs 训练时循环）、机制设计（进度流形+自接地级联）、评测口径（50 任务+遗忘验证）都是第一手的，且抢在 GEN-1.5 博客前几天开源。自变量「模型全家桶 + 关键能力开源」的打法，对照 Generalist 「数据引擎 + 全闭源」，是两种生态战略的对照实验，值得持续跟踪。

Insight 8: 四篇 EICL 论文的失败是互补的，右上角空缺正是家用场景。 把任务时长与分布漂移当两个坐标轴：StellaVLA 固定前缀无法在执行漂移后重新规划（长时程 L1 仅 0.02）；WAM-TTT 快权重执行时冻结，处理不了突发扰动；RoboTTT 场景相机本体全程固定，从未面对真分布漂移；Zero-WAM 从未测过未见环境。四篇各守一条漂移轴、无一同时打下两条，「长时程 × 分布外」的右上角只有 S1 的不可复核博客宣称覆盖。三条被独立验证的共同经验值得所有后来者抄录：人类信息只许改写感知/生成侧、不许直接触碰动作侧；训练期挂辅助目标、推理期整个剥离（辅助必须监督主分支否则剥离后一场空）；上下文不是免费午餐，模型一定走捷径（三篇在三个不同设定下独立撞进同一个坑）。

4. 可证伪的预测（12–24 个月）

1. **2027 年中前出现 1M timestep 上下文的机器人模型**（RoboTTT 路线延伸，Jim Fan 已预告）。
2. **物理提示标准格式出现**：类似 LLM 的 ChatML，会有一个「演示片段+传感器流+元数据」的封装格式被 2 家以上机构采纳。
3. **真机 OSVI 标准评测协议建立**：固定任务集+扰动协议+第三方复核，HOST 的 50 任务集是最可能的种子。
4. **one-shot 成功率在 12 个月内突破 80%**（多模态提示 + 交互式澄清驱动，非纯 ICL 改进）。
5. **第一起 physical prompt injection 安全研究发表**，具身对齐成为独立 workshop 议题。
6. **技能视频库产品化**：至少一家公司推出「录视频→机器人技能」的消费级/企业级产品（自变量是最近的候选）。
7. **涌现之争迎来裁决实验**：有机构在产业规模（≥10 万小时）预训练上做一次去机制消融，或有人把 Schaeffer 式连续度量分析应用于具身 scaling 曲线；无论结果偏向哪边，「具身 ICL 是否免费涌现」将从修辞之争变成实证问题。

5. 开放问题清单（研究机会）

- **非单调演示**：SDTW 单调假设失效的任务（含重试、可选分支、循环子任务）如何对齐？
- **力信息缺口**：纯视觉演示如何推断接触力策略？触觉手套数据能否以 HOST 的 33:1 模式低成本融入？
- **长程组合的自动分解**：GEN-1.5 的 prompt chaining 靠人工选段；谁来自动把长任务分解成提示库里的原子技能？（ManiLong-Shot 的 VLM 交互分解是仿真侧的初步答案）
- **ICL 技能的脆性根源**：GEN-1.5 承认 ICL 技能比微调脆；脆在哪（视觉分布？动作精度？时序漂移？）缺乏系统研究。
- **上下文 vs 参数的容量边界**：技能外置到上下文后，模型参数里到底存了什么？哪些技能成分必须进权重？
- **评测的初始条件协议**：20 次试验的「随机初始位姿」各家定义不同，扰动幅度需要标准化度量。
- **三种上下文接口同台对照**：结构化文本（StellaVLA）、合成视频（Zero-WAM）、快权重记忆（WAM-TTT）从未在同一 backbone、同一数据、同一评测上并排跑过——四篇互相知晓却零对比，这是边际信息量最高的单个实验。

- **常量前缀 + 递归状态的叠加**：Zero-WAM 解决未见任务但长时程崩，RoboTTT 解决长时程但场景固定；一个占输入前缀、一个占递归状态，架构上不冲突，无人组合。
- **合成演示训练、真实演示测试**：Zero-WAM 的人类视频 100% 合成且从未测过真实视频输入，这是它落地要撞的第一堵墙，也是所有合成配对路线的共同盲区。