

# 机器人 One-Shot 技能习得 调研全文报告

HOST (arXiv 2607.20033) × GEN-1.5 × S1 及同期 70+ 项工作的深度解读与趋势洞察

从「训练问题」到「提示问题」的范式拐点，以及「涌现 vs 机制」之争

调研日期：2026-08-31 (增补 S1 与四篇 EICL 论文后修订)

论文范围：HOST · GEN-0/1/1.5 · S1 · LocoFormer · Instant Policy · ICRT · RoboTTT · WAM-TTT · StellaVLA · Zero-WAM · LingBot-VA(v1/v2) · BPP · RICL · Vid2Robot · ViVLA ·  $\pi$ 0.5 · Wall-OSS · EgoScale · EgoWAM · WALL-WM · GR-3 · ManiLong-Shot · FACTR 2 · Fast-WAM · UniPi · V-JEPA 2 · Cosmos · OpenVLA ·  $\pi$ 0 · GR00T N1 · Duan 2017 · Finn 2017 · IMOP · Diffusion Policy · ACT/ALOHA · UMI · RH20T · Ego2Robot · DreamZero · Motus · DVA · Genie · LAPA · UniVLA · HumanPlus · EgoMimic · PH2D · LIBERO · RoboTwin 2.0 · OXE · Data Scaling Laws · BadRobot · RoboPAIR · AdvVLA · Contextual Backdoor · BadVLA · State Backdoor · RT-Trajectory · ATM · Im2Flow2Act · Code as Policies · VoxPoser · ReKep · Behavior Retrieval · STRAP · AgiBot GO-1 (背景与理论：DT / Prompt-DT / Algorithm Distillation / GPT-3 / 涌现 / Mirage / 贝叶斯 ICL / Induction Heads / ICL $\equiv$ GD / TTT 层)

配套材料：67 篇论文中英对照 PDF · 25 页汇总 PPT (survey\_slides.html / .pdf)

# 目录

---

1. HOST 深度解读：机器人从一段人类视频里秒级习得操作技能
2. GEN 系列深度解读：Generalist AI 的具身基础模型三部曲
3. Instant Policy 深度解读：把 in-context 模仿学习变成图扩散，用仿真伪演示喂出即时策略
4. ICRT 深度解读：next-token prediction 原教旨主义的机器人 in-context learning 配方
5. RoboTTT 深度解读：把 Test-Time Training 装进机器人策略，上下文扩到 8K 步
6. BPP 深度解读：一条演示当 prompt，任务多样性是 in-context 操作的第一驱动力
7. RICL 深度解读：给预训练 VLA 事后注入 in-context 学习能力
8. Vid2Robot 深度解读：端到端视频条件策略的 Google 规模实践
9. 外围论文速览：one-shot 技能习得调研的五个坐标
10. EgoWAM 深度解读：换掉世界预测目标，人类数据才不「漏毒」进动作头
11. Zero-WAM 深度解读：把人类视频「造」出来当任务规格，再用 IFP 逼模型真的去看
12. WALL-WM 深度解读：把世界-动作建模「循事件关节」下刀
13. WAM-TTT 深度解读：把人类演示写进快权重记忆，且只许写在感知侧
14. StellaVLA 深度解读：把演示翻译成「为什么」，四篇里唯一真零梯度
15. S1 与「涌现之争」：2026 年 8 月具身 ICL 三连发的完整拼图
16. LocoFormer 深度解读：S1 的前夜——上下文当适应机制在运动控制域先走通
17. FACTR 2 深度解读：一篇力感知论文，如何被 S1 借去质疑预训练
18. LingBot-VA 两代深度解读：把「测试时想象」坚持到底的世界-动作模型
19. GR-3 深度解读：few-shot 微调流派的工业标杆，ICL 要消灭的正是它
20. ManiLong-Shot 深度解读：OSIL 第一个像样的公开基准，和一个 30.2% 的现实
21. ICL 机制理论四篇合集：涌现之争吵的那个东西，理论上到底是什么
22. 世界模型谱系三篇合集：从像素想象到表征预测再到平台化
23. 基座 VLA 三篇合集：ICL 工作站在谁的肩上
24. One-Shot 模仿学习源头三篇合集：2017 年就有的问题，2026 年为什么才成

- 25. 生成式动作头奠基两篇合集：为什么 ICL 时代的机器人策略都是生成模型
- 26. 人类数据管线三篇合集：ICL 的燃料从哪来——UMI、RH20T、Ego2Robot
- 27. 视频-动作模型同代对照组三篇合集：WAM 战场的其他玩家
- 28. 潜动作桥梁三篇合集：无动作视频怎么变成可训练的动作信号
- 29. 上下文强化学习前史三篇合集：把控制写成序列建模，再把演示写成 prompt
- 30. 人类视频共训三篇合集：把人类数据写进权重的显式路线
- 31. 评测基准与数据地基四篇合集：数字的口径从哪来
- 32. 具身安全与提示注入合集：当技能接口开放给任意视频，攻击面在哪
- 33. 演示的另一种编码三篇合集：轨迹草图、点轨迹、物体光流当提示
- 34. 规划层 ICL 三篇合集：LLM 自己的 few-shot 能力，直接拿来控机器人
- 35. 检索增强与技能库三篇合集：上下文从哪里来——非参数记忆与 ICL 的边界
- 36. 趋势与洞察：机器人 One-Shot 技能习得的 2026 拐点

# HOST 深度解读：机器人从一段人类视频里秒级习得操作技能

HOST: Robots Acquire Manipulation Skills in Seconds from a Single Human Video arXiv 2607.20033v4

(2026-08-20 更新) · 北京理工大学 + X SQUARE ROBOT (自变量机器人) + 清华大学 作者: Guangyan Chen 等; 项目负责: Xiaofan Li; 通讯: Hao Wang、Mengyin Fu、Yi Yang、Yufeng Yue 2026-08-03 起论文、代码、模型权重全部开源 (GitHub / HuggingFace)

## 1. 一句话定位

HOST 把「教机器人一个新技能」从训练环节挪到了推理环节：给一段人类演示视频（不需要遥操作、不需要微调、不更新任何参数），机器人平均 29 秒后就能执行这个新任务，50 个未见任务平均成功率 62%，同时已掌握的旧技能一点不丢。

对照今天的主流做法——每个新任务先遥操作采集几十条演示、再离线微调几小时、还会把旧技能冲掉——HOST 相当于把「学费」从 4.0–4.9 小时/任务压到 29 秒/任务（507 倍加速），把数据需求从 50 条机器人演示压到 1 段人类视频（50 倍缩减），成功率还反超微调基线 6 个百分点（62% vs Wall-OSS+SFT 的 56%）。

## 2. 要解决的问题：训练环节循环的三重代价

当前教机器人新技能的标准流程是一个「训练环节循环」(training-time loop)：

- 贵**：熟练操作员遥操作实体机器人采集专用演示，消耗专家人力和稀缺的机器人时间；
- 慢**：离线微调把演示灌进策略要几个小时，新技能才可用；
- 自毁**：微调覆写跨技能共享的参数，每学一个新技能都会侵蚀旧技能（灾难性遗忘）。论文实测： $\pi 0.5$ +SFT 微调后旧任务只保留 20% 原性能，HOST-base+SFT 保留 22%，最好的 Wall-OSS+SFT 也只保留 43%。

强化学习路线更不可行：任务特定奖励在实体机器人上难设计、交互慢、样本效率低，而且同样会退化旧技能。

人类的对照组是显性的：看别人做一遍，把观察到的动作适配到自己身体上，不需要反复物理排练。这个设定在学术上叫 one-shot visual imitation (OSVI)，可以追溯到 Kuniyoshi 1994 年的「learning by watching」愿景，但三十年来一直没做通——此前最强 OSVI 方法在 HOST 的评测里只有 19% 成功率（HOST 62%，+43%）。

## 3. 为什么 OSVI 一直做不通：视频与执行的结构性错配

论文对失败根源的分析是全文最有洞察力的部分。以往方法把演示视频当条件输入直接回归动作，预测目标锚定在执行轨迹的固定时间偏移上。这有三个结构性问题：

(1) **时间错位把视频降格为被动上下文。** 视频演示和机器人执行是两个独立进程，速度天然不同步。把预测目标绑定在机器人轨迹的固定时间偏移上，等于让目标和视频内容解耦——模型学到的是「忽略视频照常预测」，推理时自然无法从新视频里学到新技能。

(2) **状态差异阻碍行为到动作的转译。** 整段视频一次性喂给模型，充斥着与当前阶段无关的状态；即使在对应片段上，人类视频和机器人轨迹在具身、视角、外观上差异巨大。从高维视频直接回归低维动作，模型要一步跨过所有这些鸿沟。

(3) **成对监督稀缺。** 人类视频很多、机器人轨迹也很多，但「同一行为的人类-机器人配对数据」极少，可靠的跨具身技能习得学不出来。

## 4. HOST 的两大机制

### 4.1 机制一：把预测目标耦合到演示上 (Target Coupling)

核心思想：预测目标不再是「执行轨迹上固定时间偏移处的片段」，而是「与视频未来进展逐步对应的机器人轨迹动态片段」——视频从被动条件变成预测的主动驱动者。

实现靠一个自监督对齐模块，把视频演示和机器人轨迹映射到**共享任务进度流形**上：

- 帧嵌入模型基于 Qwen3-VL-Embedding-8B，端到端训练，多视角观测拼成图像序列，取 [EOS] 位置隐状态经线性投影 + L2 归一化得到帧嵌入；
- 用负平方 L2 距离建相似度矩阵，列向 log-softmax 归一化成代价矩阵；
- **Smooth DTW**（可微分动态时间规整）前向-后向动态规划恢复单调软匹配概率，配合**时间循环一致性损失 (TCC)**（每帧经软最近邻循环回自身，惩罚偏差）和 DTW 全局对齐损失，完全不需要帧级标注；
- 得到双向帧对应后，对机器人时刻  $t$ ：先映射到视频对应帧，取视频后续  $H$  帧，再映射回机器人轨迹，得到的  $H$  个机器人时刻片段就是预测目标。

对齐质量的硬数字：按时钟时间匹配的进度误差为  $0.079 \pm 0.062$ ，进度流形对齐为  $0.006 \pm 0.008$ ，一个数量级的改善（以人工标注事件为参照）。

消融链条证明每个成分都必要（50 个新任务平均成功率）：

- 整段视频直接条件化：0.21
- 按时间戳选窗口：0.29
- 按任务进度选窗口：0.45
- 目标耦合到视频未来进展（完整机制）：**0.62**

### 4.2 机制二：自接地预测级联 (Self-Grounded Prediction)

模仿人类观察学习的认知级联（检索任务相关片段→内部模拟动作→转译为执行），HOST 把执行拆成单一自回归扩散模型内的三级因果级联：

1. **定位**：机器人当前处在演示流程的哪个阶段（输出标量进度  $p$ ）；

2. **未来观测预测**：把视频即将发生的进展转译成**机器人自己视角、自己具身**的未来观测（这一步完成跨域翻译）；
3. **动作生成**：从预测的未来观测导出动作。

关键架构细节：

- 所有视觉元素（视频窗口、近期机器人观测、目标未来观测）用 **Wan VAE** 编码到共享隐空间；
- 主干是**双专家 Mixture-of-Transformers**：视频专家从 Wan2.2 视频扩散模型初始化（负责定位+未来观测预测），动作专家同深度但更窄（动作分布复杂度低）；两专家在每层拼接 QKV 共享自注意力，FFN 各自独立；
- 语言指令经 UMT5-XXL 编码 + 本体状态投影，作为每层 cross-attention 条件；
- **自回归 flow matching**：每个生成目标表示为（噪声 token，干净 token）对，因果注意力掩码强制  $p \rightarrow o \rightarrow a$  顺序，训练时干净 token 用真值（detach 梯度）+ 小幅高斯噪声弥合训练-推理差距，三个目标在单次前向里联合优化；
- 推理时视频窗口按预测进度自主推进（ $w_{t+1} = \text{定位帧} - L/2$ ），执行 H 步动作块后进入下一轮。

消融链条（同样 50 任务）：

- 视频直接映射动作（保留目标耦合）：0.34
  - 定位级：0.43
  - 视觉预测级（与动作并行）：0.55
  - 因果级联（动作从预测观测导出）：**0.62**

两条消融融合起来读：**目标耦合贡献 0.21→0.62 里的大头，级联在耦合基础上再贡献 0.34→0.62**。定位精度 MAE 0.013（归一化进度），预测的未来观测能跨物体外观和初始配置变化保持准确。

#### 4.3 两阶段训练：绕开成对数据稀缺

- **Stage 1（同具身预训练）**：193,462 条机器人轨迹、229 个任务。同任务的不同 episode 天然构成「演示-执行」对（一条当视频，另一条提供目标观测和动作），教会模型「跟随演示流程」的能力，完全不涉及跨具身。
- **Stage 2（跨具身适配）**：5,847 条自采人类视频，与同任务机器人轨迹配对。目标仍来自机器人轨迹，只是条件视频换成人类视频。

数据配比是 33:1——同具身数据便宜管够，人类-机器人配对只要一小撮。消融证明 Stage 1 数据量单调提升最终性能，0% Stage 1（只用 Stage 2 数据）性能很差。**这个两阶段设计是 HOST 能落地的工程关键**：它把「跨具身技能习得」这个难题分解成「跟随演示」（数据充裕）+「跨域适配」（数据稀缺但需求量少）。

#### 4.4 技能持久化：视频即技能库

习得的技能以视频形式存在外部记忆里（不写进权重）：每段视频连同指令文本嵌入和初始场景嵌入（均由 Qwen3-VL-Embedding-8B 编码）入库；新任务来了按「指令相似度  $\omega$  + 场景相似度  $(1-\omega)$ 」加权检索，超过阈值  $\delta$  就复用库存视频，否则请求新演示。实测：召回旧任务和识别新任务在很宽的阈值带内同时保持高位；用检索视频执行  $\approx$  用新录视频执行。

这个设计把「持续学习」的灾难性遗忘问题直接架空了——技能在上下文里而不在参数里，自然谈不上遗忘。

## 5. 实验结果全景

平台：双臂 ARX R5（各 6 轴 + 平行夹爪），3 个 RGB 相机（双腕装 + 一个第三人称固定位），20 维双臂动作空间。每任务 20 次试验，随机初始物体位姿，人工判定成功。任务集覆盖放水果、堆碗、擦盘子、插笔等 50 项训练阶段未见的桌面操作。

| 对比对象                          | 条件                  | 成功率         | HOST 优势              |
|-------------------------------|---------------------|-------------|----------------------|
| HOST                          | 1 段人类视频，零参数更新       | 62%         | —                    |
| Vid2Robot / AWDA (OSVI)       | 同样 1 段人类视频          | $\leq 19\%$ | +43%                 |
| $\pi 0.5$ / Wall-OSS (零样本 IL) | 语言指令                | $\leq 17\%$ | +45%                 |
| Wall-OSS+SFT (最强微调基线)         | 50 条遥操作演示 + LoRA 微调 | 56%         | +6%，数据 1/50，速度 507 倍 |

细节值得注意：OSVI 基线的条件机制被移植到 HOST 同款主干上评测（排除主干差异）， $\pi 0.5$  和 Wall-OSS 则从各自大规模预训练权重继续在同一批 193k 轨迹上训练——对比是公平口径。

**鲁棒性**（四种部署扰动下保留大部分性能）：光照/颜色偏移 -1%、未见物体替换 -4%、场景替换 -6%、执行中人为移动物体 -9%。最后一项最有说服力：人在机器人执行中途移动物体，模型的定位级会感知进度倒退，重新对齐视频对应阶段并纠正执行——这是级联结构的直接红利。

## 6. 局限（作者自认 + 延伸批判）

作者列了三条：单一双臂平台未验证跨机器人形态迁移；视频不携带接触力信息，精细操作受限（提出可穿戴触觉手套方向）；技能库检索在指令/场景细微差异时可能混淆。

延伸几条论文没明说的：

- 62% 离部署仍远**。20 次试验的成功判定是人工的，任务多为桌面短程操作；与 GEN-1 后训练后的 99% 相比，one-shot 范式给出的是「快速可用的初始能力」，不是「精通」。二者互补：HOST 类方法快速冷启动，再用 GEN-1 类后训练冲精通。
- 29 秒的口径**是「录制视频 + 推理准备」的均值，不含用户走到机器人面前摆放场景的时间；但即便宽松计算，与 4 小时的差距仍是数量级的。
- 对齐模块依赖任务进度单调性假设**。SDTW 的单调路径约束意味着演示里若有来回往复、可选分支、失败重试，进度流形可能失效——这类非单调任务是天然边界。



4. **Stage 2 的 5,847 条人类视频仍是自采的。**虽然比遥操作便宜得多，但说「彻底摆脱数据采集」还早；真正的下一步是像 Vid2Robot 那样直接吃野生 YouTube 视频。

## 7. 意义与位置

HOST 出现在一个有趣的时间点：同月（2026-08）Generalist AI 发布 GEN-1.5，宣布 one-shot 物理技能学习作为**涌现能力**出现在 50 万小时数据预训练的大模型里。HOST 则证明**不需要那个数据量级**——用聪明的归纳偏置（进度流形对齐 + 自接地级联），193k 机器人轨迹 + 6k 人类视频就能把 one-shot 做到 62%，还比 GEN-1.5 的 59%（10 任务）在更大任务集（50 任务）上略高。

两条路线构成上下界：GEN 系证明数据够大能力自己长出来，HOST 证明数据不够可以靠结构设计补。对绝大多数没有 50 万小时私有数据的团队，HOST 给出的配方是可复制的：先在自己的机器人数据上做同具身「跟随」预训练，再用少量跨域配对适配——这个模式不限于人类视频，理论上可以推广到任何演示模态（仿真轨迹、其他机器人、甚至动画）。

而且这个配方是真开源：2026-08-03 起论文、代码和模型权重全部上线 GitHub（X-Square-Robot 组织）与 HuggingFace。发布方自变量机器人（X SQUARE ROBOT，C 轮）把 HOST 定位为其「推理时技能获取」战略的公开落子——该公司同时维护 WALL-A（百亿级 VLA+世界模型旗舰）、Wall-OSS（开源 VLA，即 HOST 论文里最强微调基线）和 X-Tokenizer（SRQ 动作分词器，2.4M 轨迹预训练）等产品线。学术界拿到的不只是一篇论文，而是一套可以直接跑的推理时技能习得栈。

方法论上最值得借鉴的两点：**把「对齐」从隐式期望变成显式模块**（用 SDTW+TCC 学进度流形，而不是指望 transformer 自己领悟时间对应），以及**把跨域翻译从动作空间挪到观测空间**（先预测「我自己做这件事会看到什么」，再从观测导出动作——比直接回归动作多了一个自我参照的中间表征）。



# GEN 系列深度解读：Generalist AI 的具身基础模型三部曲

GEN-0 (2025-11) · GEN-1 (2026-04) · GEN-1.5 (2026-08) Generalist AI (官方博客发布, 非 arXiv 论文) 原文: [generalistai.com/blog/gen-0](https://generalistai.com/blog/gen-0) · [/gen-1](https://generalistai.com/blog/gen-1) · [/gen-1.5](https://generalistai.com/blog/gen-1.5)

## 1. 一句话定位

GEN 系列用九个月时间把机器人学习从「验证 scaling law 存在」(GEN-0) 推到「简单任务 99% 精通」(GEN-1), 再推到「one-shot 上下文学习涌现」(GEN-1.5) ——最后这一步意味着: 给模型看 3-12 秒的一段演示, 不做任何梯度更新, 机器人几秒钟后就开始执行新任务, 10 个任务平均成功率 59%。

这是目前唯一一条公开验证了「物理交互数据规模化预训练 → 类 GPT-3 涌现能力」完整路径的工作线。GPT-3 当年靠 few-shot prompting 宣告语言模型进入基础模型时代; GEN-1.5 试图为机器人复刻同一时刻——他们自己称之为 "physical prompting" (物理提示)。

## 2. 三部曲时间线：每一代解决一个问题

| 代际      | 发布      | 数据规模         | 核心命题                      | 关键数字                                                          |
|---------|---------|--------------|---------------------------|---------------------------------------------------------------|
| GEN-0   | 2025-11 | 27 万小时真实操作数据 | 机器人存在 scaling law 吗? ——存在 | 7B 参数出现「智能相变」; 每周新增 1 万小时数据                                   |
| GEN-1   | 2026-04 | 50 万+ 小时     | 规模化能到商用精度吗? ——能           | 6 任务平均 99% 成功率 (GEN-0 基线 64%); 速度 3 倍于 SOTA; 每任务只需约 1 小时机器人数据 |
| GEN-1.5 | 2026-08 | 持续预训练 8 个月   | 适应成本能压到零吗? ——接近零          | one-shot in-context 59%; 10 梯度步 + 5 分钟数据 83%; 权重变化 <0.15%     |

三代模型背后是同一台「数据引擎」: 不用遥操作、不用仿真, 而是给人类戴上低成本手持夹爪设备, 在上千个家庭、仓库、工厂里采集日常操作活动。GEN-0 时是 27 万小时, GEN-1 时超 50 万小时, 采集速度每周 1 万小时且在加速。预训练数据里**没有一条机器人数据**——机器人执行是靠人类数据预训练 + 少量后训练迁移出来的。

## 3. GEN-0：机器人版 scaling law 与「智能相变」

### 3.1 主张

GEN-0 是直接在高保真物理交互数据上做多模态训练的具身基础模型, 架构原生面向「人类级反射与物理常识」设计。核心机制叫 **Harmonic Reasoning (谐波推理)**: 感知 token 流和动作 token 流异步、连续时间地交织训练——物理世界不会暂停等你思考, 所以模型必须边想边动。这让它不依赖 System1/System2 双系统架构就能扩展到大参数量。

### 3.2 最重要的发现：7B 相变 (ossification)

- **1B 模型**：预训练中出现「骨化」（ossification）——权重逐渐丧失吸收新信息的能力，数据越喂越多，模型反而卡死。
- **6B 模型**：开始受益于预训练，多任务能力显现。
- **7B+ 模型**：能内化大规模机器人预训练数据，下游任务只需几千步后训练。

这是机器人领域首次观察到 ossification。LLM 文献里这个现象出现在  $O(10M)$  参数量级，机器人却要  $O(1B)$  才跨过门槛——作者用 Moravec 悖论解释：人类觉得毫不费力的感知与灵巧操作，计算复杂度远高于抽象推理。**物理智能的「激活阈值」比语言智能高一个数量级以上**。这个观察对整个行业有定价意义：低于 7B 的端侧小模型路线在高数据机制下可能存在天花板。

### 3.3 可预测的 scaling law

固定下游任务和微调预算，验证误差随预训练数据量  $D$  呈幂律： $L(D) = (D_c/D)^\alpha$ 。这让「还要采多少数据才能到目标性能」变成可计算问题——例如服装整理任务，给定 10 亿条动作轨迹就能预测模型表现。16 个任务集（乐高搭建、快餐打包、“anything”类泛化任务）全部单调受益于更多预训练。

真机 A/B 盲测确认趋势外推到实体：仅用 5.6 小时任务数据后训练，预训练越多成功率越高；预训练 + 550 小时任务数据时部分任务峰值达 99%。

### 3.4 数据科学细节

大规模消融的结论是**质量和多样性比体量重要**。他们把数据按采集模式分类（Class 1 特定任务 / Class 3 自由活动 / Class 2 介于两者），跨数据供应商 A/B 测试，用两个指标筛数据：验证 MSE（低→适合 SFT）和 reverse KL（低→分布多峰、适合 RL 后训练）。数据引擎每天能吸收 6.85 年的真实世界操作经验。

## 4. GEN-1：把「精通」定义成可测量的三件事

### 4.1 Mastery = 可靠性 × 速度 × 即兴智能

GEN-1 的贡献不在架构（仍是 GEN-0 基础的继续 scaling + 算法改进），而在证明了规模化路线能跨过**商用门槛**，并把「精通」操作化为三个可测维度：

**可靠性**：6 个任务平均 99% 成功率。对照：GEN-0 微调 64%，从头训练 19%。实测视频包括连续 1 小时汽车零件配套、连续折 86 件 T 恤、连续 200+ 次维护扫地机器人、连续 1800 次装箱、连续 200 次折纸箱、连续 100 次装手机——全程无人工干预。

**速度**：折纸箱 12.1 秒，此前 SOTA（GEN-0 和  $\pi 0$  在相同纸箱上）约 34 秒，快 2.8 倍。关键是模型能**超过演示速度**执行——速度提升来自经验学习（RL）+ Harmonic Reasoning 推理演进 + 数据引擎天然包含高速人类操作（遥操作数据因延迟和缺乏力反馈天然偏慢，人类穿戴设备数据没有这个问题）。

**即兴智能**：垫圈被碰离抓取位置时，模型会放回重抓、或部分插入槽位借助外部灵巧性（extrinsic dexterity）调整、或换另一只手双手协同重抓——这些行为都在训练分布之外。

### 4.2 值得注意的工程事实

- 每个 99% 任务只用了约 1 小时机器人数据。预训练零机器人数据，所以后训练是同时在适应「这个任务」和「这台机器人」。
- GEN-1 是「系统」而非单纯权重：推理基础设施（自研 paged attention 变体支撑实时推理）、后训练技术（RL + 多模态人类引导）、模型 harness 共同贡献性能。
- 数据效率：某些测试中 GEN-1 用 1/10 的任务数据和微调步数达到 GEN-0 同等性能。

### 4.3 GEN-1 提出的新问题：具身对齐

涌现即兴是双刃剑：模型会自发「抖动袋子让物体归位」「重新整理放错物品」——但物理动作有真实后果，机器人的「成功」定义是任务、工作流、用户三层特定的。**不该做什么和该做什么同样重要**。这段讨论预示了具身模型的对齐研究会成为独立方向。

## 5. GEN-1.5: one-shot 学习涌现——机器人的 GPT-3 时刻

### 5.1 能力清单

GEN-1.5 是一个处理视频输入（30 秒记忆窗口 + 传感器 + 语言 + 本体感知）、输出 100Hz 动作轨迹的大型多模态模型。它展示的能力：

1. **One-shot 上下文学习**：3-12 秒单段演示插入上下文窗口，无训练，几秒后开始执行。10 个任务（拉链、开罐、从钱包取钱等）平均成功率 59% ( $\pm 10\%$ )。
2. **组合泛化**：两个独立录制的物理提示放进上下文，模型自动串成连续长程行为，中间的重定位、换抓、纠错动作**两段演示里都没有**。
3. **零样本 sim-to-real**：预训练完全没有仿真数据，但仿真里录的演示（脚本策略 / RL agent / 仿真遥操作）可以直接提示真机执行，且泛化到不同手、新物体位置与尺寸。
4. **人类到机器人 ICL**：某些情况下人直接用自己的手在机器人相机前演示，机器人立刻复现——跨具身差距的上下文迁移。
5. **极少梯度步适应**：1-10 步梯度下降 + 1-5 分钟数据（约 10-50 条演示）即可微调新任务。10 步 + 5 分钟数据达 83% ( $\pm 9\%$ )；极限 1 步 + 1 分钟数据达 66.5%。
6. **工具即兴**：微调「用刷子扫积木进碗」后，给香蕉会拿香蕉当刷子；给簸箕会改变策略——用簸箕铲起积木倒进碗里。这个接触序列在微调数据和预训练数据里都不存在（他们用语言最近邻搜索在 189 万个场景里核对过）。

### 5.2 最关键的科学事实：这些能力是涌现的，不是设计的

原文的表述值得逐字记录："We did not explicitly train GEN-1.5 for in-context learning"——没有为 ICL 做架构修改、没有 meta-learning 内外环、没有鼓励即兴的辅助目标、测试任务没有事先工程进预训练数据。物理提示在时间上是不连续的拼接（模型在训练中从未见过这种跳变），但模型能理解并执行。

为什么涌现？博客给了两个假说（均类比语言模型 ICL 文献）：

- 物理观测与动作的分布可能具有 **burstiness 和 Zipfian 结构**（Chan et al. 2022 证明这类数据分布特性驱动 transformer 的 ICL 涌现）；

- 物理劳动包含**自然重复循环**，模型学会了检测并延续模式（类比 Mirchandani et al. 2023 "LLM as general pattern machines"）。

5.3 few-step adaptation 的深层含义

10 个梯度步只改变权重不到 0.15%——作者的解读是：**微调不是在建立新表征，而是在轻微重新配置已有知识**。「更像是提醒模型它几乎已经知道的事，而不是传统意义上的任务训练。」

一个反直觉发现：即兴能力随微调步数减少而**增强**——轻度适应的模型更贴近预训练先验，遇到偏离演示的情形时能调用更广的行为库。这和 LLM 领域「过度微调损伤通用能力」的经验完全同构。

5.4 physical prompt engineering：新的交互范式

拖放界面选择演示片段插入上下文窗口，现场录像展示了背靠背教两个任务（拉开笔袋拉链→取出钱）。组合提示意味着：**长程任务可以从短小可复用的物理提示库里组装**，而不必采集完整复合任务的演示——这是语言 prompt chaining 的物理类比。

6. 批判性评估

**这是博客不是论文**。没有 peer review，没有完整方法细节（模型参数量、上下文编码方式、动作头设计全部未公开），数字无法独立复现。GEN-0 声称的 scaling law 图表没有给出原始数据，GEN-1.5 的 10 任务评测协议（每任务试验次数、初始条件随机化程度）未披露。对照 HOST 论文 50 任务 × 13 基线的公开评测，GEN 系列的证据强度低一档——但其数据规模（50 万小时）和涌现现象的定性展示（视频）又是学术界拿不出来的。

**任务是「简单短视界」的，作者自己承认**。59% 的 one-shot 成功率意味着五分之二的失败率，离部署很远。ICL 学到的技能「比微调模型更脆」。

**私有数据引擎是核心壁垒也是核心不可验证点**。27→50 万小时人类穿戴设备数据，成本量级估计在数千万美元。学术界无法复现这条路线，只能走 HOST 式的「聪明架构弥补数据稀缺」路线——这构成了本调研最重要的产业-学术分野（见 insight 报告）。

**「预训练零机器人数据」的说法要小心读**。预训练全是人类手持夹爪数据，但后训练/微调仍需机器人数据（每任务约 1 小时）。GEN-1.5 的 one-shot 物理提示可以是人类数据，但效果最稳的仍是机器人自身 rollout。

7. 与 HOST 的正面对照

| 维度     | GEN-1.5                   | HOST                     |
|--------|---------------------------|--------------------------|
| 路线     | 大数据涌现（50 万小时私有数据）         | 架构设计（共享任务进度流形 + 自接地预测级联） |
| ICL 机制 | 隐式，从预训练涌现                 | 显式，SDTW 对齐 + 目标耦合设计进架构   |
| 演示形式   | 人类手持夹爪 / 机器人 rollout / 仿真 | 纯人类视频（第三人称 RGB）          |
| 适应耗时   | 秒级（in-context）或 1-10 梯度步  | 平均 29 秒（无梯度更新）           |

| 维度    | GEN-1.5               | HOST                                             |
|-------|-----------------------|--------------------------------------------------|
| 成功率   | 59% (10 任务, one-shot) | 62% (50 任务, one-shot)                            |
| 旧技能保持 | 未量化报告                 | 显式验证不遗忘                                          |
| 可复现性  | 不可 (私有数据+闭源)          | 完全开源 (2026-08-03 起代码+权重上线<br>GitHub/HuggingFace) |
| 证据形式  | 博客 + 视频               | arXiv 论文 + 13 基线对比                               |

两者在 2026 年 8 月同月发布，从两条完全不同的路线逼近同一个目标——「看一次就会」。GEN 证明数据规模足够时该能力自己长出来；HOST 证明数据不够时可以用归纳偏置把它设计出来。这不是竞争关系，是上下界关系：HOST 类方法给出了小数据机制的性能下界，GEN 类方法给出了大数据机制的涌现上界。

## 8. 给从业者的判断

1. **scaling law 在机器人领域成立已是多方验证的事实**（GEN-0、 $\pi$  系列、字节 GR 系列都有印证），争论已转移到「数据从哪来」：人类穿戴设备（Generalist）、遥操作（多数公司）、人类视频（HOST/Vid2Robot 学术线）、仿真（NVIDIA 线）四条数据路线的成本-质量权衡是当前最重要的开放问题。
2. **7B 相变**如果被独立复现，对端侧部署路线是坏消息，对云端推理/蒸馏路线是好消息。
3. **ICL 涌现把「任务适应」从训练问题变成提示工程问题**——physical prompt engineering 可能催生类似 LLM prompt 工程师的新工种，以及「物理提示库」这种新资产形态。
4. GEN-1 强调的**速度维度**（3x SOTA）长期被学术评测忽视——成功率之外，任务完成时间会成为下一个军备竞赛指标。

# Instant Policy 深度解读：把 in-context 模仿学习变成图扩散，用仿真伪演示喂出即时策略

Instant Policy: In-Context Imitation Learning via Graph Diffusion arXiv 2411.12633v2 (2025-04-25 更新) · ICLR 2025 · Imperial College London, The Robot Learning Lab 作者: Vitalis Vosylius, Edward Johns

## 1. 一句话定位

Instant Policy 把「给 1-2 条演示就立即会做新任务」拆成两个可解的子问题：用异构图 + 扩散过程给 In-Context Imitation Learning (ICIL) 注入空间结构归纳偏置，用程序化生成的仿真「伪演示」(pseudo-demonstrations) 提供近乎无限的训练数据。结果是一个基础版完全不碰真实数据的模型，真机 16 个日常任务平均成功率 88.75%，比同数据训练的 BC-Z/Vid2Robot/GPT2 式基线 (34.4%-40.6%) 高一倍以上；每个新任务只需现场动觉示教 1-2 条，零训练、零微调。

## 2. 要解决的问题

ICL 在 NLP/视觉里是海量数据喂出来的涌现能力，机器人没有这个数据条件。要在机器人上做 ICIL，卡在两点：

- 数据效率**：以往 ICIL 方法 (BC-Z 的隐嵌入条件化、Vid2Robot 的 Perceiver + cross-attention、GPT2 式因果序列建模) 把演示当扁平向量或 token 序列处理，3D 空间结构全靠网络自己领悟，数据不够就悟不出来——在本文的 RL Bench 评测里这三类方法平均只有 0.34-0.38；
- 数据来源**：人工采集机器人演示贵且慢，靠真实数据堆不出 ICIL 需要的任务多样性。

作者的关键观察是概念性的：BC 的权重编码「特定任务的策略」，而 ICIL 的权重编码的是「解读上下文并照做」这个任务无关的元能力。所以训练数据不必是真实任务，只需要「语义一致的轨迹集合」——这直接解锁了第二个卡点。

## 3. 方法

### 3.1 表征：三层异构图

**局部图  $G_l$** ：分割点云（降采样到 2048 点、变换到末端执行器坐标系）经最远点采样 + PointNet++ Set Abstraction 编码成  $M=16$  个节点，特征来自一个在 ShapeNet 上预训练、训练策略时冻结的占据网络 (occupancy network) 编码器，保证特征描述局部几何（端到端训练或微调它反而显著变差）。夹爪表示为 6 个刚性变换的关键点节点，特征编码节点身份 + 开合状态。场景节点与夹爪节点连边，边属性用 NeRF 式  $\sin/\cos$  高频位置嵌入表示相对位置。

**上下文图  $G_c$** ：演示轨迹是局部图序列（每条演示降采样到  $L=10$  个 waypoint，保留起止点、夹爪开合切换点和减速点），跨时刻夹爪节点连「相对运动」边，所有演示夹爪节点连到当前观测的夹爪节点。边数随演示条数  $N$  和长度  $L$  线性增长，任意  $N$ 、 $L$  都能处理。



**动作图 Gla:** 未来  $T=8$  步动作 (SE(3) 位移 + 夹爪开合) 表示成「假装执行后」的局部图——把动作的空间后果直接画进图里, 而不是当抽象向量回归。当前与未来夹爪节点之间的边编码相对运动。

### 3.2 学习: 图上的扩散

把 ICIL 建模为图生成: 前向过程在动作上加噪 (SE(3) 经 Logmap 投影到切空间加高斯噪声再 Expmap 回来), 反向过程由异构图 transformer 预测每个夹爪节点的去噪方向  $\varepsilon \in \mathbb{R}^7$ 。三个关键设计:

- **平移/旋转解耦的流 (flow) 表示:** 去噪方向拆成质心平移 + 绕质心旋转两个分量, 避免大平移淹没小旋转。消融: 不解耦 -15%, 换四元数表示 -37%, 换轴角 -21%;
- **SVD 恢复 SE(3):** DDIM 更新节点位置后, 利用已知点对应用 SVD 求出对齐变换作为该步动作更新——动作始终以点集形式存在于图空间, 与观测同构;
- **三级子网络级联  $\sigma \rightarrow \phi \rightarrow \psi$**  (各 2 层、隐维 1024、16 头), 分别负责局部几何传播、上下文汇聚、动作节点更新。换成单个大网络或全连接图 (等价于稠密自注意力 transformer) 都显著变差——结构化信息流是必需品, 不是锦上添花。 $\phi$  的输出在当前观测的夹爪节点上形成信息瓶颈, 后面的下游应用靠它。

扩散本身也不可省: 去掉扩散直接回归动作 -29%。预测时域  $T=1$  时 -52%,  $T=8$  为基准。

### 3.3 数据: 伪演示引擎

生成流程: ShapeNet 随机放 2 个物体  $\rightarrow$  在物体上/附近采样 2-6 个 waypoint 构成「伪任务」 $\rightarrow$  虚拟移动 Robotiq 夹爪网格依次到达、开合时刚性吸附/释放最近物体  $\rightarrow$  PyRender 三个仿真深度相机录制点云。同一伪任务换物体位姿、换起始位姿重复生成, 就得到语义一致的演示集合。轨迹不需要动力学甚至运动学可行——动力学和可行抓取由推理时的真实演示 (上下文) 定义。

细节决定成败: 一半样本偏向常见技能 (抓取、抓放、开合) 采样, 一半全随机; 30% 轨迹注入局部扰动 + 回归参考轨迹的修正动作 (催生恢复行为); 10% 样本翻转当前夹爪状态输入——不加这条, 策略永远学不会松手后重抓。动作归一化到每步  $\leq 1\text{cm}/3^\circ$ 。

训练 2.5M 步 (约等价 700K 条独立轨迹, 边生成边训练、样本不重复), AdamW lr  $1e-5$ 、float16, 单张 RTX 3080-ti 约 5 天。这个成本在同类工作里低得反常。

## 4. 实验结果

**仿真 (RLBench, 24 任务  $\times$  100 rollout, Franka Panda):** 纯伪演示训练平均 0.71, 基线 0.34-0.38。追加 12 个任务各 20 条真演示微调 (PD++) 后, 见过的 12 任务 0.97, 未见的 12 任务 0.82 (基线 0.31-0.43)。注意力可视化显示模型确实在追踪任务阶段并选择性聚合上下文对应片段。

**真机 (Sawyer + Robotiq 2F-85, 2 个 RealSense D415, SAM + XMem++ 分割, 动觉示教):** 16 个日常任务  $\times$  10 rollout, 平均 88.75% (16 项中 7 项 10/10), 对 BC-Z\* 34.38%、Vid2Robot\* 40.63%、GPT2\* 36.88%。基线全部移植到同一点云编码器、同参数量、去掉语言辅助损失, 口径公平。部署前用 5 个评测外任务的演示混合伪演示 co-finetune 了 100K 步以适应真实噪声。



**新几何泛化（涌现能力）：**上下文里放不同几何物体的演示、测试完全没见过的同类物体，成功率随演示数单调上涨：N=1 时 40%，N=2 时 52.5%，N=3 时 85%，N=4 时 90%。训练时从未构造过跨几何上下文——这是图表征 + 结构化注意力的涌现红利。

**Scaling：**69M→117M 参数，平台期成功率显著上升；117M→178M 只有边际改善，瓶颈转移到数据多样性。验证损失随训练算力和容量持续下降。

**推理参数：**扩散步数从 4 砍到 2 只掉 2%；演示长度 L=1（只给最终目标）暴跌 71%，L=5 仍掉 26%——上下文必须够稠密，因为任务信息不在权重里；演示数 N=2 够用（N=1 掉 12%，N=3 仅 +2%）。

**下游应用：**人手演示跨具身迁移（MediaPipe 关键点手工映射到夹爪位姿，简单抓放可用）；利用  $\phi$  输出的信息瓶颈 + Sentence-BERT + 对比学习，小规模语言标注数据即可零样本执行语言指令任务。

## 5. 局限

作者自认六条：依赖分割点云；点云无颜色和语义；短视野 Markov 假设；对演示质量和降采样敏感；无碰撞规避、不控制完整构型空间；精度不足以做低容差和富接触任务。

延伸批判：

1. **分割是真机最大单点故障。**SAM + XMem++ 遮挡即崩，分割混入桌面或机器人点会直接污染图节点。方法主体的鲁棒性建立在一个比它脆弱的感知前置上；
2. **88.75% 不是纯仿真训练的数字。**真机评测用的是 co-finetune 后的模型，纯伪演示模型的真机成绩未单独报告，「零真实数据」的宣称要打个折扣；
3. **伪演示的先验圈定了任务空间：**刚性吸附抓取、2–6 个 waypoint、每步 1cm/3°，实际把能力限制在准静态位移操作。铰接体开合能做（微波炉 0.23/0.56 已是全表最低分之一），柔性物、动态操作、力控任务出圈；
4. **失败模式印证了 Markov 假设的代价：**演示信息冲突或状态歧义时策略停滞或振荡，作者也承认要把历史观测加进图里。

## 6. 与 HOST / GEN-1.5 的关系

Instant Policy 和 HOST 同属「结构派」：都赌 one-shot 能力可以靠归纳偏置在小数据下做出来，不必等 50 万小时数据的涌现。差别在结构加在哪一维——Instant Policy 加在**空间**（图表征 + 3D 点云 + SE(3) 扩散），HOST 加在**时间**（进度流形对齐 + 自接地级联）。两者对基线的诊断也互相印证：Vid2Robot 式扁平 cross-attention 条件化在 HOST 评测里  $\leq 19\%$ （对 HOST 62%），在这里真机 40.63%（对 88.75%）——「演示被当成被动上下文」是两篇论文共同指认的病灶，只是开的药方不同。

按调研坐标系逐条摆放：

- **演示模态线：**Instant Policy 原生要机器人自己的演示（动觉/遥操作），人手演示只是靠 MediaPipe 手工映射的附加实验，精细任务映射即失效。HOST 用 Stage 2 学习的跨具身适配原生消化人类视频，这条线上 Instant Policy 被明确超越；

- **数字口径**：88.75%（16 任务，演示与测试同物体）vs HOST 62%（50 任务，人类视频跨具身）vs GEN-1.5 59%（10 任务）不可直接比大小——三者的泛化难度不在同一层级，Instant Policy 的设置最宽松；
- **对 GEN-1.5**：本文的 scaling 实验是 GEN 路线的小尺度预演——性能随仿真数据和容量增长、178M 后卡在数据多样性上。「需要更多样、更接近真实任务的数据」这个结论，GEN-1.5 用 50 万小时真实数据给出了暴力解，Instant Policy 给出的是程序化生成解；
- **独特剩余价值**：一是伪演示引擎——证明 ICIL 元能力可以与任务语义完全解耦、用零真实成本的仿真数据训练，这个思想至今没有被 HOST/GEN 任何一方吸收（HOST 的 Stage 1 仍烧 193k 条真实轨迹，二者能否用伪演示替代是开放问题）；二是图注意力提供了 ICIL 内部机理最干净的可解释窗口（模型在哪个演示片段上聚合，直接可视化）；三是  $N=1 \rightarrow 40\%$ 、 $N=4 \rightarrow 90\%$  的跨几何插值曲线，是「上下文内泛化」能力最干净的行为学证据。

# ICRT 深度解读：next-token prediction 原教旨主义的机器人 in-context learning 配方

**In-Context Imitation Learning via Next-Token Prediction** arXiv 2408.15980v2 (2024-09-27 更新) · ICRA 2025 · UC Berkeley AUTOLAB/BAIR + Autodesk Research 作者: Letian (Max) Fu\*, Huang Huang\*, Gaurav Datta\*, Lawrence Yunliang Chen, Will Panitch, Fangchen Liu, Hui Li, Ken Goldberg

## 1. 一句话定位

ICRT 用最朴素的配方验证机器人 ICL 成立：一个随机初始化的 Llama2 架构因果 transformer (12 层、768 维)，对原始感知运动轨迹（图像、本体状态、动作）做 next-token prediction，测试时把新任务的遥操作演示轨迹直接当 prompt 喂进去，权重不动即可执行——12 个未见任务平均 79.2%，同期最强的微调后 Octo 9.2%、OpenVLA 7.5%、goal-conditioned 基线 20.0%。核心发现不在架构而在数据：让 ICL 出现的是「同一初始观测下存在多个可能任务」的数据结构（自采 ICRT-MT 仅 1098 条轨迹），不是数据量——只用 DROID 子集训练的对照组成功率为 0%。

## 2. 要解决的问题

多任务机器人基础模型预训练完仍教不会新任务：新任务要再采遥操作数据、再微调一轮，流程复杂到难以落地。LLM/LVM 已经示范了另一条路——in-context learning，prompt 里给例子、权重不动就适配新任务。本文问的是：ICL 是语言/视觉独有的，还是 next-token prediction 框架的普适性质，能否直接搬到真机连续控制上。

已有 few-shot IL 方法各有拖累：对比学习式上下文编码器与 NTP 框架难以整合；DOME 需要额外的物体分割模型；KAT 要把轨迹转成 3D 关键点 token 借用 LLM 的少样本能力；Vid2Robot 靠一堆辅助损失；One-Shot Imitation Learning (Duan et al. 2017) 和 Prompting Decision Transformer 只在仿真 + 全状态 + 已知奖励下成立。ICRT 的立场是做减法：无关键点、无分割、无辅助损失、无奖励建模，原始轨迹进、动作出，单一 L1 损失。

## 3. 方法

### 3.1 数据构造（真正的贡献所在）

- **DROID 预训练子集**：76k 条真实演示，过滤（保留 30–450 步）后采样 10k 条，按语言指令的 CLIP 文本嵌入余弦相似度  $\geq 0.9$  分组、每组至少 4 条轨迹（保证能互为 prompt），最终约 2k 条可用；
- **ICRT-MT 自采数据集**：1098 条轨迹、29 个任务、6 个动作原语（抓取、抓放、堆叠、推、戳、开关抽屉），采集协议的核心约束是**每个场景至少存在 2 个可行任务**。单任务场景（DROID 大量如此）会让模型学捷径——只看当前观测就能唯一确定动作，prompt 沦为摆设；多任务同场景把「读 prompt」从可选变成必需。这一条解释了 DROID-only 训练全零的结果。

**序列构造**：同任务轨迹随机洗牌拼接，截取  $L=512$  个 (state, action) 步的子序列（约容纳 5 条轨迹），随机取前  $k$  条标为 prompt（至少含一条完整轨迹）。传统 BC 用短序列建模轨迹内部行为，ICRT 用长序列建模**轨迹之间**的模式。

### 3.2 架构

- **视觉编码器**：ViT-Base，用 CrossMAE 在 ImageNet + Open X-Embodiment 各半的混合上预训练（专门缩小与含机器人/夹爪图像的域差），训练 ICRT 时冻结；
- **模态投影**：每个相机的全部视觉 token 与本体嵌入（MLP）做 attention pooling，多相机结果拼接成单个 state token；动作经 MLP 成 action token。每个时间步只占 2 个 token，这是 512 步长上下文能塞下 5 条轨迹的前提；
- **主干**：Llama2 架构随机初始化，12 层、768 维；输入 state/action 交替序列，在 state 位置解码未来  $h=16$  步动作（L1 损失），执行时时间集成 + 后退视野控制取 10 步；
- **参数化**：本体 = 绝对末端位姿（xyz + 旋转矩阵前两行展平的 6D 旋转 + 连续夹爪），动作 = 相对当前位姿的增量位姿 + 绝对夹爪，各 10 维。

### 3.3 两个反直觉的训练决策

1. **prompt 部分不算损失**（借鉴 Vicuna 等多轮对话模型只对 response 算损失）：对 prompt 也算损失的对照组从 79.2% 崩到 22.5%。机制：prompt 位置没有上下文可依赖，强迫模型在此做无条件生成，等于训练它「不看 prompt 也要输出」，这个习惯会泄漏到 prompt 之后；
2. **两阶段而非混合训练**：DROID 预训练（4 epoch，56 分钟）→ ICRT-MT 微调（125 epoch，18 小时）， $4\times A100$ 。单阶段混训只有 6.7%——DROID 约 200 任务对 MT 29 任务的失衡淹没了 MT 的结构信号。

### 3.4 推理

KV cache 流式推理，每步只算新 token，复杂度从二次降到线性，实测 39.6 Hz（3090Ti），支持真机实时闭环。演示以「与训练数据完全同格式」的传感运动轨迹给入，无任何转换环节。

## 4. 实验结果

平台：Franka Emika，固定侧视 + 腕装相机。评测协议设计得很尖锐：2 个原语（抓放、戳）× 各 6 个未见任务（3 个训练见过的物体 + 3 个全新物体）× 5 个难度层（0–3 个干扰物、干扰放置位），每层 1 次尝试共 60 试验；prompt 场景与测试场景不同摆放，防止照抄动作；抓放计分「抓对 0.5 / 放对 1.0」，25 秒内可重试。

主结果（平均成功率 ± 标准误）：goal-conditioned 20.0% (±4.3)，Octo 微调后 9.2% (±3.5)，OpenVLA 微调 + 16 步 chunk 后 7.5% (±2.9)，ICRT 79.2% (±4.6)，其中抓放 65.0%、戳 93.3%。戳任务是照妖镜：目标图像与初始状态几乎无差别，goal-conditioned 直接失明（6.7%）；OpenVLA 常把戳做成抓（3.3%）——只有轨迹 prompt 能无歧义地传达「用什么运动模式」。

消融（Table II）：

- **ICRT-Llama2-7B** (LoRA r=32 微调): 58.3%，比从头训练的 Base 低 21 个点。训练损失更低但推理只有 10.7 Hz (对 39.6 Hz)，实时性拖垮闭环表现；语言预训练先验在感知运动序列上没有兑现；
- **ICRT (DROID only)**: 0.0%——数据结构不对，多少数据都白搭；
- **ICRT (MT only)**: 73.3%，只比完整版低 6 个点。大规模预训练有正贡献（尤其戳原语 70% 对 93.3%）但远非决定性；
- **prompt 类型鲁棒**: 换不同类型 prompt（无/有干扰物、干扰放置位）或 1–3 条 prompt，成功率稳定在 60–80%；
- **重复性**: 两个任务各 25 次试验，标准差 0.5% 和 3.2%；
- **近似新原语**: grasp-and-drop (40–80%)、放到某物右侧 (80%) 可以泛化；与训练原语无相似性的动作不行。

## 5. 局限

作者自认：无法泛化到完全未见的动作原语，只能在 6 个训练原语的邻域内换物体、换布局；假设固定形态 + 固定阻抗控制器，跨形态迁移未涉及；ICRT-Llama2 推理太慢。

延伸批判：

1. **评测统计功效弱**: 60 次总试验、每个难度层只测 1 次，与 HOST 的 50 任务 × 20 试验相比薄得多；重复性实验只覆盖 2 个任务，无法完全打消方差疑虑；
2. **「未见任务」定义宽松**: 新物体 + 旧原语 + 新摆放。原语级技能空间在训练时就封闭了 (6 个)，这与 HOST 意义上 50 个未见任务的任务级泛化不是一个难度层级；
3. **同具身假设是隐性成本**: prompt 必须是本机器人的遥操作轨迹，每个新任务仍要专家上手采 1–3 条——比人类视频 (HOST 的输入) 的采集门槛高一个量级，「免微调」不等于「免专家」；
4. **冻结视觉编码器的代价已现形**: 同色异形干扰物会导致抓错，作者自己承认需要微调视觉编码器——细粒度视觉表征是明确短板。

## 6. 与 HOST / GEN-1.5 的关系

ICRT 是「规模派」的最小可行原型：与 GEN-1.5 共享同一信念——ICL 是 next-token prediction 的普适性质，不需要机器人特有的结构设计。GEN-1.5 用 50 万小时数据把这个配方推到涌现 (59%)，ICRT 用约 3k 条轨迹证明配方本身成立，并揭示了小数据下的苛刻前提：**数据结构必须强迫模型读 prompt** (多任务同场景 + prompt 免损失)，否则模型必然走捷径。

这个前提恰好是 HOST 论点的实证注脚。HOST 批判以往方法「时间错位把演示降格为被动上下文，模型学会忽略演示」；ICRT 的两个消融从数据侧复现了同一病灶——prompt 算损失就崩 (79.2% 到 22.5%)，单任务数据就归零。差别在药方：ICRT 用**数据工程**绕开 (精心构造逼模型读 prompt 的训练分布)，HOST 用**结构工程**正面解决 (目标耦合让演示主动驱动预测目标)。数据可控时前者便宜，数据来源不可控 (野生人类视频) 时只有后者可行。GEN-1.5 则暗示第三条路：数据量大到自然覆盖多任务歧义时，强迫函数可能自动出现——但这只是从其涌现结果反推的猜想，50 万小时对 1098 条，成本差五个数量级。

坐标定位：

- **演示模态线**：ICRT 只吃同具身遥操作轨迹，被原生消化人类视频的 HOST（62%/50 任务/29 秒习得）明确超越；
- **规模线**：被 GEN-1.5 沿完全相同的技术路线（自回归序列模型 + 轨迹 prompt）用三个数量级的数据碾过；
- **独特剩余价值**：一是 39.6 Hz KV-cache 流式闭环，是本调研涉及方法中唯一把「prompt 不重算、逐 token 增量推理」工程化并报告实时数字的；二是「数据结构大于数据量」的定量证据（1098 条精构轨迹从 0% 做到 73.3%，10k 条 DROID 是 0%），对任何 ICIL 数据预算分配是直接可操作的结论；三是 LLM 初始化的负结果（7B 反而低 21 个点）——「拿语言先验白嫖机器人控制」在这个数据尺度不成立，且失败原因（推理延迟拖垮闭环）提醒所有人：机器人 ICL 的模型选型受实时性硬约束，这条约束在语言域不存在。



# RoboTTT 深度解读：把 Test-Time Training 装进机器人策略，上下文扩到 8K 步

RoboTTT: Context Scaling for Robot Policies arXiv 2607.15275v1 (2026-07-16) · NVIDIA GEAR + Stanford + UT Austin 作者：Yunfan Jiang 等；共同指导：Li Fei-Fei、Yuke Zhu、Linxi "Jim" Fan

## 1. 一句话定位

RoboTTT 把 Test-Time Training (TTT) 层插进 VLA 模型 (GR00T N1.7)，用「推理时也做梯度下降的 fast weights」充当循环状态，把视觉运动上下文从单步扩到 8K 时间步 (30Hz 下约 5 分钟) ——比现有 SOTA 长三个数量级，推理延迟却不随上下文增长。这个长度解锁四种能力：从一段 in-context 人类视频 one-shot 模仿新装配配置 (6/10 成功，基线全灭)；DAgger Distillation 带来的在线自我改进 (+36%)；外部扰动恢复 (83% vs 最强短上下文基线 53%)；长程任务总分比单步基线高 87%，且是唯一完成 5 分钟 10 阶段 Gear Bot 装配的方法。更大的发现是：预训练上下文从 128 扩到 8K，闭环性能单调上升无饱和 (8K 比 1K 高 63%) ——上下文长度是机器人基础模型的一条新 scaling 轴。

## 2. 要解决的问题

主流机器人基础模型 ( $\pi_0$ 、OpenVLA、GR00T、RDT 等) 只吃单步或 2-8 帧短历史，而 LLM 那边上下文长度早已是核心 scaling 轴。长视觉运动上下文对三类能力不可绕过：one-shot in-context 模仿、从自身部署历史在线改进、多阶段长程任务的闭环执行 (视觉相似的阶段造成状态混叠，短上下文策略会跳步或重复做)。

做长上下文有三个结构性障碍。一是容量：RNN 的向量状态压不住几千步的稠密观测流。二是利用：朴素拼接历史帧会引入虚假相关 (causal confusion)，论文实测 GR00T N1.7 加一帧历史后在 Pup Go Car 上从 57% 掉到 39.5%——历史不但没帮忙反而有毒。三是成本：Transformer 即便有 KV cache，解码延迟仍随上下文线性涨，5 分钟 @30Hz 的近万步历史在真机上不可行。

## 3. 方法

### 3.1 TTT 层：用梯度下降当记忆写入

fast weights  $W$  参数化一个小网络  $f_W$  (两层 MLP)。每个时间步先「update」：对当前键值对做一步梯度下降，最小化  $\|f_W(K_t) - V_t\|^2$  (学习率可学习)，把上下文写进参数空间；再「apply」： $O_t = f_W(Q_t)$  读出。训练与推理都执行这套 update-then-apply。QKV 投影矩阵与初始权重  $W_0$  由外层任务损失端到端学习， $W_0$  走 MAML 式二阶梯度元学习——更新规则本身是学出来的，这是它与 Gated DeltaNet 等线性递归记忆的本质区别。

### 3.2 与 VLA 的融合

主干是 GR00T N1.7 (VLM + 16 层 DiT flow-matching 动作头)。每层 DiT 的自/交叉注意力后插一个 TTT 层：注意力只处理单步内 token ( $N=16$  个可学 register token、本体 token、噪声动作 token，

cross-attend 该步的视觉语言 token)，TTT 层沿时间维跨步整合。视觉语言 token 不直接过 TTT（省算力），靠 register token 携带其信息跨时间。 $\tanh$  门控  $O = \tanh(a) * O\_TTT + O\_attn$ ， $a$  初始化 0.001，让 TTT 贡献从近零起步、不冲垮预训练能力。

### 3.3 训练配方：两个使长上下文可训的技巧

**Sequence action forcing**：序列内每个动作块独立采样 flow-matching 噪声水平， $t = s(1-u)$ ， $u \sim \text{Beta}(1.5, 1)$ ， $s=0.999$ 。共享一个噪声水平会让整条序列同等难/易，训练不稳定（呼应 Diffusion Forcing 的发现）；消融显示去掉它闭环性能崩塌。

**TBPTT（截断式沿时间反传）**：序列切段，梯度只在段内流动，fast weights 跨段传递但 detach 梯度。显存由段长而非总长决定，训练上下文可任意加长； $W_0$  仍从首段获得梯度。

预训练：桌面双臂机器人数据 + 第一视角人类数据混合，上下文逐步升到 8K，30K 步 x 16 张 GB200。每个下游任务再以 1K 上下文 post-train 20K 步。

### 3.4 两种上下文玩法

把 flow-matching 损失在选定时间步 mask 掉，这些步就成了纯上下文（只更新 fast weights、不当模仿目标）。由此派生两个能力：

**one-shot 视频模仿**：训练时把同配置的（人类演示视频，机器人轨迹）拼成一条序列，视频段 mask 损失。所有配置共用同一句指令「assemble circuit」，目标配置只能从视频认出。测试时喂一段未见配置的人类视频即可复现装配。

**Dagger Distillation**：Dagger 轨迹里机器人错误动作和人类纠正交错。标准 Dagger 只在纠正上微调、丢掉错误动作；RoboTTT 让完整历史（含错误动作）更新 fast weights，损失只算人类纠正段——失败当上下文、纠正当目标，把「失败到纠正」的映射蒸馏进 fast weights，是 Algorithm Distillation 在机器人上的实例化。测试时模型自己犯错自己纠，无需人在环。

## 4. 实验结果

平台：YAM 双臂 + 4 RGB 相机（顶、底、双腕）。三个装配任务：Pup Go Car（平均 2 分钟，8 小时数据）、Circuit（1 分钟，80 个配置训 20 测 60，6 小时）、Gear Bot（5 分钟 10 阶段，5 小时）。

主结果：平均任务完成分 RoboTTT 79%，GR00T N1.7 42%（相对 +87%），GDN（把 TTT 换成 Gated DeltaNet 线性递归记忆的对照）56%（+41%）。三任务全成功数 9/20、13/20、2/10；Gear Bot 上 RoboTTT 是唯一有全成功的方法，所有基线 0/10。

上下文 scaling：预训练上下文 128 到 8K，RoboTTT 闭环分数单调升到 71.5%，比 1K 版（43.9%）高 63%、比最强短上下文基线（45.6%）高 57%，无饱和迹象；GDN 完全没有此趋势。作者归因：梯度下降更新加元学习的  $W_0$  与更新动力学能被更长的训练序列塑形，线性关联状态没有这个元学习空间。1K 以下 RoboTTT 变弱的原因也给了：rollout 时长超过训练窗口，fast weights 被推到训练没见过的更新步数、位置编码外推。

one-shot 模仿：Circuit 未见配置 6/10 成功（完成分 65%），GDN 0/10（33%）——GDN 拿错部件或装错顺序，说明递归记忆「能编码但不会用」上下文；RoboTTT 靠测试时梯度更新的 fast model 按需检

索演示配置。

扰动恢复：执行中人为拆掉已装好的顶棚/轮胎，RoboTTT 恢复 15/20 和 18/20，GDN 13/20 和 18/20，短上下文基线最高 10/20（含 30 分钟扰动数据共训）。

Dagger Distillation：100 条 DAgger 轨迹（RoboTTT 与 GR00T 各采 50 条）训练所有方法。标准 DAgger 平均提升 9%；蒸馏版平均 +33%（RoboTTT +36%、GDN +29%）。关键对照：把含错误动作的完整轨迹直接微调 GR00T，结果与只用纠正段完全相同（都 57%）——错误动作作为模仿目标零价值，作为上下文才值钱。定性看增益主要来自「做错后重试」：钻头没对准螺丝，抬臂、重新对准、再钻，最多重试两轮后成功。

消融（Pup Go Car）：linear fast model 比 MLP 差 27%（非线性容量是关键）；TTT 只吃 state token 起步，加 action token 相对 +23%（感知自身过去动作有助建模环境动力学），再加 register token 又 +18%；同样的 register token 加给 GR00T N1.7 无任何提升——它只在配合 TTT 时序建模时才有用。

## 5. 局限

作者自认三条：训练成本随上下文长度上涨（可引入 TNT 等更省的 TTT 训练法）；TTT 层沿用通用键值重建目标、未做机器人特化；不能覆盖全部失败模式，接 RL 直接优化任务成功率是下一步。

延伸批判：

1. **one-shot 的口径远窄于字面**。评测只在 Circuit 单一任务族的未见配置上进行，且训练用了该任务族的成对数据（每配置 5–20 段人类视频）。这是「配置级」泛化——同一装配任务换目标布局——不是跨任务的技能级 one-shot。
2. **每个下游任务仍要 20K 步 post-training**。新任务族的部署门槛没有消除，one-shot 只发生在 post-train 覆盖的分布内。
3. **人类视频与机器人执行同场景同相机**（机器人 idle、人上手装配），跨具身鸿沟被采集设定大幅压缩；换成第三人称视角或野生视频能否成立未验证。
4. 「延迟不随上下文增长」是相对声明，正文未报告 TTT 每步梯度更新的绝对推理开销，常数项多大不明。

## 6. 与 HOST / GEN-1.5 的关系

三条 one-shot 路线在此完整成形：HOST 靠**显式结构**（进度流形对齐 + 自接地级联，零参数更新，50 任务 62%）；GEN-1.5 靠**数据规模涌现**（50 万小时预训练，ICL 59%，1–10 梯度步适应 83%）；RoboTTT 给出第三条——**架构机制**：让模型在推理时继续做元学习过的梯度下降，但只在 fast weights 上。它恰好落在 HOST（零更新）与 GEN-1.5 适应模式（全模型梯度步）之间：参数确实在测试时变，但变的只是被设计成「记忆」的那一小块，且更新规则是预训练里学好的。

按 one-shot 广度比，RoboTTT 被 HOST 明确压制：6/10（60%）只覆盖单任务族的配置变化，HOST 62% 覆盖 50 个不同任务且跨具身（第三人称人类视频、不同场景）。但 RoboTTT 有三块 HOST 与 GEN-1.5 都没有的独特价值：一是**长程**，5 分钟 10 阶段任务的闭环执行与状态消歧，HOST 任务多为桌面短程；二是 **Dagger Distillation**，「失败当上下文、纠正当目标」的在线自我改进机制——HOST 的定位级

只能感知进度倒退后重对齐，没有学习过的纠错行为分布；三是**上下文长度 scaling 律的首次实证**，这条轴与 GEN-1.5 的数据小时数轴正交，两轴原则上可叠加。

对本调研的定位：RoboTTT 提供的是**基础设施层**答案（长上下文怎么做、值不值得做），HOST 提供的是**跨具身翻译层**答案（人类视频怎么变机器人动作）。两者不互斥——把 HOST 式进度对齐与预测级联装在 RoboTTT 式 TTT 主干上，是一条明显的合流方向。

# BPP 深度解读：一条演示当 prompt，任务多样性是 in-context 操作的第一驱动力

Behavior Prompting Policy: Demonstrations as Prompts for Manipulation arXiv 2606.30457v1 (2026-06-29) · Stanford (Shuran Song REAL Lab) + UC Berkeley 作者: Austin Patel、Ben Pekarek、Joel Enrique Castro Hernandez、Shuran Song

## 1. 一句话定位

BPP 把一条与机器人同传感运动空间的演示（观测 + 本体 + 动作序列，称 behavior prompt）直接喂给策略，推理时零参数更新执行新任务；配套交付三件东西：受控数据研究（固定预算下任务多样性远比每任务演示数重要，2000 任务 x 5 demos 是配方）、采集硬件 iPhUMI（UMI 夹爪的 GoPro 换成 iPhone，ARKit 免建图 + 无线传 prompt）、两个新基准（DrawAnything、LIBERO-Gen）。未见画作重建误差比 goal-image 条件低 80.7%、比 ICRT 低 33.3%；LIBERO-Gen 上无任何基础预训练即追平 LoRA 微调 10 万步的  $\pi 0.5$ 。

## 2. 要解决的问题

教机器人新技能要重训或微调；语言与 goal image 作为任务描述天生残缺——语言说得清「做什么」说不清「怎么做」（低层轨迹、抓取策略、空间细节），goal image 只有终态没有过程，「画一幅任意图」这类任务两者都原理性失灵。VLA 的零样本泛化集中在新环境、新物体，对新低层行为基本无效。

演示条件化的 in-context 路线早已存在（Duan 2017 的 one-shot IL、Vid2Robot、ICRT），但最相关的 ICRT 只在 29 任务、1098 条轨迹、6 种运动原语的规模上验证过。留下的开放问题：prompting 能力如何随任务多样性 scale、又能解锁什么测试时能力？现有基准撑不起这个问题——要么任务多样性不足，要么只测语义/视觉适应而不测动作适应。

## 3. 方法

### 3.1 behavior prompt 与架构

prompt 是一条完整演示（环境配置与执行时不同），同时提供 what 与 how。BPP = prompt encoder + action decoder：

- **分块编码**：观测/本体降采样到 1Hz，动作不降采样以保留完整行为序列；每块 {o, q, a} 经 attention pooling 合成单个 chunk embedding，一举完成同时刻模态关联与序列长度压缩；
- **prompt encoder**：transformer decoder，当前观测 token 对 prompt chunk 序列做 cross-attention，按当前所处阶段抽取相关 prompt 信息；学习式位置编码，LIBERO-Gen 版本另加 attention sink token；
- **action decoder**：Diffusion Policy 的 CNN + FiLM 架构，条件是当前观测、抽取的 prompt 信息与扩散步 k，迭代去噪出动作块。

推理效率设计：chunk embedding 每回合只算一次并缓存；prompt 信息抽取每控制步一次，与 K 步去噪解耦——去噪循环不必反复扫整条 prompt。

### 3.2 训练：不要任何对应标注

每个训练步采一条演示当 prompt，再从**同任务的其它演示**采 receding-horizon 观测与未来动作块当监督目标。两条演示环境配置不同，模型必须端到端学会 prompt 与当前观测之间的时间对应与空间差异——不需要任何显式时空对齐标注。这意味着 BPP 可直接吃现成多任务模仿学习数据集，零额外采集。任务分组粒度决定 prompt 能控制什么：想让 prompt 指定抓取策略，就得把不同抓法分成不同任务组。

### 3.3 iPhUMI 与基准

iPhUMI 保留 UMI 手持夹爪设计，把 GoPro 换成 iPhone 15 Pro：ARKit 实时 SLAM 免掉建图步骤，App 无线把演示传给工作站即刻条件化策略——同一设备既采训练数据、又在部署时出 prompt。

四个基准：DrawAnything-Sim（2000 个程序生成画图任务 x 5 demos，测 50 条人手采集的未见画作，rollout 时画板朝向与 prompt 不同，逼策略做空间换算）；DrawAnything-Real（ARX 臂 + iPhone 腕相机 + 马克笔，1000 任务 = 200 人采 + 800 脚本生成，6DoF 动作）；LIBERO-Gen Combination（LIBERO Spatial 从 10 扩到 174 任务，两只同款碗与 9 个放置位，held-out 10 个「拆开都见过、合起来没见过」的取放组合）；LIBERO-Gen Chain（LIBERO Goal 从 10 扩到 321 任务，两步链式任务含开抽屉/推盘子/开灶台，held-out 10 个未见链）。

## 4. 实验结果

**画图**：未见画作上 BPP 比 Goal-Image 降 80.7% Chamfer 误差、比 ICRT 降 33.3%。Goal-Image 在训练画作上尚可、在未见画作上退化不成形的笔画（真机上其 Chamfer 误差看似中等，实为无意义涂抹恰好盖住目标区域）；ICRT 把整条 rollout 历史留在模型上下文里，被虚假相关拖出分布。真机上 BPP 能从一条 iPhUMI 演示重建未见画作。

**LIBERO-Gen**：BPP 全面超过 Goal-Image 与 Language 基线，且无预训练即追平微调后的  $\pi 0.5$ 。Chain 上去掉「第二步单独任务」的消融（策略从未见过抽屉已开时怎么放酒瓶这类接续状态）让 BPP 对 Language 的优势从 +10.7% 扩大到 +20.8%——越是训练分布覆盖不到的状态接续，prompt 的逐步引导越值钱。总结律：任务的时序复杂度越高（单步取放 → 两步链式 → 连续画图），更富时序信息的任务描述符（goal image → 语言 → behavior prompt）收益越大。

**机制可视化**：prompt encoder 注意力在画图任务里连续追踪与当前观测最接近的 prompt 段，在 LIBERO-Gen 里离散跳向下一个「里程碑」（下一个交互物体、放置点、任务切换）。结论：BPP 的适应机制是把 prompt 当**密集子目标序列**用——比从单张终态图反推全过程容易得多。

**表征消融**（DrawAnything-Sim）：观测必需（锚定检索）；动作有用（填补 1Hz 降采样间隙的时序过渡）；本体无用（光标已在图像中可见）；观测降采样低于 1Hz 显著劣化；attention pooling 优于每模态独立 token。

**数据消融（全文核心科学结论）**：固定演示预算下，多任务 x 少演示显著优于少任务 x 多演示；训练任务数单调提升未见任务性能，每任务 5 条演示就够；只训 1-3 部件的简单画作适应不了复杂未见画，只训 4-6 部件复杂画效果最好（代价是演示数据量大涨）。



**诚实负结果（叠衣案例）：**3 个双臂叠衣任务、每任务约 150 条演示加共约 1000 条纠错演示的低多样性设定下，语言条件 96–100% 成功，BPP 分别 76%、100%、60%（fold bottom up 常做成别的任务，右臂抓对了底边、左臂却去叠袖子）。低任务多样性时 prompt 的时长与空间变化不再携带区分信息、反而是噪声，作者怀疑模型过拟合了背景等虚假任务线索。原版 LIBERO 上 BPP 97.48% 与 Language DP 96.23%、 $\pi 0.5$  97.15% 打平——旧基准已饱和，测不出范式差异，这也是要造 LIBERO-Gen 的原因。

## 5. 局限

作者自认：很多任务语言或 goal image 就够用且更便宜（愿景是多描述符灵活切换）；需要可观的训练任务多样性；**桌面操作上没有证据能适应全新动作原语**；低多样性 regime 任务条件化弱于语言；实验里 prompt 与执行同环境，跨环境 prompt 未测。

延伸批判：

1. **「新任务」的实质是组合泛化。**LIBERO-Gen 的未见任务是已见原语的新组合/新排序，DrawAnything 的未见画是已见笔画部件（线、圆、Bezier）的新拼接。技能级 one-shot（全新原语）明确不在能力范围内。
2. **实验主体在仿真。**真机只有画图（10 个评测任务）和叠衣（3 任务且以负结果为主），真机操作类任务的 prompt 适应未验证。
3. **prompt 不是自由人类视频。**iPhUMI 演示在 UMI 传感运动空间里，跨具身问题被硬件在采集端消解——免学跨域翻译是优点，但出 prompt 必须手持专用夹爪，普适性低于「拍段视频就行」。
4.  $\pi 0.5$  对照单 seed、100K LoRA 步；DrawAnything 上的消融结论作者自己声明不保证迁移到其它域。

## 6. 与 HOST / GEN-1.5 的关系

放进调研坐标系，三者代表三种杠杆：HOST 是**结构派**（进度流形对齐 + 自接地级联，50 真机任务 62%，29 秒习得，跨具身人类视频）；GEN-1.5 是**规模派**（50 万小时预训练涌现 ICL 59%，1–10 梯度步适应 83%）；BPP 是**数据配方派**——架构全是标准件（cross-attention prompt encoder 加 Diffusion Policy decoder），真正的贡献是那条受控结论：**驱动 in-context 能力的是任务多样性，不是数据总量。**这条结论 HOST（229 任务 19.3 万条轨迹）和 GEN-1.5（50 万小时）都隐含依赖但都没有单独验证，BPP 用 2000 任务 x 5 demos 的受控设定把它钉死了。

prompt 模态光谱上三者各占一格：HOST 吃第三人称人类视频（跨具身鸿沟最大，靠观测空间预测级联跨越）；BPP 吃 UMI 空间传感运动演示（硬件消解跨具身，换来信息最全的 prompt——自带动作真值）；GEN-1.5 吃机器人自身经验上下文。演示获取成本 BPP 居中：比遥操作便宜，比拍人类视频贵。

被谁超越：真机任务级 one-shot 的广度与难度上被 HOST 全面压制（50 个真机任务、跨具身 62%，对比 BPP 真机只有画图与叠衣负例）；能力上限被 GEN-1.5 的涌现路线展示（BPP 结语自己也展望 foundation-level pretraining 与 behavior prompting 的结合）。

剩余独特价值有四：任务多样性配方直接指导任何 one-shot 系统的采集预算分配，对 HOST 的 Stage 1 同样适用；DrawAnything 是「语言与 goal image 原理性失灵、prompt 不可替代」的最干净论证——



HOST 的 50 任务里没有这类连续指令跟随任务；LIBERO-Gen 把 in-context 操作研究变成可复现、免工业级数据的科学问题；叠衣负结果划出了适用边界——低任务多样性时 prompt 反而不如语言，这对 HOST 类方法是同样成立却未被 HOST 测试过的预警。

# RICL 深度解读：给预训练 VLA 事后注入 in-context 学习能力

RICL: Adding In-Context Adaptability to Pre-Trained Vision-Language-Action Models arXiv

2508.02062 · CoRL 2025 (首尔) · 宾夕法尼亚大学 + 不列颠哥伦比亚大学 作者: Kaustubh Sridhar、

Souradeep Dutta、Dinesh Jayaraman、Insup Lee · 代码与权重开源 (ricl-vla.github.io)

## 1. 一句话定位

RICL (读作 rickle) 用 400 条演示做一次「检索增强式后训练」, 给本不具备 in-context learning (ICL) 能力的  $\pi_0$ -FAST-DROID 事后装上这个能力: 此后每个新任务只需采 10-20 条演示放进检索库, 零参数更新, 完整任务成功率从基线的 2.5% 升到 31.25%, 追平「基线+微调」的 31.67%; 若再在这 20 条演示上做检索增强微调, 达到 61.67%, 几乎是普通微调的两倍。这是第一个开源 (代码+权重齐全) 的通用操作 ICL 接口。

## 2. 要解决的问题

LLM 好用的一半原因是 ICL+RAG: 例子放进上下文, 不动参数就学会新任务。VLA 没有这个接口——模仿学习目标 + 相对窄的演示分布, 训不出 ICL 涌现。于是今天改进预训练 VLA 的唯一路径是收数据再微调参数, 终端用户玩不转。

已有的机器人 ICL 尝试两边都有硬伤:

- 用现成 LLM/VLM 做 ICL (keypoint 表征、代码策略、in-context value function): 被迫开环或近开环执行, 纯语言通道还丢视觉细节, 闭环适应能力差;
- 从零训练自带 ICL 的 agent (MTT、ICRT、REGENT): 都不建立在通用机器人 VLA 之上, 覆盖面限于游戏、仿真或单一平台设定。

RICL 的定位是拼接两边优点: 拿一个已能真机部署的 SOTA VLA ( $\pi_0$ -FAST-DROID = SigLIP 视觉编码器 + Gemma 3B + FAST 动作 tokenizer, 经 DROID 数据集微调), 事后教会它使用上下文。

## 3. 方法

### 3.1 上下文组织与检索

查询 = 当前时刻三视角图像 (top/side/wrist) + 语言指令 + 本体状态 (7 关节角 + 夹爪位置)。上下文 = 检索到的 4 组近邻, 每组含三视角图像、状态和动作块, 按相似度从近到远排在查询左侧。检索键刻意做到极简: 只取 top 相机图像的 DINOv2 嵌入,  $\ell_2$  距离 + FAISS 索引, 单次检索低于 1 毫秒。

### 3.2 动作插值层: 检索先验的硬编码

最终动作不是 LLM 输出直接用, 而是与最近邻动作  $a'$  做距离加权插值 (对 FAST tokenizer 的每个动作 token 独立进行): 输出 =  $e^{(-\lambda d)} \cdot \text{one-hot}(a') + (1 - e^{(-\lambda d)}) \cdot \text{softmax}(\text{LLM 输出})$ ,  $\lambda=10$ ,  $d$  为查询与

最近邻 top 图像的 DINO 嵌入距离。d 趋近 0 时输出坍塌为复制最近邻（1-NN 行为），d 大时交还 LLM 自主预测。该层继承自同组前作 REGENT（ICLR 2025），是「查询与演示够像就直接抄」的显式归纳偏置。

### 3.3 Priming 训练配方

- 数据：Franka DROID 平台自采 20 个 pick-place 任务 × 每任务 20 条 = 400 条演示，15 Hz 采集；
- 序列构造：每条演示的每个状态当查询，从同任务其余 19 条里检索 4 组近邻拼训练序列——训练形态与部署形态完全一致；
- 只全量微调 Gemma LLM，冻结 SigLIP 图像编码器；损失只对查询的动作块算 cross-entropy（REGENT 连检索到的动作一起算，RICL 砍掉）；
- 超参：3 epochs，峰值学习率  $2.5e-5$  余弦衰减，batch 16，2 张 A100；动作块 15 步（实测优于 10 步），执行时先取前 3 步、检测到夹爪动作后改取 8 步。

### 3.4 两档用法

档位一（纯 ICL）：新任务采 20 条演示进检索库，不做任何训练。档位二（RICL-finetuned）：在同 20 条上按 RICL 同款检索增强目标再微调 1000 步——finetune like you pretrain。推理开销：token 数变 4 倍，实际 rollout 时长仅为  $\pi 0$ -FAST 的约 1.33 倍。

## 4. 实验结果

评测设定：8 个任务（pokeball、idliplate、squeegee、sink-idliplate、sink-squeegee、toaster、door、bagel），覆盖全新物体、全新动作、新场景（厨房水槽区，相机重摆无标定）与训练分布长尾；物体/动作已核查不在 DROID 和 priming 数据中；每任务 10 次 rollout，初始位姿全桌面随机。

| 方法                        | 目标任务参数更新 | 完整成功率         | 检查点完成率    |
|---------------------------|----------|---------------|-----------|
| $\pi 0$ -FAST-DROID       | 无        | 2.5%          | 至多 21.25% |
| RICL- $\pi 0$ -FAST-DROID | 无        | <b>31.25%</b> | 至多 83.75% |
| $\pi 0$ -FAST-DROID + 微调  | 有        | 31.67%        | —         |
| RICL + 检索增强微调             | 有        | <b>61.67%</b> | —         |

四个可以单独记住的结论：

1. 纯 ICL（31.25%）追平基线微调（31.67%）：零梯度更新打平了动参数的对手。Retrieve-and-play（1-NN）与从零训练的 Diffusion Policy 在最简单的三个任务上就已明显落后，被提前淘汰出后续对比。
2. 检索增强微调几乎两倍于普通微调（61.67% vs 31.67%）。作者的解释：RAG 化的模型不必用容量背数据，专注学「在检索到的状态-动作间插值」，与 RAG LLM 的参数效率结论一致。

3. 演示数量消融 (idliplate): 5 条时 RICL 退化成基线行为 (同样去抓干扰物苹果), 10 条起效, 随演示数增加逼近微调版; RICL-finetuned 在每个演示数量档位都显著高于普通微调。
4. 能力无损: 把检索库换成随机 priming 演示, 在 3 个基线本来会做的任务上 RICL 版本 80% 成功率与原版持平——注入 ICL 没有毁掉零样本能力。

另有一个计划外现象: idliplate 的 20 条演示全是「夹爪伸进盘子凹槽拖动」, RICL 却自己走到盘子左侧、闭合夹爪把盘子推过去 (toaster 任务同样观察到)。作者称之为 elicited latent actions: 上下文触发了基座潜藏的操作知识, 而非复制演示。

## 5. 局限

作者自认四条: (1) 教不会离基座能力太远的任务, 评测因此局限在 pick-place 变体, 网球正手这类大幅新动作失败; (2) 每个新任务仍要 10-20 条遥操作演示, 跨场景不可扩展, 作者点名人类视频 (R+X 路线) 是出路; (3) 相机视角/场景大变时检索失效 (priming 阶段未见过此类扰动); (4) 性能仍有空间, 寄望于扩大 priming 任务数与参数量。

延伸批判:

1. 评测样本量小: 8 任务  $\times$  10 rollouts, 无置信区间, 31.25% 与 31.67% 的「追平」在这个样本量下统计上很脆。
2. 检索键太弱: 只用单视角单帧的 DINO 嵌入, 语言指令不参与检索, 场景相似但任务不同时必然串台——这是最容易被打穿的工程点。
3. priming 分布只有 20 个 pick-place 任务, 注入的与其说是通用 ICL, 不如说是「pick-place 域内的插值能力」, 与 LLM 跨域 ICL 有本质距离; 作者用网球例子自己承认了这一点。
4. 每任务 20 条遥操作的成本没有消失, 只是从「微调机时」换成「采数据人时」; 对比 HOST 的 1 段人类视频, 数据接口贵 20 倍且必须占用真机。

## 6. 与 HOST/GEN-1.5 的关系

三条路线获得 ICL 的方式不同: GEN-1.5 用 50 万小时数据把 ICL 「养」出来 (涌现, one-shot 59%); HOST 用结构归纳偏置把 ICL 「设计」出来 (进度流形对齐 + 自接地级联, 1 段人类视频、29 秒、50 任务 62%); RICL 用后训练把 ICL 「注入」现成 VLA (400 条 priming 演示, 每任务 10-20 条, ICL-only 31.25%)。

RICL 与 HOST 最本质的差别在演示接口: RICL 的上下文吃同具身遥操作演示 (自带动作标签), 检索-插值机制依赖「上下文里有可直接参照的动作」; HOST 吃跨具身人类视频 (无动作标签), 靠观测预测级联完成跨域翻译。RICL 绕开了跨具身鸿沟, 代价是数据贵; HOST 直面它, 代价是需要专门的对齐机制。RICL 未被 HOST 评测 (平台、任务、演示模态都不同), 二者不构成直接胜负; 但按「降低新技能习得成本」这条主轴, HOST 的接口成本 (1 段视频、29 秒、零遥操作) 明显低于 RICL (20 条遥操作演示)。

RICL 保留的独特价值有三点: (1) 生态位——唯一开源、可直接架在  $\pi 0$  系 VLA 上的 ICL 接口, 工程复用性最强; (2) 「检索增强微调约 2 倍于普通微调」的发现独立于 ICL 本身, 对所有做少样本 VLA 适配的团队都可用; (3) 能力保持性验证 (随机上下文不掉点) 为「后训练注入 ICL 不伤基座」给出第一份证据。

elicited latent actions 现象与 HOST 的「先预测自己视角的未来观测」殊途同归：有效的 ICL 不是复制上下文，而是用上下文激活模型内部已有的知识。两条线显然的合流点是把 RICL 的检索式后训练配方接上人类视频演示接口——作者在 limitations 里自己指了这个方向。

# Vid2Robot 深度解读：端到端视频条件策略的 Google 规模实践

Vid2Robot: End-to-end Video-conditioned Policy Learning with Cross-Attention Transformers arXiv 2403.12943 · RSS 2024 · Google DeepMind Robotics + CMU + 多伦多大学 作者: Vidhi Jain (Google 实习成果)、Maria Attarian 等; 末位作者 Debidatta Dwibedi 是 TCC 损失的原作者 · vid2robot.github.io

## 1. 一句话定位

Vid2Robot 是 2024 年初 Google DeepMind 交出的端到端视频条件策略：看一段人类演示视频（语言不输入策略），直接在真机上输出动作复现同一任务。9 个任务上人类视频提示成功率 52.8%，比 BC-Z 基线（30.6%）高 22 个点；并首次系统展示「跨物体动作迁移」这一涌现能力——提示视频里的动作可以施加到场景中完全不同的物体上（34.2% vs BC-Z 的 17.5%）。

## 2. 要解决的问题

语言条件策略（RT-1/RT-2/RT-X）的任务接口有两个结构缺陷：一是多义性，open drawer / open jar / open cabinet 共享动词但运动控制完全不同，语言嵌入分不清「何时该泛化、何时不该」；二是「怎么做」缺失，目标图像条件下 hold the flag 与 wave the flag 的终态图一样。视频同时携带 what 和 how，是更稠密的任务规范。

但 2024 年初的视频条件策略要么假设演示与执行在同一工作区、变化有限，要么性能明显落后语言条件策略（BC-Z 口径）。作者归纳三大障碍：视频维度高（算力/显存压力）、人-机配对数据稀缺、人类演示在速度和风格上差异大。

## 3. 方法

### 3.1 三层配对数据：90% 是免费的

训练需要「提示视频-机器人轨迹」对。Vid2Robot 按成本递增拼三种来源，共约 38 万对：

- Robot-Robot（占混合比 90%）：把已有 RT-1/RT-2 机器人数据按语言指令配对——同指令、不同场景的两条轨迹互为提示。12 万条轨迹 × 每条采 3 个提示 = 36 万对，零新增采集成本；
- Hindsight Human-Robot（5%）：按机器人数据集的既有指令，让 1-5 名人类在机器人视角相机前演示，5 千条人类视频得 1.5 万对，不需要新遥操作；
- Co-located Human-Robot（5%）：人和机器人在同一工作区（客厅、会议室、厨房、工具台等）各演示一遍，金标准但最费人力，仅 5 千对。

语言指令只用于配对和辅助损失，不进策略输入——这是它与语言条件策略的分界线。

### 3.2 架构：四模块全 cross-attention

策略  $\pi(a_t | S_t, V)$  由四个模块组成：



- 1. 提示视频编码器：逐帧 ViT-B/16 + Perceiver Resampler (2 层、64 个 latent token)；
- 2. 机器人状态编码器：共享同一个 ViT + 独立 Resampler，输入当前帧加近 7 帧 (k=8)；
- 3. 状态-提示编码器：4 层 cross-attention，状态 token 当 query、提示 token 当 key/value，输出 prompt-aware state tokens——按视频内容决定关注状态里的哪个物体；
- 4. 动作解码器：4 层 cross-attention，可学习的动作位置嵌入当 query (ACT 式一次前向，不做 RT 系的自回归多次前向)，输出 11 维动作 (模式 + 夹爪位姿与开合 + 底盘) × 每维 256 bins，argmax 执行，预测视野 4 步。

Cross-attention 是显存上的胜负手：16 帧提示 + 8 帧状态在 ViT-B/16 下共 4704 个 token，全自注意力矩阵约 2200 万项；两个 64-latent Resampler 把它压到约 30 万项，缩减 70 倍，配对视频训练才跑得动。

3.3 一主三辅四损失

总损失是四项等权平均：

- 1. 动作 cross-entropy (主损失，端到端行为克隆)；
- 2. TCC 时间循环一致性：对提示/机器人视频的逐帧嵌入 (经 2 层 MLP alignment pooling) 做软最近邻 cycle-back，强制两段视频的帧级进度互相对应，逼图像编码器对具身、光照、背景、视角保持不变、只编码任务进度；
- 3. 视频-视频对比 (VVCL)：attention pooling 得到整段视频嵌入，SigLIP 损失拉近同任务的提示-机器人视频对、推远批内其他对；
- 4. 视频-文本对比 (VTCL)：与冻结文本编码器的指令嵌入做 SigLIP，即 BC-Z 式语言辅助监督。

实现：Jax，20 万步，batch 2048，AdamW 峰值 8e-5 余弦衰减至 1e-6。平台：Google Robot 移动机械臂 (7 自由度、双指软夹爪、自我中心相机)，客户端-服务器部署，推理 5-7 Hz。

4. 实验结果

评测协议先记住：人工评估员按 reach→grasp→release→terminate 四个检查点判定，全过程正确才算成功——规则式终态判定会把「抓取失败但瓶子恰好倒成目标姿态」误判为成功。主表 288 次真机 rollout (9 任务 × 8 次 × 4 行)。

| 提示来源  | BC-Z  | Vid2Robot |
|-------|-------|-----------|
| 机器人视频 | 52.6% | 54.9%     |
| 人类视频  | 30.6% | 52.8%     |

- 关键读法：机器人提示下两者打平 (训练对 90% 是机器人-机器人，都吃饱了)；换成人类提示后 BC-Z 掉 22 个点、Vid2Robot 只掉 2 个点——TCC 加对比损失学出的具身不变表征在这里兑现。
- 扩大样本的统计版 (限 2 个任务、共 314 次 rollout)：Vid2Robot 43.4±7.2% vs BC-Z 30.2±7.1%，13 个点的差距在更大样本下保持。

- 分阶段成功率：够到正确物体 78%（高出基线 8 个点）；抓取 65% vs 45%——差距最大的环节，也是整个 rollout 成败的关键；正确释放与自主终止约 57%（BC-Z 没有终止动作，只能跑满固定步数）。
- 跨物体动作迁移（240 次 rollout）：用「把可乐罐立起来」等 5 个提示对绿罐、薯片袋、订书机、毛绒玩具等 6 种无关物体执行同一动作，总体 34.2% vs 17.5%；place-into 类 54.2% vs 29.2%，knock-over 29.2% vs 0%，从抽屉取放到台面 25% vs 0%。训练配对里从未出现「提示物体 ≠ 场景物体」的样本，纯属涌现；模型还表现出隐式语用推理——场景里有绿罐时优先选最接近可乐罐的它下手。
- 无提示消融（120 次 rollout）：空白视频提示下 Vid2Robot 23%、BC-Z 5%，远低于有提示的约 55%/52.6%——策略确实在读视频，不是拿场景先验猜任务。
- 辅助损失消融（162 次 rollout）：全损失约 61%，只留动作损失约 45%；单去掉视频-文本对比仅降 1-2 个点。涨点主要来自 TCC 对齐与视频-视频对比；BC-Z 引以为核心的语言辅助监督几乎不贡献。
- 免费的长程能力：串接多段提示视频（开抽屉→放入物体→关抽屉），terminate 信号触发切换下一段，不需要任何长程训练数据。

## 5. 局限

作者自认三类：自遮挡（IK 解可能把机械臂横在相机前）、抓取失败（透明/可变形物体、抽屉把手等易碰撞区域）、干扰物误识别；单目 RGB 隐式学深度，遮挡时失效，需要多模态传感融合；训练视频全部是精心采集的 5-20 秒短指令视频，长程演示与真正 in-the-wild 网络视频需要新的配对策略。

延伸批判：

1. 评测任务全部来自训练指令集（视频未见、任务本身见过），真正 unseen task 的能力没有测——与 HOST/RICL 测全新物体+全新动作的口径不可比；跨物体迁移的 34.2% 才是它最接近 unseen 设定的数字。
2. 绝对天花板低：最好设定 54.9%，跨物体 34.2%，离可部署有代差。
3. 配对完全依赖语言标注，可扩展性受限于「带指令标签的机器人数据」，与它自己批评语言接口的立场构成微妙张力（XSkill 等免配对路线针对的正是这点）。
4. 视频是被动条件：16 帧均匀采样一次性喂进 Resampler，推理时没有执行进度与视频进度的显式对齐，TCC 只做训练期正则——这是后来被 HOST 点名的结构性死穴。

## 6. 与 HOST/GEN-1.5 的关系

Vid2Robot 在本调研坐标系里是「被超越的直接前辈」：HOST 论文把它当 OSVI 基线复现（条件机制移植到 HOST 同款主干上以排除主干差异），在 50 个未见任务上只有约 19%，被 HOST 的 62% 拉开 43 个点。

失败根源可以用它自己的设计解释：整段视频压成 64 个 token 当被动上下文，动作监督锚定在机器人轨迹的固定时间步——HOST 诊断的「时间错位让模型学会忽略视频」三宗罪，在 Vid2Robot 架构上全部成

立。修复路径有清晰的师承：Vid2Robot 的末位作者 Dwibedi 正是 TCC 原作者，Vid2Robot 把 TCC 用作辅助正则（只塑造表征）；HOST 把同一个 TCC 加上 Smooth DTW 升级成显式进度流形，推理时用它主动选择预测目标。同一个工具从「训练期损失」变成「推理期机制」，one-shot 成功率从 19% 走到 62%——这是本调研里最干净的一组对照。

对 GEN-1.5 路线，Vid2Robot 是数据曲线上的早期点位：约 10 万条机器人轨迹 + 约 1 万条人类视频，用显式配对监督练出视频跟随能力；GEN-1.5 用 50 万小时数据把同类能力做成免显式配对的涌现 ICL（59%）。Vid2Robot 留下两笔至今独特的资产：三层配对数据构造法（90% 免费的 Robot-Robot 配对 + 少量 hindsight 人类演示）是跨具身训练的省钱配方原型——HOST 的两阶段训练（193k 同具身轨迹 + 5.8k 人类视频配对）本质上是同一思想的放大版；提示视频串接做长程任务的组合技，至今仍是视频条件策略的零成本红利。跨物体动作迁移（动词与宾语解耦）则预演了 HOST 鲁棒性实验中「未见物体替换只掉 4 个点」的能力来源。

# 外围论文速览：one-shot 技能习得调研的五个坐标

配合 01\_HOST\_zh.md (HOST, arXiv 2607.20033) 与 02\_GEN\_series\_zh.md (GEN-0/1/1.5) 阅读。

本合集的五篇论文各占调研版图的一个坐标。ViVLA 是 HOST 一作团队 (Guangyan Chen / Yufeng Yue) 的直系前作，代表「隐动作端到端」的 one-shot 视频模仿路线，与 HOST 的「显式对齐 + 级联」构成方法演化链。 $\pi 0.5$  与 Wall-OSS 是 HOST 评测的两类基线：前者是语言条件零样本 IL 的上限 ( $\leq 17\%$ )，后者是最强 SFT 微调基线 (56%)，且与 HOST 同属 X SQUARE ROBOT。EgoScale 代表与 HOST 结构路线对照的「人类数据规模化」路线，用 2 万小时第一人称数据给出 scaling law 与 one-shot 适配能力，呼应 GEN-1.5 的涌现叙事。Fast-WAM 是 HOST-base 引用的世界动作模型架构来源，其「视频建模的收益在训练时而非测试时」的受控结论，是 HOST 主干选型 (双专家 MoT + Wan2.2 + flow matching) 的实证支撑。

## 1. ViVLA (See Once, Then Act: Vision-Language-Action Model with Task Learning from One-Shot Video Demonstrations)

arXiv 2512.07582 · 北京理工大学 + LimX Dynamics · arXiv preprint (2025-12)

**一句话定位：**测试时给一段专家示范视频 (含人类视频)、零参数更新学会新操作任务的 VLA；一作 Guangyan Chen 与通讯 Yufeng Yue 即 HOST 团队，可视为 HOST 的直系前作。

**核心方法：**基于 Qwen2.5-VL 联合处理示范视频与机器人观测，同时预测示范中的动作序列和机器人后续动作。跨具身动作空间靠 latent action tokenizer 统一：仅从视觉学隐动作，专家视频与机器人轨迹联合训练，加 action-centric cycle consistency 正则与局部-全局判别器防止解码器把隐动作信息泄漏回编码器。动作生成用并行解码替代自回归 (START token 指定并行数量，单次前向出全部动作 token)，避免 shortcut learning 并压低推理延迟；temporal-spatial masking 削减视频 token 冗余。数据侧自建 expert-agent 配对管线：7,421 条人类视频 (100+ 任务) 经 3D Gaussian Splatting 渲染成机器人执行同任务的 4D 场景，得到 Human2Robot 数据集 89,736 对，训练总量 892,911 对样本。

**关键结果：**unseen LIBERO 任务成功率较基线提升超 30%，跨具身示范视频条件下保持 35% 以上增益，真机上从人类视频学 unseen 任务提升超 38%。

**在本调研中的角色：**HOST 的方法学前身。ViVLA 把跨具身翻译埋在隐动作空间、把视频-执行时间对应交给 transformer 隐式学习；HOST 恰好把这两处换成显式模块 (SDTW+TCC 进度流形对齐、定位-未来观测-动作级联)。对照读能看清 HOST 每个设计选择的动机来源。

## 2. $\pi 0.5$ ( $\pi 0.5$ : a Vision-Language-Action Model with Open-World Generalization)

arXiv 2504.16054 · Physical Intelligence · arXiv preprint (2025-04)

**一句话定位：**用异构数据 co-training 做开放世界泛化的旗舰 VLA，首个在完全未见过的真实家庭里完成 10–15 分钟长程操作（清洁厨房/卧室）的端到端系统。

**核心方法：**同一模型分层推理——先以文本预测语义子任务（如「拿起砧板」），再条件于子任务输出低层动作块。预训练混合移动机器人真实家庭数据（约 400 小时）、非移动机器人多环境数据、实验室跨具身数据（含 OXE）、高层子任务标注与网页多模态数据，首阶段 97.6% 的样本不来自移动操作本体；离散 token 预训练 280k 步后，后训练 80k 步加入 flow matching action expert，并用「语言遥操作」采集的口头指令示范训练高层子任务选择。控制侧 50 Hz 输出 18–19 维动作（双 6-DoF 臂 + 夹爪 + 全向底盘 + 躯干升降）。

**关键结果：**在三个训练集外真实家庭的厨房/卧室清洁任务上一致成功，mock 环境评测与真实家庭表现吻合；泛化能力随训练环境数量持续 scaling。

**在本调研中的角色：**HOST 评测的零样本 IL 基线。在与 HOST 相同的 193k 轨迹上继续训练后， $\pi 0.5$  面对 50 个新任务仅  $\leq 17\%$  成功率（HOST 62%）——语言指令给得出任务语义，给不出新技能的运动细节，这 45 个百分点的差距是「视频演示携带执行信息」价值的直接量化。它同时也是 Fast-WAM 的主要参照（RoboTwin 79.8% vs Fast-WAM 91.8%），在本调研中是贯穿多篇论文的公共基线。

### 3. Wall-OSS (WALL-OSS: Igniting VLMs toward the Embodied Space)

arXiv 2509.11766 · X SQUARE ROBOT（自变量机器人）· arXiv preprint（2025-09），代码开源（wall-x）

**一句话定位：**X SQUARE ROBOT 的开源具身基础模型，针对 VLM 到 VLA 的三重 gap 给出紧耦合 MoE + 统一跨层级 CoT 的配方；在 HOST 评测中既是零样本基线也是最强微调基线，与 HOST 同公司。

**核心方法：**先诊断 VLM 迁移到动作空间的三个 gap——模态与数据规模（动作缺大规模对齐语料）、预训练分布（第一人称/鱼眼/自遮挡视角 vs 网络图像）、训练目标（离散 next-token vs 连续高频轨迹）。对应解法：紧耦合 MoE 在不同训练阶段激活不同专家，Inspiration 阶段以 FAST 离散 token 向 VLM 输出空间注入粗动作先验并补具身 VQA，Integration 阶段用 flow matching 训高频连续控制再联合优化；Uni-CoT 把指令推理、子目标分解、细粒度动作合成放进单一可微框架，推理时可自适应决定是否展开 CoT、可边推理边执行。数据超 10,000 小时：自采多平台真机数据 + 24 个开源动作数据集（AgiBot World、DROID、BC-Z 等）+ 通用/具身 VQA。基座 Qwen2.5-VL-3B。

**关键结果：**具身 VQA（场景描述/目标定位/动作规划）显著超原基座；六个操作任务（其中 set-table、tidy-bedroom、place-by-color 三个 unseen）超  $\pi 0$  等基线，长程任务与指令跟随增益最大。

**在本调研中的角色：**HOST 的双重对照。零样本口径  $\leq 17\%$ ；加 50 条遥操作演示 + LoRA 微调后 56%，是 HOST 论文全部微调基线中最强的，但仍低于 HOST 用 1 段人类视频、零参数更新的 62%，且 SFT 后旧技能仅保留 43%。同公司出品让这个对照排除了「挑弱基线」的质疑——HOST 打赢的是自家最强 SFT 配方。

### 4. EgoScale (EgoScale: Scaling Dexterous Manipulation with Diverse Egocentric Human Data)

**一句话定位：**用 20,854 小时动作标注的第一人称人类视频（较此前工作大 20 倍以上）预训练灵巧手 VLA，给出人类数据的 log-linear scaling law，one-shot 任务适配作为副产品出现。

**核心方法：**把人类视频转成显式动作监督——相对腕部 SE(3) 运动（消除相机全局运动依赖）+ retarget 到高自由度手关节，而非学任务无关的视觉特征。三阶段流程：2 万小时人类数据预训练 flow-based VLA；50 小时人类 + 4 小时机器人的对齐 play 数据 mid-training（匹配桌面场景与视角，把表征接地到机器人传感与控制）；下游任务 post-training。

**关键结果：**验证损失随数据量呈 log-linear:  $L = 0.024 - 0.003 \cdot \ln(D)$ ，拟合  $R^2 = 0.9983$ ，且直接预测真机表现——1k 到 20k 小时，五任务平均完成度从 0.30 升到 0.71，无饱和迹象。22-DoF 灵巧手五个任务（衬衫卷叠/卡片分拣/夹钳取物/拧瓶盖/注射器移液）上比无预训练基线平均成功率提升 54%；单条机器人示范适配 unseen 衬衫折叠任务达 88% 平均成功；迁移到 Unitree G1 三指手仍有 30% 以上绝对提升。

**在本调研中的角色：**与 HOST 构成「数据 vs 结构」的路线对照。EgoScale 与 GEN-1.5 同属规模化路线——GEN-1.5 用 50 万小时遥操作数据让 one-shot 涌现，EgoScale 用 2 万小时人类视频给出可外推的定量 scaling law；HOST 则证明 193k 轨迹 + 6k 人类视频靠归纳偏置也能做到 62%。另需辨析：EgoScale 的 one-shot 是「单示范 post-train」（更新参数），HOST 是「in-context 零更新」，两种 one-shot 语义不同，这是本调研需要区分的核心概念。

## 5. Fast-WAM (Fast-WAM: Do World Action Models Need Test-time Future Imagination?)

**一句话定位：**用受控消融回答世界动作模型 (WAM) 的根本问题——收益来自训练时的视频建模目标，还是测试时的未来想象？答案是前者：保留视频协同训练、砍掉测试时未来生成，性能基本不掉、延迟降 4 倍。

**核心方法：**Mixture-of-Transformers 架构——Wan2.2-5B 视频 DiT + 1B action expert (hidden 1024) 共享注意力，总参数 6B，双分支同用 flow matching (10 步去噪)。训练时联合优化视频预测与动作目标；推理时视频 DiT 仅对观测上下文做单次前向、充当 world encoder，只去噪动作分支。构造三个对照变体隔离变量：Fast-WAM-Joint（未来视频与动作联合去噪）、Fast-WAM-IDM（先生成未来视频再条件出动作）、无视频协同训练版。

**关键结果：**RoboTwin 2.0 上 91.8%（不用具身预训练），超  $\pi 0.5$  (79.8%) 与带预训练的 Motus (87.8%)，持平带预训练的 LingBot-VA (92.2%)。变体对照：Joint 90.6%、IDM 91.3%、无视频协同训练 83.8%——测试时想象最多贡献 1.2 个点，视频协同训练贡献 8 个点。LIBERO 平均 97.6%（去掉协同训练跌至 93.5%）。真机延迟 190 ms，比 imagine-then-execute 类 WAM 快 4 倍以上。



**在本调研中的角色：**HOST 论文中 HOST-base 基线引用的架构来源；HOST 主干的双专家 MoT、视频专家从 Wan2.2 初始化、共享注意力、flow matching 设计与 Fast-WAM 同构。Fast-WAM 的结论也为 HOST 的选型提供实证：HOST 的「未来观测预测」级不做迭代视频去噪的完整想象，而是级联内单次自回归 flow matching 的中间表征——视频先验的承重在训练目标而非测试时生成，与 Fast-WAM 的发现互为印证。



# EgoWAM 深度解读：换掉世界预测目标，人类数据才不「漏毒」进动作头

EgoWAM: World Action Models Beyond Pixels with In-the-Wild Egocentric Human Data arXiv

2607.08436 (2026-07) · Georgia Tech RL2 Lab (Danfei Xu 组) 作者: Baoyu Li\*, Xincheng Yin\*, Mengying Lin, Yixin Zhang, Danfei Xu

## 1. 一句话定位

EgoWAM 是一项受控对比研究：固定 HPT 主干（256 维/16 层）、flow-matching 动作头与数据配比，只换世界模型头的预测目标——Pixel VAE / DINO 特征 / 相机稳定化 3D motion flow——回答「WAM 人机共训中，什么世界表征最利于野生第一人称人类数据向机器人迁移」。在三个真实双臂任务、共 1800 次 rollout 上：自然人类数据经常把 BC 共训拖到 robot-only 之下，WAM 共训却稳定获益；像素目标迁移最弱，DINO 把 OOD 物体/场景泛化最高提到 4 倍，3D flow 把 in-domain 性能提高 20-30%，且对人类数据是否与机器人对齐完全免疫——cup-on-saucer 上无论演示者自然发挥还是刻意模仿机器人都恒 85%，而 Pixel/DINO 要靠人工对齐才能从 35%/50% 升到 65%/70%。结论浓缩成世界表征三准则：外观抽象（D1）、跨具身一致（D2）、自我运动分解（D3）。

## 2. 要解决的问题

行为克隆共训是吃人类数据的主流路线：把手演示重定向进机器人动作空间一起模仿。要害在于共享动作解码器是人类数据进入策略的唯一通道，可迁移内容（物体、场景、语义）与不可迁移执行（形态、头动、行为风格）被迫纠缠——论文称之为 action-level 共训的 bitter lesson。EgoScale 等已证明该范式可 scale，但前提是采集时就把视角、速度、风格对齐到机器人；一旦换自然数据，不可执行的类人动作（人横握杯、夹爪只能正面夹）漏进动作头造成负迁移——实验中三任务里只有 bag-grocery 的拾放动作天然对齐、BC 共训才有正收益。WAM 加一个预测未来场景的辅助头，开出第二条监督通道：动力学基于观测而非动作，对形态差异钝感。但「该预测什么」此前无人受控研究——多数 WAM 沿用视频 VAE 像素隐变量，光度重构把运动与外观纠缠，论文定位其为像素级 WAM 共训失效的主因。

## 3. 方法

**先把动作通道做满**，保证 BC 是强基线而非稻草人：人/机动作统一到 14 维末端空间（双臂 6-DoF SE(3)+夹爪）；人手位姿用头部位姿变换回瞬时设备系，扣掉头部自运动；速度错位用差异化窗口（人 1s、机 1.5s，均重采样 100 步）；分位数归一化抗跟踪外点。

**WAM 第二通道**：主干上 64 个动作 token 与 16 个未来 token 并行查询，联合损失  $L_{\text{action}} + \lambda \cdot L_{\text{world}}$  ( $\lambda=1$ )。三种可插拔目标：(a) Pixel——冻结 Wan VAE 隐变量 + DiT 头（从零 6 层 384 维；Pixel-PT 用预训练 VACE-1.3B），三准则全违背的重构基线；(b) DINO——DINOv2-B 补丁特征 + RAE 宽 DDT 头，满足 D1/D2，但特征锚定图像网格，D3 只部分缓解；(c) 3D flow——Track4World 稠密 3D

点跟踪 + Aria VIO 位姿把未来点变换回当前相机系，静止背景流场归零， $28 \times 40 = 1120$  锚点回归 100 步位移场（机器人 2mm、人类 10mm 阈值去噪），构造性满足全部三准则。

**推理只留动作头：**沿用 Fast-WAM 的结论（WAM 收益来自训练时表征塑造而非测试时想象），部署时丢弃世界头，单张 4090 上 30Hz，四个变体部署开销一致，rollout 差异全部归因于训练期表征。

## 4. 实验结果

平台：双 ARX5 + 头戴 Aria + 双腕 D405。三任务各 300–360 条机器人演示（2.5–3h）；人类数据两档：in-domain 各 2h（1:1）、EgoVerse-A 野生 20.5h/21h/7h（标称约 10:1）。每方法 ID/OOD 各 20 rollout（OOD=10 未见物体+10 新场景），报告 finite-sample 95% 置信区间。

主结果（Fig 3）：WAM 全面压过 BC。Pixel 最弱——bag-grocery 上凭空抓取、fold-clothes 第三折做不完；DINO OOD 最强（最高 4 倍）；3D flow ID 最强（+20–30%，全工作台任意杯位精准放置）。

UMAP（Fig 4）显示 BC 下人/机嵌入割裂，WAM 下融为一体。

四组关键消融：

- **对齐消融（A.1, cup-on-saucer）**：演示者刻意模仿机器人后 BC 才升到 robot-only 之上；Pixel 35%→65%、DINO 50%→70%，量化了违背 D3 的代价；3D flow 两种采集方式下都是 85%——别人靠人工对齐挣回的分，它构造性免费拿到。
- **错位消融（Q3, bag-grocery）**：故意采夹爪无法复刻的怪异抓取，BC 崩到 robot-only 之下，3D flow 仍高于 robot-only。
- **模态消融（A.2, cup-on-saucer）**：人类批次只给世界监督（无动作标签）已胜过只给动作标签，OOD 场景 10% vs 0%；联合最优——动作标签反向充当上下文，把流场预测损失从人流 0.23/机流 0.20 降到 0.22/0.19（表 1）。
- **仿真复现（RoboTwin, 表 4）**：pick-diverse-bottles 上 DINO 单机 4%→跨机 28%、3D flow 0→16%、BC 2→6%，而同动作空间、无世界头的 ACT-EE/DP-EE 只有 2%/5%——增益归于世界头而非统一动作空间；stack-bowls-three 因资产材质漂移意外变成外观偏移测试，只有 DINO（8%）与 flow（16%）存活，BC/Pixel 归零；hanging-mug 毫米级插入全员 ≤1%。
- **Pixel-PT 失效（A.3）**：预训练视频先验幻想袋子已打开，策略直接跳过开袋；从零训练的 Pixel 画面糊但时序忠实，反而更可靠。

## 5. 局限

作者自认三条：增益停留在 context 级（换物体/场景），学不到新运动原语（T 恤模型折不了短裤）；每任务单独训一个策略，多任务未验证；最优世界表征仍是开放问题。

延伸批判：

1. **三准则只有两条被实验支撑。**D3 有 A.1 直接量化，D1 有 RoboTwin stack 外观漂移的意外验证，但 D2「跨具身一致」通篇只有构造性论证和 Fig 4 的定性 UMAP，没有任何把 D2 与 D1/D3 解耦的实验。理论框架的三分之一是信念而非证据。

2. **统计功效薄**。3 个任务、每格 20 rollout, OOD 再劈成 10+10;「最高 4 倍」这类比值口径落在 10 次试验的分母上 (10%→40% 不过是 1 次对 4 次成功), 区间极宽。且主实验只有柱状图没有数值表, 4 倍与 20–30% 都要读图。置信区间做得比同行认真, 但改不了样本量。
3. **「in-the-wild」实为「Aria 采的 wild」**。3D flow 依赖 Aria VIO 位姿做相机稳定化, 动作标签依赖 Aria MPS 手部姿态——表现最好的表征恰是对专用眼镜元数据依赖最重的。无 VIO 的 YouTube 级真野生视频能否支撑该管线未验证。
4. **scaling 声明超出证据**。「unlock human–data scale」只有 2h 与约 20h 两个数据点, 没有 EgoScale 式多点曲线; bag–grocery 的 EgoVerse 仅 7h (对 2.5h 机器人数据不足 3:1), 10:1 是标称而非逐任务事实。
5. **受控实验没控头容量**。Pixel–PT 头 1.3B/30 层, flow 头 4 层 256 维,「只换表征」实际同时换了头架构与容量; 且 DINO/flow 的互补结论在仿真里翻转——stack (外观偏移) 上 flow 16% 反超 DINO 8%,「OOD 用 DINO」并不稳定。

## 6. 与 HOST / GEN–1.5 / EgoScale / Fast–WAM 的关系

在本调研「人类数据怎么用」的问题谱上, EgoWAM 给出**表征层答案**, 与另两篇构成三角对照: EgoScale 走**数据轴**——用采集纪律把人类数据对齐到机器人, BC 共训跑出 2 万小时 log–linear scaling law; Fast–WAM 走**时机轴**——证明视频建模的收益在训练时而非测试时; EgoWAM 走**表征轴**——把 Fast–WAM 的结论当设计前提 (推理丢世界头), 把 EgoScale 的「对齐前提」变成待消解的问题。其引言直接点名 EgoScale ([71]) 为「只有对齐数据才能 scale」的例证, 而 A.1 是两条路线的显式对照实验: 手工对齐演示者 (EgoScale 式纪律) 能救 BC、给 Pixel/DINO 提 20–30 个点, 3D flow 却不需要这一切——对齐的收益被表征选择免费吸收。

与 HOST/GEN–1.5 是分工而非竞争: EgoWAM 不做 one–shot, 作者自认增益停在 context 级、学不到新技能, 这与 HOST (测试时从一段人类视频接出动作, 50 个未见任务 62%) 和 GEN–1.5 (50 万小时数据涌现 ICL, 59%) 处于不同层。EgoWAM 回答的是这些系统**预训练阶段**该拿什么目标吃人类数据: 若 GEN–1.5 式大规模预训练把世界目标从像素换成 DINO/3D flow, 按本文证据 OOD 泛化仍有放大空间; HOST 的测试时翻译层与 EgoWAM 的训练时表征层原则上可直接叠加。A.2 还额外给了一条合流证据: 动作标签与世界监督互为增益、联合最优——动作重定向 (EgoScale 路线) 与世界预测 (EgoWAM 路线) 不是二选一, 而是两条监督通道的并联。

# Zero-WAM 深度解读：把人类视频「造」出来当任务规格，再用 IFP 逼模型真的去看

Zero-WAM: In-Context World-Action Modeling from Human Videos for Open-Ended Task Generalization arXiv 2608.26103 (2026-08) · Robbyant + 香港科技大学 (广州) + 香港科技大学

## 1. 一句话定位

四篇具身 ICL 论文里唯一正面攻打「未见任务」的一篇：在 RoboTwin 2.0 做任务级切分（43 任务训练、7 任务完全留出），测试时不给未见任务任何机器人数据、不更新任何参数，只靠一段人类操作视频当上下文，7 个未见任务平均成功率 46.95%，比 LingBot-VA（17.45%）高 29.50 个百分点、七项全胜，评测规模也是四篇里最大的（3 种子 × 每任务 100 次闭环 rollout）。两块核心积木：HumanGen 数据流水线——方向反转，从有动作的机器人轨迹合成人类视频，74.2K 对 / 8.6K 任务 / 超 45 种本体；IFP 训练期反捷径目标——没有它，人类视频塞进上下文反而是净负收益。

## 2. 要解决的问题

论文把零样本跨任务泛化重述为任务规格问题：LLM 靠上下文指定新任务，机器人也应如此；而操作任务最自然的规格不是语言（难以刻画空间约束、中间状态与时序结构），而是人类视频——它直接展示场景应当如何演化。落地有两只拦路虎。一是数据：任务丰富的人-机配对数据稀缺，人工采集成本随任务数爆炸（RH20T 110K 样本仅 147 个任务）。二是捷径：teacher-forcing 训练下，下一段机器人视频往往靠外推机器人历史即可预测，模型不读人类视频也能降损失，到未见任务上便继续无视上下文——恰好在最需要它的时候。

## 3. 方法

### 3.1 HumanGen：方向反转的数据流水线

主流做法先采人类视频再想办法配机器人动作；Zero-WAM 反过来，从已有可执行动作的机器人轨迹出发：VLM（Gemini 3.1 Pro / Qwen3.6-Plus）做任务分析并产出图像编辑提示 → 图像编辑模型（Nano Banana 2 / Qwen-Image-2.0）把机器人首帧改写成人类操作场景 → 视频生成模型（Wan 2.7 / Kling AI 3.0）合成人类操作视频 → VLM 按语义保持与物理合理性打分质检。产出 74.2K 对人-机 ICL 配对、8.6K 任务、超 45 种本体，任务数约为 RH20T（147）的 60 倍。External 子集刻意加大视觉不对齐（强制改场景、背景、物体实例与摆放，混两种视角），逼模型学任务级对应而非外观复制；In-house 子集反向保持对齐。同一套任务级重采样还产出 Task-diverse VA：把五个公开数据集重切成 6,000 多个任务、每 epoch 均衡采样约 40 万条轨迹，防止预训练被少数任务的重复遥操淹没。

### 3.2 模型：人类视频只进视频分支

主干沿 LingBot-VA 框架把 Wan-2.2-Ti2V-5B 改造成因果视频-动作模型：MoT 双 Transformer 各持参数、共享注意力，先预测下一段机器人视频，动作分支作为逆动力学从预测视频解码动作。人类视频经同一

VAE 编码后拼作前缀记忆，仅供视频分支 attend；动作分支的条件完全不变——任务语义已被吸收进预测出的机器人视频。RoPE 高度轴偏移  $\Delta H=32$  把人类视频 latent 挪出机器人视频坐标范围防混淆。ICL 推理时人类视频编码一次缓存复用，语言指令可整个关掉。

### 3.3 IFP：训练期反捷径目标

借鉴 Next Forcing 的多 chunk 预测：加  $K=4$  个 IFP 模块（各一层 Transformer，从视频分支末层初始化），要求从当前机器人视频表示（多个中间层特征融合）预测跨步  $s=2$  的多个未来 chunk，推理时整个移除。最关键的设计是 IFP 刻意不直接以人类视频为条件：若直接吃人类视频，辅助分支会自学出一个独立的视频条件预测器，主分支照旧偷懒，推理一剥离便一无所获；只有让未来损失去监督主分支表示，捷径才被堵死。这段论证对一切「训练挂辅助、推理剥离」的设计通用。预训练 15,360 GPU 小时，VA 与 HumanGen 数据按 1:5 采样，ICL 样本把语言 dropout 提到 0.4 以削弱文本依赖。

## 4. 实验结果

仿真主结果（3 种子  $\times$  100 rollout）：Zero-WAM  $46.95 \pm 0.72$ ，LingBot-VA  $17.45 \pm 1.40$ ，WAN-Action  $10.98 \pm 1.07$ ，七个未见任务全部领先；place empty cup 达 84.87%（是两基线的两倍以上），stack blocks three 上唯一非零（9.00%）。真机（双臂 Franka，每族 30 次）：物体入容器 53.3 vs 43.3，三物体顺序操作 33.3 vs 10.0，双桌腿插装 16.7 vs 0.0；注意接口不对称——Zero-WAM 只看人类视频，LingBot-VA 拿的是详细文字指令。

消融链条是全文信息量最大处。把两张消融图串起来：LingBot-VA 17.45  $\rightarrow$ （仅任务均衡采样的 text-only 变体）39.44  $\rightarrow$ （加人类视频、去 IFP）28.55  $\rightarrow$ （完整）46.95。三个读数：其一，头条 +29.50 中约 22 分来自任务级重采样这个数据工程决策，标题主张的人类视频机制连同 IFP 贡献约 7.5 分；其二，无 IFP 时加人类视频比不加低 10.89 分——朴素塞演示进上下文是净负收益，强力自证捷径论点，也说明「人类视频作为任务规格有效」远比摘要读起来脆弱；其三，IFP 把 stack blocks three 从 0.00 破到 9.00。另一组小规模消融（只用 43 个已见任务训练）显示 ICL 本身能把 10.98 提到 36.36，但长时程全灭，大规模任务多样的 ICL 预训练不可省。限定：39.44 与 28.55 出自不同消融面板，论文未声明两变体训练配置严格匹配，方向性结论成立、严格等价待作者确认。

## 5. 局限

作者自认（仅讨论一段）：实验限于静态桌面操作，移动操作、更长时程、动态非结构化环境留作未来；人-机在具身、观测、动作上的 gap 仍在，HumanGen 只是语义级桥接。

延伸批判：

1. **人类视频 100% 合成，合成到真实的 gap 零评估。**仿真评测的测试视频原文明说由流水线生成；真机训练对用词是 collect（应为真拍），但测试视频来源未明示。落地第一堵墙没有测。
2. **质检零数字。**VLM 打语义分与物理分，但通过率、抽检一致性、错误类型分布一律未报——「零人工标注」的另一面是「零人工质量把关」。
3. **基线近亲。**唯一外部基线 LingBot-VA 是同组前作，WAN-Action 为自建变体，没有与任何专为 ICL 设计的方法比过；stamp seal 与 move stapler to pad 的成功判据被修改过（对所有方法一



致、承诺开源)，而两者是其第四、第二高分任务。

4. **HumanGen 不新增任务知识**：人类视频从机器人轨迹渲染而来，规模化的是接口，不是知识。

5. **复现难**：流水线依赖 Gemini、Nano Banana、Kling 等闭源商业模型，外部重造 HumanGen 的路被堵住大半。

6. **「未见任务」只在仿真成立**：真机三族均为未见构型而非未见任务；未见环境从未测过；长时程仍是崩塌区。

## 6. 与 HOST / GEN-1.5 / S1 及四篇 EICL 论文的关系

四篇具身 ICL 各守一条泛化轴：WAM-TTT 未见场景、RoboTTT 未见构型、StellaVLA 未见扰动、Zero-WAM 未见任务——离「跨任务技能习得」的正题最近。它与 StellaVLA 同处纯上下文、零梯度一侧，且两篇撞出同一套路的两种变体：都用 VLM 把机器人轨迹重渲染成另一模态当上下文（结构化文本 vs 合成视频），互不引用；但 Zero-WAM 缺 StellaVLA 那种对/无/错演示三向干预，「上下文确实被用上」的证据只有 IFP 消融这一间接层。论文相关工作里明确与快权重派（WAM-TTT、RoboTTT 仍需测试时适应）划界，却同样零直接对比。

对产业叙事，它是最尖锐的学术反证。GEN-1.5 声称 ICL 从 50 万小时预训练自然涌现、无架构改动无辅助目标（一次性提示 59%），S1 称一条演示可抵约 380 条后训练示例（未见长时程 66%）；Zero-WAM 恰是学术侧最接近该路线的一篇——大规模预训练、纯上下文、零梯度——却用自己的核心消融证明：在 15,360 GPU 小时的规模上，没有 IFP 这个显式反捷径目标，人类视频是净负收益。公平限定：学术规模远小于产业主张，「更大规模能否免掉显式机制」仍未定论。

与 HOST 对照最意味：HOST 用真实人类视频加进度流形显式对齐（50 任务 62%，秒级习得），Zero-WAM 用合成人类视频加 IFP 反捷径——一个在推理期上结构、一个在训练期上目标，却确认了同一个病灶：演示默认会被模型忽略，必须显式逼它用。与 RoboTTT 则是互补拼图：Zero-WAM 打下未见任务但长时程崩（堆三积木 9.0%），RoboTTT 打下 5 分钟长时程但场景与任务全固定；一个占输入前缀、一个占递归状态，架构不冲突，合流是明摆着的下一步。

# WALL-WM 深度解读：把世界-动作建模「循事件关节」下刀

**WALL-WM: Carving World Action Modeling at the Event Joints** arXiv 2606.01955 (2026-06) · X Square Robot Team (自变量机器人) 技术报告, 未经同行评审 作者 31 人, Shalfun Li 领衔 (核心贡献者+项目负责人), Hao Wang 通讯; 标题化用柏拉图《斐德罗篇》「循自然关节而解」

## 1. 一句话定位

WALL-WM 是自变量机器人 (Wall-OSS/wall-x 出品方) 的世界-动作模型 (WAM) 预训练报告: 把 VLA 学习的原子单元从「固定长度动作 chunk」换成「动作接地的语义事件」——起止由行为切换而非外部时钟决定的变长片段——并配齐事件级四层字幕数据生态、Wan 视频塔+动作 DiT 层耦合双塔、Muon 基建与蒸馏+FP8 的 10Hz 部署栈。真机四套评测 (自建双臂平台, Task Progress 0-100 口径) 事件模式全面领先: 多样操作 75.86 对  $\pi$ 0.5 的 55.64; 关键消融显示事件条件执行+跨视角注意力把推理类任务从 32.6 拉到 71.6。

## 2. 要解决的问题

主流 VLA/WAM 以固定 chunk 为监督单元, 等于用外部时钟切割具身动力学。三模态粒度天然不同: 语言描述目标与事件, 视觉沿场景动力学连续演化, 动作在控制时间尺度上对接触与时序敏感。强行共享一个固定预测窗, 训练退化为短视相关拟合: chunk 会拦腰截断语义行为、或把多个行为并成一个目标, 还需额外历史帧才能确定自身语义; 这不仅浪费视频基础模型的视觉-语义先验, 还会用 chunk 特有的动作捷径覆写它, 伤及组合性与长程泛化。作者给对齐单元立三原则——保几何 (不把三模态压进单一嵌入空间)、保先验 (兼容 caption-to-video 结构)、可执行因果 (时间支撑清晰、时长跟任务走) ——固定 chunk 三条全违反, 「语义事件」三条全满足。

## 3. 方法

**事件为原子的双塔去噪器。**建模  $p(V_e, a_e | V_0, s, c_e)$ : 给定当前多视角关键帧、本体状态与事件字幕, 联合去噪事件对齐的变长未来视频与末端轨迹。视频塔继承 Wan T2V DiT (视频评测版自 Wan2.2-5B 初始化), 三件加装完成多视角化: 零初始化投影的跨视角自注意力、Camera RoPE (每相机可学旋转身份, 运行时免标定)、训练期几何掩码对 (视锥相交掩码修剪注意力拓扑+管状 patch 掩码制造跨视角检索需求)。动作塔为同深度 DiT、随机初始化, 逐层单向读视频特征, 本体 token 走专属交叉注意力。

**训练五段:** 一、只训视频塔 (事件潜变量上 v-预测流匹配, 事件截 65 潜帧/129 原始帧; 字幕按事件长度以 0.1→0.9 概率丢弃, 逼模型学纯物理延拓)。二、冻结视频塔只训动作塔, 非对称 1-to- $N_d$  映射: 视频前向只跑到 50 步调度的中噪锚点  $s^*=45$ , 动作全部 50 步都从这一次前向读特征 (每优化步复用  $K=6$  个动作噪声抽样提吞吐)。三、Qwen3.5-9B 对齐 T5 特征空间成为可插拔条件器, 附带下一事件描述头与剩余时间回归头。四、Staircase 蒸馏: MoT 分支在中继深度分叉, 下层算一次共享表征、上层并行产出  $K_c$  个连续潜推理态, 由冻结 Qwen3.5-0.8B 的潜到文本重建损失监督, 绕开逐 token 自回归。五、可选 next-chunk 适配 (观测中心窗+历史帧)。推理两模式共用主干: 事件模式由 VLM/人给下一事件描述、执行变长段; 统一模式固定 chunk 滚动, 文本条件三源可中途热切换。



**数据与基建。**四象限数据地图：互联网视频（含 1.2M OpenVID 切片）、第一视角人类视频、XRZero-G0 免机器人穿戴采集（毫米级位姿、IK 重定向）、异构遥操+开源机器人数据，中心为失败-恢复数据；光流×动作差分校正视频-动作常量时偏（20FPS 下 2 帧约 100ms）；Task/Subtask/Action/Segment 四级字幕先按原子动作边界切分再命名；VL+动作双聚类均衡采样让长尾恢复行为成为显式采样单元；接触位形附近随机初始化主动制造恢复轨迹。基建：DMuon 分布式 Muon（原生实现优化器步近 2 倍前反向开销，DMuon 压成次要成本）、多事件序列打包、DMD 蒸馏（去掉动作锚损失则动作 MAE 恶化 53%）+FP8 分块量化+CUDA Graph，端到端 10Hz 闭环。

## 4. 实验结果

**视频侧**（WorldArena 协议，自建 200 域内+50 域外任务）：对 Wan2.1-1.3B/Wan2.2-5B，具身维度全面占优——交互质量 0.434 对 0.226/0.219 近乎翻倍，语义对齐 0.886，运动平滑 0.771；画质微降（0.503 对 0.577）。CO3Dv2 3D 探针（VidFM-3D 协议）：点误差 0.271、深度误差 0.132 皆最佳（胜 WAN2.1-14B 与 DINOv2/V-JEPA），AUC@30 0.727 略逊 WAN2.1-14B。

**真机**（自建桌面双臂，Task Progress 0-100 连续口径、全文无二值成功率；基线  $\pi 0.5$ /DreamZero/LingBot-VA，另设无事件预训练的从头对照 WALL-WM-U-Scratch；事件模式由微调 Qwen3.5-VL-9B 供事件描述）：

- 多样操作（7 任务）：75.86，对 U-Scratch 63.00、 $\pi 0.5$  55.64、DreamZero 39.97、LingBot-VA 29.71；
- 推理操作（5 任务）：71.60 对 59.50/56.40/32.70/31.60；按序按按钮 64 对 U-Scratch 的 18；
- 灵巧操作（2 任务）：32.00 仅略高于 U-Scratch 的 31.25——瓶颈在低层位姿精度，事件分解帮不上，绝对分很低；
- 泛化套件（杂乱场景+指令随机切换，4 任务）：53.75 对 DreamZero 28.50、 $\pi 0.5$  24.00，U-Scratch 崩至 18.50——预训练先验在指令切换下才真正兑现；
- 消融（有预训练、去跨视角注意力、固定长度解码，对事件模式）：推理套件 32.6→71.6、泛化 22.0→53.75，按序按按钮 0→64；作者自注这是两因素合并效应，无法归因单一组件。

## 5. 局限

作者自认：自建平台+平台对齐的预训练数据构成「共享任务定义也消不掉的评测环境优势」，与 LingBot-VA/DreamZero 的比较含不对等的调参投入；事件结构依赖大规模时间接地与细粒度字幕，自监督事件边界留作未来工作；成功率类指标粗糙；灵巧接触任务仍难。

延伸批判：

1. **「关节」是标注管线手工雕的。**事件边界来自字幕栈按原子动作切分，Human 质控层未报任何边界准确率——「按事件切分更优」的核心主张，其地基（切分质量）本身不可验证。
2. **口径自定且封闭。**Task Progress 评分表自定义、无二值成功率，无法与外部论文横比；「泛化」只测场景杂乱与指令切换，无跨具身、无新技能、无 one-shot/ICL 评测。

3. **事件模式命脉在 VLM 规划器**。下一事件描述若错，主干只会忠实执行错误事件；错误传播未量化，也没有 oracle 字幕对照。
4. **部署形态与世界模型话术有距离**。推理时视频只做一次到中噪锚点  $s^*=45$  的前向，未来影像从不完整成像，再叠 DMD 蒸馏——实为「视频先验当特征库」，与 Fast-WAM「收益在训练时」在工程上殊途同归（论文也引用并认可其免想象路线）。
5. **规模信息不透明**。自采机器人数据小时数、真机所用具体模型规模（家族横跨 10B 以下至数百亿）均未披露，「更大更好」的 scaling 声明无法复核。

## 6. 与 HOST / GEN-1.5 及 WAM 系工作的关系

**Wall-OSS 系谱（确认）**：署名 X Square Robot Team 即自变量机器人——Wall-OSS (wall-x 开源) 出品方、HOST 论文（北理工+自变量+清华）合作机构；文中 QUANTA X2 轮式人形亦属其产品线。WALL 系两代同堂：Wall-OSS 是 chunk 式 SFT VLA (HOST 的最强 SFT 基线，50 任务 56%)，WALL-WM 则判 chunk 式训练「短视相关拟合」死刑、以事件单元重造底座。注意论文通篇未引用 Wall-OSS，系谱在公司层面而非引用层面。由此可见一条公司内演进线：自家 chunk 基线被自家参与的 HOST (62%，一段人类视频 29 秒零更新习得) 超越后，底座层也转向结构化单元。

**时间接地三方案对照**：HOST 用连续、自接地的进度流形（零语言标注）；WALL-WM 用离散、语言命名的事件加剩余时间回归头（重标注）；StellaVLA 的语义分段居间。WALL-WM 的剩余时间头本质是离散化的进度坐标——两条线在「模型须知自己处于任务何处」上收敛，分歧仅在该知识由标注供给还是由结构自举。

**与 WAM 系**：对 Fast-WAM（视频建模收益在训练时而非测试时）表面唱反调（保留完整视频塔）、实际同流（推理只取锚点特征、不做未来想象），贡献轴正交——Fast-WAM 问「要不要想象」，WALL-WM 问「监督单元切在哪」。Staircase 的 MoT 分支与 Fast-WAM 的 MoT 双专家（HOST 主干来源）同构不同用。

**对本调研主线**：WALL-WM 无任何 ICL/one-shot 能力，是 2026-08 具身 ICL 拐点的底座层候选而非拐点本身。其价值在为「单元假设」提供公司级证据：泛化套件 53.75 对从头训练的 18.50，说明预训练单元切对与否决定先验能否兑现。若 GEN-1.5 证明 ICL 可从 50 万小时涌现 (59%)，WALL-WM 的隐含反题是：单元切对，涌现所需规模或可大减——这正是 HOST（结构派）与 GEN-1.5（规模派）之争在预训练层的镜像。

# WAM-TTT 深度解读：把人类演示写进快权重记忆，且只许写在感知侧

WAM-TTT: Steering World-Action Models by Watching Human Play at Test Time arXiv 2607.06988

(2026-07) · 北京大学 + 银河通用 Galbot + 中科院自动化所 + 清华

## 1. 一句话定位

WAM-TTT 把「用人类视频引导机器人」形式化为测试时训练问题：部署时只拿一小批无标注第一人称人类视频，对冻结世界-动作模型（WAM）视频专家上的 TTT 快权重做  $N=1$  步 inner SGD——主干、慢投影、动作专家全冻结——再拿适应完的固定快权重去跑机器人。演示不是被模仿的轨迹，也不是拼进上下文的 token，而是被自监督视频预测「吸收」成的离线技能记忆。9 个真机任务的未见家庭场景（New 设定）平均 progress 46.2%，比把同批视频当上下文 token 喂的 WAM-ICL（7.1%）高 39.1 个点；而去掉人机配对 meta-training 后成绩几乎归零（100.0 掉到 9.0），这是四篇 EICL 论文里对「ICL 纯涌现」最直接的一条学术反证。

## 2. 要解决的问题

机器人基础模型的知识固化在预训练权重里，部署后行为由权重加狭窄条件接口（语言、目标图、短历史）决定；想引导它做新任务变体，要么补采机器人演示（贵），要么任务级微调（灾难性遗忘、丧失可复用性）。人类视频是最自然的引导接口，但现有用法各有死穴：co-training 或微调需要手部姿态、3D 运动、重定向轨迹等额外监督，噪声大成本高；直接把原始人类视频当上下文条件（如 MimicDroid）则要求预训练阶段就学会这种能力，且上下文长度随演示积累暴涨。WAM-TTT 的目标清单是：不重定向、不要机器人动作、不要人侧标注、不动预训练主干，还要可复用。

## 3. 方法

### 3.1 架构：TTT 残差只挂视频专家

主干是 LDA-1B（Qwen3-VL-4B VLM + DiT-L 双专家 MMDiT，16 块），块内视频专家与动作专家经联合注意力耦合。唯一改动是给视频专家加 TTT 残差支路：视频流输出加上  $\Delta z_{TTT}$ ，动作流一行不改。TTT 层含慢投影  $\theta_K/\theta_V/\theta_Q/\theta_O$  与快权重小 MLP  $f_W$ （head 维 48、隐宽 128），读出  $\Delta z_{TTT} = \theta_O \cdot f_W(\theta_Q(z))$ 。人类信息在架构上就进不了动作专家——这是它抗域漂移、抗遗忘的结构性原因。

### 3.2 人机 meta-training：预先学好记忆接口

对相位对齐的人机配对演示（机器人第  $t$  步取  $\phi=t/T_r$  最近相位的人类帧），内层对快权重做 SGD，损失 = 人类视频预测 +  $\lambda \cdot$  逐层键值记忆重建（KVM）——衡量  $f_W$  能否从人类 Key 重建人类 Value。外层用标准 WAM 机器人多任务损失（视频+动作双 diffusion）反传穿过内层更新，训练 WAM、慢投影与快权重初始化  $W_{init}$ ；样本用完快权重即丢弃重置。

全文最扎实的一步在附录 A：KVM 的线性特例有闭式解  $W^* = V_h^T \cdot K_h \cdot (K_h^T \cdot K_h)^{-1}$ ，各向同性假设下退化为 Hebbian 外积记忆，用机器人 Query 查询恰得  $\sum(k_i^T \cdot Q_r)v_i$ ——一个没有 softmax 的线性注意力读出。所以 KVM 不是随手加的正则项，而是「用快权重实现对人类 Key/Value 交叉注意力」的变分定义，概念上把「演示当上下文」与「演示当记忆」两种对立做法缝在了一起。

### 3.3 测试时：一步 SGD，然后冻结去跑

部署时输入只有目标场景无动作的人类 RGB 视频（GoPro 第一人称，无姿态、无接触、无 3D 线索）。以视频生成模式跑与 meta 期同款的组合目标（两项都只依赖人侧）做 N=1 步 inner SGD（学习率 0.01，meta 期 0.1），适应完的快权重在整个 rollout 期间固定。所谓「零梯度」精确说法是零主干梯度。训练开销 8 张 H800、10 万步。

## 4. 实验结果

三种真机本体（Unitree G1 人形、Galbot gripper 双臂二指、Galbot sharpa 双臂灵巧手 58 维）、9 个任务、2,286 对配对人机 episode；指标是 progress（部分给分），每格 25 次试验，Orig.（标准隔间）与 New（光照/桌高/物体联合变化的未见家庭）双设定。

主结果（New）：WAM-TTT 46.2%，对 LDA 主干 32.5%（+13.7）、WAM-Cotrain 25.3%、EgoScale 15.0%、 $\pi 0.5$  14.8%、WAM-ICL 7.1%（+39.1）。9 任务赢 7 个，Flip Steak 34.3 对 Cotrain 34.2 近乎打平（正文误写为 10.0，以 Table 1 为准），唯一输的是 Stamp Paper（8.3 对 LDA 33.3）。Orig. 到 New 的保持率最说明问题：WAM-TTT 0.76（61.1 到 46.2），WAM-ICL 仅 0.15（48.4 到 7.1）——同一批视频，当上下文 token 在真实漂移下是负资产，当快权重记忆则大部分收益存活。适应后再加扰动（Deliver Drink 换光照/空间位置），WAM-TTT 66.0/56.0 仍最高，说明快权重不是死记了那条演示。

消融（10 试验，Table Bussing / Swap Place）四条都硬：去 meta-training 100.0 掉到 9.0、88.9 掉到 0.0，几乎归零——「人到机器人」的记忆接口必须预先显式学；LoRA 替换 TTT 只有 30.0/0.0——起作用的是记忆结构而非「多了组可调参数」；去 KVM 掉到 66.7/72.0；完全去 TTT 为 40.0/74.1。

两个附录消融的信息量不亚于主表。数据配比：等预算 200 条 episode 下，（机器人100，人类100）=74.1 与（200，0）=73.7 统计上不可区分——配对人类数据可 1:1 替代机器人数据、遥操成本减半；但（10，190）只有 51.4，机器人 grounding 不可少。伪动作消融：给人类侧加 MANO 重定向伪动作与前向动力学损失，四任务均值 72.3 掉到 28.9（-43.4），三种末端全部受损——在当前单视角手部追踪成熟度下，保持人类视频「无动作」、只用抗噪的视频预测损失是对的。

## 5. 局限

作者自认三条：meta-training 的相位配对假设人机 episode 覆盖同一技能相位分布，错配会静默降级适应信号、损失不报警；适应能力受快权重表达力与冻结慢投影约束，部署任务离配对分布越远越弱，且边界未做实证刻画；接口只吃第一人称 RGB，不利用手姿、接触、3D 场景线索。

延伸批判：

1. **progress 指标显著抬高观感**。部分给分权重压在少数关键里程碑上（Pour Water 的「倒水成功」一项占 0.60，Stamp Paper 的「盖章成功」占 0.50），真实的二元完成率会显著低于 46.2%。

2. 「零梯度」实为零主干梯度，测试时仍对快权重做 SGD，与 StellaVLA、Zero-WAM 的完全零梯度不是一档。
3. WAM-ICL 这个靶子不对口：LDA 主干本就不是为长上下文 ICL 预训练的，7.1% 的崩塌有一部分要算在主干头上；「快权重优于上下文条件」未在专为 ICL 预训练的主干上验证过。
4. 无代码、无项目页、无数据集，2,286 对配对 episode 的采集协议外部无法复现，四篇里开源程度最差的一档。

## 6. 与 HOST / GEN-1.5 / S1 及其余三篇 EICL 论文的关系

在 2026-08 具身 ICL 拐点坐标系（HOST 显式结构、50 任务 62%；GEN-1.5 涌现叙事、ICL 59%；Skild S1 视频提示未见长时程 66%）里，WAM-TTT 占「演示改权重 × 适应发生在部署前一次」一格：快权重是离线装好的**技能包**，装完冻结去跑。它对「涌现」的反证在四篇里最直接——去掉 meta-training 归零，说明至少在学术界可负担的规模上，「演示能被用上」这件事必须显式教。

与其余三篇：和 RoboTTT（解读见 05）同名 TTT 却不是一回事——RoboTTT 快权重挂动作头、rollout 每步更新，是**流式工作记忆**；WAM-TTT 挂视频专家、执行期冻结。互补处几乎像刻意：RoboTTT 自述局限之一是「快权重目标仍是通用 MSE」，KVM 恰好是一个带线性注意力理论论证的机器人向替代品。和 StellaVLA、Zero-WAM 处在坐标对角：后两篇零梯度、演示留在输入里；WAM-TTT 用 WAM-ICL 的崩塌主张上下文条件不行，StellaVLA 却用结构化语言证明上下文可行——分歧其实在演示的表示（原始视频 token 对结构化文本），而四篇之间零直接对比，这是本方向最该补的实验。三条跨篇共同经验里它贡献两条实证：人类信息只许改写感知侧（残差只挂视频专家，动作流零扰动）；伪动作净负面（72.3 到 28.9）从反面确认不许碰动作侧。对本调研的定位：它是 human-robot gap 「机制层跨越」的代表，代价是 2,286 对配对 episode 的采集；HOST 用进度流形对齐绕开配对、StellaVLA 用表示层消解，三种成本结构差着数量级，尚无人同台比过。

# StellaVLA 深度解读：把演示翻译成「为什么」，四篇里唯一真零梯度

StellaVLA: In-Context Structured Demonstration for Generalizable Vision-Language-Action Models  
arXiv 2608.11671 (2026-08) · StellarEdge AI (公司技术报告)

## 1. 一句话定位

StellaVLA 把 in-context 模仿学习 (ICIL) 的创新点从适应机制挪到演示的表示形式：一条全自动离线流水线用 Qwen3-VL 把每条专家轨迹拆成 K 个语义段，生成「语义理由 (子目标描述) + 运动学理由 (3D 位移与 2D 投影的文字化)」的结构化演示；测试时检索一条当前缀，主干全程冻结——无快权重、无 inner loop，是四篇 EICL 论文里唯一真正零梯度的。VLA-Arena 榜单 (2026-08-01) 总分 0.63 居首 ( $\pi 0.5$  为 0.44、LingBot-VLA 为 0.22)，LIBERO 98.8%、LIBERO-Plus 85.1%。方法论上最大的贡献是三向干预实验：同一 checkpoint 只换演示内容，对 98.8 / 无 62.4 / 错 44.9——「错比无差 17.5 个点」直接证明策略真在用上下文。这应当成为所有 ICL 论文的标配自检。

## 2. 要解决的问题

VLA 模型出分布即崩：场景、视角、物体一变，通常就得补数据再微调。ICIL 给出测试时零权重更新的出路——把检索到的专家轨迹拼进上下文当非参数记忆。但现有 ICIL 把演示当「原始观测 + 连续动作」直接塞，只传达专家做了什么、不传达为什么，鼓励表层模仿；策略常把演示当噪声无视、退回预训练先验 (论文称为行为惯性)。另一头，Embodied CoT 类方法让模型显式推理换泛化，但自回归文本生成的延迟撞碎实时控制预算 (本文实测解码 83 个 token 要 3177ms)。StellaVLA 想同时拿两头：推理带来的泛化，与无自回归解码的控制频率。

## 3. 方法

### 3.1 离线结构化上下文提取

原始轨迹可来自真机遥操、人手追踪或 XR 重定向。流水线分两层：Qwen3-VL 按视觉变化把长轨迹切成 K 个语义段、每段生成子目标描述 (如「伸向蓝色马克杯的手柄」)；确定性 verbaliser  $\Phi$  把段内动作跨度翻译成 3D 工作空间位移与投影到相机平面的 2D 轨迹文字。全程零人工标注。最精巧处是  $\Phi$  的双尺度复用：整段尺度的输出进上下文，动作 chunk 尺度的输出做训练监督——「别人的演示」与「策略自己的预测」由此进入同一套词汇，天然可比，这是它敢做跨本体上下文的机制根基。

### 3.2 并行双专家训练

主干 Qwen3-VL-4B 全参微调，输入 = 结构化演示前缀  $\oplus$  任务指令  $\oplus$  当前观测。共享表示  $h_t$  并行喂两个专家：动作专家 (OpenVLA-OFT 式 MLP 头) 以 L1 回归动作 chunk；空间语言专家 (原生 LM 头) 以交叉熵预测当前子任务与同一 chunk 的  $\Phi$  文字化。两专家严格并行，动作预测不因果依赖文本 token；



总损失  $L_{act} + \lambda \cdot L_{lang}$ ,  $\lambda=0.3$ 。检索只用任务指令语言 embedding 的余弦相似度取 top-1, 训练时 leave-one-out。训练 3 万步、全局批 128。

### 3.3 非对称推理与前缀缓存

部署时空间语言专家整个拆掉, 单次前向 + MLP 头出动作; 演示前缀整个 episode 不变, KV cache 只算一次。实测: 无演示 64ms; 带演示无缓存 183ms、有缓存 91ms; 若保留语言解码则 3177ms (约 36 倍)。真机全管线约 205ms/chunk。「训练期挂辅助推理、推理期整个剥离」由此成立。

## 4. 实验结果

LIBERO (每 suite 500 rollout): 平均 98.8%, 超 matched control StarVLA-OFT (同主干同数据、无演示无语言监督) 的 96.6%, 增益集中在当前观测无法唯一确定意图的 Goal (+3.4) 与 Long (+3.0)。

VLA-Arena (训练只用 L0 数据, 测试时给一条目标任务演示、零参数更新): L0/L1/L2 均值 0.84/0.62/0.43 三级全部第一, 总分 0.63 对  $\pi 0.5$  的 0.44。逐 suite 三条最有信息量: Unseen Objects 三级全 0.80 (换物体指代、程序可迁移); Task Workflows 从 L0 的 0.64 升到 L2 的 0.84——测试流程离训练越远, 上下文越有用; Long Horizon 则 L1 仅 0.02、L2 为 0.00, 所有方法归零——固定前缀能指定程序, 无法在执行漂移后重新规划。

LIBERO-Plus 零样本鲁棒性 85.1% 对 StarVLA-OFT 的 75.0, 增益分布本身就是机制证据: 相机视角 +23.5、传感器噪声 +19.7、机器人初始状态 +14.7、语言 +8.3——都是观测变了但任务程序不变的轴; 物体布局仅 +0.1, 演示里场景特定的空间关系失配时结构化上下文帮不上。

真机 (AgileX Piper 六自由度, 125 条遥操 71,702 帧, 检索池另入 26 条 XR 人手与 26 条重定向轨迹): 分内 85.0%; OOD-L1 配对退化仅 -5 点 (StarVLA-OFT 为 -25、 $\pi 0.5$  为 -20); OOD-L2 未见抽屉任务无人完成, StellaVLA progress 1.9/4 领先 ( $\pi 0.5$  为 1.5、StarVLA-OFT 为 1.1)。跨源一致性: 固定观测只换演示来源, 动作分歧  $0.0014-0.0016\sigma$  (合  $0.02^\circ-0.03^\circ$  关节角)——结构化表示确实抽掉了本体外观。

理解性实验三连是全文精华。三向干预: 对 98.8 / 无 62.4 / 错 44.9; Goal suite 从 99.6 掉到 24.8 再到 0.0 (演示在定义任务意图), Spatial 在无/错下几乎一样 (72.2/72.6, 观测自带交互位置线索)。模态消融: 评测时 Text-only 98.8/84.4 几乎等于完整 Image+Text 的 98.8/85.1, Image-only 塌到 92.9/75.7——可迁移信息几乎全在语言里; 训练时 Image-only 分内略好 (98.4 对 97.3) 但 LIBERO-Plus 差 6.3 点 (78.7 对 85.0)——视觉演示诱导「外观对应」捷径。 $\lambda$  消融: LIBERO-Plus 在  $\lambda=0$  时最高 86.9、单调降到  $\lambda=1.0$  的 81.9, 选用的  $\lambda=0.3$  只有 85.1。子目标粒度: 3 帧 98.1 对 10 帧 98.8——起作用的是子目标分解而非稠密轨迹重放。

## 5. 局限

作者自认三条: 长时程组合性——前缀固定无法在执行漂移后重规划, VLA-Arena Long Horizon 对所有模型都近零; 依赖检索质量——错误演示比无演示更差, 域漂移下的鲁棒检索是下一步; 运动学文字化的量化误差可能限制精细操作精度。

延伸批判:

1.  **$\lambda$  消融自拆招牌的一半**。论文两大贡献之一是「并行双训练把推理内化」，但  $\lambda=0$ （无语言监督）的 OOD 鲁棒性反而最高（86.9 对选用的 85.1）：语言监督换来饱和基准上 +1.2 的分内提升，代价是 -1.8 的 OOD。真正起作用的是上下文条件本身；论文诚实报了数字，摘要仍把双训练当卖点。若目标是泛化而非刷榜，应先试  $\lambda=0$ 。
2. **封闭指令集使检索退化为任务标签匹配**（附录 A 自认）。仿真里检索即精确任务匹配，98.8 对 62.4 的差距有相当部分在测「知不知道任务标签」，而非开放场景的检索能力。
3. **VLA-Arena 存在测试时信息不对称**：基线数字取自榜单未重跑，只有它测试时额外拿到一条目标任务演示，且该基准上没有 matched control。
4. **真机每格仅 10 次 rollout**，作者自述单格 10–15 点噪声；跨源一致性只验证了单步预测，不是闭环不变性。
5. **算力完全未披露**（四篇里唯一一篇）；标注 VLM 与主干同为 Qwen3-VL，标注噪声与模型归纳偏置同源，且无任何质检数字。

## 6. 与 HOST / GEN-1.5 / S1 及其余三篇 EICL 论文的关系

在 2026-08 具身 ICL 拐点坐标系（HOST 显式结构、50 任务 62%；GEN-1.5 涌现叙事、ICL 59%；Skilld S1 视频提示未见长时程 66%）里，StellaVLA 占「演示改输入 × 不做任何适应」一格，是四篇里最接近产业博客主张的路线：零梯度、纯上下文。但它恰恰构成对「纯涌现」的反证：要让上下文真被用上，需要一整条离线结构化流水线、训练期语言监督加检索机制——而且自家  $\lambda$  消融显示辅助监督还在伤 OOD。与 HOST 的分野在 gap 解法层：HOST 在机制层用进度流形对齐跨越人机差异，StellaVLA 在表示层直接消解——外观进不了结构化文本，跨本体自动成立，代价是依赖可靠的 VLM 与相机内外参。

与其余三篇：和 WAM-TTT 处在坐标对角——后者用 WAM-ICL 的崩塌（7.1%）主张上下文条件不行，StellaVLA 证明结构化表示下上下文可行，分歧在演示的表示而非机制本身，但双方零直接对比。和 RoboTTT（解读见 05）是互补失败：StellaVLA 的前缀是 episode 常量、无法重规划所以长时程归零；RoboTTT 的递归快权重恰好解决长时程却从未面对真正的分布漂移——常量前缀加递归状态在架构上不冲突，是明摆着的合流方向。和 Zero-WAM 是结构性巧合：两篇都用 VLM 把机器人轨迹重新渲染成另一种模态当上下文（结构化文本对合成人类视频），互不引用却发明了同一套路的两种变体。三条跨篇共同经验里它贡献两条实证：训练期挂辅助推理期剥离（3177ms 对 88ms）；上下文不是免费午餐（Image-only 训练的外观捷径）。它的三向干预实验则是四篇里唯一直接证伪「策略忽略上下文」的证据链——方法论价值大于榜单名次。

# S1 与「涌现之争」：2026 年 8 月具身 ICL 三连发的完整拼图

Introducing S1: In-Context Learning for Robotics Skild AI 技术博客，2026-08-18 · 无论文、无开源权重、内部 benchmark 本篇同时覆盖：三家产业发布的时间线拼图，以及「ICL 是涌现还是造出来的」这场正在重演的辩论（Brown 2020 / Wei 2022 / Schaeffer 2023 → GEN-1.5/S1 vs 四篇 EICL 学术论文）

## 1. 一句话定位

Skild AI 的 S1 把具身 ICL 的主张推到三家产业发布里最远的位置：一条视频演示当 prompt，能执行**预训练从未见过、长达 10 分钟**的长时程任务（66% 累计逐步成功率，同规模语言提示只有 9%），单条上下文演示约等于 380 条后训练遥操作示范（那 380 条要花 50-100 小时采集）。与 HOST（8-03 开源）、GEN-1.5（8-19 博客）放在一起，2026 年 8 月「教机器人 = 给一段演示」在三家互不相识的机构同时成立——而同月的四篇学术论文用消融证据对「这能力是涌现出来的」这一叙事给出了一致的反证。

## 2. S1 的主张与数字

**\*\*核心能力声明。**\*\*任务由视频演示指定而非语言；演示可来自不同场景、视角、具身，策略必须隐式学出演示者意图、功能对应与任务进度。同一套权重覆盖博客全部展示，无微调无后训练。四个未见长时程任务（种植盆栽、煎饼、手冲咖啡、组件装配）最长 10 分钟、数十个操作步骤，由单条第一人称人类视频驱动。种植任务从「道具进门」到自主执行只用 33 分钟，其中演示到执行 11 分钟。

**\*\*ICL scaling 对照（博客最有科学价值的部分）。\*\***在过滤后的预训练池上做受控研究：ICL 策略与语言条件 VLA 用完全相同的数据、架构（除 prompt 嵌入）、算力，从 1k 到 100k 小时。结果分两段读：

- **已见任务：**1k 小时时语言条件反超 ICL（53% vs 43%）——语言 token 压缩任务信息在小数据下更省，ICL 的高维条件反而易过拟合；scale 到 100k 小时后 ICL 达 96%，反超语言条件。归因：语言指令容许多种合法执行、存在歧义，演示无歧义。
- **未见任务：**语言提示随数据涨得极慢，100k 小时才 9%；ICL 同点 66%，且**差距随数据量指数级扩大**。归因：新原语（翻煎饼）语言无法接地到动作；新组合语言过粗、演示直接给出。

**\*\*扰动分级 L1-L5 定量。**\*\*两条轴分开测：部署场景偏离训练条件、部署场景偏离上下文演示。L5（物体摆位迫使一半动作换到另一只臂）下语言 VLA 退化幅度是 ICL 的 3 倍；ICL 对 L4（同可供性物体替换 + 15cm 垂直位移）以内的偏移稳健，只在演示隐含的执行计划整体失效（L5）时显著退化。

**\*\*单条演示的兑换率。**\*\*未见任务上后训练 VLA 需约 380 条遥操作示范才追平 ICL 单条演示的 66%；2000 条时后训练达 86% 反超。Skild 的表述值得注意：期望靠继续 scale ICL 预训练或 ICL 后训练缩小这个差距。

**涌现性质（定性展示）。**中途扰动（滑走物体、换物、改光照）不在 prompt 里仍完成；失败后自发重试（未见任务滑板轮装配也有）；常识替代（prompt 用烧水壶，现场只有杯子，S1 用杯子；杯子已近满就只加一点）；演示纠错——示范者失手掉鸡蛋弄脏台面，S1 同一步骤做得干净利落。博客的总结句子是全文最重要的机制线索：S1 把演示当目标规格而非要复现的轨迹。

**\*\*数据引擎。\*披露有限但立场清晰：**遥操作（硬件贴近性高、扩展性最差）、UMI（全面中等）、第一人称视频（扩展性最好、域差最大）、仿真（多样性低）四类源没有全能者，全部自建并战略性混合；每 1 美元采集配 3 美元质检。时间线：LocoFormer（2025-09，运动控制 ICL）→ 2026-02 域内 ICL 首个信号 → 2026-05 第一张煎饼 → 2026-08 S1 发布。

3. 该打的折扣

- 1. **证据形式仍是博客：**无论文、无开源权重、无 API，benchmark 全部内部构建，数字不可复核。这一点与 GEN-1.5 完全相同；
- 2. **评分口径含人工干预：**长时程任务用「累计逐步成功率」，rollout 中靠人工干预从失败恢复以保证每步都被计分——博客自己说明这主要是为了 VLA 基线（否则语言基线一次都完成不了整个任务、得分为零）。这个口径下 66% vs 9% 的对比成立，但 66% 不能读成「无干预端到端完成率」；
- 3. **「未见任务」的边界模糊：**四个展示任务（煎饼、咖啡、盆栽、装配）声明不在预训练中，但预训练池的任务清单未公开，「未见」无法外部审计；
- 4. **380 条兑换率是插值估计：**博客自己注明 crossing 由测量点之间插值得出。

4. 三连发时间线：一个月内的七次发布

| 日期         | 工作                        | 形式       | 主张强度                          |
|------------|---------------------------|----------|-------------------------------|
| 2026-07-08 | WAM-TTT（北大+银河通用）          | arXiv    | 快权重技能吸收，未见场景                  |
| 2026-07-16 | RoboTTT（NVIDIA GEAR）      | arXiv    | 上下文 8K scaling 轴，配置级 one-shot |
| 2026-08-03 | HOST（北理工+自变量+清华）          | arXiv+开源 | 50 未见任务 62%，跨具身人类视频           |
| 2026-08 中  | StellaVLA（StellarEdge AI） | arXiv    | 结构化语言上下文，真零梯度                 |
| 2026-08-18 | S1（Skild AI）              | 博客       | 未见+10 分钟长时程 66%               |
| 2026-08-19 | GEN-1.5（Generalist AI）    | 博客       | 50 万小时涌现 ICL 59%              |
| 2026-08 末  | Zero-WAM（Robbyant+港科广）    | arXiv    | 合成人类视频，任务级零样本 46.95%          |

三家产业机构互不相识、路线各异（HOST 结构设计 / GEN-1.5 数据涌现 / S1 数据+配方，且 S1 博客明确点名 GEN-1.5 和 RoboTTT「局限于短时程或分布内任务」），却在 16 天窗口内发布同一能力。学术侧四篇论文两个月内齐发且互相知晓却零对比。这个密度本身就是调研第 10 号报告「拐点」判断最硬的证据。

5. 涌现之争：LLM 的辩论在具身领域重演

LLM 前史三步曲。Brown et al. 2020（GPT-3）展示 few-shot ICL 随规模出现，确立「prompt 里给例子、权重不动」的范式；Wei et al. 2022 把这类「小模型没有、大模型突然有、无法从小模型外推」的能力命名为涌现能力（emergent abilities）；Schaeffer et al. 2023（NeurIPS 2023 杰出论文）泼冷水：所谓涌现可能是度量的海市蜃楼——非线性、不连续的度量（exact match、多选正确率）会把平滑的底层改

进渲染成突变，换成连续度量后大部分「涌现」曲线变得平滑可预测。涌现是研究者度量选择的产物，还是模型的真实相变，至今没有共识。

**具身领域的重演，攻守双方都已就位。**

产业侧的叙事是「涌现」：GEN-1.5 博客强调 ICL 能力从 8 个月连续预训练中出现，**无架构改动、无 meta-learning 循环、无辅助目标**——这是把自己对标 GPT-3 时刻的修辞。S1 的措辞更谨慎（「task diversity and scale drive the emergence」），并用 meta-learning 语言解释：预训练是外环、推理时演示驱动内环），但同样主张核心能力来自规模而非机制。

学术侧四篇论文的消融证据全部指向反面：

- WAM-TTT：去掉 meta-training 阶段，成绩从 100.0/88.9 掉到 9.0/0.0，几乎归零；
- RoboTTT：去掉 sequence action forcing 训练直接不稳定；register token 单独加给基线无效，只在配合 TTT 时 +18%；
- StellaVLA：需要一整条离线结构化流水线把演示翻译成「为什么」；
- Zero-WAM：**最致命的一条**——它是四篇里最接近产业路线的（大规模预训练+纯上下文+零梯度），但没有 IFP 反捷径目标时，往上下文里加人类视频是净负收益（28.55 vs 不加的 39.44）。捷径学习不会因为数据大就自动消失，至少在 15,360 GPU 小时的规模上不会。

**\*\*公平的限定。没有任何一篇学术论文达到过 GEN-1.5（50 万小时）或 S1（100k 小时对照研究）的预训练规模。四篇严格证明的是「在学术界能负担的规模上，ICL 需要显式机制」，不是「在任何规模上都需要」。裁决实验只有一个：在产业规模上做一次去机制消融。在那之前，两边都没资格宣布获胜。**

**Schaeffer 式度量批判在具身领域同样适用，且几乎无人提及。机器人评测用的二元成功率和 rubric 完成分，恰好是 Schaeffer 指出的容易人为制造「突变」的不连续度量。GEN-1.5 的「智能相变」叙事建立在成功率曲线上；而 S1 自己公布的 scaling 曲线（1k→100k 小时，ICL 与语言的差距平滑地指数扩大）反而更接近「连续可预测改进」而非相变。如果换成逐步进度这类连续度量，「涌现」还剩多少？这是把 LLM 那场辩论的方法论武器搬进具身领域的第一个具体研究机会，目前没有人做。**

## 6. 对调研主线的修订

1. **口径提醒升级**：S1 66%、HOST 62%、GEN-1.5 59% 落在同一区间纯属巧合——三者的「未见」定义、任务时长、判定口径、干预政策全部不同。真正可比的是证据形式：HOST 有论文+代码+权重+50 任务口径可复查，两家博客只有 demo 视频和内部曲线；
2. **S1 的独特坐标**：它是唯一同时主张「任务未见」与「10 分钟长时程」两轴的发布——恰好落在四篇学术论文的漂移轴地图上无人覆盖的右上角（长时程 × 分布外），这也解释了它为什么最不可复核；
3. **「演示当目标规格而非轨迹」**：S1 的演示纠错现象与 RICL 的 elicited latent actions、HOST 的观测空间预测殊途同归——三条独立证据指向同一结论：有效的 ICL 不是复制上下文，是用上下文激活模型内部已有的能力；
4. **涌现之争成为领域主矛盾**：本调研第 10 号报告「趋势四：涌现 vs 设计，两边都赢」需要修订为三方格局——涌现叙事（GEN-1.5/S1）、机制证据（四篇 EICL 论文）、度量质疑（Schaeffer 式批判

尚无人做)。12-24 个月内最有价值的单个实验就是产业规模的去机制消融。



# LocoFormer 深度解读：S1 的前夜——上下文当适应机制在运动控制域先走通

LocoFormer: Generalist Locomotion via Long-context Adaptation arXiv 2509.23745 · CoRL 2025 ·

Skild AI (Min Liu, Deepak Pathak, Ananye Agarwal) 项目页 [generalist-locomotion.github.io](https://generalist-locomotion.github.io) · S1 博客自述时间线的第一站

## 1. 一句话定位

LocoFormer 是一个「全身型」(omni-bodied) 通用运动控制模型：同一套权重零样本控制从未见过的腿式与轮式机器人，并在测试时通过跨 episode 的长上下文对形态与动力学变化做在线适应——锁膝、断腿、上高跷这些训练中不存在的损伤，它靠读自己前几次摔倒的历史学会应对。这是 Skild AI「上下文即适应机制」路线的第一次公开验证，比 S1 (操作域) 早约一年。

## 2. 要解决的问题

运动控制器的现状是「一个本体一套策略」：每换一台机器人（甚至换一副负载）都要重新调参或重训。此前的通用化尝试要么依赖显式形态参数输入（现实中往往拿不到精确运动学），要么用短上下文策略——上下文只有几十步，装不下「试错—修正」所需的信息。LocoFormer 的问题定义借了 LLM 的框架：如果控制器能读到足够长的传感历史（跨越秒级甚至多次试验），它应该能从「电机响应不对劲」中推断出「我现在很重」或「我少了一条腿」，然后就地改变策略——即运动控制版的 in-context learning。

## 3. 方法

两个关键选择。**其一，大规模 RL + 程序化生成机器人**：不在真实机器人模型上训练，而是随机生成形态（连杆长度、质量、电机参数、腿数/轮腿混合）并施加激进域随机化，逼策略放弃对特定形态的记忆、转而学「从历史推断当前身体」的元能力。观测统一为本体感受序列，不输入任何显式形态描述。**其二，Transformer-XL 主干**：把上下文从此前策略的几十步扩到跨 episode 边界的量级。TXL 的段级递归机制是关键——处理当前段时，键值从上一（缓存）段计算但不传梯度，层数越深可利用的历史越远，显存由段长决定而与总长解耦。训练时让策略在同一 episode 内连跑多个 trial、记忆跨 trial 持续，目标是整个 episode 的累计回报——这个设定直接把「用第一次摔倒的信息改进第二次」写进了优化目标。

## 4. 实验结果

评测在 10 个训练中从未见过的真实机器人形态上进行：五款双足 (Unitree G1/H1、Fourier GR1、LimX TRON1、Berkeley Humanoid BK-H)、三款四足 (Unitree A1、Boston Dynamics Spot、ETH AnyMal C)、两款轮式 (TRON1-W、Go2-W)，仿真侧覆盖 1000 个含粗糙地形的随机化环境，真机侧零样本部署后数秒内适应。最有传播力的是涌现适应序列：锁死一个膝关节，模型适应为三腿行走（训练中不存在此设定）；锁两条腿、切除腿、加负重、上高跷，均在 2-3 个 trial 内从摔倒恢复到稳定行走——早期 rollout 的失败信息被后续 trial 显式利用，这是 few-shot 多 episode 适应的直接证据。

## 5. 局限

作者自认训练全部在仿真、依赖域随机化弥合 sim-to-real，接触丰富的操作类交互不在范围内。延伸批判：其一，「未见机器人」的分布问题——程序化生成的形态空间本身覆盖了腿式/轮式的连续谱，真实机器人是否只是这个谱的内插点？论文没有给「生成分布外」形态的失败案例分析。其二，适应上限没有探明：锁腿、加重属于动力学参数漂移，感知域漂移（换相机、换场地视觉）完全未涉及——这恰是 manipulation 域（S1/RoboTTT）后来要面对的更难的轴。其三，评测以行走稳定性为主，缺乏统一的定量适应速度指标（几步收敛、收敛质量），「数秒内适应」多为定性展示。

## 6. 与调研主线的关系

**S1 的直系前作：**Skild 时间线（LocoFormer 2025-09 → 域内 ICL 2026-02 → S1 2026-08）中，LocoFormer 验证了配方的前半段——长上下文 + 大规模多样性训练 → 测试时适应涌现；S1 把同一配方搬到 manipulation 并把「上下文」从自身传感历史扩展为他人的视频演示。注意两者「上下文」的语义差异：LocoFormer 读的是自己的实时经验（适应），S1 读的是别人的演示（模仿）——前者不需要跨具身对应，后者需要，这是 manipulation 版难度更高的根本原因。**与 RoboTTT 问题异解：**都主张「上下文长度是新 scaling 轴」，LocoFormer 用 TXL 缓存（无梯度、定长记忆），RoboTTT 用 TTT 快权重（每步梯度、递归状态）——RoboTTT 的消融恰好证明 GDN 式线性递归吃不到长上下文红利，而 TXL 缓存与线性递归的表达力差距、两条实现的直接对比，双方都没做。**对涌现之争的位置：**LocoFormer 的适应能力同样不是免费的——跨 trial 记忆持续 + 整 episode 回报这两个训练设定就是它的「显式机制」，这与四篇 EICL 论文的结论同向。

# FACTR 2 深度解读：一篇力感知论文，如何被 S1 借去质疑预训练

FACTR 2: Learning External Force Sensing for Commodity Robot Arms Improves Policy Learning arXiv 2606.12406v2 (2026-08 更新) · CMU + 早稻田大学 作者: Steven Oh\*, Jason Jingzhou Liu\*, Tony Tao, Philip Han, Kenneth Shaw, Satoshi Funabashi, Ruslan Salakhutdinov, Deepak Pathak

## 1. 一句话定位

FACTR 2 本体是一篇把力感知带给廉价机械臂的系统论文：NEXT 用 10 分钟自由运动数据、1 分钟训练，在没有任何专用力传感器的商品臂上估计外部关节力矩，精度媲美专用力矩传感器；FIRST 用估出的力信号把演示切成自由空间/预接触/接触三段并上采样接触段，五个长时程任务上比此前力感知策略的任务进度高 17% 以上。它进入本调研的原因在论文之外：Skild S1 博客引用它支撑「预训练价值有限」的立论——这个引用经得起核对吗？

## 2. 要解决的问题

接触密集操作（插入、紧固、可变形物体）需要力敏感性，但多数商品机械臂（AgileX Piper、YAM 等）为控制成本不配力传感器。已有的无传感器外力估计依赖精确的系统辨识或厂商动力学模型，商品臂两者都缺。策略学习侧的问题是：BC 均匀采样轨迹，而长时程任务里决定成败的接触段只占很小时间比例，训练信号被大量自由空间运动稀释。

## 3. 方法

**NEXT（神经外力矩估计）**：核心洞察是「自由运动时的逆动力学模型即是零外力基线」。采集 10 分钟无接触自由运动，训练一个从关节状态序列预测电机电流/力矩的小网络（1 分钟训完）；部署时用实测力矩减去该模型预测的自由运动力矩，残差即外部力矩估计。无需系统辨识、无需 CAD 模型、无需额外硬件。该估计直接支持力反馈遥操作（操作者能「感到」接触）。**FIRST（力知情重采样训练）**：用 NEXT 的力矩信号把每条演示自动分割为自由空间/预接触/接触三个阶段，BC 训练时按任务调节比例上采样后两者。策略本体是标准的从头训练 BC（MMDiT 改编的 flow-matching 头，chunk 30，另用 ACT 复验），可选把力矩估计作为额外输入。

## 4. 实验结果

力估计侧：与专用关节力矩传感器的对照显示估计质量相当（论文以曲线与遥操作可用性呈现）；力反馈遥操作在 Piper、YAM、Nero 三款低成本臂上落地。策略侧：五个长时程接触任务（含插入、装配类），FIRST 相比此前力感知策略（FACTR 一代等）任务进度提升超过 17%；消融确认收益来自重采样而非仅力输入——不带力输入仅用 FIRST 重采样也有增益（附录 D.5），电流原始信号与估计力矩的对比显示后者更稳（D.6）。

## 5. 局限

作者自认：NEXT 依赖准静态假设附近的自由运动覆盖，高速动态下残差法的精度未验证；FIRST 的重采样比例逐任务手调（附录 D.3）。延伸批判：五个任务全部使用从头训练的策略，没有与任何预训练基础模型（ $\pi_0$ /GR00T 类）做正面对照——这一点对下一节至关重要。

## 6. 与调研主线的关系：核对 S1 的引用

S1 博客的原话是：「研究表明，当后训练数据足够大且密集覆盖任务时，即使从头训练、无预训练的策略也能匹配后训练基础模型的峰值性能（Oh et al., 2026）」，并由此推出「预训练的主要意义（如果不是唯一意义）是启用 ICL」。**\*\*核对结论：这是一次外推性引用。\*\***FACTR 2 的实验确实全部用从头训练的策略并取得强结果，但论文（正文与附录）没有做「从头训练 vs 预训练基础模型后训练」的受控对照，也没有陈述这个一般性结论——它的贡献轴是力感知与数据重采样，不是预训练价值评估。S1 把「从头策略在充足域内数据下表现好」这个侧面观察，升格成了为自家 ICL 路线铺路的一般性论断。方向上未必错（社区确有同感），但证据强度与引用语气不匹配。对调研的意义有两层：其一，「预训练到底买到了什么」是 ICL 叙事的地基，目前正反双方（S1 的引申 vs EgoScale 的 log-linear scaling law、GR-3 的 few-shot 微调收益）都拿不出同规模受控对照——这是又一个无人做的裁决实验；其二，FACTR 2 自己的真正启示反而被引用忽略了：力信息是纯视觉演示的系统性盲区（本调研洞察 I4 的「信息瓶颈」），NEXT 这种零硬件力估计恰好是把力信号带进 one-shot 演示管线的最低成本路径——它与 HOST 的 33:1 解耦配方组合，是触觉增强 ICL 最具体的落地方案。

# LingBot-VA 两代深度解读：把「测试时想象」坚持到底的世界-动作模型

**v1: Causal World Modeling for Robot Control** · arXiv 2601.21998 · RSS 2026 · 蚂蚁 Robbyant (Lin Li\*, Qihang Zhang\*, Yiming Luo\* 等, Yinghao Xu 通讯) · 开源 **v2: Native Video-Action Pretraining for Generalizable Robot Control (LingBot-VA 2.0)** · arXiv 2607.08639 · 2026-07 Zero-WAM (notes/12) 的同门前作与被超越基线

## 1. 一句话定位

LingBot-VA 是 WAM 谱系里「测试时保留完整自回归想象」路线的代表：视频 token 与动作 token 交织进同一条因果序列，每个自回归步先想象未来视觉状态、再从想象中解码动作，两代演进的主线是把这条路线的两大成本——继承自视频生成模型的历史包袱与推理延迟——逐一还清：v1 在 RoboTwin 2.0 五十任务上以 92.93/91.55 (Easy/Hard 成功率) 超越  $\pi 0.5$  (82.7/76.8) 与 Motus, v2 干脆抛弃「改造视频生成模型」路线、从头做因果预训练，靠稀疏 MoE 与 Foresight Reasoning 把峰值控制频率推到 225Hz。

## 2. 要解决的问题

v1 的立论：视频世界建模与视觉-语言预训练是两条独立的机器人学习地基——前者提供「动作与视觉动力学之间的因果想象」，这是反应式 VLA (观测直接映射动作) 天然缺失的。落地要解三件事：视频与动作两种模态怎么共处一个生成过程；闭环执行怎么不断吸收真实观测 (防想象漂移)；想象的算力代价怎么不拖垮控制频率。v2 追加一刀：复用为数字内容创作设计的双向视频生成模型本身就是错的——适配成因果模型会灾难性遗忘，重建导向的 VAE 潜空间与动作精度错配。

## 3. 方法

**v1 三件套**：(一) 共享潜空间 MoT——视频与动作 token 交织成单一因果序列，共享注意力、分专家 FFN，建立在大规模预训练视频扩散主干 (Wan 系) 上，每个自回归步内「迭代去噪出未来视觉潜变量 + 同步解码动作」互为条件；(二) 闭环 rollout——KV cache 维护交互历史，每步用真实观测替换想象结果再前进 (想象只往前一步，不无限外推)；(三) 异步推理——动作预测与电机执行并行。另有噪声潜变量增强：训练时给历史潜变量加噪，让动作解码对想象误差鲁棒。**v2 四大改动**：(一) 语义视觉-动作 tokenizer (96 潜通道) 取代 WAN2.2 重建 VAE，潜空间同时对齐语义与动作；(二) 从头因果预训练 (causal DiT)，绕开双向→因果适配的灾难性遗忘；(三) 视频专家 FFN 换稀疏 MoE (128 专家 top-8 + 1 共享, loss-free 均衡)，动作专家保持稠密；(四) Foresight Reasoning——预测未来潜变量与动作执行重叠进行，每次 rollout 用学习到的前向动力学在最新真实观测上「再接地」纠漂移，配合少步一致性蒸馏与量化，峰值异步 225Hz。**v2 的 ICL**：明确跟随 Zero-WAM 与 DVA 引入视频 in-context learning——训练数据中机器人视频配对语义对齐的人类演示视频 (不要求同物体实例、同视角、同场景布局)，推理时给一段参考人类演示当任务指令，零参数更新迁移动作流程；另有 MCP (多 chunk 预测) 监督多个未来 chunk，与 Zero-WAM 的 IFP 同属反捷径家族；层级 VLM 规划器把长时程目标分解成子任务上下文。

## 4. 实验结果

v1: RoboTwin 2.0 五十任务多任务设定 (2500 条干净场景 + 25000 条重随机化场景演示), Easy/Hard 平均 92.93/91.55, 对第二名 Motus +4.2/+4.6, 对  $\pi 0.5$  +10.2/+14.8; 长时程分档 (Horizon=3) 优势扩大到 +8.2/+9.1; LIBERO 同样领先; 真机六任务成功率与进度分双指标全面超  $\pi 0.5$ , 长时程与可变形物体任务差距最大。附带能力: 视觉动力学预测、从机器人视频反推逆动力学; 论文自报涌现性质为长程时间记忆与 few-shot 适应。v2: 同一 RoboTwin 协议下对 v1 与  $\pi 0.5$  大幅领先 (论文以两者为主对照); 真机验证 few-shot 泛化与 ICL demo (人类演示视频驱动零更新执行); 消融确认语义 tokenizer、MCP、加速三件各自的贡献。

## 5. 局限

作者自认 v1 的自回归想象仍有累积误差、依赖再接地机制兜底; v2 从头预训练的算力成本未完整披露。延伸批判: 其一, 两代都以  $\pi 0.5$  为最强外部锚点, 而  $\pi 0.5$  在 RoboTwin 的配置由自家复现——与 WALL-WM 的「评测环境优势」问题同款; 其二, v2 的 ICL 是跟随式引入 (引 Zero-WAM/DVA), 论文没有做 Zero-WAM 式的「无反捷径机制时人类视频是否负收益」消融, its ICL 有效性证据以 demo 为主; 其三, 「测试时想象」与 Fast-WAM 「收益在训练时」的正面矛盾两代都未回应——v1 每步只想象一小步且立即被真实观测替换, 这个设计本身可以读作对完整想象路线的部分让步; 其四, 同门的 Zero-WAM 用它当基线时未见任务只有 17.45%, 说明 v1 的 few-shot 适应能力在任务级切分下并不成立, 「涌现 few-shot」的声明要按这个外部数字打折。

## 6. 与调研主线的关系

**同门谱系:** LingBot-VA (v1)  $\rightarrow$  Zero-WAM (借 v1 主干加 HumanGen+IFP 攻未见任务)  $\rightarrow$  LingBot-VA 2.0 (把 Zero-WAM 的视频 ICL 与反捷径思想收编回主线, 同时从头重造底座) ——蚂蚁 Robbyant 三连发构成一条完整的「WAM 底座  $\rightarrow$  ICL 机制  $\rightarrow$  底座重造」内部演化链, 与自变量的 Wall-OSS  $\rightarrow$  HOST  $\rightarrow$  WALL-WM 链条惊人对称: 都是 chunk/底座被自家 ICL 工作倒逼重构。**WAM 路线三岔口:** 测试时完整想象 (LingBot-VA) vs 训练时塑形推理时剥离 (Fast-WAM/WALL-WM/Zero-WAM 的 IFP) vs 表征空间预测 (EgoWAM 的 DINO/flow、V-JEPA 2) ——LingBot-VA 是第一条路的最强代表, 其 225Hz 工程栈证明「想象的延迟成本」可以被基建消化, 把争论焦点逼回「想象是否带来能力增益」本身。**对涌现之争:** v2 的 ICL 依赖显式配对数据与 MCP 反捷径目标, 再添一条「ICL 是造出来的」学术侧证据。



# GR-3 深度解读：few-shot 微调流派的工业标杆，ICL 要消灭的正是它

GR-3 Technical Report arXiv 2507.15493 · 字节跳动 Seed (Hongtao Wu 通讯) · 2025-07 配套硬件  
ByteMini 22-DoF 双臂移动机器人 · 对照基线  $\pi 0$  (官方 openpi 微调)

## 1. 一句话定位

GR-3 是「少量数据快速微调」适应流派的工业标杆：4B 参数 MoT 结构 VLA (VLM 主干 + DiT flow-matching 动作头)，三源数据配方 (web 级视觉-语言共训 + VR 采集人类轨迹 + 遥操作机器人轨迹)，核心卖点是**每个新物体只需 10 条 VR 人类轨迹**即可完成适配，且在长时程收桌与灵巧挂衣上全面超过  $\pi 0$ 。在本调研的坐标系里，它是 ICL 阵营 (GEN-1.5/S1) 宣称要淘汰的那个工作流的最强版本——把「后训练适应」的成本压到了 VR 手柄级。

## 2. 要解决的问题

VLA 的三个老大难：指令跟随不严格 (尤其未见指令与抽象概念)、分布外泛化弱 (新物体/新环境)、新任务适配贵 (每任务数小时遥操作)。GR-3 的回答不走 ICL，而是把三源数据各自的长处拼起来：视觉-语言数据买语义泛化，机器人轨迹买操作能力，VR 人类轨迹买低成本适配——用数据配方而非推理机制解决适应问题。

## 3. 方法

**架构**：4B MoT——预训练 VLM 处理视觉与语言，DiT 动作头以 flow matching 生成动作 chunk，引入归一化 RMSNorm 改动以强化动态指令跟随；输入自然语言指令 + 环境观测 + 机器人状态，端到端输出双臂移动底盘动作。**三源训练配方**：(一) 与 web 级视觉-语言数据共训 (语义泛化的来源，消融 GR-3 w/o Co-Training 验证)；(二) 遥操作机器人轨迹的模仿学习 (可泛化抓放任务采 35k 条轨迹、101 物体、69 小时)；(三) VR 设备采集的人类轨迹用于少样本适配——人戴 VR 用手柄示范，数据成本比真机遥操作低一个量级，采集吞吐约每小时 450 条。**硬件**：ByteMini，22 自由度、7-DoF 无偏置球腕手臂 (紧凑球腕突破传统腕关节在狭小空间的灵巧极限)，全系统面向数据采集与部署双用途设计。

## 4. 实验结果

三个真机任务、与逐任务微调的  $\pi 0$  对照。**可泛化抓放**：四设定评测 (Basic 见过环境 54 物体 / 未见环境 4 个 / 未见指令含尺寸-空间关系-常识概念 / 未见物体 45 个)，双指标 (指令跟随率 IF + 成功率)。GR-3 全设定领先  $\pi 0$ ，视觉-语言共训消融确认未见指令与未见物体上的优势主要来自共训。**few-shot 适配**：对训练中不存在的新物体，仅用每物体 10 条 VR 人类轨迹微调，性能显著跃升 (图 7b)，验证「分钟级采集 + 少步微调」的适应闭环。**长时程收桌与灵巧挂衣**：以平均任务进度计，GR-3 稳定完成多步序列 (挂衣含插衣架、挂上晾衣杆等步骤，短袖等未见衣型也能处理)， $\pi 0$  在同设定下差距明显。

## 5. 局限

作者自认评测任务数量有限（三大任务族）、依赖自建硬件平台。延伸批判：其一， $\pi 0$  基线是官方仓库微调版，但  $\pi 0$  并非为 ByteMini 本体设计，跨本体迁移的先天劣势没有从对比中剥离——「全面超  $\pi 0$ 」部分是主场优势；其二，few-shot 数字口径是「10 条/物体」的物体级适配，与 GEN-1.5/S1 的「1 条/任务」任务级 ICL 不同轴，不能直接换算；其三，VR 人类轨迹仍需实物与场地（不同于 HOST 的任意手机视频），「低成本」相对遥操作成立、相对拍视频不成立；其四，无任何 ICL/上下文条件能力，模型每次适配都改权重——旧技能是否受损（HOST 关注的遗忘问题）未报告。

## 6. 与调研主线的关系

GR-3 是趋势报告「适应预算连续旋钮」（0 步=ICL，1-10 步=轻适应，1000+ 步=冲精通）中间档的最强实例，它把这一档的成本压到了「VR 手柄 + 10 条轨迹」——这直接抬高了 ICL 路线的证明门槛：S1 的「单条演示  $\approx$  380 条后训练示范」兑换率是对着传统遥操作算的，若对手换成 GR-3 式 VR 采集（每小时 450 条），ICL 的成本优势会大幅缩水。真正的分界不在成本而在两处：GR-3 每次适配都动权重（遗忘风险 + 需要工程师在环），且以物体级泛化为主（任务级新技能仍靠数据）；ICL 阵营的主张恰是这两点的反面。另一条线索：GR-3 的 VR 人类轨迹与 WAM-TTT 的「配对人类数据 1:1 顶替机器人数据」结论互证——人类示范作为数据源的价值已被微调与 ICL 两个阵营分别确认，分歧只在它进模型的方式（梯度 vs 上下文）。

# ManiLong-Shot 深度解读：OSIL 第一个像样的公开基准，和一个 30.2% 的现实

ManiLong-Shot: Interaction-Aware One-Shot Imitation Learning for Long-Horizon Manipulation arXiv  
2512.16302 · AAAI 2026 · 附 RL Bench-Oneshot 基准 真机验证平台 UFactory xArm7 + RealSense  
D435/D415

## 1. 一句话定位

ManiLong-Shot 做了两件事：方法上，把长时程 one-shot 模仿拆成「交互感知任务分解 → 功能不变区域预测 → 区域匹配求目标位姿」三段流水线，在 10 个短程任务上训练后泛化到 20 个未见长程任务，one-shot 成功率 30.2%，比此前最优 OSIL 方法 IMOP (7.4%) 高 22.8 个百分点；基建上，从 RL Bench 挑选 30 任务（10 短程 + 20 长程分三档难度）构建 RL Bench-Oneshot——这是 one-shot 模仿领域第一个任务分层、协议明确的公开仿真基准。

## 2. 要解决的问题

已有 OSIL 方法几乎全在短程原子任务上验证：一次抓取、一次放置。长程任务的困难是复合的——单条演示既要提供「做什么」（原语序列）又要提供「怎么做」（每段的空间对应），而现有方法把演示当整体处理，原语边界、阶段间依赖、演示与测试场景的对应关系全部混在一个匹配问题里。同时领域缺乏标准评测：各家自选任务自定口径，长程 one-shot 的真实水位无人知晓。

## 3. 方法

三段流水线。**交互感知任务分解**：用 VLM 或规则式机器人状态转移（夹爪开合、接触事件）把单条无标注长程演示切成交互原语序列——每个原语是一段「预接触-抓取-后接触」的完整交互；这一步把长程问题规约为原语级 one-shot 序列。**功能不变区域预测**：对每个原语，预测演示中与任务功能绑定、跨场景不变的物体区域（如把手、开口），滤掉外观与位姿噪声。**区域匹配**：测试场景中匹配对应区域，解出目标末端位姿，交给运动规划（MoveIt）执行。训练只用 10 个短程任务的演示，泛化压力全部压在分解与区域机制上。

## 4. 实验结果

**RL Bench-Oneshot 构成**：10 短程任务（每任务 100 条成功演示，前视/双肩/腕四路 RGB-D）+ 20 长程任务分三档（L1: 13 任务 × 6 次交互；L2: 4 任务 × 9 次；L3: 3 任务 × 12 次），每个长程任务配一条成功轨迹作 one-shot 演示。协议：25 试验 × 5 种子，报均值与标准差。**结果**：20 个未见长程任务平均 30.2%，对比 IMOP 7.4%、ARP+FT 4.7%、3DDA+FT 4.5%、RVT2+FT 4.1%——微调式 SOTA 模仿方法在此设定下近乎全灭，凸显长程 one-shot 与「多演示微调」是两个问题。**真机**：xArm7 上三个长程任务（叠积木、叠杯、放杯，各 6 个交互阶段），每任务采一条遥操作演示、5 次扰动初始位姿的 one-shot 试验，验证 sim-to-real 可迁移。

## 5. 局限

作者自认依赖 VLM/规则分解的质量、运动规划器处理接触的能力有限。延伸批判：其一，30.2% 的绝对水位提醒所有人：长程 one-shot 在标准协议下远未解决——与产业博客的 59–66% 对照，后者要么任务更短、要么口径更松（S1 的人工干预计分）、要么不可复核；其二，真机每任务仅 5 次试验，是验证级而非评测级证据；其三，流水线各段误差级联，VLM 分解错误会传导到底（与 WALL-WM 依赖 VLM 事件描述、StellaVLA 依赖检索同病），三段的误差归因消融不完整；其四，RLBench 的仿真物理（无接触力细节）决定了它测不了力敏感任务——基准本身的覆盖边界要认清。

## 6. 与调研主线的关系

**评测轴：**RLBench-Oneshot 是趋势报告预测 P3（真机 OSVI 标准协议）的仿真侧先行者——任务分层（交互次数定难度）与固定协议（25×5）值得真机基准直接继承；HOST 的 50 任务集 + 这套协议设计，是最可能的 P3 落地组合。**方法轴：**三段流水线与 HOST 的进度流形同属结构派，但走离散显式路线（原语切分 + 区域对应）而非连续隐式路线（共享进度流形）；与 StellaVLA 的语义分段、WALL-WM 的事件切分构成「时间结构怎么给」的三方案对照——规则/VLM 切分（本文、WALL-WM）、离线转译（StellaVLA）、自监督对齐（HOST），标注成本递减、对模型能力要求递增。**水位轴：**它给整个领域提供了急需的「地面真相」：在无人工干预、任务级留出、固定协议下，长程 one-shot 的 SOTA 是 30.2%——任何声称大幅超越此数的工作，先检查口径再检查方法。

# ICL 机制理论四篇合集：涌现之争吵的那个东西，理论上到底是什么

覆盖四篇：Implicit Bayesian Inference (Xie et al., ICLR 2022, arXiv 2111.02080) · Transformers Learn In-Context by Gradient Descent (von Oswald et al., ICML 2023, 2212.07677) · In-context Learning and Induction Heads (Olsson et al., Anthropic 2022, 2209.11895) · Learning to (Learn at Test Time) (Sun et al., 2024, 2407.04620) 定位：LLM 背景三篇 (notes/16 §5) 是涌现之争的现象学，这四篇是机制论——GEN-1.5/S1 说 ICL 「涌现」，四篇 EICL 论文说 「需要机制」，但双方都没回答 ICL 本身是什么。LLM 侧给过三种互补答案，外加一个把答案变成架构的工程化，全部与具身直接相关。

## 1. 为什么调研要补这一层

涌现之争的攻防 (notes/16 §5) 停在「消融证据 vs 规模主张」的实证层。但 LLM 社区 2021–2024 年已经把「ICL 是什么」推进到机制层，得到的答案直接决定具身 ICL 该怎么设计：如果 ICL 是隐式贝叶斯推断，那关键在预训练分布的结构（数据配方派的理论依据）；如果 ICL 是隐式梯度下降，那快权重与纯上下文本是一体（EICL 坐标系的理论消解）；如果 ICL 靠 induction heads 这类具体线路，那「涌现」有明确的力学起点可以找。四篇各占一角。

## 2. Xie et al.: ICL 是对潜在概念的隐式贝叶斯推断

**主张：**预训练文档由「先抽潜概念  $\theta$ 、再从  $\theta$  参数化的 HMM 采样 token」生成时，语言模型做好下一词预测就必须学会从上文推断  $\theta$ ；测试时的 few-shot prompt 只是一段特殊分布的上文，模型对齐演示背后的共享概念即完成「学习」——没有任何参数更新，ICL 是预训练分布结构的必然副产品。**证据：**合成数据集 GINC (HMM 混合) 上的可控实验——即便 prompt 的拼接格式在预训练分布之外（低概率事件），只要概念可辨识 (distinguishability 条件成立)，ICL 随例子数单调变好；理论部分给出渐近最优性证明。**对具身的启示：**这是 BPP/ICRT 「数据结构 > 数据量」定律的理论原型——ICRT 的 1098 条多任务同场景轨迹之所以胜过 1 万条单任务轨迹，正是因为前者让「任务身份」成为必须从上下文推断的潜变量，后者让观测直接决定动作、潜变量推断没有梯度压力。Zero-WAM 的 IFP 反捷径目标，本质是人为制造 Xie 意义上的「可辨识性压力」。

## 3. von Oswald et al.: 注意力前向传播就是梯度下降

**主张：**构造性证明——单层线性自注意力可以精确实现对上下文样本的一步梯度下降（把 GD 的权重更新  $\Delta W$  等价改写为对数据的变换）；且在线性回归任务上训练出的 Transformer，其前向传播确实收敛到这个 GD 解，多层对应多步 GD。**含义：**ICL=元学习出的隐式优化器，「读上下文」与「在上下文上做梯度下降」是同一件事的两种描述。**对具身的启示：**这是 EICL 坐标系 (notes/16 「快权重 vs 纯上下文」) 的理论消解——RoboTTT 把「处理上下文」显式实现为快权重梯度步，纯上下文的 GEN-1.5/S1 若真具备 ICL，其注意力内部大概率在做同一件事的隐式版本。争论「哪格更好」的实用意义在于误差与算力的分配方式，而非能力的本质差异。附带一个警示：该等价性在线性注意力/线性回归设定下最干净，真实多模态策略离该设定很远，把它当严格结论外推到机器人属于过度引用。

## 4. Olsson et al.: ICL 能力有一个可定位的力学起点

**主张：**Transformer 训练早期存在一次「相变」(phase change)——induction heads (做前缀匹配 + 复制的注意力头组合：找上文中当前 token 出现过的位置、把其后继 token 提升为预测) 在这个窗口内集体形成，与 in-context learning 能力 (用上文降低后文损失的能力) 的跃升同时发生。**证据：**六条互补论证——宏观共现、共扰动 (改架构让 induction heads 更早形成，ICL 跃升同步提前)、直接消融、行为泛化 (字面复制/翻译/模式匹配)、机制合理性、小模型到大模型的连续性；对小模型是接近因果的证据，对大模型是相关性证据。**对具身的启示：**双刃剑。一方面它给「涌现」提供了最好的辩护词——涌现可以是真实的力学事件 (线路集体形成)，不只是度量假象 (Schaeffer 的批判并不覆盖这种情形)，GEN-0 的「intelligence phase transition」叙事因此不能被度量批判一票否决；另一方面它也给出了裁决工具——如果 GEN-1.5/S1 的 ICL 是涌现的，其网络里应能找到具身版 induction heads (对演示片段做「进度匹配 + 动作复制」的头)，可解释性探针是比消融更直接的验证路径，目前无人做。

## 5. Sun et al.: 把隐式优化变成显式架构 (TTT 层)

**主张：**序列模型的隐状态本身可以是一个小模型，状态更新规则就是对该小模型做自监督梯度步——「测试时训练」不再是推理技巧而是架构原语。TTT-Linear (隐状态为线性模型) 与 TTT-MLP (两层 MLP) 在 125M-1.3B 尺度对照 Transformer 与 Mamba；关键理论连接：线性模型 + batch GD 的 TTT 层严格等价于线性注意力——RNN、注意力、测试时训练三个概念在此汇合。**对具身的启示：**这是 RoboTTT 与 WAM-TTT 的直接技术祖先 (两者引用并各自改造：RoboTTT 加 tanh 门控与 sequence action forcing 装进动作头，WAM-TTT 加 KVM 损失装进感知侧)。TTT 层的「表达力换算力」权衡在机器人域刚好反转价值：机器人上下文是高维连续传感流，注意力的二次成本不可行，TTT 的线性成本 + 可学更新规则恰好补位——这解释了为什么 TTT 在 LLM 域是「有前途的替代品」、在机器人域直接成了长上下文的默认方案。

## 6. 合成：四篇拼出的一张图，与具身域的空白

四篇的关系可以串成一条论证链：Xie 说明 ICL 的**成立条件** (预训练分布必须让潜变量推断成为最优策略)；von Oswald 说明 ICL 的**计算本质** (隐式优化)；Olsson 说明 ICL 的**形成过程** (线路相变)；Sun 把本质**工程化** (显式 TTT 架构)。对照具身侧：数据配方派 (BPP/ICRT/Zero-WAM 的均衡采样) 在实践 Xie 的条件，快权重派 (RoboTTT/WAM-TTT) 在实践 Sun 的架构，纯上下文派 (GEN-1.5/S1/StellaVLA) 在赌 von Oswald 的隐式版本会自己出现，而 Olsson 式的线路级验证在具身域完全空白。三个最值得做的迁移实验：具身 induction heads 探针 (验证产业模型的涌现声明)；GINC 式可控具身预训练分布 (把「任务多样性阈值」从经验数字变成可辨识性理论量)；TTT 层与全注意力在同算力下的长上下文机器人对照 (WAM-TTT 与 RoboTTT 都没做的那个基线)。局限同样要记录：四篇全部在语言或合成任务上工作，最大 1.3B 参数，结论向多模态连续控制的外推没有任何一篇提供保证。



# 世界模型谱系三篇合集：从像素想象到表征预测再到平台化

覆盖三篇：**UniPi** (Learning Universal Policies via Text-Guided Video Generation, Du et al., NeurIPS 2023, arXiv 2302.00111) · **V-JEPA 2** (Meta, 2025, 2506.09985) · **Cosmos** (NVIDIA World Foundation Model Platform, 2025, 2501.03575) 定位：本仓库 WAM 线 (Fast-WAM/WALL-WM/EgoWAM/LingBot-VA/Zero-WAM) 的上游谱系。三篇代表「视频先验进入机器人」的三代路线：像素想象当策略 → 表征空间预测 → 世界模型平台化。

## 1. 谱系总览

「视频生成模型携带物理知识，机器人应该继承它」这个信念有三种兑现方式，恰好按时间递进。第一代 (UniPi, 2023)：视频生成模型**就是策略**——生成未来影像，再从影像反解动作。第二代 (V-JEPA 系, 2024-2025)：像素太贵且冗余，把预测搬进抽象表征空间，规划在潜空间进行。第三代 (Cosmos, 2025)：世界模型退居**平台**——不直接当策略，而是作为可后训练的模拟器底座，为下游 Physical AI 供数据与评估。本仓库主线里的 WAM 工作全部是这三代的杂交后代：Fast-WAM/WALL-WM 继承第一代的像素潜变量但砍掉测试时想象，EgoWAM 的 DINO/3D flow 目标与 V-JEPA 同属第二代，LingBot-VA 是第一代路线的坚守者，Zero-WAM 把第三代的「合成数据」思想反向用于 ICL 配对生成。

## 2. UniPi：把决策问题写成文本条件视频生成

**主张**：通用策略 = 文本条件视频生成器 + 任务无关的逆动力学模型。给定指令与首帧，扩散模型生成完成任务的未来视频 (planner)，逆动力学模型从相邻帧对解出动作 (executor)。**关键机制**：视频作为统一的状态-动作表示，天然跨环境、跨本体 (动作空间差异被推给轻量逆动力学)；训练数据可以混仿真、真机与 YouTube。**代表结果**：组合泛化任务上显著超过 Transformer BC 与轨迹级基线，多环境迁移与真机验证成立；论文明确展示「语言条件的组合性」——新的颜色-物体-关系组合靠视频生成的组合泛化直接解决。**对具身 ICL 的启示与病灶**：它确立了「演示/指令 → 未来影像 → 动作」的模板 (HOST 的自接地预测级联是这个模板的进度条件版本)，但两大成本从此困扰整条路线：推理慢 (每步都要生成视频) 与像素冗余 (光影纹理与任务无关却占尽建模容量)。后续所有 WAM 工作都可以读作对这两个病灶的不同疗法——Fast-WAM 砍测试时生成，V-JEPA 换表征空间，LingBot-VA 用工程栈硬扛。

## 3. V-JEPA 2：预测发生在表征空间，机器人控制零标注数据起步

**主张**：自监督联合嵌入预测架构 (预测目标是 learned 表征而非像素) 在超过 100 万小时互联网视频上预训练，得到的世界模型既服务理解 (Something-Something v2 top-1 77.3、Epic-Kitchens-100 动作预期 recall@5 39.7 均为当时最优) 也服务控制。**关键机制**：V-JEPA 2-AC——在冻结的 V-JEPA 2 上，仅用 Droid 数据集中不到 62 小时无标注机器人视频后训练出动作条件世界模型；部署时以能量最小化做规划 (给定图像目标，在潜空间搜索动作序列)，在两个从未采过数据的实验室的 Franka 臂上零样本完成抓放。**对具身 ICL 的启示**：其一，62 小时对 100 万小时的杠杆比是「通用视频先验 + 少量具身接地」配方的极端版本，与 HOST 的 33:1 解耦、EgoScale 的两阶段同构，且比例悬殊四个数量级——「跟随/翻译解耦」定律的又一独立验证；其二，它是 EgoWAM 三准则 (外观抽象/跨具身一致/自我运动分解) 的天然

满足者——表征空间预测天生抽象外观，这从上游解释了 EgoWAM 里 DINO 目标为何胜过像素；其三，局限同样有信息量：作者自认对相机位姿敏感、长时程规划退化、依赖图像目标——潜空间规划拿掉了像素冗余，也拿掉了人类可检查性，这是表征路线的固有代价。

#### 4. Cosmos：世界模型不当策略，当基础设施

**主张：**世界基础模型（WFM）平台——视频数据管护流水线 + 视频 tokenizer 家族 + 扩散/自回归两族预训练 WFM + 后训练示例（相机控制、机器人操作、自动驾驶），全线开源开放权重。**关键定位：**预训练 WFM 是「通用世界模拟器毛坯」，下游各自后训练成专用模拟器；机器人操作是其后训练场景之一（指令条件与动作条件的未来预测）。评测专设 3D 一致性与物理对齐两轴，承认当前 WFM 的物理保真仍有明显缺陷（物体恒存性、接触动力学误差）。**对具身 ICL 的启示：**Cosmos 代表与「WAM 当策略主干」正交的第三种用法——世界模型作为数据与评估基础设施。Zero-WAM 的 HumanGen（用生成模型合成人-机配对数据）正是这条路线的 ICL 应用实例，而 Cosmos 把该路线的上游能力（可控视频生成、物理对齐评测）平台化。它也暴露了这条路的瓶颈：Zero-WAM 依赖闭源商业模型合成数据的问题，本可由 Cosmos 类开源平台解决，但 Cosmos 自己的物理对齐评测说明「合成数据的物理可信度」尚无保证——合成配对路线的天花板在上游模拟器。

#### 5. 合成：三条赌注与本仓库 WAM 线的交叉验证

三代路线各自的赌注：像素派赌「完整成像的动力学最忠实」（代价是算力与冗余），表征派赌「任务相关信息可以无损压进潜空间」（代价是可检查性与目标指定），平台派赌「模拟器成熟会先于策略成熟」（代价是双重误差：模拟差距 + 策略差距）。本仓库 WAM 线的实验证据向表征派倾斜：Fast-WAM 证明测试时像素想象不必要，EgoWAM 证明像素目标迁移最弱、DINO/3D flow 显著更好，WALL-WM 推理时只跑到中噪锚点（实质放弃完整成像）——四组独立证据指向同一结论：**视频先验的价值在其塑造的表征，不在其生成的像素**。坚守完整想象的 LingBot-VA 是重要的对照组，其 225Hz 工程栈证明延迟可解，但「想象带来的能力增益」仍缺与表征路线的同规模对照。对 ICL 主线的最终含义：如果视频先验的价值在表征，那么「视频生成模型出身」对 ICL 的贡献是给了模型一个能读懂演示视频的眼睛，而非一个能想象未来的脑——这与 S1「把演示当目标规格而非轨迹」的行为证据、HOST 观测空间预测的设计选择相互印证。

# 基座 VLA 三篇合集：ICL 工作站在谁的肩上

覆盖三篇：**OpenVLA** (Kim et al., Stanford/Berkeley/TRI/Google DeepMind 等, CoRL 2024, arXiv 2406.09246) ·  **$\pi 0$**  (Physical Intelligence, 2024, arXiv 2410.24164) · **GR00T N1** (NVIDIA, 2025, arXiv 2503.14734) 定位：本仓库所有「给 VLA 后装 ICL」的工作都站在这三家之上——RoboTTT (notes/05) 的主干是 GR00T N1 谱系的 N1.7, RICL (notes/07) 的底座是  $\pi 0$  的 FAST 变体, GR-3 (notes/20) 与  $\pi 0.5$  系基线 (notes/01、06、09、13、14、15、19) 的对照根都是  $\pi 0$ , OpenVLA 则是 ICRT (notes/04) 与  $\pi 0$  论文自身的公共基线。不读底座, ICL 增益的口径无从校准。

## 1. 为什么补这三篇

前 23 篇解读里的增益全是相对数：RoboTTT 的 +87% 相对 GR00T N1.7, RICL 的 2.5% 到 31.25% 相对  $\pi 0$ -FAST-DROID, ICRT 的 79.2% 对 7.5% 相对微调后的 OpenVLA。增益是「添新能力」还是「补先天缺陷」, 取决于底座本来能做什么。补读三篇要回答三个问题：其一, 每家的动作生成架构给上下文留了什么「入口」——这决定后装路径 (RICL 为什么选 FAST 变体而非 flow 版  $\pi 0$ , RoboTTT 为什么只改 System 1); 其二, 预训练数据买到了什么先验——这决定 ICL 工作继承了什么; 其三, 各家数字是什么口径——三篇评测协议彼此不可比, 本仓库跨模型的胜负叙事全部来自挑战者的主场。三篇恰好代表动作生成的三种选型：自回归离散 token (OpenVLA)、共享注意力的 flow matching 动作专家 ( $\pi 0$ )、跨注意力解耦的双系统 DiT (GR00T N1)。

## 2. OpenVLA：开源自回归 VLA 的基准线

**核心架构**：Prismatic-7B VLM 直接微调——600M 双视觉编码器 (SigLIP 与 DINOv2 特征按通道拼接)、两层 MLP 投影、Llama 2 7B 主干。动作按 RT-2 配方离散化：7 维动作每维切 256 个 bin (边界取 1%-99% 分位数), 覆写 Llama 词表最少用的末 256 个 token, 只对动作 token 算 next-token 交叉熵。输入是单张 224×224 图像加指令：无本体、无历史、无动作块, 逐 token 自回归输出一步动作。设计发现：视觉编码器必须微调 (同一 Bridge 设定微调 80.0% 对冻结 46.7%, 与 VLM 领域经验相反); 要跑 27 个 epoch、训练动作 token 准确率超过 95% 后真机表现才持续上升。

**数据规模**：Open X-Embodiment 精选 97 万条真机轨迹, 过滤为「至少一个第三人称相机 + 单臂末端控制」, 混合权重沿用 Octo; DROID 以 10% 权重加入但学不动, 最后三分之一训练被移除。64 张 A100 跑 14 天 (21,500 A100 小时)。推理 bf16 需 15GB 显存, RTX 4090 上约 6Hz。

**代表数字** (A/B 评测、同初始状态; 口径：成功率  $\pm$  标准误)：BridgeData V2 WidowX 17 任务  $\times 10$  次 = 170 次 rollout, OpenVLA 70.6 $\pm$ 3.2%, RT-2-X (55B 闭源) 50.6 $\pm$ 3.5%, Octo 20.0%, RT-1-X 18.5%——参数少 7 倍而除语义泛化外全面领先; Google robot 12 任务  $\times 5$  次, 85.0 $\pm$ 4.6% 对 RT-2-X 78.3 $\pm$ 5.4%, 误差棒重叠; 摘要的「29 任务高 16.5%」即两套合并。微调：Franka-Tabletop (5Hz) 6 任务、每任务 10-150 条演示, 全参微调 67.2 $\pm$ 4.0%, 从零训练的 Diffusion Policy 48.5 $\pm$ 4.9%, Octo 微调与未经 OpenX 预训练的 OpenVLA(scratch) 均 43.4%; 但按任务拆开, 窄的单指令任务 DP 更强 (Pour Corn 100% 对 50%), OpenVLA 的优势全部来自多物体多指令任务的语言接地。LoRA  $r=32$  只训 1.4% 参数得 68.2%, 与全参 69.7% 持平; int4 量化 71.9% 对 bf16 71.3%。数据消融最有信息量：去掉

OpenX 只用 Bridge 训练，8 任务子集从 76.3% 跌到 45.6%，再去掉 DINOv2 只剩 40.6%——跨具身数据的价值是视觉编码器选型的六倍。LIBERO 四套件 LoRA 微调平均 76.5%，仅略高于 Octo 与 DP。

**在本调研中的角色：**ICRT (notes/04) 把 OpenVLA 微调并改为 16 步动作块，12 个未见任务只有 7.5%、戳任务常被做成抓——不是 OpenVLA 弱，而是语言接口传达不了运动模式，是 ICRT 论点的对照组。 $\pi_0$  论文把它放到自家混合数据上训练，结论是不支持动作块与高频控制而崩溃 (§3)。StellaVLA (notes/15) 的动作专家沿用 OpenVLA-OFT 式 MLP 回归头。

### 3. $\pi_0$ ：把 flow matching 动作专家挂到 VLM 上

**核心架构：**PaliGemma 3B (SigLIP + Gemma 2B) 作 VLM 主干，另加一组从零初始化的 300M 「动作专家」(宽 1024)，合计 3.3B。两组权重只在自注意力层交互，等价于双专家 MoE：图像与语言 token 走 VLM 权重，本体状态  $q_t$  与带噪动作块走动作专家。注意力掩码是三块式因果：[图像, 语言]  $\rightarrow$  [ $q_t$ ]  $\rightarrow$  [动作块]，块内双向、不能看后块——VLM 输入看不见机器人 token 以减小分布偏移， $q_t$  单独成块以便在流积分中缓存 KV。动作块  $H=50$ ，条件 flow matching、线性高斯路径， $\tau$  采样自  $\text{Beta}((s-\tau)/s; 1.5, 1)$ 、 $s=0.999$ ，刻意偏向高噪声端（作者论证：观测对动作的约束远强于文本对图像）；推理 10 步 Euler，前缀 KV 缓存、每步只重算动作后缀。控制最高 50Hz；RTX 4090 三相机实测板上 73ms（图像编码 14 + 观测前向 32 + 十步动作前向 27）。

**数据规模：**自采灵巧操作数据超 1 万小时——9.03 亿时间步（单臂 1.06 亿、双臂 7.97 亿），7 种构型（从单臂 UR5e 到移动双臂 Fibocom），68 个任务；开源数据（OXE、Bridge v2、DROID）只占混合的 9.1%。「任务」口径极宽（bussing 整个算一个任务）。任务-机器人组合按  $n^{0.43}$  加权抑制过采样。预训练 700k 步；后训练每任务 5 到 100 小时以上。

**代表数字**（口径：每任务 10 次 episode 的归一化分均值，部分完成计分数，无误差棒）：出厂即用 5 任务（叠衬衫、收桌、装杂货、取吐司等）， $\pi_0$  在叠衬衫与简单收桌接近满分，全面领先；只训 160k 步的「算力对齐」版仍胜所有基线（OpenVLA 160k、Octo 320k，均在  $\pi_0$  混合数据上训练）；470M、无 VLM 初始化的  $\pi_0$ -small 也胜 OpenVLA 与 Octo，语言跟随上则显著弱于  $\pi_0$ 。新任务微调（堆碗、叠毛巾、微波炉、换纸巾卷、Franka 抽屉）： $\pi_0$  总体最佳，预训练相对从零最多 2 倍；反常发现：最强的先前方法是从零训练的 ACT 与 DP，带 OXE 预训练权重的 OpenVLA 与 Octo 反而更差——预训练迁移对先前架构本身就是难题。复杂多阶段任务（叠衣、折纸箱、装鸡蛋等，5–20 分钟）无外部基线、只对照自身消融：完整配方全部任务超过 50% 满分，越难预训练增益越大。

**在本调研中的角色：** $\pi_0$  是本仓库被引最多的锚点，但引的是三个版本。RICL (notes/07) 的底座  $\pi_0$ -FAST-DROID 是  $\pi_0$  家族的自回归离散分支（PaliGemma 主干 + FAST 动作 tokenizer），不是本文的 flow 版，§5 说明这不是偶然。GR-3 (notes/20) 的全部对照是官方 openpi 微调的  $\pi_0$ 。 $\pi_0.5$  (notes/09) 是 HOST、BPP、WAM-TTT、StellaVLA、WALL-WM、LingBot-VA 六篇的公共基线，HOST 实测其 50 个新任务零样本 IL  $\leq 17\%$ 、SFT 后旧任务只保留 20% (notes/01)。GR00T N1 的 Beta 时间步采样与动作编码 MLP 明文引自  $\pi_0$ 。

### 4. GR00T N1：双系统与数据金字塔



**核心架构：**公开的 GR00T-N1-2B 共 2.2B 参数，VLM 占 1.34B。System 2 是 Eagle-2 VLM (SmolLM2 + SigLIP-2)，224x224 图像经 pixel shuffle 压成每帧 64 个 token；策略只取 LLM 第 12 层（中间层）特征。System 1 是 DiT 变体：交替的跨注意力块（读视觉语言 token）与自注意力块（在带噪动作 token 与状态嵌入上），AdaLN 注入去噪步；每个具身一组 MLP 状态/动作编码器与解码器。动作块 H=16，flow matching 目标与  $\tau$  分布沿用  $\pi_0$ ，推理只需 K=4 步。L40 bf16 采样 16 步动作块 63.9ms；引言口径 System 2 以 10Hz、System 1 以 120Hz 运行。作者选跨注意力而非  $\pi_0$  式共享注意力，是为了让 VLM 与动作模型可各自替换。

**数据规模：**附录表 7 合计 5.929 亿帧、8,375.7 小时，「数据金字塔」四层：真机 3,288.8 小时（自采 GR-1 人形遥操作仅 88.4 小时，AgiBot-Alpha 1,979.4 小时占大头，其余为 OXE 子集）；人类第一视角视频 2,517.0 小时（七个数据集，Ego4D 占 2,144.7）；仿真 1,742.6 小时（DexMimicGen 从几十条源演示自动扩增，含后训练共 78 万条约 6,500 小时，生成只用 11 小时）；神经轨迹 827.3 小时（WAN2.1-I2V-14B 以 LoRA 在 88 小时 GR-1 数据上微调，配新指令生成约 30 万条反事实视频，耗约 10.5 万 L40 小时）。无动作数据靠 LAPA 式 VQ-VAE 潜动作（当作独立的「LAPA 具身」用同一 flow matching 损失训练，同一潜动作在 8 种机器人与人类具身间语义一致）与逆动力学模型（IDM）伪动作标注。预训练 5 万 H100 小时，batch 16,384、20 万步，视觉编码器解冻、语言部分冻结。

**代表数字：**仿真三基准、每任务 100 条演示后训练（口径：100 次试验平均成功率，取最后 5 个 checkpoint 的最大值）：RoboCasa 24 任务 32.1% 对 Diffusion Policy 25.6%、BC-Transformer 26.3%；DexMimicGen 9 任务 66.5% 对 56.1%/53.9%；GR-1 桌面 24 任务 50.0% 对 32.7%/16.1%；平均 45.0% 对 33.4%/26.4%。真机 GR-1 13 任务四类（口径：每任务 10 次、部分完成计分）：全量 76.8% 对 DP 46.4%，10% 数据 42.6% 对 DP 10.2%——10% 数据的 GR00T 只比全量 DP 低 3.8 点。预训练 checkpoint 不经后训练直接跑（5 物体 ×3 次，抓到未放入计 0.5）：左手取物换右手上架 76.6%，新物体放入未见容器 73.3%。神经轨迹共训：RoboCasa 30/100/300 条三档 +4.2/+8.8/+6.8 点，真机 8 任务 +5.8 点。定性结果：预训练模型面对左手侧的苹果会左手抓、换右手、放入篮子，后训练模型因数据全是右手操作而失去此能力——底座层面灾难性遗忘的实证。

**在本调研中的角色：**RoboTTT (notes/05) 的主干 GR00T N1.7 属此谱系（VLM + 16 层 DiT flow-matching 动作头），TTT 层插在每层 DiT 的注意力之后沿时间维整合，VLM 输出不进 TTT 而靠 16 个 register token 跨时间携带；RoboTTT 还给出底座的关键测量——N1.7 朴素加一帧历史后 Pup Go Car 从 57% 掉到 39.5%，底座对历史「有毒」。N1 的神经轨迹生成与 Zero-WAM 的 HumanGen、notes/23 的 Cosmos 平台化同属合成数据路线。

5. 合成：三家架构选型对照，与 ICL 后装的适配性

|            | OpenVLA                    | $\pi_0$                             | GR00T N1                     |
|------------|----------------------------|-------------------------------------|------------------------------|
| 动作表示       | 每维 256 bin 离散 token，自回归，单步 | 连续动作块 H=50，flow matching，10 步 Euler | 连续动作块 H=16，flow matching，4 步 |
| VLM 与动作的耦合 | 同一 LLM，动作 token 占词表末 256 位 | 双专家共享自注意力，三块式因果掩码                   | 独立 DiT 跨注意力读 VLM 第 12 层特征    |
| 参数         | 7B                         | 3.3B (3B VLM + 0.3B 专家)             | 2.2B (1.34B VLM)             |

|       | OpenVLA               | $\pi 0$                     | GR00T N1                                               |
|-------|-----------------------|-----------------------------|--------------------------------------------------------|
| 观测接口  | 单图 + 指令，无本体、无历史       | 2-3 图 + 指令 + 本体 q_t, 单步     | 多图 + 指令 + 本体，单步                                        |
| 预训练数据 | 97 万条 OXE 轨迹（单臂、第三人称） | 约 1 万小时自采（9.03 亿步）+ 9.1% 开源 | 8,376 小时四层金字塔（真机 3,289 / 人类 2,517 / 仿真 1,743 / 神经 827） |
| 推理    | 4090 约 6Hz（单步）        | 4090 73ms 出 50 步块           | L40 63.9ms 出 16 步块                                     |
| 算力    | 21,500 A100 小时        | 未披露                         | 50,000 H100 小时（另 10.5 万 L40 小时生成视频）                    |
| 开放度   | 权重 + 代码 + 数据配方全开      | 论文未提供开源（后续 openpi 才放出）      | 2B 权重 + 数据 + 仿真环境开                                     |

三种选型给上下文留的入口不同，直接决定了后装路径。

**单流自回归（OpenVLA 及  $\pi 0$ -FAST）：**唯一入口是 LLM 的 token 序列：加演示等于加 token，无需新模块，文本侧的上下文能力也可能部分迁移（RICL 的 elicited latent actions 是旁证）。代价一是长度：一步观测就是几百个图像 patch token，整条演示放不进，所以 RICL 只检索 4 组单步近邻（token 数 4 倍、rollout 时长 1.33 倍），底座又只有 6Hz 量级；二是离散输出反成资产——RICL 的动作插值层  $e^{(-\lambda d)} \cdot \text{one-hot}(a') + (1 - e^{(-\lambda d)}) \cdot \text{softmax}$  要求类别分布输出才能与最近邻动作凸组合，这是它选  $\pi 0$ -FAST 而非 flow 版  $\pi 0$  的结构性原因。

**共享注意力的 flow 专家（ $\pi 0$ ）：**入口有两个，VLM 前缀与动作专家。演示观测可进前缀，且前缀 KV 只算一次、10 步流积分只重算后缀，摊销上优于自回归；但演示**动作**没有输入通道——动作在  $\pi 0$  里只以「带噪目标」出现在最后一块，因果掩码又禁止前缀回看机器人 token。装 ICL 必须新开掩码块并从头教模型用它。本仓库没有任何工作在 flow 版  $\pi 0$  上后装过 ICL， $\pi 0.5$  在六篇论文里全是被挑战的基线而非宿主，与此一致；BPP 与 ICRT 从零训练，部分就因为要自己设计「演示动作作为输入」的通路。

**跨注意力双系统（GR00T N1）：**System 1 是自足的 transformer，序列里本来就有状态与动作 token，VLM 只被跨注意力「读取」。这给出两个别家没有的入口：不动 System 2 就能往 DiT 序列加 token；VLM 按步算、DiT 按块算，两者之间天然有可插循环状态的缝。RoboTTT 两条都用了：TTT 层插在每个 DiT 块的注意力后，tanh 门控初始化 0.001 保护预训练行为；喂过去动作 token 相对 +23%，正因为动作已是 DiT 的输入模态。4 步去噪与 16 步块让每块一次 fast-weight 更新的常数项可承受；代价是视觉语言 token 不在 DiT 序列里，跨时间必须压成 register token。

底座数据买到的先验也不同：OpenVLA 的 97 万条是单臂第三人称低频抓放； $\pi 0$  的 1 万小时是 50Hz 双臂灵巧但专有；GR00T 有 2,517 小时人类第一视角视频以「LAPA 具身」进了同一个 flow matching 目标——底座已把人类手部帧映射进潜动作空间。RoboTTT 的 one-shot 人类视频模仿（6/10）建立在这个底座上，人类视频层是否是必要条件无人消融，值得检验。最后与 notes/22 的 Xie 条件相通：三家预训练始终提供语言指令，任务身份由文本给定，模型没有「从上下文推断任务」的梯度压力——这解释了 RICL 为什么必须先用 400 条演示 priming、5 条演示时退回底座行为，也解释了 ICL 对这三家永远是后装而非涌现。



## 6. 局限与批判

**三套协议互不可比。**OpenVLA 报 170+60 次 rollout 的成功率  $\pm$  标准误、A/B 同初始状态，口径最干净； $\pi_0$  报每任务 10 次 episode 的归一化分、无误差棒，最难的任务只与自身消融比；GR00T N1 仿真取最后 5 个 checkpoint 的最大值（乐观选择），真机只对照 DP 与 BC-Transformer——**三篇没有一篇把另两篇放进同一协议**。 $\pi_0$  论文里的 OpenVLA 只训 160k 步且不支持动作块，那张图证明的是「单步离散策略不适合 50Hz 灵巧数据」而非公平的架构对比；OpenVLA 评 RT-2-X 时取第二可能动作规避全零动作冻结（作者如实披露），补丁本身暴露了单步离散策略对 no-op 标签的病态敏感——LIBERO 里过滤 no-op 被称为「至关重要」。

**数据披露与可复现性。** $\pi_0$  的 1 万小时全部专有、开源份额 9.1%、「68 任务」按宽口径计，无法复现；GR00T N1 的 8,376 小时里人形真机只有 88.4 小时（1.06%），而**金字塔各层从未被逐层消融**——论文只给了神经轨迹的 +4 到 +9 点，人类视频 2,517 小时贡献多少无人知道；OpenVLA 最透明，但 DROID 学不动被中途移除，7B 自回归对高多样性数据的拟合有上限。

**没有一家有历史或上下文机制。**OpenVLA 单图， $\pi_0$  单观测，GR00T N1 单步且加一帧历史即掉 17.5 点（RoboTTT 测量）。所有「VLA + ICL」都是外科手术；GR00T N1 后训练丢失换手行为与 HOST 测得的  $\pi_{0.5}$ +SFT 旧任务保留 20% 互相印证——底座层面「适应即遗忘」是真的，这是 ICL 路线的立足点。

**算力与版本漂移。**OpenVLA 21,500 A100 小时、GR00T 50,000 H100 小时加 10.5 万 L40 小时、 $\pi_0$  未披露：后装 ICL 的「便宜」只是边际成本。三家都在快速换版（GR00T N1  $\rightarrow$  N1.5  $\rightarrow$  N1.7， $\pi_0 \rightarrow \pi_0$ -FAST  $\rightarrow \pi_{0.5}$ ），各篇引用的「同一底座」其实是不同模型，跨篇比数字必须带版本号。

# One-Shot 模仿学习源头三篇合集：2017 年就有的问题，2026 年为什么才成

覆盖三篇：**One-Shot Imitation Learning** (Duan et al., NeurIPS 2017, arXiv 1703.07326, OpenAI + Berkeley) · **One-Shot Visual Imitation Learning via Meta-Learning** (Finn et al., CoRL 2017, 1709.04905, Berkeley) · **One-Shot Imitation Learning with Invariance Matching for Robotic Manipulation** (IMOP, Zhang & Boularias, RSS 2024, 2405.13178, Rutgers) 定位：Duan 是 one-shot 模仿的问题定义者（演示条件策略 + 软注意力），Finn 是元学习路线的开端（MAML 进视觉模仿、首次真机数字），IMOP 是 2026 年之前学术 OSIL 的最后一个结构派高点，也是 ManiLong-Shot (notes/21) 的直接前作与 RL Bench-Oneshot 基线 (7.4%)。三篇合起来是 HOST / GEN-1.5 / S1 的前史。信息来源深度：三篇均以 PyMuPDF 从 arXiv PDF 全文提取精读 (Duan v3、Finn v1、IMOP v2)，IMOP 另核对 arXiv HTML 版；IMOP 在 RL Bench-Oneshot 上的 7.4% 取自 ManiLong-Shot 原文。

## 1. 为什么补这三篇

本仓库的主线从 2026 年 8 月的三连发往回追，最远只到 Vid2Robot 与 ICRT (2024)。但「一条演示、零参数更新、执行新任务」的完整形式化在 2017 年就已写下，而且当年就分裂成今天仍在对峙的两条路线：把演示当输入 (Duan) 还是当梯度 (Finn)。不读源头，说不清 2026 年是解决了 2017 年的问题，还是换了一个更容易的问题；也说不清 GEN-1.5 那句「我们没有为 ICL 做任何训练」在历史上有多反常。IMOP 提供另一个锚点：没有大模型先验时，把结构设计推到极致能走多远——答案是短程 41.3%、长程 7.4%，这两个数字是判断 2026 年各家进步「来自哪里」的对照组。

## 2. Duan et al. 2017: 问题的定义者

**问题设定。**任务分布  $T$ ，策略  $\pi_\theta(a|o,d)$  同时以当前观测  $o$  和一条演示  $d$  为条件；训练时从同一任务采两条演示，一条作输入、另一条提供  $(o,a)$  监督对；测试时给未见任务的一条演示，要求策略在该任务的新实例上表现良好。这个「同任务不同 episode 天然构成演示-执行对」的构造，就是 HOST Stage 1 (193,462 条轨迹、229 任务) 与 ICRT 的训练方案，九年没变。摘要末句值得逐字记：「我们预期在更多样的任务与场景上训练该模型，将得到一个能把任意演示转成鲁棒策略的通用系统」——这正是 GEN-1.5 的全部赌注。

**方法。**仿真 7-DOF Fetch 臂堆积木，观测是各积木相对夹爪的  $(x,y,z)$  坐标加夹爪开合，没有图像，感知外包给仿真器。三模块：演示网络（时间丢弃  $p=0.95$  把数百至数千步的演示压缩 20 倍，叠加膨胀时间卷积与邻域注意力——每个积木以自身为 query 注意其他积木，保持排列不变性）；上下文网络（以当前状态为 query 对演示各时间步做软注意力，再对当前状态各积木做注意力，经 4 步 LSTM 迭代，输出与演示长度、积木数都无关的定长嵌入）；操作网络 (MLP)。「以当前状态为 query 检索演示」在结构上就是 cross-attention——这篇论文比 Transformer 早三个月，用的是同一个原语。

**代表数字与口径。**140 个训练任务、43 个测试任务（任务 = 积木布局字符串，2–10 块），每任务 1000 条脚本策略演示，约 14 万条训练轨迹；评测为每任务 100 个新初始配置、每次以一条训练未见的演示为条件、10 个下采样演示集成、贪心动作。未见任务上 DAGGER 版按阶段数：2 阶段 94.9%、4 阶段

77.0%、5 阶段 65.9%、6 阶段 50.6%、7 阶段 36.5%、8 阶段 18.0%；作为上界的脚本演示者自己也只有 95.8% 到 29.0%。三个当年就成立的发现：BC 与 DAGGER 持平，无需交互监督；条件整条演示优于只给最终状态（阶段越多差距越大），甚至优于给已分好段的关键帧快照；注意力热图在时间轴上稀疏，高权重区域数与任务阶段数一致——策略自己学会了给演示分段。附录里还有一句被遗忘的观察：粒子到达任务的学习曲线出现「相变」，作者猜测对应「网络学会从演示推断任务」的时刻。

**局限。**全状态输入、仿真、单一任务族（所有任务共享组合结构）、脚本演示者；失败拆解显示多数失败是操作失败而非误读演示，瓶颈在低层技能而非任务推断。作者列的三条未来工作——图像输入、多条演示、更广任务分布——恰好是接下来九年的路线图。

### 3. Finn et al. 2017: 元学习路线

**问题设定。**与 Duan 同一形式化（任务分布、每任务至少两条演示、测试任务留出），但把「学新任务」定义为参数更新：学一个初始化  $\theta$ ，使得在单条演示上做一步梯度下降后的  $\theta'$  就是该任务的好策略。作者对 Duan 路线的批评是数据效率：「先前工作用了 10,000 条以上演示」，上下文策略在中等数据量下学不出来。

**方法。**MAML 内环用行为克隆 MSE 损失，外环在第二条演示上评估。三处改造：双头架构——更新前后用不同输出层，等价于元学习一个内环损失函数，由此推理时可去掉专家动作、只用视频做适应（作者注明「人类视频到机器人视角的域偏移留待未来」）；偏置变换——给隐层拼接可学参数向量，让一步梯度能更直接地改写偏置；空间 softmax CNN 加层归一化（演示内时间相关性太强，BatchNorm 失效）。

**代表数字与口径。**仿真推物（MuJoCo，7-DoF 力矩控制，125×125 RGB，116 个 thingiverse 网格中 105 训练 11 测试，5000 余纹理），74 任务 × 6 次 = 444 次试验，最大 9200 条演示：one-shot 成功率 MIL 85.81%，Duan 式 LSTM 78.38%，以最终帧为条件的 contextual 58.11%；去掉动作只留视频加状态时 MIL 72.52% 对 LSTM 37.61%，纯视频 66.44% 对 34.23%；双头对单头 85.81 对 80.63。真机 PR2 放置：约 1300 条 VR 遥操作演示、约 100 个训练物体，29 个留出物体、18 任务 × 4 次 = 72 次试验，MIL 90%，纯视频 68.33%，LSTM 与 contextual 均 25%（作者归因为无法定位目标，放到了任意物体上）。这是 one-shot 视觉模仿第一次在真机上给出可信数字，但 72 次试验是验证级证据。

**局限。**「新任务」实为同一任务族内的新物体或新目标，任务多样性作者自认有限；测试时必须做梯度更新，不是纯上下文；MAML 的二阶梯度与全网络更新在 2017 年的小 CNN 上可行，在十亿参数模型上不可行——这条路线之后没有跟上 scaling 曲线，与 Duan 路线的命运分岔在此埋下。复合误差与人机域偏移两个真问题被明确推给未来。

### 4. IMOP 2024: 结构派的极致

**问题设定。**基础任务集有大量演示，新任务只给一条未标注演示、不许微调；状态是整个场景的原始点云，动作是关键帧级 6D 末端目标位姿加夹爪/碰撞两个二值，由 MoveIt 规划执行。相比 2017 年，「新任务」第一次指向真正不同的任务类别（RLBench 九类中 22 个新任务，与 18 个基础任务在物体与目标上均不同），而不是同族新实例。

**方法。**核心概念是「不变区域」：在末端预接触位姿坐标系下，跨所有共享同一语义动作的场景保持坐标不变的点集（抓杯子时是杯柄）。三个网络：不变区域匹配网络在点云 KNN 图上用 point transformer 做图

注意力，逐点 sigmoid 预测支持帧的不变区域，再与查询场景做图交叉注意力、双 softmax 得到对应矩阵 C；位姿不由网络回归，而是用可微 Procrustes 解最小二乘  $T_j = \operatorname{argmin} \|T \cdot T_j^{-1} \cdot P_j \cdot C - P_s\|$  解析得出；状态路由网络用 PTv2 场景特征拼接关节位置与时间步，交叉注意力从演示里选出与当前查询对应的支持帧——这是 Duan 「以当前状态为 query 检索演示」的显式化版本。训练用 RLBench 的实例分割与 C2F-ARM 关键帧抽取构造真值，推理不需要分割。

**代表数字与口径。**18 个基础任务（每任务 100 条演示，前/左右肩/腕四路 128×128 RGB-D，每任务 25 次试验、5 次运行取均值）：IMOP 69.6% 对 Act3D 65.1%、RVT 62.9%，place cups 一项 52.8% 对基线最高 4%。22 个新任务 one-shot 无微调：IMOP 41.3%，对照用一条演示微调的 RVT+FT 29.8%、加适配层的 RVT+HDT 26.9%，不微调的 RVT 为 0；RVT+FT 微调后基础任务从 62.9% 跌到约 4.7%——这是 HOST 引用的「灾难性遗忘」论据在 2024 年的原始版本。消融最有价值的一行：换成 Act3D 式常规位姿回归头，基础任务 65.1% 几乎不变，新任务直接失败——分布内成绩对 one-shot 泛化零预测力。真机 Kuka iiwa，仿真训练、一条真机演示直接迁移，5 个任务各 10 次：8/10、4/10、5/10、4/10、5/10，对照 one-shot 微调 RVT 3/10、1/10、2/10、2/10、2/10。长程新任务 block pyramid 5.2%、slide place 6.8%；在 ManiLong-Shot 的 RLBench-Oneshot 20 个未见长程任务（25 试验 × 5 种子）上 7.4%，Set Table、Stack Blocks、Block Pyramid 三项 0.0%。

**局限。**不变区域定义绑定刚体变换，平面（开盒、关微波炉）与小区域（灯开关）导致最小二乘不稳定；只路由到成功演示、无失败恢复；sim-to-real 时 sigmoid 输出整体偏低，阈值须降到 0.1；训练依赖分割与关键帧抽取。更根本的是：它把「不变性」写死为几何先验，换到需要语义对应（功能相同、几何不同）的场景就没有余量——这恰是视频基础模型先验能补的位置。

## 5. 合成：九年跨度对照

**连续的部分比想象中多。**问题形式化与训练对构造（Duan Fig.1c = HOST Stage 1 = ICRT）没有变；「用当前状态去演示里检索对应阶段」这一机制，从 Duan 的稀疏时间注意力、到 IMOP 的状态路由网络、到 HOST 的进度定位级，是同一件事的三种实现；Finn 的「纯视频演示、无专家动作」在 2017 年就是明确目标，S1 与 HOST 只是把域偏移那一步真正做掉；Finn 与 Duan 之争（梯度 vs 上下文）原样延续为 RoboTTT / WAM-TTT 与 GEN-1.5 / S1 之争，连 RoboTTT 快权重初值的 MAML 式元学习都是 Finn 的直系；IMOP 的 RVT+FT 62.9→4.7% 与 HOST 的  $\pi 0.5$ +SFT 仅存 20%，是同一个动机的两次陈述。甚至「涌现」叙事也有前身：Duan 附录的相变观察比 GEN-0 的「智能相变」早八年，且发生在单卡一小时内训完的小网络上——这对 notes/16 的涌现之争是一条关键证据：相变不需要规模，Olsson 式的线路形成解释比「规模阈值」解释更贴合历史。

**断裂点有三处，重要性递增。**其一，任务定义。2017 年的「新任务」是同族新实例（新积木布局、新物体），IMOP 把它推到跨类别，短程 one-shot 的数字就落到 41.3%，而同族设定下 Finn 的真机数字是 90%——两者口径不可比，但差距的方向说明了任务定义的权重；2026 年三家的「未见任务」是真机桌面短程任务，比 IMOP 的跨类别宽松、比 Duan 的同族严格，且判定口径各异——HOST 62% 与 Duan 94.9%（2 阶段）或 IMOP 41.3% 之间没有任何一对可以直接比大小。其二，数据规模与结构。Duan 约 14 万条脚本轨迹但只有一个任务族；Finn 1300 条真机演示；IMOP 1800 条仿真演示；HOST 19.3 万条真机轨迹 229 任务加 5847 条人类视频；GEN-1.5 50 万小时。按 Xie（notes/22）的可辨识性条件，单一任务族让「任务身份」不构成必须推断的潜变量，策略可以走捷径——Duan 自己的数据里，短任务上只看

最终状态与看整条演示一样好，正是捷径存在的证据；BPP 的任务多样性定律说的是同一件事。其三，主干先验，这是决定性的。2017 年可用的最强先验是冻结一层 VGG-19 卷积；IMOP 的 PTv2 从头训练、8080 万参数，只能把不变性写成刚体几何；HOST 的视频专家从 Wan2.2 初始化、帧嵌入用 Qwen3-VL-Embedding-8B——跨具身、跨外观的「功能对应」不再需要配对数据从零学，而是从互联网视频先验里继承。Finn 明确推迟的「人类视频到机器人视角的域偏移」，不是被某个算法解决的，而是被先验消解的。

**所以差在哪。**三者都差，但权重不同：任务定义解释了为什么数字不能跨年代比，数据规模解释了为什么 2017 年的架构学不出任务推断，主干先验解释了为什么 2026 年能用人类视频而 2017 年只能用机器人自身状态。反过来看没变的东西更有信息量：Duan 的阶段衰减曲线（2 阶段 94.9% 到 8 阶段 18.0%）、IMOP 的长程 7.4%、ManiLong-Shot 的长程 30.2%，说明严格协议下长时程 one-shot 九年来只从「接近零」走到「三成」；S1 的 66% 是含人工干预的逐步计分口径，不构成对这条曲线的反证。2026 年解决的是 Duan 定义的短程问题的真机视觉版本，长程部分仍在 2017 年的曲线上。

## 6. 对当前调研的启示

第一，Duan 的阶段衰减表应作为长程 one-shot 的「历史基线曲线」纳入评测轴，与 RLBench-Oneshot 的 L1/L2/L3 分档（6/9/12 次交互）对齐；任何声称长程 one-shot 突破的工作，先问阶段数与判定口径。第二，IMOP「分布内 65.1% 不变、one-shot 归零」的消融是本仓库最干净的一条警示：GEN-1 的 99% 精通与 GEN-1.5 的 59% one-shot 是两个独立指标，前者不预测后者。第三，Finn 的「上下文路线要一万条、MAML 只要一千三百条」给出了梯度路线与上下文路线的数据交叉点，S1 的「一条演示约等于 380 条后训练示范」是 2026 年版本的同一条交叉曲线；可证伪预测：数据受限时快权重派占优，数据充裕时纯上下文派占优，RoboTTT 的 8K 上下文无饱和暗示两者最终合流。第四，Duan 2017 的相变观察应补入 notes/16 §5 的涌现之争时间线，作为「小规模也有相变」的历史证据。第五，三篇之间有一层未覆盖的沉积：Yu et al. 2018 (DAML, MAML 直接吃人类视频)、Dasari & Gupta 2020 (Transformer one-shot 视觉模仿)、Mandi et al. 2022 (MOSAIC)、Xu et al. 2022/2023 (Prompting DT、HDT)、Biza et al. 2023 (interaction warping)，其中 DAML 与 Dasari 分别是 Finn 路线与 Duan 路线的最后一站，值得作为下一批补读对象。README 建议：IMOP 归入 2.2 结构派并注明「ManiLong-Shot 前作」；Duan 与 Finn 新开「2.11 OSIL 源头」小节，与 2.8 LLM 背景对称。



# 生成式动作头奠基两篇合集：为什么 ICL 时代的机器人策略都是生成模型

覆盖两篇：**Diffusion Policy: Visuomotor Policy Learning via Action Diffusion** (Chi, Xu et al., Columbia/TRI/MIT, RSS 2023, IJRR 扩展版 arXiv 2303.04137v5) · **Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware** (Zhao, Kumar, Levine, Finn, Stanford/Meta/Berkeley, RSS 2023, arXiv 2304.13705, 即 ACT/ALOHA) 定位：本调研覆盖的动作头几乎清一色是 flow matching 或 diffusion——HOST 的自回归 flow matching、 $\pi_0$  的 flow matching action expert、GR-3 与 GR00T N1 的 DiT flow matching、BPP 直接沿用 Diffusion Policy 的 CNN+FiLM 解码器、Instant Policy 的图扩散 (GEN 系列为博客，动作头未公开)；而它们无一例外按「动作块」输出。两个习惯的源头就是 2023 年春天相隔不到两个月发布的这两篇。

## 1. 为什么调研要补这两篇

此前的解读把「上下文如何进模型」争得很细，却把「动作如何出模型」当作默认配置略过。这个默认配置有来历：2023 年以前主流行为克隆是逐步回归 (BC-MLP、RT-1 的离散分类、LSTM-GMM 的单步混合高斯)，之后几乎所有策略都改成「以观测为条件、对未来一段动作序列的生成模型」。Diffusion Policy 论证了为什么要建模分布而非回归，ACT 论证了为什么要预测动作块而非单步，并把双臂遥操作的硬件门槛砸到 2 万美元。补这两篇是为了给后续 VLA 的动作头找到口径可查的原始数字，并正面回答一个本调研反复碰到却没处理的问题：生成式头是否是具身 ICL 成立的必要条件。

## 2. Diffusion Policy：把策略从「回归函数」改成「条件分布的采样器」

**主张。**把视觉运动策略表示为动作空间上的条件去噪扩散过程：从高斯噪声出发，噪声预测网络  $\epsilon_\theta(O_t, A^k_t, k)$  迭代  $K$  次得到干净动作序列。两个继承自扩散模型的性质：能表达任意可归一化的多模态分布（学的是分数函数  $\nabla_a \log p(a|o)$ ，绕开了 EBM 的归一化常数  $Z$ ，因此比 IBC 训练稳定）；对高维输出友好，因此一次预测整段序列而非单步。三项工程贡献让它能跑实机：**闭环动作序列**（观测/预测/执行视野  $T_o/T_p/T_a$  默认 2/16/8，执行 8 步后重规划，即 receding horizon）；**视觉条件化**（只建模  $p(A|O)$  而非 Janner 式联合分布  $p(A,O)$ ，视觉编码每次推理只算一遍）；**时序扩散 Transformer**（噪声动作为 token、观测经 cross-attention 注入，避免 1D 卷积对高频动作的过平滑）。实机用 DDIM 把训练 100 步压到推理 10 步（附录表为 16 步），RTX 3080 上 0.1 秒。

**为什么要建模分布。**Push-T 的一个状态讲清多模态：末端可从左或从右绕过 T 块，LSTM-GMM 与 IBC 偏向一侧，BET 在两种模式间来回抖，扩散策略两种都学会且每次 rollout 只提交一种。序列预测另有两个副产品：时间一致性（逐步独立采样会在两条合法轨迹间跳变）与对「停顿动作」的鲁棒性（遥操作的原地停留会让单步策略学成卡死）。反常识发现是位置控制优于速度控制：位置控制下多模态更显著而扩散策略恰好不怕，且对延迟更鲁棒（模拟延迟 4 步内性能不掉）。控制论小节：LQR 演示下最优去噪器闭式恢复  $a=-Ks$ ，且预测未来动作必须隐式学到任务相关动力学——这是「策略即隐式世界模型」最早的形式化陈述。



**数字与口径。**仿真 15 任务 4 基准 (Robomimic 5 任务 9 变体、Push-T、Block Push、Franka Kitchen) 平均提升 **46.9%**，口径：每个任务取扩散策略两种主干的最高分对所有基线的最高分算相对提升再跨任务平均，忽略 mh (多人混合演示) 列；主表同时报「最佳 checkpoint」与「最后 10 个 checkpoint 均值」，3 种子 × 50 初始条件 (作者注明 Robomimic 因代码 bug 只用了 22 个)。长时程多模态优势最大：Block Push 的 p2 相对 +32%，Kitchen 的 p4 相对 +213%。实机 UR5 Push-T (136 条演示，20 次评测，10 Hz 指令插值到 125 Hz) 成功率 95%、终态 IoU 0.80 对人类 0.84，IBC 与 LSTM-GMM 最好变体 0% 与 20%；Franka 倒酱 IoU 0.74、涂酱覆盖 0.77 (人类 0.79/0.79)，翻杯 90% (20 次，250 条演示)；扩展版双臂打蛋器 55% (210 条)、展垫 75% (162 条)、叠衣 75% (284 条)，均 20 次试验，全部沿用 Push-T 超参。

### 3. ACT/ALOHA：动作分块 + CVAE + 时间集成，让 2 万美元双臂做毫米级操作

**硬件主张。**问题设定是「学习能否让低成本、低精度硬件完成精细操作」。ALOHA 用两台 ViperX 6-DoF 臂 (约 5600 美元，负载 750 g，精度只有 5–8 mm) 做 follower，两台更小的 WidowX (3300 美元) 做 leader，**关节空间直接映射**遥操作——不走 VR 手柄的任务空间映射，因为精细操作常在奇异形附近、逆运动学频繁失败，而 leader 臂的重量还能阻尼操作者抖动。4 台 Logitech 网络摄像头 480×640，遥操作与记录均为 **50 Hz**；整机不到 2 万美元，非专家 2 小时可装配，能复现 40 万美元 Shadow 遥操作系统 15 个演示任务中的 14 个。用户研究 (6 人) 证明频率不是装饰：从 50 Hz 降到 5 Hz (RT-1 等大模型的典型频率)，穿扎带 33 秒对 20 秒、分杯 16 秒对 10 秒，总耗时增加 62%， $p < 0.001$ 。

**算法主张。**直接动机是复合误差：像素到动作的策略在 50 Hz、400–700 步的轨迹上逐步漂移，DAgger 式在线纠正与噪声注入在精细任务上都不可用。解法三件套：**动作分块**——建模  $\pi(a_{t:t+k}|s_t)$  而非  $\pi(a_t|s_t)$ ， $k=100$  (即 2 秒)，任务有效长度缩短  $k$  倍，同时把「演示里的停顿」这类时序相关混杂因素吞进块内；**时间集成**——每步都查询策略，同一时刻累积多份来自不同时刻的预测，按  $w_i = \exp(-m \cdot i)$  加权平均 (平均的是对同一时刻的多次预测，不引入偏差，不增加训练成本)；**CVAE**——编码器从关节状态与动作块推断「风格变量」 $z$ ，解码器 (即策略) 以图像、关节与  $z$  为条件输出块，测试时  $z$  置为先验均值 0、确定性解码。实现细节几乎全被后人照抄：动作是 leader 关节绝对位置 (差分关节反而更差；用 leader 而非 follower 是因为两者之差经 PID 隐式编码了力)，Transformer 编码器融合 4 路 ResNet18 特征、关节与  $z$ ，解码器经 cross-attention 生成  $k \times 14$  动作，L1 损失比 L2 更精确，约 80M 参数每任务从头训练，单张 2080 Ti 5 小时，推理 0.01 秒。

**数字与口径。**6 个真机双臂任务，每任务 50 条演示 (穿魔术贴 100 条)，每条 8–14 秒，合计每任务 10–20 分钟数据；真机 1 种子 25 次评测，仿真 3 种子 × 50 次。最终成功率：滑开密封袋 88%、装电池 96%、开调料杯 84%、穿魔术贴 20%、备胶带 64%、穿鞋 92%；四个基线 (BC-ConvMLP、BeT、RT-1、VINN) 在真机任务上没有一个越过第一阶段。仿真两任务上 ACT 比最强基线高 59/49/29/20 个百分点。三条消融是这篇的真正遗产：(1) 块长  $k$  从 1 到 100，四设定平均成功率从 **1% 升到 44%**， $k=200/400$  略降 (接近开环)；给 BC-ConvMLP 与 VINN 加分块同样显著提升——分块是通用技巧，不依赖 Transformer；(2) 时间集成给 ACT +3.3、BC-ConvMLP +4 个百分点，对非参数的 VINN 反而有害 (它检索的是真值动作，无建模误差可平滑)；(3) CVAE 在脚本数据上无差别，在人类数据上从 **35.3% 掉到 2%**——生成式目标是吃人类数据的必要条件。

## 4. 合成：从「回归动作」到「生成动作」再到「上下文条件生成」

**三级演进。**第一级是回归动作：策略是  $o \rightarrow a$  的函数（或单步离散分类、单步 GMM），隐含假设是同一观测下只有一个正确动作。两篇各自击穿这一假设的不同侧面：Diffusion Policy 击穿「单模态」——同一状态下人类演示有多种合法解，回归取均值落在模式之间；ACT 击穿「马尔可夫单步」——逐步输出让误差复合、让停顿变成陷阱。第二级是生成动作：共同形式是  $p(A_{[t:t+H]}|o_t)$ ，以观测为条件、定义在动作序列上的分布。差别在采样器：扩散策略真的从分布采样（随机初始化决定收敛到哪个模式，块内保持一致），ACT 训练时是 CVAE、测试时  $z=0$  退化为确定性解码——「生成」只是训练期吸收人类随机性的手段。第三级是上下文条件生成：把条件从  $o_t$  扩成  $(o_t, \text{演示})$ ，这正是本调研 ICL 各篇的形式——HOST 以人类视频窗口为条件的自回归 flow matching，BPP 以 prompt 演示为条件的 Diffusion Policy 解码器，Instant Policy 以演示图为条件的图扩散。

**继承清单。**Diffusion Policy  $\rightarrow$  flow matching 一脉： $\pi_0$  把自己定义为「ACT 式动作分块架构 + flow matching（扩散的变体）」， $H=50$  的块以最高 50 Hz 输出，并把 Diffusion Policy 与 ACT 同列为单任务基线；GR00T N1 的 DiT 头用同一 flow-matching 损失、块长 16、推理  $K=4$  步 Euler，时间步采样 Beta(1.5,1) 直接沿用  $\pi_0$ ；GR-3、HOST、Fast-WAM、EgoWAM 的动作专家全部同源。ACT 的动作分块被几乎所有 VLA 继承： $\pi_0$  与 GR00T 写到 chunking 时引用的都是 Zhao et al. 2023；OpenVLA 原版不支持分块， $\pi_0$  论文点名这是其劣势，OpenVLA-OFT 正是补上了分块 + L1 回归 + 并行解码；ICRT 执行时的「时间集成 + 后退视野取 10 步」是两篇执行策略的合体。ALOHA 硬件谱系：Mobile ALOHA 加移动底盘，用静态 ALOHA 数据共训，每任务 50 条演示把成功率最多提升 90%；ALOHA 2 之上的 ALOHA Unleashed 改用 Diffusion Policy 训练大规模数据——两条奠基线在 2024 年物理合流；HOST 的 ARX 双臂、GR-3 的 VR 采集都是「便宜遥操作产出海量演示」这条谱系的延续。

**生成式头是 ICL 的必要条件吗。**先给支持论证。按 notes/22 的贝叶斯视角，多模态动作分布可写成对潜在变量的混合  $p(a|o) = \sum_{\theta} p(a|\theta)p(\theta|o)$ —— $\theta$  是任务身份、抓法、绕行方向这类演示者做出的选择。生成式头负责表示这个混合，ICL 负责用演示推断  $\theta$ ：一段演示恰好把混合坍缩到演示者选的那个分量上。ICRT 的「戳 vs 抓」是最干净的实例——目标图像不区分运动模式，轨迹 prompt 一给就清楚。两者是同一问题的两面：分布建模「保留所有模式」，上下文「选出一个」。ACT 的  $z$  尤其耐人寻味——它就是一个训练时从动作块推断、测试时被砸回先验均值的任务/风格潜变量；ICL 等价于把  $z$  的推断挪到测试期，用演示而不是 0 去填它。实证来自 Instant Policy：在演示已在上下文中的 ICIL 设定里，去掉扩散改回归仍掉 29%，说明上下文消不掉全部歧义，残余多模态仍需生成式头兜底。

再给反例。ICRT 用 L1 回归头 ( $h=16$  块) 拿到 79.2%，StellaVLA 用 OpenVLA-OFT 式 MLP 头 L1 回归动作块做 ICL，RICL 用离散 token 交叉熵——三个可工作的具身 ICL 系统都不是扩散或 flow matching 头。反例说明的不是「生成式头无用」，而是必要性的真正来源：上下文足够强时  $p(a|o, \text{上下文})$  已近单模态，回归够用；上下文欠定（一段跨具身人类视频对应机器人多种合法路径）或训练数据本身带人类随机性（ACT 那条  $35.3 \rightarrow 2$  的消融）时，回归头会重新掉进模式平均。结论应表述为：**生成式头不是 ICL 的逻辑必要条件，而是「上下文消歧不完全」这一常态下的实践必要条件**；真正被所有系统无一例外继承的只有动作分块。这也解释了工业 VLA 几乎全选 flow matching 而学术 ICL 原型敢用回归：前者吃的是跨场景、跨操作员的海量遥操作数据，残余多模态最大。

## 5. 局限与批判

两篇都在单任务、从头训练、无语言条件的行为克隆设定下工作，没有一句话涉及 ICL——第 4 节的「潜变量-上下文」论证是本调研的推断，不是作者的主张。口径上：Diffusion Policy 的 46.9% 是偏向己方的平均方式（两主干取最优、忽略 mh 列），仿真评测有已承认的 22 个初始条件 bug，实机全部 20 次单种子；ACT 真机 25 次单种子，物体只沿 15 cm 参考线随机，穿魔术贴 20% 说明毫米级任务仍卡在感知； $k=100$  配合「最旧预测权重最大」的指数加权意味着新观测进入执行很慢，后续 VLA 大多只留分块、弃用时间集成。方法层面，ACT 测试时  $z=0$  意味着它并不能采样多模态，确定性解码得到的是「风格平均」，多模态问题只解决了一半；扩散策略则相反，随机采样使评测方差变大，「每次 rollout 只提交一种模式」只在块内成立。计算上扩散策略 0.1 秒一次推理做不到 ACT 论证的 50 Hz——两篇的优点在 2023 年互斥， $\pi_0$  用 flow matching + 少步采样才把两者合到一起。最后一条对本调研最重要：「多模态需要生成式头」的结论全部来自遥操作人类数据；若 ICL 时代的数据主体改为人类第一人称视频或仿真伪演示，多模态的来源与形态会变，生成式头的必要性需要在新数据分布上重新消融，目前无人做。

# 人类数据管线三篇合集：ICL 的燃料从哪来——UMI、RH20T、Ego2Robot

覆盖三篇：Universal Manipulation Interface: In-The-Wild Robot Teaching Without In-The-Wild Robots (Chi, Xu et al., Stanford/Columbia/TRI, RSS 2024, arXiv 2402.10329) · RH20T: A Comprehensive Robotic Dataset for Learning Diverse Skills in One-Shot (Fang et al., 上海交大, 2023, arXiv 2307.00595) · Ego2Robot: Scalable Robot Data Synthesis from Egocentric Human Data (Wang et al., 阿里 Qwen Team + 人大 AIM3 等, 2026-08-03, arXiv 2608.02580) 定位：趋势三 (insights/10) 的四分天下写的是「用数据的人」，这三篇是「造数据的人」。此前调研只以二手方式碰到它们：BPP 的 iPhUMI 是 UMI 换了台手机；Zero-WAM 拿 RH20T 「110K 样本仅 147 任务」当任务覆盖瓶颈的反面数字；S1 博客把 UMI 评为三轴全 Moderate 的折中方案；Ego2Robot 在趋势三表里只有一行。

## 1. 为什么补这三篇

VLA 时代衡量数据管线的尺子是「每任务多少小时」，ICL 时代换了尺子。BPP 的受控实验（固定预算下 2000 任务 x 5 demos 远胜少任务多演示）与 ICRT 的对照（1098 条多任务同场景轨迹从 0% 做到 73.3%，1 万条 DROID 为 0%）共同给出定律：驱动 in-context 能力的是任务数与场景内歧义，不是每任务密度。于是管线的问题变成：一小时人力、一美元设备、一 GPU 小时算力，各能买到多少个新任务？三篇恰是三种成本结构——UMI 把成本压到设备端（一人一夹爪），RH20T 压在工位端（机械臂加十台相机加力反馈手柄），Ego2Robot 把成本从采集端整体搬到计算端。另一动机是核口径：三篇的规模单位分别是「条」「条与 TB」「形态 x 小时」，趋势三表把它们与 GEN 的 50 万小时并排，不回原文就会比错。

## 2. UMI：在采集端消掉具身差距的手持夹爪

**机制。**三维打印平行夹爪加一台 GoPro 是全部传感器。观测侧补足腕视角的信息缺口：155° 鱼眼保留视觉上下文（策略直接吃原始鱼眼图）；夹爪两侧物理镜面制造隐式双目；GoPro 内置 IMU 配改造版 ORB-SLAM3 做视觉惯性 SLAM，恢复带绝对尺度的 6DoF 末端轨迹。动作侧：基准标记连续追踪开度（配 TPU 软指形成隐式力控），SLAM 绝对位姿允许按目标机器人运动学过滤不可达演示。策略接口令模型硬件无关：按实测延迟对齐观测流并提前发送动作；动作与本体全用相对当前末端的轨迹表示，免标定；双臂加相对双夹爪位姿（靠先建图后定位共享坐标系）。策略统一为 Diffusion Policy。

**规模与口径。**逐任务独立采集、独立训练：杯子摆放 305 条（2 人）、动态抛掷 280 条、双臂叠衣 250 条、7 步洗碗 258 条（1 人）；野外实验 3 人 12 人时在 30 个地点采 1400 条，约 117 条/人时（含重置）。SLAM 精度按 MoCap 基准（7 单臂 + 7 双臂任务）：位置 ATE 6.1mm、旋转 3.5°，双夹爪相对位姿 10.1mm / 0.8°。真机 20 次试验：杯子 20/20，同一 checkpoint 换 Franka FR2 18/20（两败均为关节限位）；抛掷 105/120（关延迟匹配掉到 69/120）；叠衣 14/20（去双夹爪本体掉到 6/20）；洗碗 14/20；两个未见环境 43/60=71.7%，仅用窄域数据训练则 0%。消融里最有信息量的是绝对动作只 5/20——SLAM 与机器人坐标系的标定误差直接吃掉性能，是「野外数据拿不到绝对坐标」的实证。

**成本。**夹爪 BoM \$73、GoPro 及配件 \$298，整机 780g；新场景建图约 1 分钟。15 分钟吞吐对照：杯子任务 UMI 比 SpaceMouse 遥操快 3 倍以上、为裸手 48%；抛掷任务为裸手 64%，遥操 15 分钟零条成

功。

**局限。**作者自认：运动学可行性只能靠丢数据（丢弃率未报）；SLAM 依赖纹理；仍慢于裸手且自由度减少。延伸：论文没有任何多任务模型——它证明「一条管线能采到什么」，不证明「采多少任务」；形态锁定平行夹爪；无显式力觉。

### 3. RH20T：力反馈遥操的规模标杆，也是任务覆盖瓶颈的标本

**机制。**名字即口径：Robot-Human demonstration in 20TB。立场是接触丰富的操作必须用带力反馈的遥操采——3D 鼠标、VR 手柄遥操在接触时易撞出急停，前人只能避开接触或减速，故每工位配腕部六维力传感器与力渲染手柄。硬件 7 种配置：Flexiv / UR5 / Franka / Kuka 四种臂 x 四种夹爪 x 三种力传感器，Cfg 7 另加 uSkin 指尖触觉。每工位 1-2 台手内相机、8-10 台全局相机、2 支麦克风，全部外参标定并逐场景人工核验；模态含 RGB / 深度 / 双目 IR 与关节角、力矩（10Hz），末端位姿与六维力（100Hz），音频（30Hz），触觉（200Hz）。人类演示在同一工位由真人完成，加一台第一人称相机。

**规模与口径。**110K+ 机器人序列与等量人类演示视频，机器人帧 4000 万 +、人类帧 1000 万 +；147 任务对应 42 个技能动词（48 个源自 RLBench、29 个源自 MetaWorld、70 个自提），平均每任务约 750 条；单条多在 10-100 秒（未报总时长，折算约 300-3000 小时）。多样性来自 50 余种桌布、数十名志愿者（培训不到 1 小时）、每技能改条件重复 10 次、对抗与协作式人为干扰。每条由操作者打 0-9 分，成功失败约 10:1，失败保留。数据按任务内相似度组成树状层级，同祖先叶节点可配出百万级「人类演示-机器人操作」对。

**实验。**作者坦承算力不够跑基础模型，只做 ACT 微调对照：新环境 75 条遥操，加 335 条同任务与 195 条相近任务预训练，20 次试验，reach/pick/place 从 55/5/0 升到 80/25/25；40 条加预训练（70/25/15）超过 75 条不预训练；换新砝码与桌布预训练组一致更好。绝对数字低，place 最高 25%。

**成本与局限。**作者自认：采集昂贵；基础模型潜力未评估。延伸：每任务 750 条是 BPP 配方（每任务 5 条）的 150 倍，任务数 147 只是其 2000 的 7%——这个配方在微调时代是优点，在 ICL 时代成了 Zero-WAM 引用的反面数字（HumanGen 8.6K 任务约为其 58 倍）。但它握着另两篇都没有的东西：真实力 / 触觉 / 音频，以及 110K 对真实而非合成的人机配对。

### 4. Ego2Robot：一次采集、十五份形态副本

**机制。**三阶段把第一人称人手视频改写成机器人格式。动作对齐：21 个手部关键点定义虚拟指尖（0.7 食指 + 0.3 中指），拇指与虚拟指尖的中点为 TCP、间距为开度、连线为夹持轴，左右手映射到同一夹爪坐标系；Savitzky-Golay 与 SLERP 平滑；人手比遥操快得多，训练时按源降帧（ANT/EgoDex 到 60%，EgoVerse 45%，ViTRA 25%，即慢 1.7-4 倍）。视觉对齐：SAM 3 分割手臂 → ProPainter 时序修补 → 基座位姿网格搜索（MuJoCo IK 在关键帧的可行率减去偏离 65% 臂展的惩罚）→ 逐帧 IK 渲染 → Depth Anything V3 估深度做遮挡感知合成。质检三级：管线内（IK 误差 <5cm、无自碰撞）、统计（Q1/Q99 离群与突变，无效帧超 60% 整条丢弃）、Qwen3.5 审计渲染视频与指令的语义一致性。两条入口：Path A 吃带手势标注的数据集，Path B 用 WiLoR + DynHaMR 从原始视频估手势、Qwen3.5 按 60 秒切段并生成 5-12 词指令。动作统一为相机坐标系相对末端增量，免逐视频标定。



**规模与口径。**输入四源约 1,940 小时（自采 ANT 7h、EgoDex 732h、ViTRA 249h、EgoVerse 954h），输出 18,561 小时、15 种形态（Panda、UR5e、ARX-L5、xArm7、Sawyer、Kinova Gen3、IIWA、Jaco、FR3、UR10e、ViperX、WidowX、Piper、YAM、Aloha-Agilex）。**关键口径：**18,561 是 15 形态并行渲染之和，单形态 1,237 小时（5 形态 6,187、10 形态 12,374，严格等分，说明单形态数字是均值而非逐形态实测）——真实人类交互经质检约 1,240 小时，其余是同一批交互的视觉副本。

**实验。**Qwen3.5-4B + DiT 动作头（32 步动作块、flow matching）；机器人数据约 6,565 小时（DROID 511、AgibotWorld 2,404、InternData 仿真 3,650）；所有预训练配置同为 200K 步约 1920 万帧——比的是配方不是数据量。RoboTwin 2.0 上 50 任务各 50 条微调、每设定每任务 50 次：Robot-only 在 Clean/Rand/Visual/Scene/Embodiment/Task/EBench 为 62.2/50.9/61.4/52.9/23.8/46.2/39.6，1:1 混合为 68.1/53.5/67.3/56.9/27.2/54.1/49.8，3:1 在 EBench 最高 51.7（+12.1）、未见物体 29.3→40.0。跨具身：ARX 44→51，UR5 20→31，Franka 始终低于 7%。仅用 ego 数据预训练的消融（Rand）：原始 ego 共训 28.1 → 单形态渲染 31.7 → 15 形态 33.5 → 再加原始 ego 37.3。真机 ARX ACone 5 个长程任务，每任务 20 条遥操加约 35 分钟随手拍的 ego play（5 场景）经 Path B 生成 675 条合成 episode，1:1 混合微调五项全部最佳，Put Blocks +14、Insert Screw +13（分步计分、20 次）。

**成本与局限。**采集边际成本为零，全部成本变成算力（SAM 3、修补、15 次 IK 搜索、VLM 审计），但论文未报每小时视频的处理算力——评估「可扩展性」最需要的数字缺席。作者自认：重定向只到平行夹爪；修补与合成在遮挡和复杂光照下有伪影；评测局限于 RoboTwin 任务域。延伸：物理接触是假的——物体仍由原视频里的人手移动，渲染夹爪与物体没有真实接触关系；多形态收益薄，1→15 形态仅 +1.8 而加一份原始 ego +3.8，副本的边际价值低于一份真实；跨具身评测的 ARX 与 UR5 都在 15 形态训练列表内，唯一真正未见的 Franka 接近零。

5. 合成：成本-多样性-具身贴近性三角与 ICL 配方匹配度

S1 博客（sources/skild\_s1\_blog.txt Fig. 3）的三轴是硬件贴近性、多样性、可扩展性，评遥操 高/低/低、UMI 中/中/中、第一人称视频 低/高/高、仿真 中/低/高，结论「无源全胜、全部自建再混合」。三篇原文给这张定性表加刻度，并补上博客没列的合成一行（EgoScale、HOST 两行取自 insights/10 与 notes/01，仅作参考）：

| 管线     | 代表        | 单位成本（原文口径）                          | 任务覆盖                | 具身差距处理              | 力信息            |
|--------|-----------|-------------------------------------|---------------------|---------------------|----------------|
| 力反馈遥操  | RH20T     | 整工位（臂 + F/T + 8-10 相机 + 力手柄），作者自认昂贵 | 147 任务 / 每任务约 750 条 | 无差距，7 配置换机          | 100Hz 六维力 + 触觉 |
| 手持夹爪   | UMI       | \$371/套；约 117 条/人时；换场景 1 分钟建图       | 论文 5 任务单任务模型；硬件不设上限 | 采集端硬件同构消解，残余靠运动学过滤  | 软指隐式           |
| 第一人称视频 | EgoScale  | 头戴相机                                | 日常活动全集              | 4D 重建 + 对齐纪律        | 无              |
| 合成重定向  | Ego2Robot | 零采集，算力未报                            | 继承源数据集，任务数未统计       | 后处理端重建：IK + 渲染 + 降速 | 无，且接触为假        |



| 管线    | 代表   | 单位成本（原文口径） | 任务覆盖    | 具身差距处理    | 力信息 |
|-------|------|------------|---------|-----------|-----|
| 直接条件化 | HOST | 5.8k 段视频   | 50 评测任务 | 学习端进度流形对齐 | 无   |

对照 BPP/ICRT 的「任务多样性 > 每任务密度、同场景须有歧义」定律，三条管线的匹配度分明。

**RH20T 是定律的反面。**每任务 750 条是为微调设计的密度；树状层级能配出百万级人机对，但对数再多也不增加任务数——Zero-WAM 宁可从机器人轨迹合成 8.6K 任务的假人类视频，也不用现成的 110K 真配对，理由正在此。反过来它是唯一把力写进数据的管线，而趋势四的信息论判断说 one-shot 的下一瓶颈恰是演示视频不携带的接触力：最不合配方的管线，握着 ICL 最缺的信息。

**UMI 在硬件层天然满足。**换任务的边际成本约等于换物体加一分钟建图，「3 人 30 地点 12 人时」就是 BPP 用 iPhUMI 采 200 个真机任务、GEN 系在上千家庭采 50 万小时的生产方式；动作真值随视频自带，prompt 直接落在策略的传感运动空间，BPP 因此免掉跨具身翻译。但须说清：UMI 论文自身配方仍是 VLA 时代的（每任务 250–305 条、单任务模型），任务多样性是后人的用法，硬件只是不设障碍；且它把用户能给的 prompt 限定为手持专用夹爪，普适性低于拍段视频（06\_BPP 批判 3）。

**Ego2Robot 在源数据层满足、在结构层不满足。**EgoDex/EgoVerse 是日常活动全集，任务多样性三者最高，一个厨房视频天然满足 ICRT 的同场景多任务条件。但三点使它暂不能直接当 ICL 燃料：任务标签来自 VLM 的 5–12 词分段，分组粒度不可控，而 BPP 指出分组粒度决定 prompt 能控制什么；合成的是单条轨迹而非演示–执行配对，要做 ICL 预训练仍需按任务重组；15 份形态副本不增加任务数，按定律其 ICL 价值应按 1,237 小时而非 18,561 小时计。实证收益也印证这一点——增益集中在视觉与语义不变性（光照 +7.6 取 1:1、未见物体 +10.7 取 3:1），不在轨迹覆盖。

一句话回答标题：**任务数的天然供给方是手持夹爪与人类视频，密度与力的天然供给方是遥操；ICL 配方要前者，信息瓶颈要后者。**S1 的「全部自建再混合」不是外交辞令，是三角约束的唯一解。

6. 批判与空白

- 1. **单位陷阱。**趋势三表把 Ego2Robot 18,561 小时与 GEN 50 万、EgoScale 20,854 并排，三者分别是「15 形态渲染总和」「真实穿戴交互」「真实 ego 视频」，有效真实交互差一个数量级以上；RH20T 只报条数与 TB。建议趋势三表加口径注；notes/12 的「约 60 倍」与 insights/10 的「约 25 倍」应统一为 8.6K/147 约 58 倍。
- 2. **三篇都没有 ICL 实验。**UMI 单任务 Diffusion Policy，RH20T ACT 微调，Ego2Robot VLA 预训练加微调。「哪条管线更适合 ICL」是从 BPP/ICRT 定律推出的间接结论；同一 ICL 架构在 UMI 式多任务少演示、RH20T 式少任务多演示、Ego2R 式合成多任务三种数据上的受控对比无人做。
- 3. **力信息与配方错位。**唯一含力的管线最不合配方。FACTR 2（notes/18）的零硬件外力估计是把力带进手持与合成管线的最低成本路径，尚无人接。
- 4. **Ego2Robot 的多形态叙事超出证据。**1→15 形态 +1.8，Franka 不动；「一次采集多形态复用」的实际价值在形态无关的视觉鲁棒性，不在具身迁移。
- 5. **UMI 隐藏成本未量化：**运动学过滤丢弃率、SLAM 失败率、建图人力均未报；BPP 的 ARKit 免建图正补这块，但同样没给数字。

6. **RH20T 的 110K 真实人机配对无人用于 ICL**。HOST 的跨域配对只有 5.8k 段，RH20T 有其近 20 倍的真实配对（多视角、多人、多具身）；用它跑 HOST 式 Stage 2 或做 Zero-WAM 的真实视频测试，是现成可做、且能回答「合成到真实差距」的实验。
7. **管线级 scaling law 缺两条**。EgoScale 给了 ego 视频的 log-linear，GEN-0 给了手持夹爪的幂律，遥操与合成重定向都没有；「每美元、每 GPU 小时买到的任务数」三篇皆未报——这才是 ICL 时代管线的核心指标。

# 视频-动作模型同代对照组三篇合集：WAM 战场的其他玩家

覆盖三篇：**DreamZero** (World Action Models are Zero-shot Policies, NVIDIA GEAR, arXiv 2602.15922, 2026-02, 开源权重与推理代码)·**Motus** (Motus: A Unified Latent Action World Model, 清华大学 (朱军、苏航组) + 北京大学 + 地平线机器人, arXiv 2512.13030, 2025-12)·**DVA** (Causal Video Models Are Data-Efficient Robot Policy Learners, Rhoda AI 研究博客, 2026-03, 无论文无权重, 存档见 [sources/rhoda\\_dva\\_blog.txt](#)) 定位：本仓库 WAM 线 (Fast-WAM / WALL-WM / EgoWAM / LingBot-VA v1-v2 / Zero-WAM / HOST) 的表格里，这三篇长期占着「第二名」与「被引先例」的位置：Motus 是 RoboTwin 2.0 上被 LingBot-VA 两代与 Fast-WAM 共同垫底的强基线，DreamZero 是 WALL-WM 真机表里的输家、LingBot-VA 2.0 开篇并列的范式共同奠基者，DVA 是 LingBot-VA 2.0 引入视频 ICL 时与 Zero-WAM 并列的先例。它们的机制与口径此前从未被单独审视。

## 1. 为什么补这三篇

三个理由。其一，主线的头条差距靠它们撑分母：LingBot-VA v1 对 Motus 的 +4.2/+4.6、WALL-WM 对 DreamZero 的 75.86 对 39.97，若基线口径失真则结论随之失真——本文将证明失真确实存在，幅度可达四十个百分点。其二，三篇对本调研三个核心争论各有鲜明立场（测试时想象 vs 训练时塑形、像素 vs 表征、演示视频如何进上下文），且此前 WAM 线除 EgoWAM 外全是团队，补进两家美国旗舰才能检验坐标系有没有地域偏差。其三，三篇恰是同一路线的三个极端：DreamZero 把「联合建模」拧到最紧（视频与动作共享去噪时间步），DVA 把「解耦」放到最松（视频模型与逆动力学各自独立），Motus 把「一个模型」铺到最广（五种推理模式）。

## 2. DreamZero：把想象全额保留，再用 38 倍加速买回实时

**机制。**Wan2.1-l2V-14B 骨干改造成自回归 WAM：每 chunk 2 个潜帧对齐 48 步动作（视频 5FPS、动作 30Hz, 1.6 秒/chunk），最多 4 个 chunk 即 33 原始帧、6.6 秒上下文；视频与动作在同一条流里联合流匹配去噪并刻意共享时间步（与其他 WAM 相反）；teacher forcing 训练，闭环时每执行完一个 chunk 就用真实观测覆写 KV cache 里的预测帧，消掉累积误差。论文把联合分布写成「视频预测 × 逆动力学」，却坚持单模型端到端而非两模型级联，并点名 LingBot-VA 为「两个独立模型」的代表。实时化是工程重头：单卡 5.7 秒/chunk 起步，CFG 双卡并行、按速度余弦相似度跳步（16 步压到 4 步）、torch.compile+CUDA Graph、NVFP4 量化，再加 DreamZero-Flash——训练时把视频时间步偏向高噪 (Beta(7,1), 期望 0.125) 而动作保持均匀，逼模型从仍带噪的视频里解出干净动作——两张 GB200 上累计 38 倍、150ms、约 7Hz。

**数字（口径：任务进度 0-100%，默认未见环境+未见物体，每任务 8 次 rollout 跨 4 台机器人）。**AgiBot G1 约 500 小时遥操作、22 个真实场景、7.2K 段，每段平均 4.4 分钟含约 42 个子任务，采集原则「多样优先于重复」（一个任务满 50 段即下架）。已见 10 任务平均进度 62.2，同数据续训的最强预训练 VLA (GR00T N1.6/ $\pi$ 0.5) 27.4，从零 VLA 近零；未见 10 任务（解鞋带、熨衣、握手等）39.5 对 16.3；DROID-Franka 未见动词 20 任务进度 49%、成功率 22.5%，对  $\pi$ 0.5 的 33%/7.5%。跨具身：9 个未见任务各 8 条纯视频演示（YAM 20 分钟或人类第一视角 12 分钟，只上视频预测目标）与预训练数据 1:1 续训 1 万步，38.3±7.6 升到 55.4±9.5 / 54.3±10.4。消融（5 万步、bs 32、仅 PnP-Easy）：同 500 小

时多样数据 50 对重复数据 33；14B 50 对 5B 21；VLA 换 14B 底座在多样数据上仍为 0；双向与自回归同为 50，自回归更平滑、快 3-4 倍。Flash 单步 74 对四步 83，非 Flash 单步 52。

**被谁当基线、输在哪。**WALL-WM 在自建双臂平台、自定 Task Progress 口径下报 DreamZero 39.97/32.70/28.50（多样/推理/泛化套件）对自家 75.86/71.60/53.75，但 WALL-WM 自认平台与数据对齐带来「共享任务定义也消不掉的评测环境优势」，调参投入亦不对等。LingBot-VA 2.0 没拿它比数字，而是把「视频动作 token 拼接、单流联合去噪」定义为与自家「视频生成 × 逆动力学分项损失」相对的另一参数化。

**立场。**(a) 正文是想象派最硬的证据：多数失败源自视频生成错误而非动作解码，「策略忠实执行视频规划的一切」，故「提升机器人能力约化为提升视频生成」；但 Flash 是对自己的让步——单步推理时视频几乎不成像，动作从高噪表征里解出，工程形态已滑向 Fast-WAM 的「视频塔当世界编码器」，四步到单步的 9 分差距（混杂了动作去噪步数）是想象溢价的上界。(b) 坚定像素派，附录 A 专门反驳潜空间世界模型 (JEPA/Dreamer)「测试时要规划搜索」；12 分钟人类视频带来 16 分提升与 EgoWAM「像素目标迁移最弱」相悖，但两个标准误相互覆盖，且演示是任务匹配的室内采集而非野生数据。(c) 无任何 ICL：跨具身靠续训更新参数；上下文 6.6 秒，作者自认未测记忆任务。它是 WAM 装上 ICL 机制之前的素体。

### 3. Motus：一个模型五种模式，被所有人拿来垫底

**机制。**三专家 MoT：以 Qwen3-VL-2B 输出为输入的理解专家、Wan 2.2 5B 生成专家、与 Wan 同深度的 641.5M 动作专家，只共享自注意力 (Tri-modal Joint Attention)，FFN 各持，总参 8B。UniDiffuser 式调度器给视频与动作分派独立时间步，训练一次即可在推理时切换五种模式——VLA（视频留噪只去噪动作）、世界模型、逆动力学、视频生成、视频-动作联合预测。动作稠密视频稀疏：视频 8 帧@5Hz 对动作 48 步@30Hz，防视频 token 淹没动作 token；10 步推理。潜动作是跨具身桥：DPFlow 光流转 RGB，DC-AE 压成 4x512 再投到 14 维，90% 无标注重构加 10% 有标注（含 Curobo 随机采样的任务无关数据）拉齐潜动作与真实动作分布。三阶段：只训视频塔（约 8000 GPU 时）→ 全模型加潜动作（约 10000 GPU 时，VLM 冻结）→ 目标机器人 SFT（约 400 GPU 时）；六层数据金字塔含 Egodex 23 万段人类第一视角、RoboTwin 2.75 万段仿真、AgiBot 72.8 万段多机器人、自采 2000 段。

**数字（口径：RoboTwin 2.0 五十任务多任务，2500 干净+25000 随机化演示，各方法从自家预训练权重续训 4 万步，每任务 100 次）。**Motus 88.66/87.02（干净/随机化），X-VLA 72.80/72.84， $\pi 0.5$  42.98/43.84，GO-1 37.8/36.24；无预训练约 77，仅阶段一约 82。真机（每任务 100 条演示，多任务联训，部分成功率）：AC-One 九任务 63.22 对  $\pi 0.5$  14.79，Agilex-Aloha-2 五任务 59.30 对 48.60。LIBERO-Long 97.6 与 X-VLA 持平；VLABench 0.48 对 0.43。附录两组数字最有信息量：同一权重 VLA 模式 83.90 对联合模式 87.02——测试时想象值 3.1 分；IDM 模式动作 MSE 0.014，专训的 ResNet18/DINOv2 头为 0.044/0.122。

**被谁当基线、输在哪。**LingBot-VA v1 92.93/91.55 (+4.2/+4.6)，按时程分档 Motus 从 Horizon=1 的 91.0 跌到 Horizon=3 的 85.0，差距扩到 +8.2/+9.1；LingBot-VA 2.0 93.8/93.4；Fast-WAM 平均 91.8 对 87.8。三家都直接抄 Motus 论文的数字而非复跑（LingBot-VA 注明 X-VLA 数字「取自 Motus」），训练步数还不一致（4 万对 5 万）。更要紧的是同表的  $\pi 0.5$ ：Motus 复现 43，LingBot-VA 复现 82.7/76.8

——同一基线同一协议差 40 分。Motus「+45% 超  $\pi 0.5$ 」的头条是复现失真的产物，按 LingBot 的  $\pi 0.5$  算只剩 +6/+10。

**立场。**(a) 结构上中立，且给出内部测量：+3.1。(b) 混合派——世界建模留在像素 (Wan VAE)，跨具身对齐搬到运动表征 (光流潜动作)；按 EgoWAM 三准则，光流满足外观抽象、部分满足跨具身一致，但不做自我运动分解，Egodex 的头动会污染流场，而论文从未单独消融人类数据的贡献 (阶段一到阶段二同时加了潜动作与新数据层)。(c) 无 ICL，五种模式里没有一种以演示为条件；在 notes/16 坐标里它是纯 SFT——RoboTwin 上的 Wall-OSS。

## 4. DVA：解耦到底，把一段人类演示直接塞进因果视频模型的上下文

**机制。**两件独立的东西：一个从零预训练的因果视频模型 (明确不从双向模型蒸馏)，配 Context Amortization——像语言模型一样在无噪长上下文的每个位置都预测未来，从而以数百帧上下文高效训练，推理用 KV cache、永远以真实观测为上下文；一个小型、具身专属的非因果逆动力学模型，每种具身约 10 小时数据即可、随机运动亦可、跨同型机器人跨任务复用。博客自称「首个从零预训练的因果视频模型、首个在实时闭环里做完整视频去噪」。Leapfrog Inference：每次预测足够远以覆盖下一次推理延迟，并以当前正在执行的动作为条件保证轨迹连续——LingBot-VA 2.0 专门用一小节把它与自家 Foresight Reasoning 对照 (后者每 chunk 用前向动力学起草潜帧、再被真实观测覆写)。

**数字 (全部为博客叙述，无成功率无基线无基准)。**10–20 小时机器人数据后训练即可做长时程工业任务：拆箱分拣 11 小时数据、1.5 小时无干预连续运行；拆解 50 磅集装箱 17 小时数据、160 分钟连续运行；退货处理需长上下文，只记 8 帧会重复已完成步骤；壳游戏演示记忆。一次性演示跟随：训练只用「一张桌子十来个物体、演示在别处采集」，测试外推到新物体、新容器、办公室环境；画图任务复现笔顺。

**立场。**(a) 最纯粹的想象派：决策全在生成视频里、动作只是翻译，比 LingBot-VA「想一步即覆写」更极端，与 Fast-WAM 正面对立却零消融。其论据不是性能而是数据经济学：决策从网络视频学、逆动力学只要 10 小时——这是 UniPi 模板 (notes/23) 加因果长上下文的复活，也是 DreamZero 明文拒绝的两模型级联。两家美国旗舰在「耦合还是解耦」上反向下注，LingBot-VA 2.0 各取一半。(b) 纯像素，并把「可用自回归 rollout 检视决策」列为核心优点——恰是 notes/23 归给像素派的可检查性。(c) ICL 实现方式：「把视频样例注入上下文」，人类演示只是因果视频模型的前缀，没有对齐模块、没有反捷径目标。与 Zero-WAM 对照：后者把人类视频只喂视频分支、动作分支看不见；DVA 因逆动力学是独立模型，演示在结构上根本进不了动作侧——Zero-WAM 用注意力掩码做到的隔离，DVA 由架构免费得到；但 Zero-WAM 证明无 IFP 时人类视频是净负收益，DVA 无相应证据。与 HOST 对照：HOST 消融里整段视频直接条件化只有 0.21、进度流形耦合才到 0.62，DVA 正是前者形态，赌的是原生长上下文能自行完成进度对齐。它的 ICL 同样依赖配对训练数据，与「ICL 是造出来的」学术侧一致，只是被叙述为长上下文的副产品。

## 5. 合成：放进本仓库的两套坐标

**像素/表征/平台三路线** (notes/23)。三篇的世界模型全在像素阵营：DreamZero 像素加紧耦合，Motus 像素世界加光流动作，DVA 像素加全解耦。表征派在这批工业与准工业旗舰里没有代表——但每家都藏着



让步：Flash 让动作从高噪视频里解出，Motus 的 VLA 模式只丢 3.1 分，唯有 DVA 不让步也不消融。像素 vs 表征之争在规模端因此仍无裁决：没有一家像素旗舰跑过表征目标的对照。

**想象溢价账本**（同权重内部对照）：Fast-WAM -1.2（联合 90.6 对免想象 91.8）、Motus +3.1、DreamZero  $\leq +9$ （混杂）。**训练时塑形账本**：Fast-WAM 去视频协同训练 -8，Motus 去预训练 -11，DreamZero 最极端——同为 14B、同样多样数据，VLA 为 0 而 WAM 为 50，没有视频目标这批数据根本学不动。三个独立团队确认：训练时效应大（8 到 50 分）、测试时效应小且正负不定。Fast-WAM 的结论被加固，DVA 的反向赌注尚未被检验。地域上值得记一笔：「免想象」的证据全部来自中国团队与 EgoWAM，两家美国旗舰都押完整想象——但这是路线分歧而非证据分歧，因为想象派没有做过同权重消融，Flash 的 9 分只是间接读数。

**快权重/纯上下文坐标**（notes/16）。DreamZero 与 Motus 在网格之外——纯预训练泛化加 SFT，是 WAM 线装上 ICL 之前的对照素体；DVA 落在纯上下文格，与 Zero-WAM/S1/GEN-1.5 同格，证据形态与后两者同为博客。它没有 GEN-1.5 的「涌现」修辞，而把 ICL 归于长上下文加配对数据，更接近学术侧。**数据结构定律**再添一证：DreamZero 同小时数多样对重复 50 对 33，与 ICRT「多任务同场景胜单任务海量」、Zero-WAM 任务均衡采样贡献 22 分同向（notes/22 §2 的贝叶斯解释）。**基线质量教训**：主线中涉及这三篇的每个头条差距都是「论文报数对论文报数」或「自家复现的基线」； $\pi 0.5$  在两篇论文间 40 分的离散说明复现噪声可比宣称增益大一个量级，LingBot-VA 对 Motus 的 4-6 分应视为噪声区间内，直到有人公开共享协议。

## 6. 局限与批判

1. **DreamZero**：未见任务每任务 8 次 rollout，标准误 7-10 分，跨具身增益落在重叠区间内；「2 倍」是进度而非成功率；7Hz 需两张 GB200；上下文 6.6 秒、单具身预训练、无 ICL；失败归因「视频错误」只有两例图示。三篇里它最可复现——权重、推理代码与 RoboArena/PolaRiS/Genie Sim 评测脚本已开源，500 小时数据待放。
2. **Motus**： $\pi 0.5$  复现 43 对同行 83 使「+45%」失效；真机  $\pi 0.5$  在 AC-One 冲咖啡、按键盘为 0 而无预训练模型按键盘 100%，基线调优可疑；五种模式只有联合模式被当策略评测；潜动作贡献从未被单独隔离；两张表的无预训练数字不一致（72.8 与 77.56）；约 1.84 万 GPU 时换来 VLABench 上 0.43 到 0.48 的微增。
3. **DVA**：无论文、无数字、无成功率、无基线、无基准、无硬件与延迟披露，网络视频规模不明，「首个」声明不可核；一次性演示跟随只有 demo，配对数据规模未知。LingBot-VA 2.0 把它与 Zero-WAM 并列为 ICL 先例，等于给一份博客学术地位；本仓库应与 S1/GEN-1.5 同等对待——记作主张而非结果。
4. **横向**：三篇互不比较——DreamZero 引 LingBot-VA 不引 Motus，DVA 引 DreamZero 与 LingBot-VA 不引 Motus，Motus 早于两者。DreamZero 称 LingBot-VA 为「两个独立模型」，LingBot-VA 2.0 反称 DreamZero 为「单流联合」——同一对方法互指对方为另一极，说明「耦合程度」这条轴至今没有公认定义与受控实验。



# 潜动作桥梁三篇合集：无动作视频怎么变成可训练的动作信号

覆盖三篇：**Genie** (Generative Interactive Environments, DeepMind, ICML 2024, arXiv 2402.15391) · **LAPA** (Latent Action Pretraining from Videos, KAIST/UW/NVIDIA 等, ICLR 2025, 2410.11758) · **UniVLA** (Learning to Act Anywhere with Task-centric Latent Actions, 2025, 2505.06111) 定位：人类视频进入机器人策略有三条桥——显式重定向 (EgoScale/GR-3/Ego2Robot)、世界预测通道 (EgoWAM/WAM 线)、潜动作 (本篇)。本仓库已有的潜动作线索：ViVLA (notes/09, HOST 前作的潜动作 tokenizer)、Motus (notes/28, 光流潜动作)、LingBot-VA 2.0 (notes/19, 语义视觉-动作 tokenizer)。

## 1. 为什么补这三篇

HOST 用一段人类视频当上下文，靠的是显式进度对齐；EgoWAM 让人类数据只走世界预测通道，绕开动作头。两条路都在回避同一个问题：人类视频里没有机器人动作标签，怎么把它变成监督信号？潜动作路线正面回答——从相邻帧的变化里无监督地学出一个离散「动作码」，让无动作视频获得伪动作标签，再教一个小解码器把伪动作映射到真机器人动作。三篇构成完整的演化：Genie 证明这个码可以从纯视频学出且可控（在游戏世界里），LAPA 把它变成 VLA 的预训练目标并用真机验证，UniVLA 修正 LAPA 的核心缺陷——潜动作会把相机抖动、光照变化这些与任务无关的动态一并编码。

## 2. Genie：从 20 万小时游戏视频学出 8 个动作码

**主张**：第一个无监督地从无标注互联网视频训练出的生成式交互环境——11B 参数，训练数据是从 20 万小时公开游戏视频中过滤出的 3 万小时 2D 平台游戏录像，无任何动作或文本标注，却可以逐帧被「潜动作」控制。**机制三件套**：时空视频 tokenizer (ST-ViViT) 把帧压成离散 token；潜动作模型 (LAM) 以 VQ-VAE 目标从「过去帧 + 未来帧」推断出一个离散码，再要求解码器仅凭「过去帧 + 该码」重建未来帧——于是这个码被迫编码「过去到未来最有意义的变化」，即动作；自回归动力学模型以历史 token 和潜动作预测下一帧 token。**关键设计**：码本被刻意压到  $|A| = 8$ ，为的是「人类可玩」与强可控性——码本越小，每个码越接近一个语义明确的动作原语（左、右、跳）。**对机器人的伸手**：论文附录 E 展示用 Genie 的 LAM 给无动作视频打标签后做行为克隆，且单独训练了一个机器人数据版本 (RT-1 无动作视频)，证明潜动作模型在真实机器人视频上同样能学出与真实动作一致的离散码。**局限**：游戏域、2D、每秒一帧的粗时间粒度、 $|A|=8$  在操作任务上明显不够；论文自己指出潜动作对相机运动敏感（相机平移会被编码成「动作」）——这条缺陷成了 UniVLA 的立论起点。

## 3. LAPA：潜动作当 VLA 预训练目标，30 倍算力效率反超真动作预训练

**主张**：无需真机动作标签的 VLA 预训练——先用 Genie 式 VQ-VAE 从视频学离散潜动作，再让 VLM 学会「给观测与指令，预测下一个潜动作」，最后用少量带真动作的机器人数据微调一个潜动作到真动作的映射。**核心数字**（论文自报口径）：Language Table 基准三种预训练-微调组合下全面超过从头训练与 UniPi/VPT 等视频预训练基线；真机桌面操作任务上，仅用 Open-X 无动作视频预训练的 LAPA 比用真动作标签训练的 OpenVLA 高 6.22%（语言条件、未见物体、未见指令三类任务平均），预训练算力效率高 30 倍以上；仅用 Something-Something V2 的 22 万条人类日常操作视频预训练，也对机器人任务有正

迁移。**附带能力**：LAPA 的 VLM 当动作预测器、LAM 的解码器当世界模型，两者拼起来就是一个闭环神经网络模拟器——这与 WAM 线 (notes/23) 的「世界模型当平台」用法殊途同归。**局限**：潜动作是离散的且粒度粗，精细操作（插装、可变形物体）未验证；「+6.22%」是对 OpenVLA 单一基线的比较，且 OpenVLA 并非为该真机平台微调过；论文自认潜动作把相机运动与物体运动混编，跨视角泛化弱。

#### 4. UniVLA：任务中心潜动作，1/20 算力超 OpenVLA

**主张**：LAPA 式潜动作的问题在于「任务无关动态」——相机抖动、背景人物走动、光照变化都会被压进潜动作码，让下游策略学到假因果。UniVLA 两刀修正：把潜动作模型建在 DINO 特征空间而非像素空间（外观抽象），并引入语言指令条件把潜动作分解为「任务相关」与「任务无关」两部分，只让前者进策略。**核心数字**（论文自报口径）：LIBERO 上比 OpenVLA 高 18.5 个百分点成功率，Room2Room 导航高 29.6，真机部署高 36.7；真机平均成功率 68.9%（平均得分 2.49），对照 LAPA 28.9% (1.36) 与 OpenVLA 20.0% (0.98)；预训练算力仅为 OpenVLA 的 1/20（GPU 小时口径），下游数据 1/10。数据 scaling 消融显示随预训练数据增加（含跨具身、跨视角机器人数据与无标注人类视频）性能持续上升。**局限**：DINO 空间的潜动作牺牲了像素级几何精度（与 EgoWAM 发现 DINO 强于 OOD 泛化、3D flow 强于域内精度一致）；「任务相关/无关」的分解依赖语言指令质量；LIBERO 是饱和仿真基准（StellaVLA 在其上 98.8%），18.5 点的增益要按基准难度打折。

#### 5. 合成：潜动作与 ICL 的关系

**三条桥的成本-保真度对照**：显式重定向（EgoScale/GR-3/Ego2Robot）保真度最高但需要手部姿态估计或 VR 采集，且遇到 EgoWAM 指出的「不可执行动作漏进动作头」；世界预测通道（EgoWAM）零动作标注、对具身差距免疫，但只能塑造表征、不能直接给动作监督；潜动作介于两者之间——零标注、能给出直接的动作监督信号，代价是动作语义由数据分布决定、不可解释且可能混入任务无关动态。三篇的演进（Genie 像素 VQ → LAPA 直接沿用 → UniVLA 搬进 DINO 空间 + 语言分解）与 EgoWAM 的三准则（外观抽象、跨具身一致、自我运动分解）几乎逐条对应：UniVLA 的 DINO 空间对应外观抽象，跨具身共享码本对应跨具身一致，而「自我运动分解」正是潜动作路线至今没有干净解法的那一条——Genie 自认的相机运动敏感问题，UniVLA 只用语言条件部分缓解。

**\*\*潜动作是否让「人类视频当上下文」不再需要显式对齐？\*\***部分是。HOST 的进度流形解决的是「演示的哪一段对应执行的哪一刻」这个时间对齐问题；潜动作解决的是「演示里的运动是什么」这个语义翻译问题——两者正交。ViVLA（HOST 前作）恰是潜动作路线：把专家视频编码成潜动作序列当条件，LIBERO unseen +30%，但在 HOST 的 50 任务真机口径下被显式对齐路线大幅超越 (notes/01)。这个同团队的路线切换是有信息量的：潜动作给了模型「读懂演示运动」的词汇，但没有给「跟着演示走到哪一步」的时钟。理想的组合是潜动作当演示编码（替代 HOST 的 Qwen3-VL 帧嵌入）加进度流形当对齐，目前无人做。

**对 ICL 数据配方的含义**：潜动作把「任务多样性」的来源从机器人数据扩到全部互联网视频（Genie 20 万小时、LAPA 的 Something-Something 22 万条）——BPP/ICRT 的「任务数 > 每任务密度」定律在潜动作路线下有了近乎无限的任务供给；但 Zero-WAM 的 IFP 教训同样适用：潜动作预训练若不强迫模型读演示，模型仍会走「从观测直接预测下一码」的捷径。

## 6. 局限与批判

三篇的评测基线都以 OpenVLA 为锚，而 OpenVLA 的单帧、无动作块结构使其成为 2024 年后所有 VLA 都能轻易超越的软基线（notes/24）——「超 OpenVLA N 点」的信息量随时间递减。潜动作的离散码本大小（Genie 8、LAPA/UniVLA 更大但仍有限）与操作任务的连续精细控制之间存在根本张力，三篇都没在插装、拧盖这类毫米级任务上验证。最重要的空白：没有任何一篇把潜动作作用作 ICL 的演示编码去做 one-shot 评测——潜动作路线至今是预训练路线，它与上下文路线的结合是明确的研究机会。

# 上下文强化学习前史三篇合集：把控制写成序列建模，再把演示写成 prompt

覆盖三篇：**Decision Transformer** (RL via Sequence Modeling, Berkeley/Google/Facebook, NeurIPS 2021, arXiv 2106.01345) · **Prompt-DT** (Prompting Decision Transformer for Few-Shot Policy Generalization, ICML 2022, 2206.13499) · **Algorithm Distillation** (In-context RL with AD, DeepMind, ICLR 2023, 2210.14215) 定位：具身 ICL 的算法前史。ICRT/BPP 的「演示当 prompt」、LocoFormer/RoboTTT 的「跨 episode 上下文改进」，都能在这三篇里找到形式化原型。相关解读：[notes/04\\_ICRT](#)、[06\\_BPP](#)、[17\\_LocoFormer](#)、[05\\_RoboTTT](#)、[22\\_ICL\\_theory](#)。

## 1. 为什么补这三篇

本仓库讨论具身 ICL 时默认了一个前提：策略是一个自回归序列模型，演示可以作为序列前缀。这个前提在 2021 年之前并不成立——RL 策略是值函数或策略网络，不是序列模型。三篇论文分三步把它变成常识：Decision Transformer 证明控制问题可以整个改写成条件序列建模；Prompt-DT 证明「同任务的几段轨迹」放进前缀就能 few-shot 泛化到新任务，参数不动；Algorithm Distillation 更进一步，证明 Transformer 能在上下文里蒸馏出一个完整的 RL 算法——策略随着上下文中自己的历史变长而改进。2026 年的机器人 ICL 论文几乎不引用它们，但它们的机制、失败模式与数据要求全都在四年后重演了一遍。

## 2. Decision Transformer：控制问题的序列化改写

**主张：**抛弃值函数与策略梯度，把离线 RL 变成有条件的序列建模——轨迹被排成 (return-to-go, state, action) 三元组序列，用 GPT 式因果 Transformer 自回归预测动作；测试时给定期望回报作为条件，模型「生成」能达到该回报的动作。**机制细节：**上下文窗口取最近 K 步共 3K 个 token，每种模态一个线性嵌入层，加 episode 级时间步位置编码；视觉输入换卷积编码器。**代表数字**（论文自报口径）：在 Atari、OpenAI Gym (D4RL) 与 Key-to-Door 上匹敌或超过当时最强的无模型离线 RL 基线 (CQL 等)；Key-to-Door 这类长程稀疏奖励任务上优势最明显——因为序列建模天然做信用分配，不需要 bootstrapping。**对具身 ICL 的遗产：**三点。第一，「策略 = 序列模型」让此后一切「往前缀里放东西」的操作成为可能；第二，return-to-go 条件是第一个「用输入指定要什么」的接口，语言指令、目标图像、演示视频都是它的后继；第三，K 步上下文窗口的设定直接埋下了 RoboTTT 后来要攻的问题——上下文多长才够。

## 3. Prompt-DT：轨迹片段当 prompt，few-shot 泛化不微调

**主张：**给 DT 加一段「轨迹 prompt」——目标任务的少量演示片段（几个时间步的 return/state/action 三元组）拼在序列前缀——就能让同一套权重零微调泛化到未见任务。**设定：**五个 MuJoCo/Meta-World 基准 (Cheetah-dir、Cheetah-vel、Ant-dir、Dial、Meta-World reach-v2)，训练任务与测试任务不重叠；prompt 长度 K\* 极短——Cheetah/Ant 系 5 步、Dial 15 步、reach-v2 仅 2 步。**代表数字：**Prompt-DT 大幅超过 MT-BC-Finetune（同量数据微调）与 MACAW（元离线 RL 强基线），且对 prompt 长度变化鲁棒、能泛化到分布外环境参数。**对具身 ICL 的遗产：**它是 ICRT (notes/04) 的直系祖

先——ICRT 的「同任务多条轨迹拼进上下文、next-token 预测」在形式上与 Prompt-DT 完全一致，区别只在 ICRT 用的是真机视觉观测与真实机器人。Prompt-DT 论文里还有一条被后人反复重新发现的结论：prompt 里必须含任务判别性信息（不同任务的 prompt 要可区分），否则模型忽略 prompt——这正是 Xie et al. 贝叶斯视角（notes/22）的「可辨识性」条件，也是 ICRT「单任务场景数据训不出 ICL」与 Zero-WAM 需要 IFP 反捷径的同一根源。

## 4. Algorithm Distillation：在上下文里蒸馏出整个 RL 算法

**主张：**把「学习强化学习」当成跨 episode 的序列预测问题——用一个源 RL 算法在许多任务上跑出**学习历史**（从随机策略到收敛的全过程轨迹），然后训练因果 Transformer 以「此前的学习历史」为上下文预测动作。结果是：部署时策略随上下文里自己的经验积累而改进，全程不更新参数——这就是 in-context RL。**关键区分：**与 DT/Prompt-DT 蒸馏「专家或收敛后」序列不同，AD 蒸馏的是学习过程本身，所以它能在上下文内从零开始学新任务。**代表数字**（论文自报口径）：在稀疏奖励、组合任务结构、像素观测的多种环境（Dark Room 9x9 网格找隐藏目标、Dark Key-to-Door、DMLab Watermaze）上实现上下文内 RL；AD 学出的算法比生成源数据的 RL 算法**更数据高效**；用演示 prompt 可以加速 AD；上下文必须跨越多个 episode（覆盖源算法的多轮改进）才能涌现上下文 RL——单 episode 上下文不够。**对具身 ICL 的遗产：**LocoFormer（notes/17）的跨 trial 适应（早期摔倒改进后期策略）与 RoboTTT（notes/05）的 on-the-fly self-improvement、Dagger 蒸馏（失败当上下文、纠正当目标），在机制上都是 AD 的具身版：把「自己过去的失败」放进上下文，让策略在推理期改进。

## 5. 合成：四年的间隔、同一现象、最早的反证

\*\*「演示当 prompt」为什么从 2022 到 2026 隔了四年？\*\*Prompt-DT 已经把形式做对了，缺的是三样：感知模态（它用低维状态向量，真机需要视觉——而视觉演示与执行之间的具身差距是低维状态没有的问题）、任务多样性（五个 MuJoCo 任务族的参数化变体，不是数千个语义不同的操作任务——BPP 后来量化了这个阈值）、主干规模与先验（DT 是从头训练的小 Transformer，没有 VLM/视频模型级别的世界知识去消解视觉歧义）。三样缺一不可，2026 年恰好同时补齐。

AD 的上下文 RL 与 S1 的「失败后重试、演示纠错」是同一现象吗？形式上是——都是「上下文里的经验改变后续动作」；但证据等级差一个量级。AD 证明了改进随上下文长度单调、可以从零学起、跨任务成立；S1 只展示了几段定性视频。更重要的是 AD 给出了成立条件：训练数据必须包含学习过程（失败→改进的完整历史），而非只有成功演示。RoboTTT 的 Dagger 蒸馏（失败当上下文 +33%）是这条原理在真机上的第一次量化验证；S1 若真有稳定的推理期自我改进，其预训练数据里必须有类似结构——博客没有披露。

**对涌现之争的位置：**AD 是「ICL 需要显式数据结构」最早的干净证据之一——同样的架构、同样的算力，喂专家序列得到 DT 式模仿，喂学习历史才得到上下文 RL；上下文短于源算法的改进周期，能力就不出现。这与四篇 EICL 论文的消融（notes/16）、Xie 的可辨识性条件（notes/22）、BPP 的任务多样性定律（notes/06）构成跨越四年、三个领域的同一结论：上下文学习的能力形态由预训练序列的结构决定，规模只是让这个结构被学到的充分条件。

## 6. 局限

三篇全部在低维状态或简单像素的仿真环境上工作，最大模型不过亿级参数；DT 的 return 条件在真机上无法给定（没有奖励函数），这解释了机器人 ICL 全线改用演示/语言/目标图像作条件的原因；Prompt-DT 的任务变体是参数化的（方向、速度），任务判别性由参数差异保证，远比真实操作任务的语义判别容易；AD 的环境奖励稀疏但结构简单（找隐藏目标），其「更数据高效」的结论在连续控制上未验证。把三篇当作机制原型而非性能参考，是使用它们的正确方式。



# 人类视频共训三篇合集：把人类数据写进权重的显式路线

覆盖三篇：**HumanPlus** (Humanoid Shadowing and Imitation from Humans, Stanford, CoRL 2024, arXiv 2406.10454) · **EgoMimic** (Scaling Imitation Learning via Egocentric Video, Georgia Tech, 2024, 2410.24221) · **PH2D / HAT** (Humanoid Policy ~ Human Policy, UCSD, 2025, 2503.13441) 定位：本仓库人类数据路线的第四块拼图。已有：EgoWAM (notes/11, 世界预测通道绕开动作头)、EgoScale (notes/09, 2 万小时 scaling law)、WAM-TTT (notes/14, 配对人类数据 1:1 顶替机器人数据)、Ego2Robot (notes/27, 合成重定向)、潜动作桥 (notes/29)。这三篇是「动作级共训」的代表——人类动作经重定向后直接当机器人动作监督，与机器人数据混训同一策略。

## 1. 为什么补这三篇

EgoWAM 的立论是一条 bitter lesson：动作级共训把不可执行的人类动作漏进动作头，除非人类数据与机器人在视角、速度、行为风格上精心对齐，否则伤害性能。这个判断针对的正是本篇三项工作所代表的路线。要判断 EgoWAM 说得对不对，得看动作级共训的最佳实践到底做了什么对齐、拿到了什么数字、在哪些条件下失效。三篇恰好覆盖三种对齐策略：HumanPlus 用全身姿态重定向 + 人形本体（形态最接近人），EgoMimic 用第一人称眼镜 + 动作分布归一化 + 视觉遮罩（感知最接近人），PH2D 用统一的 3D 头手位姿动作空间 + 具身标签（表示最接近人）。

## 2. HumanPlus：让人形机器人实时「影子」人类，再从影子数据里模仿

**主张**：两级系统。低层是任务无关的 Humanoid Shadowing Transformer (HST) ——用 40 小时人体运动数据集在仿真里以 RL 训练、零样本迁到真机，输入是重定向后的人形目标姿态，让 33 自由度、180cm 的人形（头部双第一人称 RGB 相机 + 两只 6-DoF 灵巧手）仅凭一台 RGB 相机实时跟随人类全身与手部动作，即「影子」(shadowing)。高层是 Humanoid Imitation Transformer (HIT) ——用影子过程采集的第一人称数据做模仿学习，学出自主技能。**代表数字**（论文自报口径）：穿鞋站立行走、整理衣架、叠衣、重排物体、打字、与另一台机器人握手等任务，最多 40 条演示达到 60–100% 成功率。**对齐方式**：人类姿态 → 人形姿态的重定向在低层 RL 策略里完成，高层模仿数据本身已经是机器人的第一人称观测与机器人动作——人类只是遥操作者。**在本调研中的定位**：严格说 HumanPlus 不是「人类视频当训练数据」，而是「人类当遥操作器」——它用人形本体把具身差距转成了姿态重定向问题，人类数据从未直接进入模仿策略的动作头。这恰好绕开了 EgoWAM 的 bitter lesson，代价是每条数据仍需人形机器人在场，扩展性与遥操作无异。

## 3. EgoMimic：Aria 眼镜第一人称数据与机器人数据平等共训

**主张**：把人类第一人称视频（配 3D 手部轨迹）当作与机器人演示同等地位的「具身演示数据」，用统一策略共训。四件套：（一）Project Aria 眼镜采集人类数据，同款眼镜装在机器人头上当主传感器——感知同构；（二）跨域对齐——归一化并对齐人类与机器人的动作分布，用视觉遮罩抹掉人手与机械臂的外观差异；（三）统一模仿架构——共享视觉编码器与策略网络，人类手部动作与机器人末端动作各自解码；（四）侧向场景相机在手离开主相机视野时仍能追踪手部（人类习惯头先于手移动）。**代表数字**（论文自报口径）：

在多个长时程单臂与双臂任务上显著超过 ACT/MimicPlay 等模仿学习基线，并能泛化到全新场景；scaling 趋势——追加 1 小时人类手部数据的价值显著高于追加 1 小时机器人数据。与 EgoWAM 的关系（同组两年演进）：EgoWAM 的作者组（Danfei Xu, Georgia Tech）正是 EgoMimic 的作者组。EgoMimic 2024 年把人类数据对齐到机器人（同款眼镜、遮罩、归一化）后做动作级共训并报出正 scaling；EgoWAM 2026 年则说，一旦人类数据是「野生」的（视角、速度、风格未对齐），动作级共训会把性能拖到 robot-only 以下，必须改走世界预测通道。两篇合读才是完整结论：动作级共训在对齐充分时有效且 scaling 好，但对齐本身就是隐藏成本——EgoMimic 的对齐依赖同款硬件与手工遮罩，野生数据不具备。

## 4. PH2D / HAT：人与人形当作同一策略的两个具身域

**主张：**数据侧构建 PH2D——任务导向的第一人称人类演示数据集，直接对齐人形操作任务的分布；采集设备是消费级头显（Apple Vision Pro 内置相机 + ARKit 头手位姿，Meta Quest 3 / Vision Pro + ZED 相机），比 Aria 眼镜更易得。模型侧是 Human Action Transformer（HAT）——状态与动作空间对人类和人形统一（3D 头部与手部位姿），可微分地重定向到机器人动作；人类与人形被当作不同具身域，各自归一化，无额外监督地共训。**代表数字**（论文自报口径）：自主技能执行的分布外测试（背景、纹理、物体摆放三类泛化）上，加入人类数据共训在 Humanoid A 全部任务上带来接近 100% 的相对提升（如某任务 29/70 → 49/60 量级的跃升，表 2）；另有跨异构具身的 few-shot 迁移实验与具身归一化的消融。**对齐方式：**靠动作空间统一（头手位姿是人与人形共有的自然坐标）+ 逐具身归一化，不做视觉遮罩。**局限：**PH2D 的人类数据是「任务导向」采集的——采集者被要求按人形任务的方式做——这与 EgoMimic 一样，把对齐成本前置到了采集阶段，不是野生视频。

## 5. 合成：三种共训的适用条件，与 ICL 的成本对照

**动作级共训 vs 世界预测通道 vs 合成重定向：**三篇的共同点是全部在采集端做了对齐——同款眼镜、任务导向采集、人形本体——所以它们的正结果与 EgoWAM 的负结果并不矛盾：EgoWAM 测的是野生数据。适用条件因此清晰：能控制采集流程（企业自建数据引擎，如 GEN 系与 S1 的 UMI/穿戴采集）时动作级共训是最直接的路线，且 EgoMimic 与 WAM-TTT 从两个方向验证了人类数据的边际价值高于机器人数据；只能拿到野生视频（互联网、用户随手拍）时，必须走世界预测通道（EgoWAM）或潜动作（notes/29）；需要多形态复用走合成重定向（Ego2Robot）。

**\*\*共训与 ICL 在具身差距上谁更省？\*\***共训把人类数据写进权重，每新增一种具身或视角就要重新对齐、重新训练；ICL 把人类演示放进上下文，具身差距在推理期由模型（HOST 的进度流形、Zero-WAM 的 IFP 训出的对应能力）现场消解。前者对齐成本在数据侧、一次性但随具身数线性增长；后者对齐成本在模型侧、一次性训出后对任意演示复用。这解释了产业分岔：GEN/S1 拥有采集控制权，两条都做（共训做底座，ICL 做接口）；HOST/Zero-WAM 没有大规模采集能力，全押 ICL。

**EgoMimic → EgoWAM 的两年演进说明了什么：**同一个组从「对齐后动作级共训有效」走到「野生数据必须换通道」，不是推翻而是划界——动作级共训的有效域边界就是对齐的可控域边界。这条边界对 ICL 同样成立：HOST 的 5.8k 人类视频是实验室采的第三人称视频，其在用户随手拍视频上的表现（视角、光照、遮挡全部野生）论文没有测——这是 one-shot 演示接口落地前必须回答的问题。

## 6. 局限与批判

三篇的评测都是自建任务、自建平台、每任务数十次试验，无公共基准；HumanPlus 的 60—100% 区间跨度极大且未报每任务试验数细节；EgoMimic 的「1 小时人类数据 > 1 小时机器人数据」是趋势陈述，论文以曲线呈现而非给出等价比例；PH2D 的「接近 100% 相对提升」发生在分布外设定，分布内增益小得多，且 Humanoid B 上的结果与 A 不一致（附录 D）。三篇都没有测「共训是否伤害了原有机器人技能」——EgoWAM 报告的「人类数据把 BC 共训拖到 robot-only 以下」在对齐数据上是否也以更弱形式存在，无人检验。

# 评测基准与数据地基四篇合集：数字的口径从哪来

覆盖四篇：**LIBERO** (Benchmarking Knowledge Transfer for Lifelong Robot Learning, UT Austin, NeurIPS 2023, arXiv 2306.03310) · **RoboTwin 2.0** (Scalable Data Generator and Benchmark with Strong Domain Randomization, Lumina EAI 等, 2025, 2506.18088) · **Open X-Embodiment** (Robotic Learning Datasets and RT-X Models, 21 机构, 2023, 2310.08864) · **Data Scaling Laws in Imitation Learning for Robotic Manipulation** (Lin et al., 清华/上海期智, 2024, 2410.18647) 定位：本调研反复说「不同工作的成功率禁止直接比」，这四篇是被仓库内论文反复使用的评测协议与数据地基——口径问题的源头。

## 1. 为什么补这四篇

仓库里的数字大多挂在三个坐标系上：LIBERO (StellaVLA 98.8、ViVLA unseen +30、UniVLA +18.5、LingBot-VA)、RoboTwin 2.0 (LingBot-VA 两代、Zero-WAM 任务级切分 43/7、Motus、Fast-WAM)、以及 OXE 供给的预训练数据 (OpenVLA 的 97 万条、 $\pi 0$ /Octo 的公共部分)。notes/28 发现同一  $\pi 0.5$  基线在 RoboTwin 2.0 上被 Motus 复现出 43、被 LingBot-VA 复现出 83——40 分的离散比多数论文的头条增益还大。要判断这类离散是谁的问题，得回到基准本身看协议钉死了什么、放开了什么。Lin et al. 的数据 scaling law 则是 GEN-0「机器人 scaling law」叙事之外的学术侧独立证据，且给出了与 BPP「任务多样性定律」同构的结论。

## 2. LIBERO：为终身学习设计，却被当成通用打分板

**设计**：面向终身学习决策 (LLDM) 的程序化任务生成流水线，理论上可生成无限任务；正式基准取四个套件共 130 个任务 (Spatial / Object / Goal / 100)，每任务配高质量人类遥操作演示；研究问题是知识迁移——前向迁移、遗忘、视觉编码器与预训练策略的影响。**论文自己的发现** (口径：终身学习协议)：顺序微调在前向迁移上反而优于专门的终身学习方法；没有单一视觉编码器在所有迁移类型上占优；朴素监督预训练可能损害后续终身学习表现。**被本仓库怎么用**：几乎没有人用它测终身学习。StellaVLA 在其上 98.8% (notes/15)、UniVLA 在其上比 OpenVLA +18.5 (notes/29)，都是把四个套件当多任务成功率打分板——而四套件设计时的难度并不面向 2025 年的 VLA，已接近饱和；StellaVLA 自己的三向干预实验揭示其 Goal 套件的分数大半在测「知不知道任务标签」。LIBERO-Plus (StellaVLA 用的七轴扰动版) 是社区对饱和的补救。**口径提醒**：LIBERO 数字的信息量取决于是否报告了扰动版与每套件 500 次 rollout 这类细节；只报四套件均值的 LIBERO 结果，在 2026 年已不足以区分方法。

## 3. RoboTwin 2.0：50 双臂任务、五种具身、结构化域随机化

**设计**：RoboTwin-OD 物体库 (731 实例、147 类，带语义与操作标注) + MLLM 生成任务执行代码并在仿真中迭代修正 + 五轴结构化域随机化 (杂乱、光照、背景、桌面高度、语言指令)；50 个双臂任务横跨五种机器人具身。**基准协议** (论文口径)：默认 Aloha-AgileX 双臂具身，每任务 50 条干净专家演示训练，测试 100 次 rollout，分 Easy (干净) 与 Hard (域随机化) 两档；论文报告代码生成成功率 +10.9%，大规模合成数据 + 仅 10 条真机演示可让 VLA 相对提升 367% (口径为其自建 sim-to-real 设定)。**被本仓库怎么用**：LingBot-VA 沿用「2500 条干净 + 25000 条随机化」多任务设定报 92.93/91.55

(notes/19); Zero-WAM 在其上做任务级切分 (43 训 7 测) 报 46.95% (notes/12); Motus 与 Fast-WAM 也以它为主战场。「43 vs 83」的解释: 基准钉死了任务、演示数与 rollout 数, 但没钉死至少四个自由度——(a) 训练数据配比 (是否加入 25000 条随机化演示、是否多任务联合训练); (b) 基线的微调配方 ( $\pi 0.5$  的学习率、步数、是否冻结 VLM、动作 chunk 长度都由复现者定); (c) 评测档位 (Easy/Hard 均值还是分开报); (d) 具身与相机配置 (五种具身可选)。Motus 与 LingBot-VA 对  $\pi 0.5$  的复现差 40 分, 最可能落在 (a) 与 (b): Motus 论文的  $\pi 0.5$  大概率在更少数据或更弱配方下微调。结论: RoboTwin 2.0 是当前最好的双臂仿真基准, 但**基线复现值不可跨论文引用**, 只有同一论文内的对照有效。

#### 4. Open X-Embodiment: 22 种机器人、100 万条轨迹的公共地基

**设计:** 21 家机构汇集 22 种机器人具身、超 100 万条轨迹、527 种技能 (160,266 个任务) 的统一格式数据集, 附 RT-X 系列预训练权重。**代表结果** (论文口径): RT-1-X 在小规模数据集上相对原始方法平均提升约 50%; RT-2-X (55B) 在需要空间关系理解等涌现能力的评测上明显超过 RT-2; 容量实验显示 RT-1-X 在大规模数据上欠拟合 (表 I 里 RT-1-X 27% 对 RT-1 40%), 高容量模型才能吸收跨具身多样性。**被本仓库怎么用:** OpenVLA 的 97 万条训练轨迹 (notes/24)、Octo、 $\pi 0$  的公共数据部分、LAPA 的无动作视频预训练 (notes/29) 均取自 OXE 子集; 它是「跨具身正迁移」这一信念的实证起点。**口径提醒:** OXE 的 100 万条轨迹里, 任务定义、动作空间、控制频率、成功标注全部异构, 「在 OXE 上预训练」这句话的信息量取决于用了哪些子集与如何统一动作空间——不同论文的 OXE 子集差异极大, 这是 VLA 之间数字不可比的另一个隐藏来源。

#### 5. Lin et al.: 数据 scaling law 的学术侧独立证据

**设计:** 真机模仿学习的数据 scaling 系统研究——采集超 4 万条演示、执行超 1.5 万次真机 rollout, 在严格协议下研究策略泛化随训练环境数、物体数、演示数的变化。**核心发现** (论文口径): 策略对新物体、新环境或两者同时的泛化能力, 与训练物体数、环境数近似呈幂律; 同时改变环境与物体比单独改变任一者更能提升数据多样性, 且单环境-物体组合内追加演示的收益很快饱和 (25% 与 100% 演示用量的曲线重叠); 给出可操作的采集策略——尽可能多的环境 (如 32 个), 每个环境一个独特物体、50 条演示, 即可训出对任意新环境新物体约 90% 成功率的策略; 两个任务的数据在一个下午即可采齐。**与本调研的关系:** 这是 BPP 「2000 任务  $\times$  5 条完胜少任务  $\times$  多条」(notes/06) 与 Zero-WAM 任务级重采样 (notes/12) 的独立同构证据——多样性轴 (环境/物体/任务) 的边际价值远高于密度轴 (每组合演示数); 它与 EgoScale (人类数据 log-linear) 和 GEN-0 (机器人数据幂律) 互相印证而非冲突: 三者分别在物体/环境多样性、数据小时数、算力三条轴上给出可预测的改进, 共同构成「机器人 scaling 不是单轴」的证据。区别在于 Lin 明确指出了饱和点 (单组合内的演示数), 而 GEN-0 的博客曲线没有报告任何饱和。

#### 6. 合成: 一个真机 one-shot ICL 标准协议应该长什么样

把四篇的经验与本仓库已有的评测批判 (notes/21 RLBench-Oneshot、HOST 的 50 任务集、趋势五) 合起来, 预测 P3 所说的「真机 OSVI 标准评测协议」应该钉死以下自由度: (1) 任务级留出——训练任务与评测任务不重叠 (Zero-WAM/RLBench-Oneshot 的做法), 而非配置级留出 (RoboTTT 的「同一电路板 80 种构型」); (2) 演示来源声明——演示是真人视频还是合成、第一人称还是第三人称、是否与评测场景同源; (3) 扰动协议分档——继承 RoboTwin 2.0 的五轴域随机化定义与 S1 的 L1-L5 分级, 报每档而非

均值；(4) 判定口径——二元成功率必报，进度分/rubric 分只作补充，人工干预必须声明且单独报；(5) 试验数与种子——每任务不少于 20 次真机试验（HOST 口径）或 100 次仿真 rollout × 3 种子（Zero-WAM 口径）；(6) 基线复现披露——基线的训练数据、微调配方、checkpoint 选择方式必须与主方法同等详细，否则不允许跨论文引用基线值。第六条直接针对「43 vs 83」；前五条针对 62% / 59% / 66% 不可比的根源。

## 7. 局限

四篇本身的局限：LIBERO 设计目标（终身学习）与实际用途（打分板）错位；RoboTwin 2.0 的域随机化是结构化枚举，与真实世界的长尾分布仍有差距，sim-to-real 结论建立在自建设定上；OXE 的异构性使「跨具身正迁移」的结论对子集选择敏感；Lin 的 scaling law 只在两个任务（倒水、鼠标整理）与单臂平台上验证，幂律指数的普适性未知。对本调研的启示是一致的：没有一个现有基准是为 one-shot ICL 设计的，最接近的 RLBench-Oneshot 是仿真，HOST 的 50 任务集是最可能的真机种子。



# 具身安全与提示注入合集：当技能接口开放给任意视频，攻击面在哪

覆盖六篇：**BadRobot** (Jailbreaking Embodied LLM Agents in the Physical World, 2024, arXiv 2407.20242) · **RoboPAIR** (Jailbreaking LLM-Controlled Robots, UPenn, 2024, 2410.13691) · **AdvVLA** (Exploring the Adversarial Vulnerabilities of VLA Models in Robotics, 2024, 2411.13587) · **BadVLA** (Backdoor Attacks on VLA via Objective-Decoupled Optimization, 2025, 2505.16640) · **State Backdoor** (Stealthy Real-world Poisoning Attack on VLA in State Space, 2026, 2601.04266) · **Contextual Backdoor** (Compromising Embodied Agents with Contextual Backdoor Attacks, 2024, 2408.02882) 定位：本篇同时是一次预测验证。趋势报告预测 P5 「12 个月内出现第一起 physical prompt injection 安全研究」、洞察 I6 「技能来自用户随手拍的视频，模型对不该做什么理解为零」。结论先行：**预测 P5 信息不足——它预测的事在做出预测前就已部分发生。**

## 1. 为什么补这一层

one-shot ICL 把技能接口从「工程师采集数据、微调、验证」变成「任何人拍一段视频」。接口开放的另一面是攻击面开放：演示视频是策略的直接输入，而 StellaVLA 的三向干预实验 (notes/15) 已经无意中量化了这件事——给错误演示 (44.9%) 比不给演示 (62.4%) 还差 17.5 个点，说明策略确实会被上下文带偏。本调研此前只把它当「策略真在读上下文」的证据，从安全视角看它同样是「演示攻击有效」的证据。检索结果显示，具身安全研究已在三个层次成型，而本调研最关心的第四层——针对视频演示 ICL 策略的推理期注入——仍是空白。

## 2. 语言层：越狱 LLM 控制的机器人

**BadRobot**：针对语音交互式具身 LLM 智能体，归纳三类漏洞——机器人系统内 LLM 可被操纵、语言输出与物理动作错位、世界知识缺陷导致的非故意危险行为；构建恶意物理动作查询基准，指标为操纵成功率 (MSR, 提示导致恶意动作的比例) 与危害分 (对语言与动作输出分别评分)；在导航与桌面操作任务上验证。**RoboPAIR**：把 LLM 越狱算法 PAIR 改造成面向机器人的 RoboPAIR，在三个真实系统上做越狱——NVIDIA Dolphins 自动驾驶 LLM、装 GPT-4o 规划器的 Clearpath Jackal 无人车、Unitree Go2 机器狗——常达 100% 攻击成功率，其中 Go2 是首次对商用机器人的成功越狱。一个与本调研直接相关的细节：论文的「上下文越狱」(in-context jailbreak) 设定里，视频被当作独立上下文喂给 Dolphins——直接引用视频描述有害动作的请求几乎全被拒绝，但把视频当纯上下文、再要求给出「在该视频范围内」的高层计划伪码，成功率 100% (上下文式) 与 94% (模板式)。这是「把内容放进上下文比放进指令更容易绕过对齐」的实证，与 ICL 的工作方式完全同构。**同类工作**：Adversarial Attacks on Robotic VLAs (2506.03350) 把 LLM 越狱套到端到端 VLA 上——rollout 开始时附加一次文本后缀即可获得动作空间的完全可达性并在长时程持续，且攻击无需与「有害」语义关联 (挪一下手在悬崖边就是危险)。

## 3. 感知层：视觉对抗扰动

**AdvVLA**：首次系统研究 VLA 的对抗脆弱性——提出无目标动作偏差攻击（UADA）、无目标位置攻击（UPA）与有目标操纵攻击（TMA），以及可放进相机视野的小型彩色对抗补丁（数字与物理环境均有效）；在一套仿真操作任务上任务成功率最高下降 100%。**同类工作**：Universal Adversarial Perturbation 对现代 BC 策略的研究（2502.03698）显示 Vanilla BC、LSTM-GMM、IBC、Diffusion Policy、VQ-BeT 全部对离线生成的单一通用扰动高度敏感——生成式动作头（notes/26）并没有带来对抗鲁棒性。**对 ICL 的含义**：演示视频是视觉输入，感知层攻击可以直接施加在演示帧上；而 ICL 策略比普通策略多一条攻击通道——攻击者不必接触部署现场的相机，只需提供一段被扰动的演示视频。

## 4. 演示层：训练期投毒后门已成体系

这是检索结果里最出乎预料的部分。**BadVLA**：目标解耦优化的两阶段后门——先在感知模块注入最小扰动触发器、拉开触发与干净输入的特征空间距离，再冻结感知、只用干净数据微调动作头以保住正常性能；多个 VLA 基准上接近 100% 攻击成功率，对输入扰动、任务迁移、模型微调均鲁棒。**State Backdoor**：不用视觉触发，而用**机器人初始状态**（关节位形）当触发器——偏好引导遗传算法在状态空间搜最小触发；在 ACT、Diffusion Policy、SmolVLA、 $\pi 0$ 、OpenVLA 五个模型、SO101 真机臂五个任务上超过 90% 攻击成功率且不影响正常任务，对经典后门防御仍有效；论文还提出把它反用作数据集水印。**TrojanRobot**（2411.11683, Robot Collapse）：供应链后门——以 LVLM 本身当后门模块，用上下文指令学习（ICIL）设计后门系统提示，实现顺序颠倒、停滞、定向三种攻击，在 UR3e 与 myCobot 真机验证。**Contextual Backdoor**（2408.02882）：对以 LLM 生成代码控制的具身智能体，**只投毒少数上下文演示**（以 LLM 对抗博弈优化中毒演示）即可让黑盒 LLM 生成带条件缺陷的程序——程序看起来逻辑正确，遇到特定文本或视觉触发才激活；覆盖机器人规划、操作、组合视觉推理，并成功攻击真实自动驾驶系统。这是文献里与「上下文演示注入」最接近的工作，且发表于 2024 年 8 月。

## 5. 合成：P5 裁决、ICL 特有的攻击面、三个防御切入点

**\*\*P5 裁决**：部分实现，且预测本身滞后于事实。**\*\*分三层看**：(a) 语言层越狱与感知层对抗——2024 年即成体系，真机验证充分；(b) 训练期演示投毒后门——2024 至 2026 年至少四篇，覆盖从 ACT 到  $\pi 0$  的全谱系动作头，真机成功率 90% 以上；(c) 上下文演示投毒——Contextual Backdoor 2024 年已做，但针对的是 LLM 代码生成型智能体的文本演示，不是视频演示驱动的端到端 ICL 策略。**真正的空白只剩一格**：对 HOST/S1/Zero-WAM 这类以人类视频为上下文的策略，在推理期用一段精心构造的演示视频诱导危险动作——截至 2026-09 未检索到直接研究（检索关键词：adversarial demonstration、poisoned demonstration imitation learning、in-context robot policy attack、one-shot imitation attack、video prompt injection robot）。趋势报告的 P5 应修正为：语言/感知/训练期投毒三层已有，**推理期视频演示注入**是待填的最后一格，而非「第一起研究尚未出现」。

**ICL 特有的攻击面**：与微调路线相比，ICL 策略多出三个攻击者不需要接触训练流水线就能利用的入口。第一，演示即输入——StellaVLA 的 17.5 点退化与 Zero-WAM 无 IFP 时人类视频是净负收益（28.55 对 39.44）说明策略对演示内容高度敏感，而这两个数字是良性错配下测出的，恶意优化的演示只会更糟；第二，S1 的「演示纠错」现象是双刃剑——模型会修正演示者的失误（示范者失手掉鸡蛋，机器人做得干净利落），意味着它对演示有一层「意图推断」而非逐帧复制，这既是对粗糙攻击的天然防御，也是新攻击面：攻击者可以构造「意图上危险、动作上正常」的演示，让模型推断出错误目标；第三，技能库外置

(HOST 的视频库、GEN-1.5 的提示片段) 把攻击从「一次性」变成「持久化」——一段中毒演示进入技能库后会被反复检索复用，效果等同后门。

**三个防御切入点：**其一，演示一致性检验——把 StellaVLA 的三向干预从评测工具变成部署时的运行检查：策略对「有演示 / 无演示 / 随机演示」的输出分歧度可作为演示可信度信号；其二，IFP 式反捷径的安全解读——Zero-WAM 让模型不能只外推机器人历史，反过来也可以训练模型不能只依赖演示（要求演示与当前观测的物理可行性一致），即在训练目标里加入「演示-观测矛盾检测」；其三，行为约束层——RoboPAIR 与 BadRobot 都指出对齐必须是上下文相关的 (context-dependent alignment)，对 ICL 策略而言这意味着一个独立于演示通道的安全裁决器（不读演示、只看观测与预测动作）作为最后一道闸。

## 6. 局限

六篇的攻击成功率都是对自选模型、自选任务的自报数字，跨论文不可比；越狱类工作的「危害」定义依赖人工判定；后门类工作假设攻击者能进入训练数据供应链，这在企业自建数据引擎 (GEN/S1) 场景下门槛很高、在开源社区数据集场景下门槛很低——威胁模型的现实性因部署形态而异。本篇未覆盖防御侧文献（对齐微调、输入过滤、形式化验证），因为检索显示具身侧防御研究远少于攻击研究——这本身是又一个空白。

# 演示的另一种编码三篇合集：轨迹草图、点轨迹、物体光流当提示

覆盖三篇：**RT-Trajectory** (Robotic Task Generalization via Hindsight Trajectory Sketches, Google DeepMind, 2023, arXiv 2311.01977) · **ATM** (Any-point Trajectory Modeling for Policy Learning, Berkeley 等, RSS 2024, 2401.00025) · **Im2Flow2Act** (Flow as the Cross-Domain Manipulation Interface, Columbia 等, CoRL 2024, 2407.15208) 定位：本仓库此前讨论的演示编码都是「原始像素」(HOST/Zero-WAM 的视频帧、GEN-1.5 的传感器流) 或「结构化语言」(StellaVLA)。这三篇是第三种——把演示压成**运动的几何表示**(末端轨迹草图、任意点轨迹、物体光流) 再当条件。EgoWAM (notes/11) 把 2D 点轨迹与 3D 光流列为人类视频到机器人的第二条轴，这里是那条轴的代表作。

## 1. 为什么补这三篇

演示视频里对策略真正有用的信息是「什么东西怎么动」，像素里的光影、纹理、背景是噪声，具身外观(人手 vs 夹爪) 更是干扰。潜动作路线 (notes/29) 用无监督码本压掉这些噪声，代价是不可解释；结构化语言路线 (StellaVLA) 用 VLM 转译，代价是空间精度损失。几何中间表示走中间路线：轨迹、点轨迹、光流既抽象掉了外观与具身，又保留了空间精度，还能被人直接画出来——RT-Trajectory 的「人手画一条草图当提示」是字面意义上的物理提示工程。三篇分别解决：提示怎么给 (RT-Trajectory)、提示怎么从视频里学出来 (ATM)、提示怎么跨越人到机器人的域差 (Im2Flow2Act)。

## 2. RT-Trajectory：把末端轨迹草图当任务条件

**主张**：语言条件策略在「语义上未见的任务」(训练只有抓放、测试要折叠) 上无能为力，因为语言与运动之间缺少接地；把任务条件换成末端执行器的 2D/2.5D 轨迹草图——粗略的一条线画在初始图像上，就能让同一策略泛化到运动模式全新的任务。**训练**：事后 (hindsight) 从已有演示数据里自动提取末端轨迹叠加到首帧上作为条件，不需要额外标注。**推理时提示的四种来源**：人用 GUI 手画、语言模型生成代码画出、从人类手部姿态估计提取、从已有轨迹检索——同一策略吃任何来源。**代表数字** (论文口径：Everyday Robots 平台上的未见任务集)：RT-Trajectory 2D 50%、2.5D (加高度) 67%，对照 RT-1 16.7%、RT-2 11.1%、目标图像条件的 RT-1-Goal 26%。附录记录了涌现行为——提示工程 (改画法改行为)、重试、2.5D 的高度消歧。**对 ICL 的意义**：它是 2023 年最接近「物理提示」的工作——提示是人画的、是视觉的、零参数更新、可组合；与 GEN-1.5 的区别只在提示模态 (草图 vs 传感器流) 与主干规模。它也提前暴露了物理提示的一个特性：同一任务的不同画法给出不同成功率，提示质量成为变量——洞察 I2 「physical prompt engineering 会成为工种」的最早实证。

## 3. ATM：从无动作视频学任意点的未来轨迹

**主张**：视频里没有动作标签，但有运动——预训练一个轨迹模型，给定任务指令与首帧中任意一组点的初始位置，预测这些点的未来轨迹；再用预测轨迹作为细粒度控制引导，训练策略只需极少动作标注数据。**两阶段**：先在视频数据上用点跟踪器 (如 CoTracker) 自动生成任意点轨迹标签、训练轨迹 Transformer；再训练轨迹条件策略，轨迹提供「往哪动」的稠密监督替代动作标签。**代表数字** (论文口径：LIBERO 四套件 + 真机，共 130 余个语言条件任务)：平均比强视频预训练基线高 80%；能从人类视频与不同形态机器人

视频迁移技能。**对 ICL 的意义**：ATM 证明点轨迹是一种跨具身可学的「动作代理」——与潜动作

(notes/29) 目标相同、路线相反：潜动作是隐式离散码，点轨迹是显式连续几何。它对本调研的直接价值是提供了 HOST 之外另一种「演示→执行」的对应机制：HOST 对齐任务进度，ATM 对齐点的空间运动。两者互补：进度对齐告诉你现在该做演示的哪一段，点轨迹告诉你这一段里东西该往哪动。

#### 4. Im2Flow2Act：物体光流作跨域接口，零真机数据

**主张**：把「人类演示视频」与「机器人执行」之间的接口定义为**物体光流** (object flow) ——只描述被操作物体上关键点怎么动，不含任何具身信息。两个网络：光流生成网络从任务描述与首帧生成完整任务光流（在真实人类视频上训练，微调预训练 Stable Diffusion 做视频生成得到光流）；光流条件模仿策略在仿真机器人「玩耍」数据上训练，学会跟随任意物体光流。因为接口不含具身，仿真训的策略可以直接吃真实人类视频生成的光流。**代表数字**（论文口径）：四个真机任务（含刚体、铰接、可变形物体）平均成功率 81%，**训练中没有用任何真机机器人数据**——真实世界只贡献了人类视频。**对 ICL 的意义**：这是「人类视频 → 机器人动作」链条里对具身差距处理最彻底的方案——不是对齐、不是重定向、不是共训，而是在接口层面直接把具身信息去掉。代价也清楚：光流只描述物体运动，抓取姿态、力、多物体协调这些不在物体上的信息全部丢失（论文自认长时程多物体任务与初始 3D 关键点依赖是局限）。

#### 5. 合成：几何中间表示与像素/语言/潜动作四种演示编码的对照

**四种编码的取舍**：像素 (HOST/Zero-WAM/S1) 信息最全但噪声最大，对齐机制负担最重；结构化语言 (StellaVLA) 抽象最强，空间精度最差、长时程崩塌；潜动作 (Genie/LAPA/UniVLA) 零标注、可 scale 到互联网视频，但不可解释且混入任务无关动态；几何中间表示 (本篇三种) 外观与具身不变、空间精度高、人可读可画，代价是只编码运动不编码意图（「轻放」还是「随便放」在轨迹上看不出来），且依赖点跟踪/光流估计的质量。**它们并不互斥**：HOST 用 Qwen3-VL 帧嵌入做演示编码——换成 ATM 式点轨迹或 Im2Flow2Act 式物体光流，理论上可以同时获得更好的具身不变性与更低的对齐难度；反过来，RT-Trajectory 的轨迹提示如果配上 HOST 的进度流形，就能从「一条静态草图」升级为「随执行进度动态更新的引导」。这两个组合都没有人做。

**对涌现之争的一条旁证**：RT-Trajectory 用 RT-1 级别的小模型和几万条轨迹就实现了对语义未见任务的零更新泛化——靠的是把条件从语言换成运动几何。这说明「零更新泛化到新任务」这个能力本身不需要 50 万小时数据，需要的是让条件信号与动作空间足够接近。GEN-1.5 的传感器流提示恰好是最接近动作空间的条件；其「涌现」有多少来自规模、多少来自提示模态本身与动作的接近性，RT-Trajectory 提供了一个便宜的对照起点。

#### 6. 局限与批判

三篇都在相对简单的桌面任务上验证，长时程与多物体协调是共同弱项；RT-Trajectory 的未见任务集与基线 (RT-1/RT-2) 都是自家模型，数字不可外推到其他平台；ATM 的 80% 增益以「视频预训练基线」为参照而非最强的动作标注方法；Im2Flow2Act 的 81% 建立在四个任务、每任务有限试验之上，且光流生成网络微调自 Stable Diffusion——其在真实人类视频上的生成质量对成功率的贡献没有单独消融。三篇共同

的隐含假设是「运动几何足以指定任务」，这在接触密集、力控主导的任务上不成立——与本调研洞察 I4「信息瓶颈在力」一致。



# 规划层 ICL 三篇合集：LLM 自己的 few-shot 能力，直接拿来控机器人

覆盖三篇：**Code as Policies** (Language Model Programs for Embodied Control, Google, ICRA 2023, arXiv 2209.07753) · **VoxPoser** (Composable 3D Value Maps for Robotic Manipulation with Language Models, Stanford, CoRL 2023, 2307.05973) · **ReKep** (Spatio-Temporal Reasoning of Relational Keypoint Constraints, Stanford, CoRL 2024, 2409.01652) 定位：本仓库此前的 ICL 全部发生在**策略层**——演示进策略网络的上下文。这三篇代表另一条平行路线：ICL 发生在**规划层**——用 LLM/VLM 已有的文本 few-shot 能力生成机器人程序、代价图或约束，底层执行交给经典规划器。两条路线对「上下文学习」的依赖方式完全不同，值得并排看。

## 1. 为什么补这三篇

GPT-3 的 ICL 在 2020 年就有了，为什么机器人要等到 2026 年才谈 ICL？一个被忽略的答案是：机器人界其实 2022 年就用上了 GPT-3 的 ICL——只是用在规划层。Code as Policies 用几个「指令注释 + 对应代码」的例子做 few-shot prompt，让 LLM 为新指令写出机器人程序；VoxPoser 让 LLM 写代码合成 3D 代价图再用运动规划器求解；ReKep 让 VLM 看图写关键点约束函数。三篇都是零训练、零机器人数据、纯上下文——比 HOST/GEN-1.5 早三年实现了「教机器人不用训练」。它们与策略层 ICL 的差别，恰好界定了后者存在的理由。

## 2. Code as Policies: few-shot 提示让 LLM 写机器人程序

**主张：**以「语言模型程序」(LMP) 为核心——prompt 里放几条示例（自然语言指令作注释 + 对应的策略代码），LLM 对新指令自动重组 API 调用生成新程序；程序可以调用感知 API（物体检测）、控制 API（抓放原语）与第三方库（NumPy、Shapely）做几何与算术推理，因此写出的策略能处理空间关系（「把方块放在碗左边 10 厘米」）、条件逻辑、循环与反应式控制。**关键技术：**层级代码生成——递归定义尚未定义的函数，让 LLM 自己把复杂任务分解成子函数，这一技巧同时把 HumanEval 代码基准的解决率提升到当时最优的 39.8%。**验证：**多个真机平台（桌面操作、移动机器人、白板绘画）与仿真桌面基准，另建了机器人代码生成基准分析泛化。**在本调研中的定位：**这是「演示当 prompt」的文本版鼻祖——示例是代码而非轨迹，学习发生在 LLM 的上下文里而非策略的上下文里；它的能力上限由感知/控制 API 的粒度决定，接触密集与灵巧操作在 API 之外。

## 3. VoxPoser: LLM 写代码合成 3D 代价图，规划器零样本求轨迹

**主张：**不让 LLM 直接输出动作或调原语，而是让它把自由形式指令（含「小心那个花瓶」这类约束）翻译成**可组合的 3D 值图**——用代码调用 VLM 定位物体，再在体素空间里写出可供性图与约束图，最后由传统运动规划器在值图上零样本合成轨迹；配合在线经验可以高效学接触密集场景的动力学模型。**代表数字**（论文口径，真机日常操作任务每任务 10 次）：VoxPoser 总成功率 88.0%（有干扰时 70.0%），对照动作原语基线 24.0%（有干扰 0.0%）；仿真里对未见指令与属性的泛化在物体交互、组合等类别上大幅超过基线。**在本调研中的定位：**VoxPoser 把「上下文学习的产物」从程序推进到**空间场**——LLM 的 ICL 输出不

再是离散逻辑而是连续几何，这是规划层 ICL 能处理连续控制的关键一步；但它仍不做闭环学习，每个新任务都要重新推理一次值图，且成败依赖 VLM 的检测精度。

#### 4. ReKep: VLM 看图写关键点约束，双臂与移动平台零样本

**主张：**把操作任务表示为**关系关键点约束**（ReKep）——一组 Python 函数，每个函数把场景中若干 3D 关键点映射到一个数值代价，任务由分阶段的约束序列定义（先让茶壶口到杯子上方，再倾斜）；用大视觉模型（DINOv2 + SAM）自动提关键点、用 VLM（GPT-4o）看叠加了关键点编号的图像写出约束函数，再以层级优化实时求解机器人动作。**代表数字**（论文口径，每任务 10 次）：轮式单臂与固定双臂平台上七个任务（倒茶、回收罐子、放书、封箱、叠衣、装鞋、协作叠衣）自动标注版总成功率 68.6%，人工标注约束版 44.3%，VoxPoser 基线 10.0%；外部干扰下 46.7% 对 VoxPoser 6.7%。**在本调研中的定位：**ReKep 是规划层 ICL 的当前形态——VLM 的视觉 ICL 直接产出可优化的约束，做到了双臂协作与可变形物体（叠衣）；同时它也暴露了这条路线的天花板：错误分析显示失败集中在关键点提议与约束函数生成，即 VLM 的空间推理仍是瓶颈，且整套系统对 RGB-D 与关键点跟踪的依赖使其无法处理遮挡与快速动态。

#### 5. 合成：规划层 ICL 与策略层 ICL 的分界线

**两条路线的结构差异：**规划层 ICL 把「学什么」交给 LLM/VLM 的语言先验，把「怎么动」交给经典规划器与原语库——上下文是文本示例或标注图像，学习结果是程序/值图/约束，零机器人数据；策略层 ICL（HOST/GEN-1.5/S1/Zero-WAM）把演示视频直接喂进端到端策略，学习结果是动作分布，需要大规模机器人数据预训练。**各自的边界：**规划层胜在零数据、可解释、可组合，败在接触密集与灵巧操作——凡是不能用「关键点到位」描述的任务（拧盖的力、叠衣时布料的褶皱、翻煎饼的时机）都在它的表达能力之外，而这恰是 S1 拿来展示 ICL 的任务（煎饼、咖啡）；策略层胜在能学接触与时机，败在数据成本与不可解释。**为什么 2022 年的规划层 ICL 没有引发「GPT-3 时刻」的叙事：**因为它没有解决机器人特有的问题——低层控制。Code as Policies 与 VoxPoser 的成功率天花板由原语库与规划器决定，LLM 再强也补不上；直到策略层 ICL 让低层控制本身可以从演示上下文学习，「教机器人 = 给一段演示」才对全部任务成立。这就是本调研把 2026 年 8 月而非 2022 年定为拐点的理由。

**可能的合流：**ReKep 的分阶段约束与 HOST 的进度流形描述的是同一件事（任务的时间结构），一个由 VLM 显式写出、一个由策略隐式学出；WALL-WM 的事件切分、StellaVLA 的语义分段也在同一谱系上（notes/13、15）。一个自然的混合体是：规划层 ICL 给出阶段划分与约束（可解释、可校验——这对安全至关重要，见 notes/33），策略层 ICL 在每个阶段内从演示学接触与时机。目前只有 LingBot-VA 2.0 的「层级 VLM 规划器 + 视频 ICL 底层」（notes/19）与 S1 的隐式长时程组合接近这个形态，且都没有正面评测两层的分工收益。

#### 6. 局限与批判

三篇的评测都是每任务 10 次真机试验、自选任务、自建对照，与本调研其他工作一样口径不可比；Code as Policies 的机器人代码生成基准在后续文献中未被广泛采纳；VoxPoser 的 88% 建立在检测器与规划器都工作正常的前提下，论文的错误分解显示感知错误占主导，这意味着数字对场景整洁度高度敏感；ReKep 的自动标注版超过人工标注版（68.6 vs 44.3）是个反直觉结果，论文归因于自动提议的关键点更

密集，但也可能说明人工标注协议本身有问题——未做进一步分析。三篇共同的问题：LLM/VLM 的 API 版本随时间变化，结果的可复现性比端到端策略更差。

# 检索增强与技能库三篇合集：上下文从哪里来——非参数记忆与 ICL 的边界

覆盖三篇：**Behavior Retrieval** (Few-Shot Imitation Learning by Querying Unlabeled Datasets, Stanford, RSS 2023, arXiv 2304.08742) · **STRAP** (Robot Sub-Trajectory Retrieval for Augmented Policy Learning, UW + Bosch, 2024, 2412.15182) · **AgiBot World Colosseo / GO-1** (智元, 2025, 2503.06669) 定位：ICL 默认「上下文由用户给」——一段演示视频。但 HOST 的技能库（视频库检索复用）、RICL 的检索增强后训练 (notes/07)、GEN-1.5 的提示片段库都指向同一件事：上下文可以从一个**非参数记忆库**里检索出来。这三篇是检索路线的谱系：检索什么（轨迹→子轨迹）、怎么检索（VAE 嵌入→视觉基础模型 + DTW）、以及一个百万级技能库长什么样（AgiBot World）。

## 1. 为什么补这三篇

策略层 ICL 与检索增强只差一步：ICL 把检索到的演示放进上下文零更新执行，检索增强把检索到的数据拿去微调。RICL (notes/07) 已经证明两者可以合成一套配方——检索 + 上下文条件 + 可选微调。但检索本身有一串没被本仓库讨论过的问题：用什么相似度检索、以整条轨迹还是片段为单位、库要多大才有用、检索错了会怎样。三篇分别给出答案，且 GO-1 的 ViLLA 架构把潜动作 (notes/29) 与技能库接到了一起。

## 2. Behavior Retrieval：用少量专家数据当查询，从无标注库里捞相关行为

**主张**：少量任务专家数据的价值不只是训练样本，更是**查询**——它告诉智能体该从大规模无标注离线数据（含大量次优行为）里取哪些先验数据。方法很简单：先在离线数据上预训练一个相似度度量（VAE 嵌入状态-动作对），用专家数据在嵌入空间里检索相关转移，过滤掉次优与无关数据，再把专家数据与检索数据联合训练策略。**代表结果**（论文口径，仿真 + 真机 NutAssembly/Pickle 任务）：检索到的确实是任务相关转移；在少量演示设定下超过「预训练 + 微调」与朴素混合数据训练，也超过其他检索策略；真机验证成立。**对 ICL 的意义**：这是「上下文该放什么」问题的第一个系统回答——不是所有数据都该进上下文，相关性过滤是必要的；而它使用的「专家数据作查询」与 HOST 用用户视频在技能库里检索、RICL 用当前观测检索训练轨迹是同一个操作。它的局限也预示了后续方向：整条轨迹级别的检索会把任务里共享的低层行为（伸手、抓取）与任务特有部分绑在一起。

## 3. STRAP：子轨迹检索 + 视觉基础模型 + 动态时间规整

**主张**：主张「部署时训练」而非零样本部署——遇到新场景时非参数地检索相关数据并现场训练；关键改进是检索粒度降到**子轨迹**：许多任务共享大量低层行为，整条轨迹检索会漏掉跨任务共享内容、利用率低。三件套：用预训练视觉基础模型（DINOv2 等）编码轨迹帧得到鲁棒的相关性度量；用子序列动态时间规整（S-DTW）在大语料里高效检索与查询演示片段对齐的子轨迹；把检索结果与少量目标演示一起训练。**代表结果**（论文口径）：LIBERO-10 仿真与真机（Franka 笔入杯、DROID 厨房数据集）上超过此前检索算法与多任务学习方法，能扩展到大规模真实离线数据集，用少数几条真机演示即可学出鲁棒策略。**对 ICL 的意义**：STRAP 的 S-DTW 与 HOST 的 SDTW (notes/01) 是同一个工具的两种用法——STRAP 用它在库

里找「与演示片段对齐的子轨迹」，HOST 用它对齐「演示与执行的进度」；两者都在回答「演示的哪一段对应什么」。子轨迹粒度对 ICL 的启示更直接：长时程演示应该被切成可复用的片段进上下文（S1 的长时程组合、ManiLong-Shot 的原语分解、WALL-WM 的事件切分都在做同一件事），而不是整段塞进去。

## 4. AgiBot World Colosseo / GO-1: 百万轨迹技能库 + 潜动作规划器

**主张：**数据侧构建 AgiBot World——超过 100 万条轨迹、217 个任务、五类部署场景（家居、零售、工业、餐饮、办公），标准化采集流水线含人在环质检，规模比既有数据集高一个量级；模型侧是 GO-1，采用 ViLLA（Vision-Language-Latent-Action）三段架构：潜动作模型从无动作视频（含互联网人类视频）学离散潜动作码（与 LAPA 同源，notes/29），潜动作规划器以 VLM 预测潜动作序列作为中间规划，动作专家再把潜动作解码成真机动作。**代表数字**（论文口径）：在 AgiBot World 上预训练的策略比在 OXE 上预训练的平均高 30%（域内与分布外均成立），且仅用相当于 OXE 十分之一小时数的子集就把泛化提升 18%；GO-1 在真机灵巧与长时程任务上超过 60% 成功率，比 RDT 高 32%；性能随数据量持续上升，且数据质量（人在环质检）被单独消融证明重要。**对 ICL 的意义：**GO-1 目前不做 ICL——它是微调范式的技能库；但它同时具备 ICL 化的两个前提：一个按任务组织的百万级演示库（检索源）与一个潜动作接口（把人类视频与机器人演示放进同一词汇）。它与 Zero-WAM（notes/12，8.6K 任务的合成配对库）的对比有信息量：AgiBot 217 任务 × 每任务约 5000 条，Zero-WAM 8.6K 任务 × 每任务约 9 对——正是 BPP「任务多样性 > 每任务密度」定律（notes/06）与 Lin 数据 scaling law（notes/32）所预测的两种极端，前者利于精通、后者利于 ICL。

## 5. 合成：检索、技能库与 ICL 的三种关系

**检索是 ICL 的上游。**ICL 论文默认演示由用户提供，但部署形态里演示更可能来自库：HOST 的推理循环就是「用户视频 → 检索技能库 → 命中则复用、未命中则新建」；GEN-1.5 的提示片段库同理。Behavior Retrieval 与 STRAP 回答了检索该怎么做——相关性度量要用基础模型嵌入而非像素、粒度要到子轨迹、检索结果要过滤次优。这些结论直接适用于 ICL 的上下文构建，却没有任何 ICL 论文引用它们。

**检索是 ICL 的替代品。**STRAP 的立场值得单独记录：它明确反对零样本部署，主张「检索后现场训练」——这与 GEN-1.5 的 few-shot 路线（ICL 提示后再 1-10 步梯度）在实践上收敛：都承认纯上下文不够、都在检索到的数据上做少量更新。区别在于 STRAP 的更新是分钟级微调、GEN-1.5 是 10 步梯度——本调研「适应预算连续旋钮」（洞察 I3）的两个刻度。

**技能库是 ICL 的攻击面。**notes/33 指出技能库外置把一次性注入变成持久化后门。Behavior Retrieval 的相关性过滤在这里有第二重意义：它本来是为了滤掉次优数据，同样可以滤掉恶意演示——检索层是 ICL 系统里天然的安全检查点，目前无人从这个角度设计它。

**GO-1 的位置：**它是「技能库 + 潜动作」但不做 ICL 的模型，与 HOST（ICL + 显式对齐但库小）、Zero-WAM（ICL + 合成库）形成三角。三者各缺一角，合流路径清晰：AgiBot 级别的库 + ViLLA 的潜动作接口 + HOST/Zero-WAM 的上下文机制。

## 6. 局限与批判

Behavior Retrieval 的 VAE 嵌入在视觉复杂场景下的相关性度量质量有限，STRAP 用基础模型替代正是针对此；STRAP 的「部署时训练」需要分钟级算力与库的在线访问，与 HOST 「29 秒零更新」的部署形态不兼容，两者的成本对照论文没有给；AgiBot World 的 30% 与 18% 增益以 OXE 为对照，而 OXE 的异构性 (notes/32) 使它成为一个易被超越的基线；GO-1 的「超过 60%」与「比 RDT 高 32%」是自建任务、自选基线的口径，与本仓库其他数字一样不可横比。三篇都没有报告检索错误（取回不相关或有害数据）对性能的影响——这恰是 ICL 视角下最该测的一项。



# 趋势与洞察：机器人 One-Shot 技能习得的 2026 拐点

本报告基于对 HOST (arXiv 2607.20033)、GEN-0/1/1.5、Skild S1、LocoFormer、Instant Policy、ICRT、RoboTTT、WAM-TTT、StellaVLA、Zero-WAM、LingBot-VA (两代)、BPP、RICL、Vid2Robot、EgoScale、EgoWAM、WALL-WM、GR-3、ManiLong-Shot、FACTR 2、 $\pi$ 0.5、Wall-OSS、Fast-WAM 等工作的深度解读，外加十五个纵深专题：ICL 机制理论 (notes/22)、世界模型上游谱系 (notes/23)、基座 VLA (notes/24)、One-Shot 模仿源头 2017→ (notes/25)、生成式动作头奠基 (notes/26)、人类数据管线 (notes/27)、视频-动作同代对照组 (notes/28)、潜动作桥梁 (notes/29)、上下文 RL 前史 (notes/30)、人类视频共训 (notes/31)、评测基准与数据地基 (notes/32)、具身安全与提示注入 (notes/33)、演示的几何编码 (notes/34)、规划层 ICL (notes/35)、检索增强与技能库 (notes/36)。写作时间：2026-08-31 (09-01 增补 S1 与四篇 EICL 论文；09-02 增补 EICL 直系 6 项 + 理论与谱系专题；09-02 晚由 5 路子 agent 并行补齐历史源头、底座、动作头、数据管线、同代对照 13 项；09-03 补齐潜动作、上下文 RL 前史、人类共训、基准地基、具身安全 19 项，并据此修正预测 P5；09-04 补齐几何编码、规划层 ICL、检索与技能库 9 项)

## 0. 一页结论

2026 年 8 月是机器人技能习得范式的分水岭：「教机器人」正在从训练问题变成提示问题。同月内，Generalist AI 宣布 one-shot 上下文学习作为涌现能力出现在 50 万小时数据预训练的 GEN-1.5 里 (59%，10 任务)，自变量机器人开源了用架构设计达成同等能力的 HOST (62%，50 任务，29 秒/技能)，Skild AI 发布了把主张推到最远的 S1 (未见且长达 10 分钟的任务 66%，同规模语言提示仅 9%)。三家互不相识的机构、三条不同的路线在 16 天窗口内汇合于同一个能力点——这不是巧合，是领域相变的信号。同月，四篇学术论文 (WAM-TTT、RoboTTT、StellaVLA、Zero-WAM) 把「演示怎么被用上」做成了可核对的实验，其消融证据一致指向：至少在学术可负担的规模上，具身 ICL 需要显式机制，不是免费涌现 (详见第 16 号报告)。

类比语言模型的历史坐标：这就是机器人的 GPT-3 时刻。GPT-3 (2020) 之后，NLP 的重心从「为每个任务微调」转向「为每个任务写 prompt」；机器人正在进入同一转折——physical prompting (物理提示) 取代 per-task fine-tuning。

## 1. 领域快照：通往 2026-08 的时间线

| 时间      | 事件                                               | 意义                                               |
|---------|--------------------------------------------------|--------------------------------------------------|
| 1994    | Kuniyoshi "learning by watching"                 | OSVI 愿景起点                                        |
| 2017-03 | Duan et al. One-Shot Imitation Learning (OpenAI) | 问题定义者：演示条件策略 + 软注意力；未见积木 2 阶段 94.9% → 8 阶段 18.0% |
| 2021-06 | Decision Transformer (Berkeley)                  | 控制问题的序列化改写，「策略=序列模型」让一切前缀操作成为可能                  |
| 2022-06 | Prompt-DT (CMU, ICML 2022)                       | 轨迹片段当 prompt 零微调泛化——ICRT/BPP「演示当 prompt」的直系祖先    |

| 时间      | 事件                                           | 意义                                               |
|---------|----------------------------------------------|--------------------------------------------------|
| 2022-09 | Code as Policies (Google)                    | few-shot 提示让 LLM 写机器人程序——规划层 ICL 零训练实现「教机器人不用训练」 |
| 2022-10 | Algorithm Distillation (DeepMind)            | 上下文内蒸馏出整个 RL 算法；「ICL 需要显式数据结构」最早的干净证据            |
| 2017-09 | Finn et al. One-Shot Visual Imitation (MAML) | 元学习路线；真机 PR2 一条演示 90%，二阶梯度使其未能跟上 scaling         |
| 2023-02 | UniPi (MIT+Google)                           | 视频生成当策略的开山：文本条件想象+逆动力学                           |
| 2023-03 | Diffusion Policy (Columbia+TRI)              | 策略从「回归函数」变「条件动作分布采样器」，flow-matching 动作头的源头       |
| 2023-04 | ACT / ALOHA (Stanford)                       | 动作分块 + CVAE + 时间集成；动作分块被此后几乎所有 VLA 继承            |
| 2023-04 | Behavior Retrieval (Stanford)                | 专家数据当查询检索无标注库——「上下文该放什么」的第一个系统回答                 |
| 2023-06 | LIBERO (UT Austin)                           | 四套件 130 任务，为终身学习设计却成通用打分板                        |
| 2023-07 | VoxPoser (Stanford)                          | LLM 合成 3D 值图 + 规划器零样本求轨迹，真机 88%                  |
| 2023-07 | RH20T (上海交大)                                 | 110K 条 / 147 任务力反馈遥操数据集——任务覆盖瓶颈的标本               |
| 2023-10 | Open X-Embodiment (21 机构)                    | 22 具身 / 100 万+ 轨迹，跨具身正迁移的实证起点与 VLA 公共地基          |
| 2023-11 | RT-Trajectory (DeepMind)                     | 人手画轨迹草图当任务条件，未见任务 67% vs RT-2 11%——最早的物理提示       |
| 2024-01 | ATM (Berkeley 等)                             | 从无动作视频学任意点轨迹当控制引导，130 余任务超视频预训练基线 80%            |
| 2024-02 | Genie (DeepMind)                             | 20 万小时游戏视频无监督学出 8 个潜动作码——潜动作桥的开山                 |
| 2024-02 | UMI (Stanford+Columbia)                      | 手持夹爪采集范式开山，在采集端消掉具身差距                            |
| 2024-03 | Vid2Robot (DeepMind)                         | 端到端视频条件策略，跨注意力+辅助对比损失                            |
| 2024-05 | IMOP (Rutgers, RSS 2024)                     | 无大模型先验的结构派极致：不变区域匹配；长程 7.4%                      |
| 2024-06 | OpenVLA (Stanford 等)                         | 7B 开源自回归 VLA，多篇 ICL 工作的公共基线                      |
| 2024-06 | HumanPlus (Stanford)                         | 人形实时影子人类；人类当遥操作器而非训练数据                           |
| 2024-07 | Im2Flow2Act (Columbia 等)                     | 物体光流作人-机接口，零真机数据达 81%                            |
| 2024-08 | Contextual Backdoor (多机构)                    | 投毒少数上下文演示即可后门 LLM 具身智能体——上下文演示注入的首个研究            |

| 时间      | 事件                                             | 意义                                                  |
|---------|------------------------------------------------|-----------------------------------------------------|
| 2024-09 | ReKep (Stanford)                               | VLM 看图写关键点约束，双臂零样本 68.6%——规划层 ICL 的当前形态             |
| 2024-12 | STRAP (UW+Bosch)                               | 子轨迹检索 + DTW，主张「部署时训练」而非零样本                          |
| 2024-10 | LAPA / EgoMimic / RoboPAIR / Data Scaling Laws | 潜动作预训练超真动作 VLA；Aria 共训 scaling；首次越狱商用机器人；环境-物体多样性幂律 |
| 2024-08 | ICRT (Berkeley)                                | 机器人 ICL 用 next-token prediction 形式化                 |
| 2024-10 | $\pi 0$ (Physical Intelligence)                | VLM + flow matching 动作专家范式确立；RICL 底座、GR00T 设计上游     |
| 2024-11 | Instant Policy (Imperial)                      | 图扩散 ICL，伪演示无限生成                                     |
| 2025-03 | GR00T N1 (NVIDIA)                              | 双系统 VLA，System 1 自足结构是 RoboTTT 插 TTT 层的前提           |
| 2025-03 | AgiBot World / GO-1 (智元)                       | 100 万+ 轨迹 217 任务技能库 + ViLLA 潜动作规划器，超 OXE 预训练 30%    |
| 2025-05 | UniVLA / BadVLA                                | DINO 空间任务中心潜动作 1/20 算力超 OpenVLA；VLA 后门接近 100% 成功率   |
| 2025-06 | RoboTwin 2.0 (Lumina EAI 等)                    | 50 双臂任务五具身域随机化基准，WAM 系主战场                           |
| 2025-04 | $\pi 0.5$ (Physical Intelligence)              | VLA 开放世界泛化的代表                                       |
| 2025-08 | RICL                                           | 给预训练 VLA 后装 ICL 能力的通用配方                             |
| 2025-07 | GR-3 (字节 Seed)                                 | few-shot 微调流派工业标杆：10 条 VR 轨迹适配新物体                   |
| 2025-09 | Wall-OSS 开源 (自变量)                              | 中国开源 VLA 基座                                         |
| 2025-09 | LocoFormer (Skild, CoRL 2025)                  | 上下文当适应机制在 locomotion 域先走通，S1 直系前作                   |
| 2025-11 | GEN-0 (27 万小时)                                 | 机器人 scaling law + 7B 相变                             |
| 2025-12 | Motus (清华+北大+地平线)                              | 一模型五模式 8B MoT；RoboTwin 上被 LingBot-VA/Fast-WAM 一致超越  |
| 2026-01 | State Backdoor                                 | 机器人初始位形当后门触发器，五模型真机 >90%——投毒攻击进入状态空间                |
| 2026-01 | ManiLong-Shot / RLBench-Oneshot (AAAI 2026)    | OSIL 标准协议：未见长程任务 SOTA 仅 30.2%                       |
| 2026-01 | LingBot-VA (蚂蚁, RSS 2026)                      | 「测试时保留完整想象」的 WAM 代表，Zero-WAM 同门前作                   |
| 2026-02 | DreamZero (NVIDIA GEAR)                        | 像素想象派旗舰：14B Wan 骨干单流联合去噪，无 ICL 的 WAM「素体」            |
| 2026-02 | EgoScale (NVIDIA GEAR)                         | 20,854 小时第一人称人类视频，log-linear scaling law            |

| 时间         | 事件                               | 意义                                         |
|------------|----------------------------------|--------------------------------------------|
| 2026-04    | GEN-1                            | 6 任务 99% 精通 + 3x 速度                        |
| 2026-06    | BPP                              | 行为提示策略                                     |
| 2026-06    | WALL-WM (自变量系)                   | 事件关节切分的世界动作建模                              |
| 2026-07    | EgoWAM (Georgia Tech)            | WAM 世界表征对照: DINO/3D flow 远胜像素              |
| 2026-07-08 | WAM-TTT (北大+银河通用)                | 快权重技能吸收: 人类视频写进感知侧记忆                       |
| 2026-07-16 | RoboTTT (NVIDIA GEAR + Stanford) | TTT 快权重把上下文扩到 8K timestep (3 个数量级)         |
| 2026-08-03 | Ego2Robot (阿里 Qwen 等)            | 1,940 小时第一人称视频 → 18,561 小时合成 / 15 形态       |
| 2026-08-03 | HOST 开源                          | 架构派 one-shot: 62%, 29 秒, 零参数更新, 不遗忘        |
| 2026-08 中  | StellaVLA (StellarEdge AI)       | 结构化语言上下文, 三向干预实验首创                         |
| 2026-08-18 | S1 (Skild AI)                    | 未见+10 分钟长时程 66%, 单演示≈380 条后训练示范            |
| 2026-08-19 | GEN-1.5                          | 涌现派 one-shot: 59%, physical prompting 命名确立 |
| 2026-08 末  | Zero-WAM (Robbyant+港科广)          | 合成人类视频 74.2K 对, 任务级零样本 46.95%              |

## 2. 六大趋势

### 趋势一：ICL 正在成为机器人学习的新范式轴，四条实现路线并行

「从演示上下文即时学习、不更新参数」这一目标，2026 年有四条技术路线同时逼近：

1. **涌现派 (GEN-1.5)**：什么都不设计，靠 50 万小时数据预训练让 ICL 自己长出来。上限最高（还能组合泛化、sim2real 提示、跨具身提示），但不可复现、需要天价数据引擎。
2. **架构派 (HOST、Instant Policy)**：把「对齐」「跨域翻译」显式设计进模型。HOST 用 SDTW+TCC 学共享任务进度流形 + 三级自接地级联；Instant Policy 用图扩散把 ICL 结构化。小数据可达 (HOST 只用 193k 轨迹 + 5.8k 人类视频)，完全开源。
3. **上下文扩展派 (RoboTTT、ICRT)**：把 LLM 的长上下文/TTT 技术搬到机器人。RoboTTT 用 TTT 快权重（每个传感器读数触发内部小模型一次梯度步，把历史压缩进权重空间）把上下文从约 10 timestep 扩到 8,000 (30Hz 下约 5 分钟)，推理成本不变；8K 上下文预训练比 1K 好 62%，比单步基线好 87%，且 context scaling curve 无饱和迹象。

4. **VLA 加装派 (RICL、BPP)**: 不动预训练 VLA 基座, 通过 retraining recipe 后装 ICL 能力。工程上最务实——所有已部署的  $\pi 0$ /OpenVLA 类模型都可以走这条路升级。

判断: 四条路线会合流。终局形态大概率是「大规模预训练基座 (涌现派的数据) + 显式对齐结构 (架构派的归纳偏置) + TTT 长上下文 (扩展派的机制)」的混合体。RoboTTT 已经是雏形——它把 ICL 和梯度更新的界限直接消掉了: 上下文处理本身就是梯度步。

**2026 年 7-8 月的四篇 EICL 论文把实现空间切得更细** (详见第 12/14/15 号报告与第 05 号 RoboTTT 报告)。两个维度: 演示最终改变了什么 (写进快权重 vs 停留在输入里)  $\times$  适应发生在何时 (部署前一次 vs 每步 vs 不适应)。四篇各占一格零重叠: WAM-TTT (快权重·感知侧·部署前一次)、RoboTTT (快权重·动作侧·每步递归)、StellaVLA (纯上下文·结构化语言·真零梯度)、Zero-WAM (纯上下文·合成人类视频·零梯度)。GEN-1.5 与 S1 主张的路线落在「纯上下文·零梯度」一格, 与 Zero-WAM 最近——而恰是 Zero-WAM 的消融证明了这一格需要反捷径机制才能成立。四篇互相知晓却零直接对比, 「三种上下文接口同台对照」是当前边际信息量最高的空缺实验。

**趋势二: 上下文长度成为机器人 scaling 的新轴**

GEN-0 证明了数据轴 (27 万小时→幂律), GEN-1.5 的 30 秒记忆窗口装下一段演示, RoboTTT 则把「上下文长度」独立成第三条 scaling 轴: 128→8K timestep 单调提升闭环性能、无饱和。时间上更早的证据来自 LocoFormer (CoRL 2025): TXL 跨 episode 上下文让同一策略在锁膝、断腿、上高跷下 2-3 个 trial 内涌现适应——Skild 先在 locomotion 域验证了「上下文即适应机制」, 一年后才有了 S1。Jim Fan 的表述值得记录: "What LLM enjoys, robotics should too. Soon, even 1M context is not a fantasy."

上下文变长的直接后果: 能装进上下文的东西从「一段演示」变成「多段演示 + 自己的执行历史 + 纠错记录」。RoboTTT 已展示 on-the-fly self-improvement——机器人中途失败后的自我修正会进入上下文、改进后续动作。**上下文即记忆, 记忆即学习。**

**趋势三: 数据路线四分天下, 人类数据 scaling law 已被量化**

「数据从哪来」是当前最重要的产业分歧, 四条路线的 2026 版图:

| 路线        | 代表                 | 规模                                        | 优势                                                          | 短板                |
|-----------|--------------------|-------------------------------------------|-------------------------------------------------------------|-------------------|
| 穿戴设备/手持夹爪 | Generalist (GEN 系) | 50 万小时, 每周 +1 万                           | 高保真动作标签、天然高速                                                | 私有、成本数千美元级        |
| 第一人称人类视频  | EgoScale、EgoSteer  | EgoScale 20,854 小时; 公开 ego 视频存量约 11.6 万小时 | log-linear scaling law 已验证; embodiment-agnostic motor prior | 需 4D 重建提取动作, 误差累积 |
| 合成/重定向    | Ego2Robot          | 18,561 小时、15 种机器人形态                       | 一次采集多形态复用                                                   | 渲染真实差距            |
| 人类视频直接条件化 | HOST、Vid2Robot     | HOST 仅 5.8k 段                             | 零标注、用户可产生                                                   | 无力信息、依赖对齐质量       |

| 路线      | 代表                  | 规模                         | 优势                                      | 短板                  |
|---------|---------------------|----------------------------|-----------------------------------------|---------------------|
| 合成人-机配对 | Zero-WAM (HumanGen) | 74.2K 对 / 8.6K 任务 / >45 本体 | 任务覆盖比 RH20T 高约 58 倍 (8.6K vs 147)、零人工标注 | 全合成、真实性未评估、依赖闭源商业模式 |

EgoScale 的贡献是把第二条路线的收益变成可预测的：人类数据规模 vs 验证损失呈 log-linear，且验证损失强相关于真机性能——22-DoF 灵巧手 +54%（对比无预训练）。这意味着人类视频数据的采购决策可以像 GEN-0 的机器人数据一样精算了。

趋势四：涌现 vs 设计——LLM 的辩论在具身领域重演，现在是三方格局

Sutton 的 bitter lesson 预言通用方法+算力终将碾压手工设计。GEN-1.5 是教科书式的涌现叙事（强调无架构改动、无 meta-learning 循环、无辅助目标），S1 的措辞稍缓但同样把能力归因于任务多样性与规模。但 HOST 用 1/100 量级的数据靠归纳偏置达到了同等成功率——在数据受限机制下，设计仍然是不可替代的杠杆。

2026 年 8 月之后，这个二元对立升级成了三方格局（完整论证见第 16 号报告）：

- 1. 涌现叙事（产业侧）：GEN-1.5/S1，证据是 demo 视频与内部曲线，规模不可复现；
- 2. 机制证据（学术侧）：四篇 EICL 论文的消融全部反对免费涌现——WAM-TTT 去 meta-training 从 100.0 掉到 9.0；RoboTTT 去 sequence action forcing 训不出来；StellaVLA 需要整条离线结构化流水线；Zero-WAM 最致命，它是路线上最接近产业博客的一篇（大规模预训练+纯上下文+零梯度），但没有 IFP 反捷径目标时往上下文加人类视频是净负收益（28.55 vs 39.44）。公平的限定：四篇的规模都远低于产业（最大 15,360 GPU 小时 vs 50 万小时数据），严格结论是「在学术可负担的规模上需要显式机制」；
- 3. 度量质疑（尚无人做）：Schaeffer et al. 2023 证明 LLM 的「涌现」很大程度是不连续度量制造的海市蜃楼。一条历史注脚：Duan et al. 2017 的附录已记录小网络在积木任务上学习曲线的「相变」（notes/25），比 GEN-0 的「intelligence phase transition」早八年——相变现象本身不新，新的是把它与规模绑定的叙事。机器人的二元成功率和 rubric 完成分恰是这类度量；S1 自己公布的 scaling 曲线（1k→100k 小时差距平滑指数扩大）反而更像连续改进而非相变。把度量批判搬进具身领域是当前空白。

原有的信息论判断仍然成立且被 S1 加强：HOST 62%、GEN-1.5 59%、S1 66% 落在同一区间（口径不可比，但量级一致），one-shot 学习的瓶颈可能已经不在方法，而在信息论层面——一段演示视频本身承载的任务信息有上限（初始条件覆盖、力信息缺失、意图歧义）。下一波提升更可能来自：(a) 多模态提示（视频+语言+力反馈）；(b) 交互式澄清（执行中请求补充演示）；(c) 提示组合（GEN-1.5 的 prompt chaining、S1 的长时程组合已是雏形）。

趋势五：评测严重滞后，「62%」和「59%」不可直接比

- GEN-1.5：10 个任务、试验次数未披露、任务自选、无第三方复核；



- S1: 内部 benchmark、任务清单未公开；长时程「累计逐步成功率」允许人工干预恢复计分（博客自述主要为救语言基线，否则基线为零），66% 不能读成无干预端到端完成率；
- HOST: 50 个任务、每任务 20 试验、13 个基线对照，但平台单一（ARX R5 双臂）、成功判定人工；
- 仿真侧 RLBench-Oneshot (ManiLong-Shot, AAAI 2026) 刚出现：30 任务（10 短程 + 20 长程分三档）、25 试验 × 5 种子，是 OSIL 第一个像样的标准协议，但仿真结果与真机相关性未知。

**真机 one-shot 评测没有共同基准**，是当前论文数字通胀的根源。谁先建立被广泛采纳的真机 OSVI 评测协议（固定任务集 + 固定扰动协议 + 第三方复核），谁就拿到定义领域进展的话语权。

### 趋势六：开源在加速吃掉先发优势

2026 年的开源节奏：AgiBot World 数据集（智元）→ Wall-OSS/Wall-OSS-0.5（自变量）→ X-Tokenizer（自变量，SRQ 动作分词器）→ EgoSmith 数据流水线（开源，9 倍于 HaWoR 吞吐）→ HOST 全栈（论文+代码+权重）。闭源阵营只剩数据壁垒（Generalist 的 50 万小时、Physical Intelligence 的采集网络）。

自变量的策略清晰可读：用开源抢生态位。HOST 开源意味着任何拥有中等规模机器人数据（10 万条轨迹级）的团队都能复刻推理时技能获取——这直接把「one-shot 能力」从竞争壁垒降格为公共基础设施，逼迫闭源玩家在数据规模和工程系统上继续拉开差距。

## 3. 七条核心洞察

**Insight 1: 技能的存储位置从参数空间迁移到上下文空间，技能因此变成资产。** HOST 的技能库=视频库（外部记忆，检索复用，永不遗忘）；GEN-1.5 的技能=物理提示片段（可拖放、可组合）。当技能不再固化在权重里，它就变成了可存储、可传播、可交易的数字资产。可预见的衍生形态：机器人技能商店（上传一段演示视频=发布一个技能）、技能版本管理、跨机器人技能市场。灾难性遗忘这个困扰持续学习二十年的问题，被「技能外置」直接架空而非解决。

**Insight 2: physical prompt engineering 会成为真实工种。** GEN-1.5 已有拖放式提示界面；提示的选择（哪 3-12 秒）、组合（A+B 串联）、质量（视角/速度/清晰度）显著影响成功率。类比 2021-2023 年 LLM prompt 工程师的出现轨迹，12-24 个月内会出现：物理提示设计指南、提示库标准格式、提示质量自动评估工具。HOST 的检索阈值  $\delta$  调优就是这个工种的雏形工作内容。

**Insight 3: ICL 与梯度适应的边界正在消失。** GEN-1.5 的 1 梯度步（权重变化 <0.15%）效果接近 ICL；RoboTTT 干脆把「处理上下文」实现为「对内部快权重做梯度步」。二者是同一枚硬币：都是把新信息以极低成本注入模型。理论含义：ICL 可能本来就是隐式的元优化（LLM 文献已有此论），机器人给了这个假说一个物理验证场。工程含义：未来的适应接口不会区分「提示」和「微调」，只有一个连续的「适应预算」旋钮（0 步=纯 ICL，1-10 步=轻适应，1000+ 步=后训练冲精通）。

**Insight 4: one-shot 的下一个瓶颈是信息，不是算法。** 59-62% 的汇合（趋势四）+ HOST 扰动实验（人为干扰只掉 9%）说明现有方法已经能高效榨取单段视频的信息。剩下 38% 失败里，相当比例来自视频根本没携带的信息：接触力大小、被遮挡的接触点、演示者的隐含意图（「轻放」还是「随便放」）。三个

补救方向都已有先行者：触觉手套采集（HOST 作者自己提的方向）、多模态提示融合、执行中交互式请求补充演示。

**Insight 5: 「跟随演示」与「跨具身翻译」的解耦是可推广的方法论。** HOST 两阶段训练（193k 同具身对预训练「跟随」+ 5.8k 跨域对适配「翻译」，配比 33:1）本质上发现了：模仿能力的大头可以从廉价数据中学，昂贵的配对数据只需教「翻译」。EgoScale 独立验证了同构配方（human 预训练 + aligned mid-training）。这个模式适用于一切跨域模仿设定——仿真到真机、机器人到机器人、甚至动画到机器人。

**Insight 6: 具身对齐将从脚注变成独立研究方向。** GEN-1 首次把它说透：涌现即兴是能力也是风险（机器人自发「整理」你故意摆的东西）。ICL 加剧了这个问题——技能来自用户随手拍的视频，模型对「不该做什么」的理解为零。物理世界没有 undo。预计 12 个月内出现第一批「physical prompt injection」攻击研究（恶意演示视频诱导危险行为）和对应的提示过滤/行为约束工作。

**Insight 7: 中国团队第一次在范式定义层面与美国头部并跑。** 此前中国具身智能的叙事是「跟随+工程化」（复现  $\pi 0$ 、复现 RT-2）。HOST 是范式级原创：问题定义（推理时技能获取 vs 训练时循环）、机制设计（进度流形+自接地级联）、评测口径（50 任务+遗忘验证）都是第一手的，且抢在 GEN-1.5 博客前几天开源。自变量「模型全家桶 + 关键能力开源」的打法，对照 Generalist 「数据引擎 + 全闭源」，是两种生态战略的对照实验，值得持续跟踪。

**Insight 9: 2017 → 2026 的断裂点在主干先验，不在问题定义；生成式动作头是实践必要而非逻辑必要。** one-shot 模仿的问题在 2017 年已被 Duan 完整定义（演示条件策略 + 「同任务两条演示配对训练」——这个配方原样活在 HOST Stage 1 与 ICRT 里），元学习路线（Finn）在 1300 条数据的小规模上一度领先上下文路线，却因二阶梯度跟不上 scaling 而出局；无大模型先验的结构派极致 IMOP 在短程新任务上做到 41.3%，长程只有 7.4%。九年后差的不是任务定义与数据配方，而是 Wan2.2 / Qwen3-VL 级视频-语言先验消解了 Finn 当年明确推迟的人机域偏移——2026 年解决的仍是 Duan 短程问题的真机视觉版，长程部分（IMOP 7.4% → ManiLong-Shot 30.2%）还在 2017 年的曲线上（notes/25）。另一条被本轮修正的判断：HOST/ $\pi 0$ /GR00T/GR-3 的动作头全是 flow matching 或 diffusion，源头是 Diffusion Policy 与 ACT，但 ICRT/StellaVLA/RICL 用回归或离散头也能做 ICL——生成式头是「上下文消歧不完全」常态下的实践必要条件，不是逻辑必要条件；真正被所有系统无一例外继承的只有 ACT 的动作分块（notes/26）。GEN-1.5 的动作头设计未公开，不应算入已证实的 flow-matching 名单。

**Insight 10: 人类视频进机器人有三条桥，选哪条由「能否控制采集」决定；而每条桥都把攻击面带了进来。** 显式重定向/动作级共训（HumanPlus、EgoMimic、PH2D、GR-3、EgoScale）保真度最高，但只在采集可控（同款眼镜、任务导向采集、人形本体）时成立——EgoMimic 与 EgoWAM 同组两年的演进划出了边界：野生视频必须换通道；世界预测通道（EgoWAM）零标注、对具身差距免疫，只能塑造表征；潜动作（Genie → LAPA → UniVLA）零标注且能给直接动作监督，代价是语义由数据分布决定、相机运动至今没有干净解法（notes/29、31）。ICL 是第四条：不把人类数据写进权重，把演示放进上下文，对齐成本从数据侧转到模型侧——这解释了产业分岔（GEN/S1 有采集控制权，共训做底座 + ICL 做接口；HOST/Zero-WAM 无大规模采集能力，全押 ICL）。安全侧的对应事实（notes/33）：训练期投毒后门已覆盖从 ACT 到  $\pi 0$  的全谱系动作头（State Backdoor 真机 >90%），而 ICL 把演示变成推理期输入，StellaVLA 的「错演示比无演示差 17.5 点」与 Zero-WAM 的「无反捷径时人类视频净负收益」在安全视角下都是攻击有效性的良性下界。技能库外置（HOST 视频库、GEN-1.5 提示片段）更把一次性注入变成持久化后门。防御研究远少于攻击研究，是当前最不对称的空白。

**Insight 11: ICL 有两层——规划层的 2022 年就成了，策略层的 2026 年才成；拐点定在 2026 是因为低层控制第一次可以从上下文学。** Code as Policies (2022) 用 GPT-3 的 few-shot 提示写机器人程序，VoxPoser (2023) 与 ReKep (2024) 让 LLM/VLM 合成值图与关键点约束——零训练、零机器人数据、纯上下文，比 HOST/GEN-1.5 早三年做到「教机器人不用训练」，却没有引发「GPT-3 时刻」的叙事，因为它们的成功率天花板由原语库与规划器决定：凡不能用「关键点到位」描述的任务（拧盖的力、叠衣的褶皱、翻煎饼的时机）都在表达能力之外，而那恰是 S1 拿来展示 ICL 的任务 (notes/35)。策略层 ICL 让低层控制本身从演示上下文学习，「教机器人 = 给一段演示」才对全部任务成立。两层的合流形态已现雏形——LingBot-VA 2.0 的层级 VLM 规划器 + 视频 ICL 底层 (notes/19)、S1 的隐式长时程组合——但两层分工的收益无人正面评测。规划层 ICL 的可解释与可校验（约束函数可读、可审）在安全上是策略层 ICL 缺失的一环 (notes/33)，这是合流最实际的理由。演示编码侧同样存在被遗忘的选项：RT-Trajectory 的手画轨迹草图 (2023) 是字面意义的物理提示，用 RT-1 级小模型就做到未见任务 67%——「零更新泛化到新任务」不需要 50 万小时，需要的是条件信号与动作空间足够接近 (notes/34)。GEN-1.5 的传感器流提示恰是最接近动作空间的条件，其「涌现」有多少来自规模、多少来自提示模态本身，RT-Trajectory 提供了一个便宜的对照起点。

**Insight 8: 四篇 EICL 论文的失败是互补的，右上角空缺正是家用场景。** 把任务时长与分布漂移当两个坐标轴：StellaVLA 固定前缀无法在执行漂移后重新规划（长时程 L1 仅 0.02）；WAM-TTT 快权重执行时冻结，处理不了突发扰动；RoboTTT 场景相机本体全程固定，从未面对真分布漂移；Zero-WAM 从未测过未见环境。四篇各守一条漂移轴、无一同时打下两条，「长时程 × 分布外」的右上角只有 S1 的不可复核博客宣称覆盖。三条被独立验证的共同经验值得所有后来者抄录：人类信息只许改写感知/生成侧、不许直接接触动作侧；训练期挂辅助目标、推理期整个剥离（辅助必须监督主分支否则剥离后一场空）；上下文不是免费午餐，模型一定走捷径（三篇在三个不同设定下独立撞进同一个坑）。

## 4. 可证伪的预测（12–24 个月）

1. **2027 年中前出现 1M timestep 上下文的机器人模型** (RoboTTT 路线延伸, Jim Fan 已预告)。
2. **物理提示标准格式出现**：类似 LLM 的 ChatML，会有一个「演示片段+传感器流+元数据」的封装格式被 2 家以上机构采纳。
3. **真机 OSVI 标准评测协议建立**：固定任务集+扰动协议+第三方复核，HOST 的 50 任务集是最可能的种子。
4. **one-shot 成功率在 12 个月内突破 80%**（多模态提示 + 交互式澄清驱动，非纯 ICL 改进）。
5. **第一起 physical prompt injection 安全研究发表 → 修正 (2026-09-03, notes/33)**：这条预测信息不足——语言层越狱 (BadRobot/RoboPAIR 2024)、感知层对抗 (AdvVLA 2024)、训练期演示投毒后门 (Contextual Backdoor 2024-08、BadVLA 2025、State Backdoor 2026) 在预测做出前已成体系，Contextual Backdoor 更是直接做了「投毒上下文演示」。修正后的预测：**12 个月内出现首个针对视频演示 ICL 策略 (HOST/S1/Zero-WAM 类) 的推理期演示注入攻击研究**，这是文献里唯一还空着的一格；具身对齐成为独立 workshop 议题的判断保留。
6. **技能视频库产品化**：至少一家公司推出「录视频→机器人技能」的消费级/企业级产品（自变量是最近的候选）。

7. **涌现之争迎来裁决实验**：有机构在产业规模（ $\geq 10$  万小时）预训练上做一次去机制消融，或有人把 Schaeffer 式连续度量分析应用于具身 scaling 曲线；无论结果偏向哪边，「具身 ICL 是否免费涌现」将从修辞之争变成实证问题。

## 5. 开放问题清单（研究机会）

- **非单调演示**：SDTW 单调假设失效的任务（含重试、可选分支、循环子任务）如何对齐？
- **力信息缺口**：纯视觉演示如何推断接触力策略？触觉手套数据能否以 HOST 的 33:1 模式低成本融入？
- **长程组合的自动分解**：GEN-1.5 的 prompt chaining 靠人工选段；谁来自动把长任务分解成提示库里的原子技能？（ManiLong-Shot 的 VLM 交互分解是仿真侧的初步答案）
- **ICL 技能的脆性根源**：GEN-1.5 承认 ICL 技能比微调脆；脆在哪（视觉分布？动作精度？时序漂移？）缺乏系统研究。
- **上下文 vs 参数的容量边界**：技能外置到上下文后，模型参数里到底存了什么？哪些技能成分必须进权重？
- **评测的初始条件协议**：20 次试验的「随机初始位姿」各家定义不同，扰动幅度需要标准化度量。
- **三种上下文接口同台对照**：结构化文本（StellaVLA）、合成视频（Zero-WAM）、快权重记忆（WAM-TTT）从未在同一 backbone、同一数据、同一评测上并排跑过——四篇互相知晓却零对比，这是边际信息量最高的单个实验。
- **常量前缀 + 递归状态的叠加**：Zero-WAM 解决未见任务但长时程崩，RoboTTT 解决长时程但场景固定；一个占输入前缀、一个占递归状态，架构上不冲突，无人组合。
- **合成演示训练、真实演示测试**：Zero-WAM 的人类视频 100% 合成且从未测过真实视频输入，这是它落地要撞的第一堵墙，也是所有合成配对路线的共同盲区。
- **潜动作当演示编码 + 进度流形当对齐**：潜动作解决「演示里的运动是什么」（语义翻译），进度流形解决「执行到演示的哪一步」（时间对齐），两者正交且无人组合；ViVLA→HOST 的同团队路线切换暗示这是下一步（notes/29）。
- **推理期视频演示注入攻击与防御**：对 HOST/S1/Zero-WAM 类策略构造恶意演示视频诱导危险动作的研究为零，防御侧（演示一致性检验、演示-观测矛盾检测、独立于演示通道的安全裁决器）同样为零（notes/33）。
- **规划层 + 策略层 ICL 的分工评测**：VLM 给阶段与约束（可解释、可校验）、策略从演示学接触与时机——LingBot-VA 2.0 与 S1 已是雏形，但两层各贡献多少无人测（notes/35）。
- **几何编码 + 进度对齐的组合**：ATM 点轨迹 / Im2Flow2Act 物体光流替代 HOST 的帧嵌入做演示编码，同时获得具身不变性与更低对齐难度；RT-Trajectory 的草图配进度流形可从静态提示升级为动态引导——两个组合都无人做（notes/34）。
- **检索层作为 ICL 的安全检查点**：Behavior Retrieval 的相关性过滤本为滤次优数据，同样可滤恶意演示；技能库检索是 ICL 系统天然的安全闸门，无人从此角度设计（notes/36、33）。
- **基线复现的披露标准**：RoboTwin 2.0 上同一  $\pi 0.5$  被复现出 43 与 83，差距超过多数头条增益——「基线训练数据、微调配方、checkpoint 选择与主方法同等披露」应成为评测协议硬性条款

(notes/32)。