

调研报告 · 2026-08-31

机器人技能习得的范式拐点

从「训练问题」到「提示问题」——One-Shot 技能习得全景调研

HOST · 结构派 · 开源

GEN-1.5 · 规模派 · 涌现

S1 · 未见长时程

18 项工作 · 5 条路线

核心对象：HOST (arXiv 2607.20033) × GEN-1.5 (Generalist AI) × S1 (Skild AI)

同期工作：Instant Policy · ICRT · RoboTTT · WAM-TTT · StellaVLA · Zero-WAM · BPP · RICL · Vid2Robot · ViVLA · $\pi 0.5$ · Wall-OSS · EgoScale · EgoWAM · WALL-WM · Fast-WAM

2026 年 8 月，三家互不相识的机构在 16 天内汇合于同一能力点： 「教机器人」正在从训练问题变成提示问题

结构派 HOST（自变量系，开源）

62% 50 个未见真机任务

一段第三人称人类视频，零参数更新，29 秒后执行；旧技能不掉。用架构设计（进度流形 + 预测级联）造出 one-shot。8-03 全栈开源。

规模派 GEN-1.5（Generalist AI）

59% 10 个评测任务

3-12 秒演示当 prompt，零梯度。50 万小时数据预训练后 ICL 作为涌现能力出现——无架构改动、无 meta-learning。8-19 博客。

规模派 S1（Skild AI）

66% 未见 + 10 分钟长时程

主张推到最远：一条视频演示执行预训练从未见过、最长 10 分钟的任务（语言提示同规模仅 9%）；单条演示 ≈ 380 条后训练示范。8-18 博客。

为什么是拐点：三家方法论各异（归纳偏置 vs 数据暴力 vs 数据+配方），却在 16 天窗口交付同一能力——范式转移不再依赖单一路径成立。同月，四篇学术论文（WAM-TTT/RoboTTT/StellaVLA/Zero-WAM）把「演示怎么被用上」做成可核对的实验，其消融一致反对「免费涌现」叙事——本调研其余 15 项工作提供了这场汇合与争论的完整证据链。

旧范式下，每个新技能都是一次小型科研项目： 数百条遥操作 + 数小时微调 + 旧技能坍塌

数据成本

50–300 条

遥操作演示起步。专家 + 真机独占，采集一个任务以小时计；RICL 口径 20 条/任务已算「少」，仍比拍一段人类视频贵一个量级。

适配门槛

10 万步

BPP 对照中 $\pi 0.5$ 的 LoRA 微调步数。GPU 机时 + 调参专业知识，把「教机器人」锁定为算法工程师的工作，终端用户不可及。

灾难性遗忘

43%

Wall-OSS 经 SFT 学会新任务后，旧技能只保留 43% (HOST 论文实测)。每教一个新技能，都在赌之前的投入不清零。

与此同时，LLM 那边「教模型」早已是提示工程：例子放进上下文、权重不动。机器人界的问题变成：ICL 是语言独有的运气，还是感知运动序列上同样成立的普适性质？——12 篇论文用五条不同路线回答了它。

此前的视频模仿为什么不 work： 演示被当成「被动上下文」，模型学会了忽略它

病灶 ① 时间错位

把整段视频压成固定 token（Vid2Robot: 64 个）当条件，动作监督锚定机器人轨迹固定时间步——演示进度与执行进度从不对齐，梯度不流经「读视频」路径。

病灶 ② 捷径学习

ICRT 实证：单任务场景数据下，当前观测已唯一决定动作，prompt 沦为摆设——DROID 1 万条训练，测试 0%：对 prompt 也算损失，79.2% 崩到 22.5%。

病灶 ③ 跨具身鸿沟

人手 ≠ 夹爪：外观、运动学、速度全不同。隐动作空间（ViVLA）翻译不透明；硬件消解（BPP 的 iPhUMI）要用户手持专用夹爪，普适性打折。

共同的问题 (QUESTION)：怎样让演示从「被动参考」变成「主动驱动执行的信号」？——结构派的答案是把对齐做成显式机制（HOST），规模派的答案是让数据多到捷径不存在（GEN-1.5），中间还有数据配方（BPP/ICRT）、架构机制（RoboTTT）、事后注入（RICL）三条路。

HOST 与 GEN-1.5：方法论镜像，能力点重合

	HOST (2026-08-03 开源)	GEN-1.5 (2026-08 博客发布)
能力来源	架构设计：进度流形对齐 + 自接地预测级联	规模涌现：50 万小时真实操作数据预训练
演示接口	第三人称人类视频（跨具身，无动作标签）	3—12 秒演示做「physical prompting」
one-shot 成绩	62% · 50 个未见任务 · 每技能约 29 秒	59% · 10 个评测任务 · 秒级生效
few-shot 升级	—（论文范围外）	1—10 个梯度步适应后 83%
技能保持	零参数更新，旧技能无损（对照 SFT 保留 43%）	上下文模式无更新；梯度步模式未公布保持率
训练成本	193k 轨迹（229 任务）+ 5.8k 人类视频配对，两阶段	50 万小时多具身数据（约为 HOST 数据量数百倍）
可验证性	论文 + 代码 + 权重全开源，口径可复查	博客数字，无论文、无第三方复现渠道

读法警告：62% 与 59% 不可直接比大小——任务集、难度、判定口径都不同。真正的信息是：两条成本结构完全不同的路线，都把 one-shot 从论文指标做成了可演示能力。

HOST 的两个机制，分别对准两个病灶： 时间错位用「目标耦合」治，跨具身鸿沟用「自接地级联」治

机制 ① 目标耦合 —— 演示与执行共享任务进度流形

Qwen3-VL 逐帧嵌入 → 投影到进度流形，SDTW + TCC 训练对齐。推理时实时定位机器人执行进度在人类视频里的对应位置，把「演示接下来的样子」动态选为预测目标。

≈ 把 Vid2Robot 里只在训练期起效的 TCC 正则，升级成推理期的主动机制——进度倒退可感知、可重对齐。

机制 ② 自接地预测级联 —— 三级跨越具身鸿沟

级联三步：定位（进度对齐）→ 预测自己视角的未来观测（把人类动作翻译成机器人世界的图像）→ 解码动作。翻译发生在观测空间而非隐动作空间，每级可检查。

主干：双专家 MoT（视频专家自 Wan2.2 初始化）+ flow matching——与 Fast-WAM 同构，「视频先验承重在训练目标」有独立实证支撑。

两阶段训练：Stage 1 用 193k 同具身轨迹练「预测-执行」基本功；Stage 2 用 5.8k 组（人类视频, 机器人轨迹）配对练跨具身对齐——演化自 ViVLA（同团队前作）：把前作埋在隐动作空间的翻译、交给 transformer 隐式学的对应，全部换成显式模块。

同一批 50 个未见任务上的成功率阶梯：
语言 17 → 视频被动条件 19 → SFT 56 → **HOST 62**



阶梯的含义

17→19: 被动看视频几乎无增益; 19→62: 同样的视频, 换成主动对齐机制, +43 个点——增益全部来自**机制**而非模态本身。

压过自家最强 SFT

Wall-OSS 与 HOST 同属自变量机器人: 56% 是自家最强微调配方 + 50 条遥操作的成绩, 仍低于 1 段人类视频 + 零更新的 62%, 且 SFT 旧技能只剩 43%。排除了「挑弱基线」质疑。

鲁棒性

未见物体替换只掉约 4 个点; 演示与执行场景不同、第三人称视角均可工作。50 任务 × 20 次试验的口径, 是本调研里统计功效最强的真机评测。

GEN 三部曲九个月走完：验证 scaling law → 99% 精通 → ICL 涌现

2025-11 · GEN-0

验证存在性。27 万小时数据、10B+ 模型上确立机器人操作的 scaling law：算力与数据翻倍，能力可预测地上升；提出「intelligence phase transition」——足够规模后突然出现的能力跃迁。

2026-04 · GEN-1

兑现精通。简单操作任务成功率推到 99% 级别（mastery 定义：连续长时间无失败运行）。证明 scaling 不只涨曲线，能落到可靠性。

2026-08 · GEN-1.5

涌现 ICL。50 万小时数据后，one-shot 从演示学新任务的能力**未经专门设计而出现**：3-12 秒演示 prompt → 10 任务 59%；加 1-10 个梯度步 → 83%。

谨慎读数：全部数字来自公司博客——10 个评测任务（对 HOST 的 50 个）、无同行评审、无开源复现渠道。GEN-1.5 的价值不在数字本身，而在它给出「ICL 会随规模自然出现」的存在性证明，与 ICRT 在 3k 条轨迹上的最小可行原型（79.2%）首尾呼应：配方相同，规模差五个数量级。

S1 (Skild AI) 把主张推到最远： 未见任务 × 10 分钟长时程，单条演示 ≈ 380 条遥操作示范

核心声明

66% vs **9%**

ICL vs 语言提示，**100k 小时**同数据同架构同算力对照。四个未见任务（煎饼/咖啡/盆栽/装配）最长 10 分钟、数十步，由单条人类视频驱动；盆栽任务从演示到自主执行 11 分钟。

Scaling 对照的两段读法

已见任务：1k 小时时语言反超 ICL (53% vs 43%)；100k 小时后 ICL 达 96% 反超——语言的歧义成为天花板。

未见任务：差距随数据量平滑指数扩大至 66% vs 9%——注意这是连续改进曲线，不是相变。

兑换率与涌现性质

后训练 VLA 需 **380 条**示范 (50–100 小时遥操作) 才追平单条上下文演示；2000 条达 86% 反超。定性展示：抗中途扰动、失败自发重试、常识替代（无壶用杯）、**演示纠错**——把演示当目标规格而非轨迹复制。

该打的折扣：与 GEN-1.5 同样无论文、无开源、内部 benchmark；长时程「累计逐步成功率」允许人工干预恢复计分（博客自述主要为救语言基线），66% 不是无干预端到端完成率；预训练任务清单未公开，「未见」无法外部审计；380 条兑换率是插值估计。时间线：LocoFormer (2025-09) → 域内 ICL (2026-02) → 第一张煎饼 (2026-05) → S1 (2026-08)。

同一个目标，五条路线：one-shot 能力可以被设计、被喂出、被配方化、被机制化、被事后注入

路线	代表工作	核心赌注	代表性结果
结构派	HOST · Instant Policy · ViVLA	归纳偏置能在小数据下造出 one-shot：HOST 加在时间维（进度对齐），Instant Policy 加在空间维（图 + SE(3) 扩散）	HOST 62% (50 任务)；IP 88.75% (16 任务、宽松口径)
规模派	GEN-1.5 · EgoScale	数据够大 ICL 自然涌现；EgoScale 给出人类视频的 log-linear scaling law ($R^2=0.998$)	GEN-1.5 59% (10 任务)；EgoScale 单示范适配 88%
数据配方派	BPP · ICRT	驱动 ICL 的不是数据量而是数据结构：任务多样性 + 强迫读 prompt 的分布设计	ICRT 1098 条轨迹 → 79.2%；BPP：2000 任务 × 5 demos 配方
架构机制派	RoboTTT	推理时在 fast weights 上继续做元学习过的梯度下降，上下文扩到 8K 步且延迟不涨	长程 +87%；上下文 128→8K 单调上升无饱和
事后注入派	RICL	预训练 VLA 缺 ICL 不必重训：400 条演示检索增强后训练即可装上	$\pi 0$ -FAST-DR0ID 2.5% → 31.25% (零更新)
合成配方派	Zero-WAM · StellaVLA	上下文的制造也可以规模化：从机器人轨迹反向合成人类视频（Zero-WAM），或把演示离线转译成结构化语言（StellaVLA）	HumanGen 74.2K 对/8.6K 任务；7 未见任务 46.95%

18 项工作一页对照：演示接口决定成本，机制决定上限

工作	时间/出处	演示接口	参数更新	关键数字	本调研角色
HOST 主角	2026-08 · 开源	人类视频×1	零	50 任务 62% · 29 秒	结构派答案
GEN-1.5 主角	2026-08 · 博客	3-12 秒演示	零 / 1-10 步	10 任务 59% / 83%	规模派答案
Instant Policy	ICLR 2025	动觉示教 1-2 条	零	16 任务 88.75% (同物体)	空间结构派
ICRT	ICRA 2025	遥操作轨迹 1-3 条	零	12 任务 79.2% (6 原语内)	NTP 最小原型
RoboTTT	2026-07 · NVIDIA	人类视频 (同场景)	仅 fast weights	one-shot 6/10 · 长程 +87%	上下文 scaling 轴
BPP	2026-06 · Stanford	iPhUMI 演示×1	零	画图误差 -80.7% vs goal-image	任务多样性定律
RICL	CoRL 2025	遥操作 10-20 条	零 (可选微调)	2.5-31.25%; 微调 61.67%	ICL 事后注入
Vid2Robot	RSS 2024 · Google	人类视频×1	零	9 任务 52.8%; HOST 口径 19%	被超越的前辈
ViVLA	2025-12 · 北理工	专家视频×1	零	LIBERO unseen +30%	HOST 直系前作
π0.5	2025-04 · PI	语言指令	零样本	HOST 口径 ≤17%	语言条件上限
Wall-OSS	2025-09 · 自变量	遥操作 50 条	LoRA SFT	56%, 旧技能存留 43%	最强 SFT 对照
EgoScale	2026-02 · NVIDIA	单条机器人示范	post-train	2 万小时 · L=0.024-0.003lnD	人类数据 scaling
S1 主角	2026-08 · 博客	视频演示 prompt	零	未见长程 66% vs 语言 9%	最远主张
WAM-TTT	2026-07 · 北大+银河通用	GoPro 人类视频	仅快权重 (部署前)	未见场景 46.2 (progress) · 保持率 76%	快权重技能包
StellaVLA	2026-08 · StellarEdge	结构化语言前缀	零 (真零梯度)	对 98.8 / 无 62.4 / 错 44.9	三向干预首创
Zero-WAM	2026-08 · Robbyant+港科广	合成人类视频	零	7 未见任务 46.95% (3 种子×100)	任务级零样本
EgoWAM	2026-07 · Georgia Tech	ego 人类数据 (训练用)	训练期	DINO 00D ~4× · 3D flow +20-30%	WAM 表征对照
WALL-WM	2026-06 · 自变量	— (事件单元预训练)	训练期	多样操作 75.86 vs π0.5 55.64 (progress)	WAM 时间结构底座

各行成功率的任务集与判定口径互不相同，禁止跨行直接比大小；详见各篇 notes 的「延伸批判」节。

决定 ICL 成败的不是数据量，是数据结构： 「强迫模型读演示」是所有路线的共同前提

ICRT: 1098 条 > 10000 条

自采 1098 条「同场景多任务」轨迹 → 73.3%；1 万条单任务场景的 DROID → 0%。单任务场景下观测唯一决定动作，模型必然走捷径无视 prompt。

BPP: 多样性 > 密度

固定预算下 2000 任务 × 5 条完胜少任务 × 多条；任务数单调提升未见任务性能，每任务 5 条就够。叠衣负例：低多样性时 prompt 反而不如语言条件。


ICRT: prompt 免损失

对 prompt 段也算模仿损失 = 训练模型「没上下文也要输出」，79.2% 崩到 22.5%。HOST 的目标耦合、RoboTTT 的损失 mask，都是同一原理的不同实现。

对 GEN-1.5 的反推：50 万小时数据「自然」覆盖了多任务歧义场景——规模派的涌现，可能只是数据配方派的强迫函数在大数据下自动满足。这条假设可以用 BPP 式受控实验在中等规模上证伪。

上下文长度是与数据量正交的第二条 scaling 轴： 128 → 8K 步，性能单调上升，尚未见顶

RoboTTT 的 scaling 实证



8K 比 1K 高 **63%**，无饱和迹象；对照组 GDN（线性递归记忆）完全没有此趋势——**能存上下文 ≠ 会用上下文**，元学习过的更新规则才是关键。

为什么这条轴重要

- 朴素加历史帧是**毒药**：GR00T N1.7 加 1 帧历史，57% → 39.5%（causal confusion）——长上下文必须配对对齐机制或记忆机制
- 8K 步 ≈ 30Hz 下 5 分钟：够放一整段演示视频 + 自身执行历史 + 纠错记录（DAgger 蒸馏 +36% 即来自「失败当上下文」）
- 与 GEN-1.5 的数据小时数轴**正交**：两轴原则上可叠加，是最直接的合流方向

推论：「HOST 式显式对齐」与「RoboTTT 式长上下文 TTT 主干」不互斥——把进度流形装进 8K 上下文的 fast weights 架构，是本调研看到的最明确的下一代系统蓝图。

全场最干净的对照：同一个工具（TCC）， 从「训练期正则」升级为「推理期机制」，19% → 62%

Vid2Robot (RSS 2024, Google DeepMind)

TCC 作为**辅助损失**：训练期逼视频编码器只编码任务进度、对具身不变。推理时视频压成 64 个 token 被动喂入，无任何执行-演示对齐。

19% HOST 50 任务口径（原文 9 任务 52.8%）



HOST (2026-08, 北理工 + 自变量)

同款 TCC + SDTW 升级为**显式进度流形**：推理时实时定位执行进度在演示中的位置，动态选择预测目标，进度倒退可感知、可重对齐。

62% 同一 50 任务集，+43 个点

师承有据

Vid2Robot 末位作者 Dwibedi 正是 TCC 原作者。工具早就存在，差的是「把对齐从损失函数搬进推理循环」这一步认知——两年时间、43 个点。

方法论启示

「训练期学到的好表征」不等于「推理期被用起来的能力」。同一原理的第三个实例：RoboTTT 把「记忆」从静态权重搬进推理期梯度更新的 fast weights。

学术侧同月交卷：四篇论文把「演示怎么被用上」切成 2×2 坐标，各占一格、零重叠、零对比

坐标（改什么 × 何时）	工作 / 机构	核心机制	最硬的数字
快权重 · 部署前一次	WAM-TTT（北大+银河通用）	人类视频经 TTT 写入感知侧快权重记忆；KVM 损失 = 无 softmax 线性注意力	演示当记忆 46.2 vs 当 token 7.1；配对人类数据 1:1 顶替机器人数据
快权重 · 每步递归	RoboTTT（NVIDIA GEAR）	快权重=递归状态，在动作侧随 rollout 逐步更新；上下文 8K 步	1K→8K：43.9→71.5 无饱和；失败当上下文 +33%
纯上下文 · 零梯度	StellaVLA（StellarEdge AI）	演示离线转译成结构化语言（做了什么→为什么）当前缀	三向干预：对 98.8 / 无 62.4 / 错 44.9—错比无差，证明真在读上下文
纯上下文 · 零梯度	Zero-WAM（Robbyant+港科广）	合成人类视频当任务规格；IFP 反捷径目标；74.2K 对/8.6K 任务	7 未见任务 46.95% vs 17.45%；无 IFP 时加人类视频是负收益（28.55<39.44）

三条被独立验证的共同经验：① 人类信息只许改写感知/生成侧，不许直接接触动作侧（WAM-TTT 与 Zero-WAM 从相反路线撞到同一结论）；② 训练期挂辅助目标、推理期整个剥离，且辅助必须监督主分支否则剥离后一场空；③ 上下文不是免费午餐——三篇在三个不同设定下独立发现「模型必走捷径」（多给一帧历史反而降 17.5 个点、无反捷径目标时人类视频是净负收益）。GEN-1.5 与 S1 主张的「纯上下文·零梯度」恰是 Zero-WAM 所在的格子。

ICL 是涌现出来的，还是造出来的？ LLM 的辩论正在具身领域重演

LLM 前史三步曲（2020—2023）

- **Brown 2020 (GPT-3)**: few-shot ICL 随规模出现，确立「例子进 prompt、权重不动」范式
- **Wei 2022**: 命名「涌现能力」——小模型没有、大模型突然有、无法外推预测
- **Schaeffer 2023**: 涌现可能是**度量的海市蜃楼**——不连续度量把平滑改进渲染成突变；换连续度量后多数「涌现」消失（NeurIPS 2023 杰出论文）

具身领域的攻守（2026）

- **涌现叙事**: GEN-1.5「无架构改动、无 meta-learning、无辅助目标」；S1 归因于任务多样性+规模
- **四条学术反证**: WAM-TTT 去 meta-training 100.0→9.0；RoboTTT 去 sequence action forcing 训不出；StellaVLA 需整条离线流水线；Zero-WAM 无 IFP 时人类视频是**净负收益** (28.55 < 39.44)
- 最致命是 Zero-WAM: 它正是产业主张的路线（大规模预训练+纯上下文+零梯度），却证明该路线需要显式反捷径机制

公平的限定与无人做的第三方视角：学术侧最大规模 15,360 GPU 小时，远低于产业 50 万小时——严格结论是「在学术可负担的规模上需要显式机制」，裁决要等产业规模的去机制消融。另一把武器无人使用：机器人的二元成功率/rubric 恰是 Schaeffer 指出的易造「涌现假象」的不连续度量；S1 自己的 scaling 曲线（差距平滑指数扩大）反而更像连续改进而非相变。把度量批判搬进具身领域，是当前空白的研究机会。

六大趋势：范式、scaling 轴、数据、路线、评测、生态

T1 ICL 成为新范式轴

四条实现路线并行（涌现/结构/配方/注入），全部在 18 个月内交付真机结果。「新任务 = 新一轮训练」的默认假设已被推翻。

T2 上下文长度成为新 scaling 轴

RoboTTT: 128→8K 单调上升无饱和；与数据小时数轴正交可叠加。Jim Fan 预告 1M timestep。

T3 数据路线四分天下

遥操作（GEN）、人类视频（HOST/EgoScale）、仿真伪演示（Instant Policy）、UMI 硬件（BPP）；EgoScale 把人类数据价值量化成 log-linear 律 ($R^2=0.998$)。

T4 涌现 vs 设计：升级为三方格局

涌现叙事（GEN-1.5/S1，博客证据）vs 机制证据（四篇 EICL 消融全部反对免费涌现）vs 度量质疑（Schaeffer 式批判，无人做）。裁决实验：产业规模的去机制消融。

T5 评测严重滞后

各家任务集/口径互不兼容，62% vs 59% 无法直接比；ManiLong-Shot、RLBench-Oneshot 等标准化基准 2026 下半年才起步。谁定义评测，谁定义下一轮叙事。

T6 开源在吃掉先发优势

HOST 论文+代码+权重全开源，抢在 GEN-1.5 博客前数日； $\pi 0$ 系、GR00T、Wall-OSS 全线开源。闭源数据引擎的护城河窗口正在收窄。

洞察 1—4：技能变成资产，提示变成工种，ICL 与微调的边界正在消失

I1 技能从参数空间迁移到上下文空间，因此变成资产

HOST 的技能库 = 视频库（外部记忆、检索复用、永不遗忘）；GEN-1.5 的技能 = 可拖放的提示片段。灾难性遗忘被「技能外置」架空而非解决。可预见：机器人技能商店、技能版本管理、跨机器人技能交易。

I2 physical prompt engineering 会成为真实工种

提示的选择（哪 3—12 秒）、组合（A+B 串联）、质量（视角/速度）显著影响成功率；GEN-1.5 已有拖放式界面。对标 2021—2023 LLM 提示工程师的出现轨迹。

I3 ICL 与梯度适应是同一枚硬币

GEN-1.5 单梯度步（权重变化 $<0.15\%$ ） $\approx$ ICL 效果；RoboTTT 干脆把「读上下文」实现为「对 fast weights 做梯度步」。未来只有一个连续的「适应预算」旋钮：0 步 = ICL，1—10 步 = 轻适应，1000+ 步 = 冲精通。

I4 下一个瓶颈是信息，不是算法

59—62% 汇合 + HOST 抗扰实验说明单段视频的信息已被高效榨取；剩余失败相当比例来自视频**根本没携带**的信息——接触力、被遮挡接触点、隐含意图。出路：触觉采集、多模态提示、交互式补充演示。

洞察 5—8：解耦配方可推广，具身对齐将独立成科，中国团队范式层并跑，四篇 EICL 的失败互补

I5 「跟随」与「翻译」解耦是可推广配方

HOST 两阶段（193k 廉价同具身对练「跟随」+ 5.8k 昂贵跨域对练「翻译」，配比 33:1）；EgoScale 独立验证同构配方。适用于一切跨域模仿设定。

I6 具身对齐将从脚注变成研究方向

技能来自用户随手拍的视频，模型对「不该做什么」理解为零，物理世界没有 undo。预计 12 个月内出现 physical prompt injection 攻击研究与对应防御。

I7 范式定义层的中美并跑

HOST 问题定义、机制、评测口径均第一手原创，抢在 GEN-1.5 博客前数日开源。自变量「全家桶+开源」vs Generalist「数据引擎+闭源」，两种生态战略的对照实验。

I8 四篇 EICL 的失败互补，右上角空缺

StellaVLA 长时程崩（L1 仅 0.02）、WAM-TTT 快权重执行时冻结、RoboTTT 场景全程固定、Zero-WAM 未测未见环境——各守一条漂移轴。「长时程 × 分布外」右上角只有 S1 的不可复核博客宣称覆盖，那正是家用场景的真实位置。

一句话收拢：当「教机器人」的成本从数百条遥操作跌到一段手机视频，瓶颈就从算法转移到信息、安全和生态——这三个新战场目前几乎无人占位。

七条可证伪的预测：把判断写成可以被打脸的形式

编号	预测	依据 / 验证方式
P1	2027 年中前出现 1M timestep 上下文的机器人模型	RoboTTT 8K 无饱和 + TTT 延迟不随上下文涨；Jim Fan 已公开预告
P2	「物理提示」出现标准封装格式（演示片段 + 传感器流 + 元数据），≥2 家机构采纳	对标 LLM 的 ChatML 出现轨迹；GEN-1.5 拖放界面是雏形
P3	真机 OSVI 标准评测协议建立（固定任务集 + 扰动协议 + 第三方复核）	HOST 开源的 50 任务集是最可能的种子；ManiLong-Shot 已在仿真侧起步
P4	one-shot 成功率 12 个月内突破 80%	驱动力是多模态提示 + 交互式澄清（洞察 I4），而非纯 ICL 改进
P5	第一起 physical prompt injection 安全研究发表，具身对齐成为独立 workshop 议题	洞察 I6；技能接口开放给任意视频输入后，攻击面随之打开
P6	「录视频 → 机器人技能」产品化，至少一家推出消费级/企业级产品	自变量（HOST 开源方）与 Skild（S1 已进商业伙伴）是最近的候选
P7	涌现之争迎来裁决实验：产业规模（≥10 万小时）的去机制消融，或 Schaeffer 式连续度量分析应用于具身 scaling 曲线	notes/16 §5；无论结果偏向哪边，「免费涌现」将从修辞变成实证问题

每条预测都指定了时间窗与可观察事件——12 个月后回看本页，错了的部分同样有信息量。

九个无人占位的研究缺口，每个都可以直接立项

非单调演示对齐 SDTW 的单调假设覆盖不了含重试、可选分支、循环子任务的演示。真实人类演示恰恰充满这三样。	力信息缺口 纯视觉演示推断不出接触力策略。触觉手套数据能否按 HOST 的 33:1 解耦配方低成本融入，是最具体的切入点。	长程任务自动分解 GEN-1.5 的 prompt chaining 靠人工选段。把长任务自动分解成提示库里的原子技能，仿真侧刚有初步答案 (ManiLong-Shot)，真机侧空白。
ICL 技能的脆性根源 GEN-1.5 自己承认 ICL 技能比微调后的脆。脆在视觉分布、动作精度还是时序漂移？无系统研究。	上下文 vs 参数的容量边界 技能外置到上下文后，权重里到底还存什么？哪些技能成分必须进参数？这是 ICL 理论在具身域的核心问题。	评测初始条件协议 「随机初始位姿」各家定义不同，扰动幅度无标准化度量——这是 62% vs 59% 不可比的技术根源，也是 P3 的前置工作。
三种上下文接口同台对照 结构化文本 / 合成视频 / 快权重记忆从未在同一 backbone、同一数据、同一评测上并排跑过。四篇互知却零对比——边际信息量最高的单个实验。	常量前缀 + 递归状态叠加 Zero-WAM 解决未见任务但长时程崩，RoboTTT 解决长时程但场景固定；一个占输入前缀、一个占递归状态，架构不冲突，无人组合。	合成演示训练、真实演示测试 Zero-WAM 的人类视频 100% 合成且从未测过真实视频输入——合成配对路线落地要撞的第一堵墙，全线盲区。

本调研仓库：18+3 篇论文 PDF（17 篇中译） + 16 份深度解读 + 本报告

仓库结构 awesome_ICL/

- papers/pdf/ – 21 篇英文原版 PDF（含 LLM 背景 3 篇）
- papers/zh/ – 17 篇中文翻译 PDF（super_translate）
- notes/ – 15 份深度解读（01–09、11–16）
- insights/ – 趋势与洞察报告（10）
- sources/ – S1 博客与微信深度综述存档
- report/ – 本 HTML PPT + PDF 版 + 全文报告 PDF

论文索引（arXiv）

HOST 2607.20033 · Instant Policy 2411.12633 · ICRT 2408.15980 · RoboTTT 2607.15275 · BPP 2606.30457 · RICL 2508.02062 · Vid2Robot 2403.12943 · ViVLA 2512.07582 · π 0.5 2504.16054 · Wall-OSS 2509.11766 · EgoScale 2602.16710 · Fast-WAM 2603.16666 · WAM-TTT 2607.06988 · StellaVLA 2608.11671 · Zero-WAM 2608.26103 · EgoWAM 2607.08436 · WALL-WM 2606.01955

LLM 背景：GPT-3 2005.14165 · 涌现 2206.07682 · Mirage 2304.15004；GEN-0/1/1.5 与 S1：公司博客（非 arXiv）

推荐阅读顺序：本 PPT → insights/10（趋势全文）→ notes/01（HOST）+ notes/02（GEN 系列）+ notes/16（S1 与涌现之争）→ 按兴趣进入其余 12 份解读；每份解读的「延伸批判」与「关系定位」两节是与摘要差异最大的增量内容。